

Evaluating Language Models: Training and Test Sets

Thành viên nhóm 1:

Bảo Quý Định Tân - 24520028

Lê Văn Thức - 24521748

Lê Phạm Thành Nhân - 24520022

University of Information Technology - VNUHCM

Ngày 24 tháng 2 năm 2026

Extrinsic vs Intrinsic Evaluation

Extrinsic Evaluation

- Đánh giá hiệu quả mô hình trong **ứng dụng thực tế**
- Dùng LM trong speech recognition / MT
- So sánh độ chính xác đầu ra hệ thống

Intrinsic Evaluation

- Đánh giá **chất lượng nội tại** của LM
- Không phụ thuộc ứng dụng cụ thể
- Metric chuẩn: **Perplexity**

Trade-off

- Extrinsic: chính xác nhưng tốn kém
- Intrinsic: nhanh nhưng gián tiếp

Training set

- Dùng để học tham số mô hình
- Ví dụ: đếm n-gram từ corpus

Development (Dev, Validation) set


- Dùng để điều chỉnh mô hình / chọn hyperparameters
- Dùng nhiều lần trong quá trình phát triển

Test set

- Dữ liệu chưa từng thấy
- Đánh giá cuối cùng khả năng tổng quát hóa
- Chỉ dùng **một lần** (hoặc rất ít)

Why Separate Training / Dev / Test?


- Phải đánh giá khả năng học của model để tránh underfit
- Model có thể fit hoàn hảo training data
- Nhưng thất bại trên dữ liệu mới → overfit.



Hình 1: Overfit & Underfit

How do we use Train / Dev / Test?

- Train: học tham số mô hình
- Dev: chọn mô hình / hyperparameters tốt nhất
- Test: đánh giá cuối cùng, độc lập tuyệt đối.
- Domain của dataset phải consistent.
- Test set phải đủ lớn về mặt thống kê, nhưng không quá lớn.



Hình 2: Model development workflow

Data contamination = train trên test

- Test sentence xuất hiện trong training
- Model gán xác suất cao ảo
- Metric bị sai lệch, thiếu khách quan.

Một dạng contamination khác

- Tune model nhiều lần trên test → Vô tình overfit test set

Giải pháp

- Dùng dev set để thử nghiệm
- Chỉ evaluate một hoặc rất ít lần trên test set khi hoàn tất