

Evaluating Language Models: Training and Test Sets & Perplexity

Thành viên nhóm 1:

Bảo Quý Định Tân - 24520028

Lê Văn Thức - 24521748

Lê Phạm Thành Nhân - 24520022

University of Information Technology - VNUHCM

Ngày 24 tháng 2 năm 2026

Sử dụng $P(W)$ để đánh giá hiệu quả giữa các mô hình ?

Sử dụng $P(W)$ để đánh giá hiệu quả giữa các mô hình ?

Hầu như không có ai sử dụng !!!

Đánh giá mô hình: Tại sao không dùng $P(W)$?

Vấn đề của xác suất dự đoán $P(W)$:

Đánh giá mô hình: Tại sao không dùng $P(W)$?

Vấn đề của xác suất dự đoán $P(W)$:

- Sự phụ thuộc vào độ dài: $P(W) = \prod_{i=1}^N P(w_i | w_{<i})$.

Đánh giá mô hình: Tại sao không dùng $P(W)$?

Vấn đề của xác suất dự đoán $P(W)$:

- **Sự phụ thuộc vào độ dài:** $P(W) = \prod_{i=1}^N P(w_i|w_{<i})$. Khi $N \uparrow$ thì $P(W) \downarrow$ cực nhanh.

Đánh giá mô hình: Tại sao không dùng $P(W)$?

Vấn đề của xác suất dự đoán $P(W)$:

- **Sự phụ thuộc vào độ dài:** $P(W) = \prod_{i=1}^N P(w_i|w_{<i})$. Khi $N \uparrow$ thì $P(W) \downarrow$ cực nhanh.
- **Khó so sánh:** Không thể so sánh hiệu suất giữa các tập dữ liệu có độ dài khác nhau.

Đánh giá mô hình: Tại sao không dùng $P(W)$?

Vấn đề của xác suất dự đoán $P(W)$:

- **Sự phụ thuộc vào độ dài:** $P(W) = \prod_{i=1}^N P(w_i|w_{<i})$. Khi $N \uparrow$ thì $P(W) \downarrow$ cực nhanh.
- **Khó so sánh:** Không thể so sánh hiệu suất giữa các tập dữ liệu có độ dài khác nhau.

$\Rightarrow$ **Giải pháp:** Sử dụng độ đo chuẩn hóa theo độ dài như **Perplexity** .

Ví dụ: Hạn chế của xác suất $P(W)$

Giả sử mô hình unigram dự đoán từ nào cũng có xác suất bằng nhau là $P(w_i) = 0.2$.

Ví dụ: Hạn chế của xác suất $P(W)$

Giả sử mô hình unigram dự đoán từ nào cũng có xác suất bằng nhau là $P(w_i) = 0.2$.

Test 1 (Câu ngắn): tôi đi học ($N = 3$)

- $P(W_1) = 0.2 \times 0.2 \times 0.2 = \mathbf{0.008}$

Ví dụ: Hạn chế của xác suất $P(W)$

Giả sử mô hình unigram dự đoán từ nào cũng có xác suất bằng nhau là $P(w_i) = 0.2$.

Test 1 (Câu ngắn): tôi đi học ($N = 3$)

- $P(W_1) = 0.2 \times 0.2 \times 0.2 = \mathbf{0.008}$

Test 2 (Câu dài): tôi đi học lập trình ($N = 5$)

- $P(W_2) = 0.2^5 = \mathbf{0.000032}$

Ví dụ: Hạn chế của xác suất $P(W)$

Giả sử mô hình unigram dự đoán từ nào cũng có xác suất bằng nhau là $P(w_i) = 0.2$.

Test 1 (Câu ngắn): tôi đi học ($N = 3$)

- $P(W_1) = 0.2 \times 0.2 \times 0.2 = \mathbf{0.008}$

Test 2 (Câu dài): tôi đi học lập trình ($N = 5$)

- $P(W_2) = 0.2^5 = \mathbf{0.000032}$

Nghịch lý xảy ra

Mặc dù mô hình dự đoán "tự tin" như nhau trên từng từ (0.2), nhưng tổng thể $P(W_1)$ lại lớn hơn rất nhiều $P(W_2)$.

Ví dụ: Hạn chế của xác suất $P(W)$

Giả sử mô hình unigram dự đoán từ nào cũng có xác suất bằng nhau là $P(w_i) = 0.2$.

Test 1 (Câu ngắn): tôi đi học ($N = 3$)

- $P(W_1) = 0.2 \times 0.2 \times 0.2 = \mathbf{0.008}$

Test 2 (Câu dài): tôi đi học lập trình ($N = 5$)

- $P(W_2) = 0.2^5 = \mathbf{0.000032}$

Nghịch lý xảy ra

Mặc dù mô hình dự đoán "tự tin" như nhau trên từng từ (0.2), nhưng tổng thể $P(W_1)$ lại lớn hơn rất nhiều $P(W_2)$.

⇒ Nếu chỉ nhìn vào $P(W)$, ta sẽ hiểu lầm là mô hình "giỏi" ở Test 1 hơn Test 2. **Đây là sự so sánh khập khiễng!**

Định nghĩa Perplexity (PP)

Perplexity là nghịch đảo xác suất của tập kiểm tra, được chuẩn hóa bởi số lượng từ N thông qua căn bậc N .

Định nghĩa Perplexity (PP)

Perplexity là nghịch đảo xác suất của tập kiểm tra, được chuẩn hóa bởi số lượng từ N thông qua căn bậc N .

Công thức tổng quát

$$PP(W) = P(w_1 w_2 \dots w_N)^{-\frac{1}{N}} = \sqrt[N]{\frac{1}{P(w_1 w_2 \dots w_N)}}$$

Định nghĩa Perplexity (PP)

Perplexity là nghịch đảo xác suất của tập kiểm tra, được chuẩn hóa bởi số lượng từ N thông qua căn bậc N .

Công thức tổng quát

$$PP(W) = P(w_1 w_2 \dots w_N)^{-\frac{1}{N}} = \sqrt[N]{\frac{1}{P(w_1 w_2 \dots w_N)}}$$

Sử dụng quy tắc chuỗi (Chain Rule):

$$PP(W) = \sqrt[N]{\prod_{i=1}^N \frac{1}{P(w_i | w_{1:i-1})}}$$

Định nghĩa Perplexity (PP)

Perplexity là nghịch đảo xác suất của tập kiểm tra, được chuẩn hóa bởi số lượng từ N thông qua căn bậc N .

Công thức tổng quát

$$PP(W) = P(w_1 w_2 \dots w_N)^{-\frac{1}{N}} = \sqrt[N]{\frac{1}{P(w_1 w_2 \dots w_N)}}$$

Sử dụng quy tắc chuỗi (Chain Rule):

$$PP(W) = \sqrt[N]{\prod_{i=1}^N \frac{1}{P(w_i | w_{1:i-1})}}$$

Mô hình càng tốt $\rightarrow$ Xác suất càng cao $\rightarrow$ **Perplexity càng thấp.**

Ví dụ: Khả năng đánh giá của Perplexity

Giả sử mô hình dự đoán mỗi từ với xác suất đều là $P(w_i) = 0.2$.

Ví dụ: Khả năng đánh giá của Perplexity

Giả sử mô hình dự đoán mỗi từ với xác suất đều là $P(w_i) = 0.2$.

Câu Test 1 (Ngắn - $N = 3$): tôi đi học

- $P(W_1) = 0.2^3 = \mathbf{0.008}$

- $PP(W_1) = \sqrt[3]{\frac{1}{0.008}} = \mathbf{5}$

Ví dụ: Khả năng đánh giá của Perplexity

Giả sử mô hình dự đoán mỗi từ với xác suất đều là $P(w_i) = 0.2$.

Câu Test 1 (Ngắn - $N = 3$): tôi đi học

- $P(W_1) = 0.2^3 = \mathbf{0.008}$
- $PP(W_1) = \sqrt[3]{\frac{1}{0.008}} = \mathbf{5}$

Câu Test 2 (Dài - $N = 5$): tôi đi học lập trình

- $P(W_2) = 0.2^5 = \mathbf{0.00032}$
- $PP(W_2) = \sqrt[5]{\frac{1}{0.00032}} = \mathbf{5}$

Ví dụ: Khả năng đánh giá của Perplexity

Giả sử mô hình dự đoán mỗi từ với xác suất đều là $P(w_i) = 0.2$.

Câu Test 1 (Ngắn - $N = 3$): tôi đi học

- $P(W_1) = 0.2^3 = \mathbf{0.008}$
- $PP(W_1) = \sqrt[3]{\frac{1}{0.008}} = \mathbf{5}$

Câu Test 2 (Dài - $N = 5$): tôi đi học lập trình

- $P(W_2) = 0.2^5 = \mathbf{0.00032}$
- $PP(W_2) = \sqrt[5]{\frac{1}{0.00032}} = \mathbf{5}$

Nhận xét khả năng đánh giá

Xác suất thô $P(W)$ giảm **25 lần** khiến ta lầm tưởng mô hình kém đi ở Test 2. Nhưng **Perplexity** đã chuẩn hóa hoàn hảo về mức **5** (chỉ số rõ ràng). $\Rightarrow$ Giúp đánh giá mô hình một cách nhất quán và công bằng!

Công thức thay đổi tùy theo ngữ cảnh mà mô hình xem xét:

Tính toán cho các mô hình N-gram

Công thức thay đổi tùy theo ngữ cảnh mà mô hình xem xét:

- **Unigram:** $PP(W) = \sqrt[N]{\prod_{i=1}^N \frac{1}{P(w_i)}}$

Tính toán cho các mô hình N-gram

Công thức thay đổi tùy theo ngữ cảnh mà mô hình xem xét:

- **Unigram:** $PP(W) = \sqrt[N]{\prod_{i=1}^N \frac{1}{P(w_i)}}$
- **Bigram:** $PP(W) = \sqrt[N]{\prod_{i=1}^N \frac{1}{P(w_i|w_{i-1})}}$

Tính toán cho các mô hình N-gram

Công thức thay đổi tùy theo ngữ cảnh mà mô hình xem xét:

- **Unigram:** $PP(W) = \sqrt[N]{\prod_{i=1}^N \frac{1}{P(w_i)}}$
- **Bigram:** $PP(W) = \sqrt[N]{\prod_{i=1}^N \frac{1}{P(w_i|w_{i-1})}}$

Lưu ý: Các ký hiệu bắt đầu/kết thúc câu (như $\langle s \rangle, \langle /s \rangle$) cũng được sử dụng để tính toán.

Tập huấn luyện (Train Set) - 6 câu:

Tập huấn luyện (Train Set) - 6 câu:

① <s> tôi đi học </s> (3 lần)

Tập huấn luyện (Train Set) - 6 câu:

- ➊ <s> tôi đi học </s> (3 lần)
- ➋ <s> nó đi chơi </s> (2 lần)

Tập huấn luyện (Train Set) - 6 câu:

- ➊ <s> tôi đi học </s> (3 lần)
- ➋ <s> nó đi chơi </s> (2 lần)
- ➌ <s> nó đi làm </s> (1 lần)

Tập huấn luyện (Train Set) - 6 câu:

- ❶ <s> tôi đi học </s> (3 lần)
- ❷ <s> nó đi chơi </s> (2 lần)
- ❸ <s> nó đi làm </s> (1 lần)

Tập kiểm tra (Test Set):

Tập huấn luyện (Train Set) - 6 câu:

- ❶ <s> tôi đi học </s> (3 lần)
- ❷ <s> nó đi chơi </s> (2 lần)
- ❸ <s> nó đi làm </s> (1 lần)

Tập kiểm tra (Test Set): tôi đi học </s> ($N = 4$)

Bảng tổng kết xác suất và Perplexity

Bước dự đoán	Unigram	Bigram	Trigram
--------------	---------	--------	---------

Bảng tổng kết xác suất và Perplexity

Bước dự đoán	Unigram	Bigram	Trigram
$P(\text{tôi} \mid \dots)$	0.125	0.5	0.5

Bảng tổng kết xác suất và Perplexity

Bước dự đoán	Unigram	Bigram	Trigram
$P(\text{tôi} \mid \dots)$	0.125	0.5	0.5
$P(\text{đi} \mid \dots)$	0.250	1.0	1.0

Bảng tổng kết xác suất và Perplexity


Bước dự đoán	Unigram	Bigram	Trigram
$P(\text{tôi} \mid \dots)$	0.125	0.5	0.5
$P(\text{đi} \mid \dots)$	0.250	1.0	1.0
$P(\text{học} \mid \dots)$	0.125	0.5	1.0

Bảng tổng kết xác suất và Perplexity

Bước dự đoán	Unigram	Bigram	Trigram
$P(\text{tôi} \mid \dots)$	0.125	0.5	0.5
$P(\text{đi} \mid \dots)$	0.250	1.0	1.0
$P(\text{học} \mid \dots)$	0.125	0.5	1.0
$P(\langle /s \rangle \mid \dots)$	0.250	1.0	1.0

Bảng tổng kết xác suất và Perplexity

Bước dự đoán	Unigram	Bigram	Trigram
$P(\text{tôi} \mid \dots)$	0.125	0.5	0.5
$P(\text{đi} \mid \dots)$	0.250	1.0	1.0
$P(\text{học} \mid \dots)$	0.125	0.5	1.0
$P(\langle /s \rangle \mid \dots)$	0.250	1.0	1.0
P(W)	0.00097	0.25	0.50



Bảng tổng kết xác suất và Perplexity

Bước dự đoán	Unigram	Bigram	Trigram
$P(\text{tôi} \mid \dots)$	0.125	0.5	0.5
$P(\text{đi} \mid \dots)$	0.250	1.0	1.0
$P(\text{học} \mid \dots)$	0.125	0.5	1.0
$P(\langle /s \rangle \mid \dots)$	0.250	1.0	1.0
P(W)	0.00097	0.25	0.50
Perplexity (PP)	5.66	1.41	1.19

Bảng tổng kết xác suất và Perplexity

Bước dự đoán	Unigram	Bigram	Trigram
$P(\text{tôi} \mid \dots)$	0.125	0.5	0.5
$P(\text{đi} \mid \dots)$	0.250	1.0	1.0
$P(\text{học} \mid \dots)$	0.125	0.5	1.0
$P(\langle /s \rangle \mid \dots)$	0.250	1.0	1.0
P(W)	0.00097	0.25	0.50
Perplexity (PP)	5.66	1.41	1.19

Công thức áp dụng ($N = 4$): $PP(W) = \sqrt[4]{\frac{1}{P(W)}}$

Bảng tổng kết xác suất và Perplexity

Bước dự đoán	Unigram	Bigram	Trigram
$P(\text{tôi} \mid \dots)$	0.125	0.5	0.5
$P(\text{đi} \mid \dots)$	0.250	1.0	1.0
$P(\text{học} \mid \dots)$	0.125	0.5	1.0
$P(\langle /s \rangle \mid \dots)$	0.250	1.0	1.0
P(W)	0.00097	0.25	0.50
Perplexity (PP)	5.66	1.41	1.19

Công thức áp dụng ($N = 4$): $PP(W) = \sqrt[4]{\frac{1}{P(W)}}$

**n lớn thì
mô hình dự đoán tốt ?**

Tổng kết: Perplexity vs. Thực tế

Nguyên tắc tối ưu hóa

Các mô hình ngôn ngữ được huấn luyện để **tối thiểu hóa Perplexity** ($PP \downarrow$).

Tổng kết: Perplexity vs. Thực tế

Nguyên tắc tối ưu hóa

Các mô hình ngôn ngữ được huấn luyện để **tối thiểu hóa Perplexity** ($PP \downarrow$).

- Lưu ý

Tổng kết: Perplexity vs. Thực tế

Nguyên tắc tối ưu hóa

Các mô hình ngôn ngữ được huấn luyện để **tối thiểu hóa Perplexity** ($PP \downarrow$).

- **Lưu ý**

- Perplexity chỉ là một thước đo *nội tại* (intrinsic metric).

Tổng kết: Perplexity vs. Thực tế

Nguyên tắc tối ưu hóa

Các mô hình ngôn ngữ được huấn luyện để **tối thiểu hóa Perplexity** ($PP \downarrow$).

- **Lưu ý**

- Perplexity chỉ là một thước đo *nội tại* (intrinsic metric).
- Perplexity thấp trên tập test chỉ chứng tỏ mô hình dự đoán từ ngữ giỏi, chưa chắc đã hoàn thành tốt các tác vụ phức tạp.

Tổng kết: Perplexity vs. Thực tế

Nguyên tắc tối ưu hóa

Các mô hình ngôn ngữ được huấn luyện để **tối thiểu hóa Perplexity** ($PP \downarrow$).

- **Lưu ý**

- Perplexity chỉ là một thước đo *nội tại* (intrinsic metric).
- Perplexity thấp trên tập test chỉ chứng tỏ mô hình dự đoán từ ngữ giỏi, chưa chắc đã hoàn thành tốt các tác vụ phức tạp.

Kết luận quan trọng

Cần có sự đánh giá đầu cuối trên các tác vụ thực tế để xác nhận hiệu quả thực sự của mô hình.

Giả sử ta có 2 mô hình ngôn ngữ A và B có Perplexity trên tập devset/valid set lần lượt là 0.10 và 0.9.

Giả sử ta có 2 mô hình ngôn ngữ A và B có Perplexity trên tập devset/valid set lần lượt là 0.10 và 0.9.

Vậy ta sẽ muốn dùng mô hình nào hơn ? Tại sao?