

Evaluating Language Models: Training and Test Sets & Perplexity

Thành viên nhóm 1:

Bảo Quý Định Tân - 24520028

Lê Văn Thức - 24521748

Lê Phạm Thành Nhân - 24520022

University of Information Technology - VNUHCM

Ngày 24 tháng 2 năm 2026

Hệ số phân nhánh (Branching Factor) của một ngôn ngữ là số lượng các từ có thể nối tiếp ngay sau một từ bất kỳ.

Giả sử ta có một loại ngôn ngữ chỉ có 3 từ, từ nào cũng có thể được nói sau một từ bất kỳ:

$$L = \{\text{red, blue, green}\} \quad (3.18)$$

Hệ số phân nhánh (Branching Factor) của ngôn ngữ này là 3.

Perplexity as Weighted Average Branching Factor

Ta huấn luyện một mô hình ngôn ngữ (LM) gọi là $\mathbf{A}$ mà xác suất của mỗi từ theo sau một từ bất kỳ là $\frac{1}{3}$.

Với test set $T = \text{"red red red red blue"}$, ta có được perplexity là 3:

$$\begin{aligned}\text{perplexity}_A(T) &= P_A(\text{red red red red blue})^{-\frac{1}{5}} \\ &= \left(\left(\frac{1}{3} \right)^5 \right)^{-\frac{1}{5}} \\ &= \left(\frac{1}{3} \right)^{-1} = 3\end{aligned}\tag{3.19}$$

Perplexity as Weighted Average Branching Factor

Nếu ta huấn luyện một mô hình ngôn ngữ (LM) khác gọi là **B** mà lúc huấn luyện từ **red** xuất hiện thường xuyên hơn:

$$P(\text{red}) = 0.8 \quad P(\text{green}) = 0.1 \quad P(\text{blue}) = 0.1 \quad (3.20)$$

Thì perplexity bây giờ sẽ thấp hơn:

$$\begin{aligned} \text{perplexity}_B(T) &= P_B(\text{red red red red blue})^{-1/5} \\ &= (0.8^4 \times 0.1)^{-\frac{1}{5}} \\ &= 0.04096^{-\frac{1}{5}} \\ &= 0.527^{-1} = 1.89 \end{aligned} \quad (3.21)$$

Hệ số phân nhánh trung bình có trọng số (Weighted Average Branching Factor) chính là số lượng các từ tiếp theo thực sự có khả năng xảy ra cao nhất và tính trung bình, thay vì đếm tổng tất cả các từ ngữ pháp hợp lệ.

Ví dụ:

- ① Sau từ 'bánh' thì có thể là từ 'mì' hoặc 'hỏi' nhưng hiếm khi hoặc không bao giờ là từ 'đền', 'bàn',
- ② Giả sử có nhiều loại bánh hơn là loại xe. Nên số lượng từ có thể theo sau từ 'bánh' sẽ nhiều hơn là theo sau 'xe'.

Perplexity as Weighted Average Branching Factor

Hệ số phân nhánh trung bình có trọng số là ý nghĩa.
Perplexity là cách tính.

Một mô hình ngôn ngữ có **hệ số phân nhánh trung bình có trọng số** (Weighted Average Branching Factor) hay **Perplexity** thấp thì có ý nghĩa gì?

Khi bạn crawl web để làm dataset cho LM, mọi người có nhận thấy khả năng nguy hiểm nào không?