

Sampling and Generalization in N-gram Models

Chapters 3.4 – 3.5

Nhóm 3

Phạm Ngọc Phú Thịnh Phạm Nguyễn Duy Anh
Nguyễn Trường Giang Hà Bùi Trọng Nghĩa

Khoa Khoa học Máy tính
Trường Đại học Công nghệ Thông tin - UIT **Xử lý ngôn ngữ tự nhiên**

Ngày 1 tháng 3 năm 2026

Nội dung bài thuyết trình

1 Sampling sentences from a language model

- Vì sao cần sampling?
- Sampling trong trường hợp Unigram
- Sampling với Bigram
- Ý nghĩa khi tăng bậc n
- Ý nghĩa của việc Sampling
- Kết luận

2 Generalizing vs. Overfitting the Training Set

- Sự phụ thuộc vào dữ liệu huấn luyện
- Ví dụ thực tế với Shakespeare
- Phụ thuộc vào miền dữ liệu (Domain Dependence)
- Hệ quả thực tế trong xây dựng Language Model
- Khác biệt về phương ngữ và biến thể ngôn ngữ
- Xử lý từ chưa từng thấy (OOV)
- Kết luận

Table of Contents

1 Sampling sentences from a language model


- Vì sao cần sampling?
- Sampling trong trường hợp Unigram
- Sampling với Bigram
- Ý nghĩa khi tăng bậc n
- Ý nghĩa của việc Sampling
- Kết luận

2 Generalizing vs. Overfitting the Training Set

- Sự phụ thuộc vào dữ liệu huấn luyện
- Ví dụ thực tế với Shakespeare
- Phụ thuộc vào miền dữ liệu (Domain Dependence)
- Hệ quả thực tế trong xây dựng Language Model
- Khác biệt về phương ngữ và biến thể ngôn ngữ
- Xử lý từ chưa từng thấy (OOV)
- Kết luận

Vì sao cần Sampling?


- **Khái niệm:** Là cách quan trọng để hiểu một Language Model (LM) "biết" điều gì.
- **Bản chất:** LM biểu diễn một phân phối xác suất trên các câu.
- **Sampling nghĩa là:** Chọn ngẫu nhiên các điểm theo đúng xác suất của chúng.
- **Kết quả:**
 - Sinh ra các câu dựa trên xác suất mô hình gán.
 - Câu xác suất cao xuất hiện thường xuyên hơn.
 - Câu xác suất thấp xuất hiện hiếm hơn.
- Ý tưởng đề xuất bởi **Shannon (1948)**.



Hình 1: Minh họa phân phối lấy mẫu Shannon.

Sampling trong trường hợp Unigram

- **Mô hình hóa:** Mỗi từ chiếm một đoạn trên trục số từ 0 đến 1.
- **Tỉ lệ:** Độ dài mỗi đoạn tỉ lệ thuận với xác suất của từ đó.
 - Ví dụ: "the" (phổ biến) chiếm đoạn lớn, "polyphonic" (hiếm) chiếm đoạn rất nhỏ.
- **Cách sinh từ:**
 - 1 Chọn số ngẫu nhiên $r \in [0, 1]$.
 - 2 Xác định đoạn chứa r và in ra từ tương ứng.
 - 3 Lặp lại đến khi gặp token kết thúc `</s>`.



Hình 1: Minh họa phân phối lấy mẫu.

Sampling với Bigram

- Quá trình tương tự Unigram nhưng có thêm **điều kiện ngữ cảnh**.

Bước 1: Chọn Bigram bắt đầu

Chọn ngẫu nhiên một cặp ($\langle s \rangle, w$) theo xác suất: $P(w \mid \langle s \rangle)$.

Bước 2: Tiếp tục theo ngữ cảnh

Giả sử từ vừa sinh là w . Ta chọn tiếp một cặp (w, w_{next}) theo xác suất điều kiện: $P(w_{next} \mid w)$.

Bước 3: Lặp lại

- Dùng từ hiện tại làm ngữ cảnh để lấy phân phối xác suất điều kiện tiếp theo.
- Quá trình dừng lại khi sinh ra token kết thúc $\langle /s \rangle$.

Ý nghĩa khi tăng bậc n

- **Sự thay đổi về tính mạch lạc:**

- **Unigram:** Không có tính mạch lạc, từ ngữ rời rạc.
- **Bigram:** Bắt đầu có liên kết cục bộ giữa các cặp từ.
- **Trigram:** Câu bắt đầu có cấu trúc tự nhiên hơn.
- **4-gram:** Câu có thể rất giống dữ liệu gốc (tính ghi nhớ cao).

- **Ngữ cảnh càng dài:**

- Câu càng có vẻ **"coherent"** (mạch lạc).
- Mô hình phản ánh mạnh mẽ các đặc điểm của dữ liệu huấn luyện.
- Dễ dẫn đến hiện tượng **Overfitting** ở các bậc n cao.

Sampling giúp ta quan sát điều gì?

- **Phản ánh tri thức của mô hình:**

- Cho thấy những mẫu (*patterns*) mà mô hình đã học được từ dữ liệu.
- Thể hiện mức độ phụ thuộc của mô hình vào tập huấn luyện (*training corpus*).

- **Mối liên hệ với bậc n :**

- Khi tăng n , mô hình dần "ghi nhớ" được các chuỗi từ dài hơn.

Nguy cơ Overfitting

Khi n tăng quá cao, mô hình có xu hướng **Overfit** dữ liệu huấn luyện, làm giảm khả năng tổng quát hóa.

Kết luận về phương pháp Sampling

- **Công cụ trực quan hóa:** Giúp hiểu rõ phân phối xác suất thực tế mà mô hình đã học được từ dữ liệu.
- **Đánh giá bậc n :** Cho phép so sánh trực tiếp sự khác biệt về khả năng biểu diễn giữa các mô hình Unigram, Bigram và Trigram.
- **Quan sát tính mạch lạc:** Minh chứng rõ nét cho việc tăng bậc n sẽ giúp câu sinh ra có cấu trúc tự nhiên và mạch lạc hơn.
- **Tiền đề nghiên cứu:** Chuẩn bị nền tảng để phân tích sâu hơn về sự đánh đổi giữa khả năng **Tổng quát hóa (Generalization)** và **Quá khớp (Overfitting)**.

Table of Contents

1 Sampling sentences from a language model

- Vì sao cần sampling?
- Sampling trong trường hợp Unigram
- Sampling với Bigram
- Ý nghĩa khi tăng bậc n
- Ý nghĩa của việc Sampling
- Kết luận

2 Generalizing vs. Overfitting the Training Set

- Sự phụ thuộc vào dữ liệu huấn luyện
- Ví dụ thực tế với Shakespeare
- Phụ thuộc vào miền dữ liệu (Domain Dependence)
- Hệ quả thực tế trong xây dựng Language Model
- Khác biệt về phương ngữ và biến thể ngôn ngữ
- Xử lý từ chưa từng thấy (OOV)
- Kết luận

N-gram phụ thuộc mạnh vào tập huấn luyện

- Giống như nhiều mô hình thống kê, n -gram phụ thuộc trực tiếp vào **training corpus**.

Hệ quả 1: Đặc trưng hóa

Xác suất học được thường phản ánh những đặc điểm rất cụ thể và riêng biệt của tập dữ liệu huấn luyện.

Hệ quả 2: Sự khớp dữ liệu

Khi tăng giá trị của n , mô hình sẽ mô tả và khớp với tập dữ liệu huấn luyện ngày càng tốt hơn.

Rủi ro tiềm ẩn

Việc mô hình quá khớp với dữ liệu huấn luyện sẽ dẫn đến vấn đề **Overfitting**, làm giảm khả năng dự đoán trên dữ liệu mới.

Minh họa: Sampling từ mô hình Shakespeare

1
gram

–To him swallowed confess hear both. Which. Of save on trail for are ay device and rote life have

–Hill he late speaks; or! a more to leg less first you enter

2
gram

–Why dost stand forth thy canopy, forsooth; he is this palpable hit the King Henry. Live king. Follow.

–What means, sir. I confess she? then all sorts, he is trim, captain.

3
gram

–Fly, and will rid me these news of price. Therefore the sadness of parting, as they say, 'tis done.

–This shall forbid it should be branded, if renown made it empty.

4
gram

–King Henry. What! I will go seek the traitor Gloucester. Exeunt some of the watch. A great banquet serv'd in;

–It cannot be but so.

Hình 2: Các câu văn được tạo ngẫu nhiên từ mô hình n -gram huấn luyện trên Shakespeare.

- **Quan sát:** Khi n tăng từ 1 lên 4, câu văn chuyển từ hỗn loạn sang mạch lạc và cuối cùng là trích dẫn nguyên văn dữ liệu gốc.

Tăng bậc n làm câu sinh ra "giống" dữ liệu hơn

Khi lấy mẫu từ các mô hình huấn luyện trên Shakespeare:

- **Unigram:** Rời rạc, không có tính mạch lạc hay cấu trúc rõ ràng.
- **Bigram:** Bắt đầu có sự liên kết cục bộ giữa các từ.
- **Trigram:** Câu sinh ra bắt đầu mang phong cách của Shakespeare.
- **4-gram:** Giống đến mức có thể trích dẫn nguyên văn dữ liệu gốc.

Ví dụ thực tế (4-gram)

Cụm từ **"It cannot be but so"** xuất hiện trực tiếp trong tác phẩm *King John*.

Tại sao mô hình lại "ghi nhớ" dữ liệu?

- **Tập dữ liệu giới hạn:** Tập Shakespeare có $N \approx 884,647$ từ và từ vựng $V \approx 29,066$.
- **Ma trận xác suất thưa:**
 - Số khả năng Bigram: $V^2 \approx 844$ triệu.
 - Số khả năng 4-gram: $V^4 \approx 7 \times 10^{17}$.
- **Hệ quả:**
 - Khi chọn một 3-gram cụ thể, khả năng lựa chọn từ tiếp theo cực kỳ hạn chế.
 - Mô hình thực chất đang **ghi nhớ** các chuỗi có sẵn trong dữ liệu thay vì học quy luật.

Kết luận

Đây chính là biểu hiện rõ rệt nhất của hiện tượng **Overfitting** (Quá khớp).

Sự khác biệt giữa các Corpus huấn luyện

- Thử nghiệm huấn luyện trên tập dữ liệu hoàn toàn khác: **Wall Street Journal (WSJ)**.
- **Đặc điểm chung**: Cả hai đều là tiếng Anh.
- **Sự khác biệt thực tế**: Hầu như không có sự trùng lặp n -gram giữa Shakespeare và WSJ.

Shakespeare (Kịch/Thơ)	WSJ (Kinh tế/Báo chí)
"thy", "thou", "hath"	"stock market", "interest rates"
Phong cách cổ điển, trang trọng	Thuật ngữ tài chính, doanh nghiệp

Kết luận quan trọng

Nếu tập huấn luyện và tập kiểm tra khác biệt lớn về phân phối xác suất, mô hình thống kê sẽ gần như **vô dụng** trong việc dự đoán.

Minh họa: Sampling từ mô hình Wall Street Journal

1 gram	Months the my and issue of year foreign new exchange's september were recession exchange new endorsed a acquire to six executives
2 gram	Last December through the way to preserve the Hudson corporation N. B. E. C. Taylor would seem to complete the major central planners one point five percent of U. S. E. has already old M. X. corporation of living on information such as more frequently fishing to keep her
3 gram	They also point to ninety nine point six billion dollars from two hundred four oh six three percent of the rates of interest stores as Mexico and Brazil on market conditions

Hình 3: Các câu văn được tạo ngẫu nhiên từ mô hình n-gram huấn luyện trên WSJ.

- **So sánh:** Các câu "giả WSJ" mang phong cách báo chí hiện đại, hoàn toàn khác biệt với "giả Shakespeare".

Phương pháp giải quyết

- **Nguyên tắc cốt lõi:** Để mô hình hoạt động hiệu quả, **Training Corpus** phải cùng thể loại với nhiệm vụ thực tế.
- **Ví dụ về sự tương thích:**

Dịch thuật Pháp lý

Cần tập dữ liệu văn bản luật, nghị định, hợp đồng.

Phân tích Mạng xã hội

Cần dữ liệu từ Facebook, X (Twitter) để hiểu tiếng lóng, icon.

Hệ thống Hỏi – Đáp

Cần Corpus gồm các cặp câu hỏi và câu trả lời thực tế.

Y khoa / Kỹ thuật

Cần các bài báo nghiên cứu, thuật ngữ chuyên ngành.

Biến thể ngôn ngữ và Phương ngữ

- Ngay cả trong cùng một ngôn ngữ, sự khác biệt về phương ngữ tạo ra các **phân phối xác suất khác nhau**.
- **Các ví dụ tiêu biểu:**
 - African American English (AAE).
 - Nigerian Pidgin.
 - Các phương ngữ vùng miền (Bắc - Trung - Nam).

Đặc điểm riêng biệt

- Từ vựng riêng.
- Mẫu n -gram đặc trưng.
- Cấu trúc ngữ pháp riêng.

Hệ quả kỹ thuật

Nếu **Training Corpus** không bao phủ các biến thể này, mô hình sẽ hoạt động cực kỳ kém trên các tập dữ liệu đó.

"Tính bao hàm của dữ liệu quyết định độ chính xác của mô hình."

Vấn đề từ chưa từng thấy (OOV)

- **Thực trạng:** Một từ xuất hiện trong Test set nhưng hoàn toàn vắng bóng trong Training set.
 - Ví dụ: Tên riêng như "**Jurafsky**".

Cách tiếp cận truyền thống

Gán nhãn tất cả từ lạ là token đặc biệt <UNK>. (*Dễ mất thông tin*)

Giải pháp hiện đại: Subword

Sử dụng các thuật toán như **BPE** (Byte-pair encoding).

- **Cơ chế Subword Tokens:**
 - Phân tách từ thành các đơn vị nhỏ hơn (ví dụ: *un + break + able*).
 - Có thể phân tách đến từng ký tự nếu cần thiết.
- **Ưu điểm:** **Test set** sẽ không bao giờ chứa một token hoàn toàn chưa từng thấy, giúp mô hình luôn có thể xử lý được.

Kết luận: Generalizing vs. Overfitting

- **Sự phụ thuộc dữ liệu:** Mô hình n -gram chịu ảnh hưởng trực tiếp và mạnh mẽ từ **Training Corpus**.
- **Cái bẫy của bậc n :**
 - Tăng n giúp mô hình khớp dữ liệu huấn luyện tốt hơn.
 - Tuy nhiên, n quá cao dẫn đến **Overfitting** (ghi nhớ thay vì học quy luật).
- **Điều kiện hoạt động:** Mô hình chỉ thực sự hiệu quả khi tập huấn luyện và tập kiểm tra có **cùng phân phối dữ liệu**.

Mục tiêu cốt lõi

Mục tiêu của Language Model không phải là mô tả hoàn hảo dữ liệu cũ, mà là khả năng **Tổng quát hóa (Generalization)** — dự đoán chính xác trên những dữ liệu hoàn toàn mới.

CẢM ƠN CÁC BẠN!

Nhóm 3

QUIZ TIME!

Mời các bạn tham gia phần giải đố để ôn lại kiến thức về N-gram.