

Đại học Quốc gia Thành phố Hồ Chí Minh
Trường Đại học Công nghệ Thông tin



Môn học: Xử lý Ngôn ngữ Tự nhiên
CS221.Q21.KHTN

Logistic Regression and Text Classification

Nhóm 7

Nguyễn Thiên Bảo - MSSV: 23520127
Cao Lê Công Thành - MSSV: 23521437
Đặng Quang Vinh - MSSV: 23521786

Ngày 10, tháng 03, năm 2026

- 1 Machine learning and classification
- 2 The sigmoid function
- 3 Classification with Logistic Regression

1. Machine Learning and Classification

Định nghĩa (Classification)

Là nhiệm vụ gán một **nhãn (label)** cho một đầu vào.

Mục tiêu

Input: một đầu vào x (observation)

Output: một lớp y thuộc tập các lớp cho trước $Y = \{y_1, y_2, \dots, y_M\}$

Ví dụ:

- x có thể là một review, $Y = \{\text{positive, negative}\}$
- x : email, $Y = \{\text{spam, not spam}\}$
- x : đoạn văn bản cần được biết ngôn ngữ, Y là tập hợp các ngôn ngữ

1. Rule-based methods

- Sử dụng các luật do con người viết.
- Ví dụ: nếu xuất hiện từ *love* trong *x*, và nó không đứng sau từ *don't* → positive.

Nhược điểm

- Khó bao phủ tất cả trường hợp.
- Các đặc trưng tương tác phức tạp (ví dụ: phủ định).
- Khó mở rộng khi dữ liệu thay đổi.

Large Language Models for Classification

Sử dụng **Large Language Models (LLMs)** thông qua Prompting.

Hạn chế cần lưu ý

- Có thể **hallucinate** (ảo tưởng dữ liệu).
- Khó giải thích (*Interpretability*) tại sao chọn nhãn đó.

Supervised Machine Learning

Một trong những cách tiếp cận phổ biến nhất là **Supervised Machine Learning**

Labeled Training Set

$$\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})\} \quad (1.1)$$

Trong đó

- $x^{(i)}$: dữ liệu đầu vào
- $y^{(i)}$: nhãn đúng của dữ liệu

Mục tiêu: Học một mô hình có khả năng tổng quát hóa để dự đoán nhãn cho dữ liệu mới chưa từng thấy.

Logistic Regression là một **probabilistic classifier**. Nó không chỉ đưa ra nhãn mà còn tính toán xác suất:

$$P(y|x)$$

Ví dụ xác suất

$$P(\text{positive}|x) = 0.8$$

$$P(\text{negative}|x) = 0.2$$

Lợi ích:

- Hiểu mức độ chắc chắn (*confidence*) của dự đoán.
- Hữu ích khi kết hợp nhiều hệ thống khác nhau.

Components of a Probabilistic Classifier

Một **probabilistic classifier** gồm:

4 Thành phần cốt lõi

1 Feature Representation

- Biểu diễn input dưới dạng vector đặc trưng
- $x = [x_1, x_2, \dots, x_n]$

2 Classification Function:

- Tính xác suất $P(y|x)$
- Ví dụ: sigmoid hoặc softmax

3 Objective Function: Hàm mục tiêu để tối ưu (Loss function).

4 Optimization Algorithm: Thuật toán học tham số để tối ưu hóa hàm mục tiêu (ví dụ: Gradient Descent).

Logistic Regression (hay bất kỳ **probabilistic machine learning classifier** nào) cũng đều có hai giai đoạn chính:

Phase 1: Training

Học các tham số:

- Trọng số **weight vector** w
- Hệ số chặn **bias** b

Phase 2: Testing

Dự đoán trên x mới:

- Tính xác suất $P(y|x)$.
- Chọn label có xác suất cao nhất.

2. The sigmoid function

- **Mục tiêu:** Huấn luyện một bộ phân loại (classifier) để đưa ra quyết định nhị phân cho một quan sát đầu vào (observation) mới.
- Quan sát đầu vào x được biểu diễn bằng một vector các đặc trưng (features): $[x_1, x_2, \dots, x_n]$.
- Đầu ra của bộ phân loại y có thể nhận giá trị:
 - 1: Quan sát thuộc về lớp đang xét.
 - 0: Quan sát không thuộc về lớp đó.
- **Điều cần tìm:** Xác suất $P(y = 1|x)$ (ví dụ: xác suất văn bản mang cảm xúc tích cực) và $P(y = 0|x)$ (xác suất văn bản mang cảm xúc tiêu cực).

Trọng số (Weights) và Độ lệch (Bias)

- Hồi quy logistic giải quyết bài toán bằng cách học từ tập dữ liệu huấn luyện (training set) để tìm ra một vector **trọng số** (weights) và một **độ lệch** (bias term).
- **Trọng số w_i :**
 - Là một số thực đi kèm với một đặc trưng đầu vào x_i .
 - Thể hiện mức độ quan trọng của đặc trưng đó đối với quyết định phân loại.
 - Có thể mang giá trị dương (ủng hộ lớp positive) hoặc âm (ủng hộ lớp negative).
- **Độ lệch b (bias / intercept):** Là một số thực được cộng thêm vào tổng các đầu vào đã nhân trọng số.

Tính toán bằng chứng cho lớp (Tổng trọng số)

- Để đưa ra quyết định cho một dữ liệu kiểm thử (test instance), bộ phân loại thực hiện các bước sau:
 - ➊ Nhân mỗi đặc trưng x_i với trọng số w_i tương ứng.
 - ➋ Tính tổng tất cả các giá trị vừa nhân.
 - ➌ Cộng thêm độ lệch b .
- Kết quả là một con số duy nhất z , biểu diễn tổng trọng số bằng chứng (weighted sum of evidence) cho lớp đó:

$$z = \left(\sum_{i=1}^n w_i x_i \right) + b \quad (2.1)$$

Ký hiệu Tích vô hướng (Dot Product)

- Trong đại số tuyến tính, tổng trên có thể được biểu diễn gọn gàng hơn bằng ký hiệu **tích vô hướng** (dot product).
- Tích vô hướng của hai vector a và b (viết là $a \cdot b$) là tổng các tích của từng phần tử tương ứng của mỗi vector.
- Bằng cách biểu diễn đầu vào thành vector x và trọng số thành vector w , ta có công thức tương đương cho z :


$$z = w \cdot x + b \quad (2.2)$$

Hàm Sigmoid (Hàm Logistic)

- **Vấn đề:** Phương trình 2.2 không giới hạn z là một xác suất hợp lệ (nằm trong khoảng từ 0 đến 1). Vì các trọng số là số thực, z có thể trải dài từ $-\infty$ đến ∞ .
- **Giải pháp:** Đưa z qua **hàm sigmoid** $\sigma(z)$ (còn được gọi là hàm logistic).
- Hàm sigmoid ánh xạ một số thực bất kỳ vào khoảng $(0, 1)$, hoàn hảo để biểu diễn xác suất:

$$\sigma(z) = \frac{1}{1 + e^{-z}} = \frac{1}{1 + \exp(-z)} \quad (2.3)$$

Trực quan hóa Hàm Sigmoid



Nhận xét từ đồ thị:

- **Đầu vào z (Trục hoành):** Có thể nhận bất kỳ giá trị số thực nào (từ $-\infty$ đến ∞).
- **Đầu ra $\sigma(z)$ (Trục tung):** Luôn bị giới hạn (ánh xạ) vào khoảng $(0, 1)$, hoàn hảo để biểu diễn xác suất.
- **Đặc điểm hình học:**
 - Gần như tuyến tính ở khu vực xung quanh gần $z = 0$.
 - z càng lớn thì $\sigma(z)$ càng tiến sát về 1, z càng nhỏ (âm) thì $\sigma(z)$ càng tiến sát về 0.

Tính toán Xác suất cho từng Lớp

- Để đảm bảo $\sigma(z)$ là một xác suất hợp lệ, tổng xác suất của 2 trường hợp $P(y = 1)$ và $P(y = 0)$ phải bằng 1. Ta tính toán như sau:

$$\begin{aligned} P(y = 1) &= \sigma(w \cdot x + b) \\ &= \frac{1}{1 + \exp(-(w \cdot x + b))} \\ P(y = 0) &= 1 - \sigma(w \cdot x + b) \\ &= 1 - \frac{1}{1 + \exp(-(w \cdot x + b))} \\ &= \frac{\exp(-(w \cdot x + b))}{1 + \exp(-(w \cdot x + b))} \end{aligned} \tag{2.4}$$

Thuộc tính của Hàm Sigmoid

- Hàm sigmoid sở hữu một thuộc tính đối xứng rất hữu ích:

$$1 - \sigma(x) = \sigma(-x) \quad (2.5)$$

Chứng minh:

$$\begin{aligned} 1 - \sigma(x) &= 1 - \frac{1}{1 + e^{-x}} = \frac{(1 + e^{-x}) - 1}{1 + e^{-x}} \\ &= \frac{e^{-x}}{1 + e^{-x}} = \frac{e^{-x} \cdot e^x}{(1 + e^{-x}) \cdot e^x} \quad (\text{Nhân tử và mẫu với } e^x) \\ &= \frac{1}{e^x + 1} = \sigma(-x) \quad (\text{Điều phải chứng minh}) \end{aligned}$$

- Nhờ vào thuộc tính này, thay vì phải biểu diễn $P(y = 0)$ bằng phép tính trừ phức tạp như ở phương trình 2.4, ta có thể viết lại gọn gàng hơn:

$$P(y = 0) = \sigma(-(w \cdot x + b))$$

Hàm Logit và Ý nghĩa Xác suất

- Đầu vào của hàm sigmoid, giá trị điểm $z = w \cdot x + b$ từ (Eq. 2.2), thường được gọi là **logit**.
- Lý do là vì **hàm logit** chính là hàm ngược của hàm sigmoid, và nó biểu diễn logarithm của tỷ lệ chênh lệch (odds ratio) $\frac{p}{1-p}$:

$$\text{logit}(p) = \sigma^{-1}(p) = \ln \frac{p}{1-p} \quad (2.6)$$

Chứng minh Logit là hàm ngược của Sigmoid

Để tìm hàm ngược, ta bắt đầu từ hàm Sigmoid: $p = \sigma(z)$ và giải z theo p :

$$p = \frac{1}{1 + e^{-z}}$$

$$\Leftrightarrow 1 + e^{-z} = \frac{1}{p}$$

$$\Leftrightarrow e^{-z} = \frac{1}{p} - 1 = \frac{1 - p}{p} \quad (\text{Chuyển vế và quy đồng})$$

$$\Leftrightarrow e^z = \frac{p}{1 - p} \quad (\text{Nghịch đảo 2 vế})$$

$$\Leftrightarrow z = \ln\left(\frac{p}{1 - p}\right) = \text{logit}(p) = \sigma^{-1}(p) \quad (\text{Điều phải chứng minh})$$

- Sử dụng thuật ngữ logit cho z để cho thấy: bằng cách dùng sigmoid để biến z (từ $-\infty$ đến ∞) thành xác suất, ta đang ngầm hiểu z chính là "log odds" (log của tỷ lệ chênh lệch) chứ không chỉ là một số thực vô nghĩa.

Ký hiệu $\hat{y}$ (y hat)

- Trong bài toán phân loại nhị phân, để tiện lợi, ta thường gọi đầu ra của hàm sigmoid $\sigma(w \cdot x + b)$ (chính là phép tính $P(y = 1)$) là $\hat{y}$.
- $\hat{y}$ (đọc là **y hat**) mang ý nghĩa là "xác suất mà quan sát đầu vào thuộc về lớp dương (positive class)".
- Vì là phân loại nhị phân, ta chỉ cần giữ một giá trị xác suất vô hướng này, và hoàn toàn có thể suy ra xác suất còn lại bất cứ lúc nào bằng công thức:

$$P(y = 0) = 1 - P(y = 1) = 1 - \hat{y}.$$

3. Classification with Logistic Regression

- Hàm Sigmoid cho phép chúng ta lấy một mẫu đầu vào x và tính toán xác suất $P(y = 1|x)$.

$$\text{decision}(x) = \begin{cases} 1 & \text{nếu } P(y = 1|x) > 0.5 \\ 0 & \text{ngược lại} \end{cases}$$

3.1 Phân loại Cảm xúc (Sentiment Classification)

- **Bài toán:** Phân loại nhị phân đánh giá phim thành cảm xúc tích cực (+) hoặc tiêu cực (-).

Ví dụ: Đoạn văn bản đánh giá phim (Input Document)

"It's hokey . There are virtually no surprises , and the writing is second-rate. So why was it so enjoyable ? For one thing , the cast is great. Another nice touch is the music . I was overcome with the urge to get off the couch and start dancing. It sucked me in , and it'll do the same to you ."

3.1 Phân loại Cảm xúc - Định nghĩa Đặc trưng

- Mỗi đánh giá (document) được biểu diễn bằng một vector gồm 6 đặc trưng ($x_1 \dots x_6$):

Ví dụ: Đoạn văn bản đánh giá phim (Input Document)

"It's hokey . There are virtually no surprises , and the writing is second-rate. So why was it so enjoyable ? For one thing , the cast is great. Another nice touch is the music . I was overcome with the urge to get off the couch and start dancing. It sucked me in , and it'll do the same to you ."

Biến	Định nghĩa
x_1	Số từ thuộc từ điển tích cực
x_2	Số từ thuộc từ điển tiêu cực
x_3	Có chứa từ "no" (1: có, 0: không)
x_4	Số đại từ ngôi thứ 1 và 2
x_5	Có chứa dấu "!" (1: có, 0: không)
x_6	$\ln(\text{tổng số từ và dấu câu})$

3.1 Phân loại Cảm xúc - Quá trình Trích xuất

- Quá trình đổi chiều văn bản thực tế để tìm ra giá trị của các đặc trưng:




Figure 4.2 A sample mini test document showing the extracted features in the vector x .

- Từ đó, ta thu được vector đặc trưng đầu vào cho bài đánh giá này:

$$x = [3, 2, 1, 3, 0, 4.19]$$

3.1 Phân loại Cảm xúc - Ra Quyết định

- **Trọng số (Weights) & Bias:** Giả sử mô hình đã học được:
 - $w = [2.5, -5.0, -1.2, 0.5, 2.0, 0.7]$
 - $b = 0.1$
- **Tính toán xác suất lớp Tích cực (+):**

$$\begin{aligned}P(+|x) &= P(y = 1|x) = \sigma(w \cdot x + b) \\&= \sigma([2.5, -5.0, \dots] \cdot [3, 2, \dots] + 0.1) \\&= \sigma(0.833) = 0.70\end{aligned}\tag{2.6}$$

- **Tính toán xác suất lớp Tiêu cực (-):**

$$P(-|x) = P(y = 0|x) = 1 - 0.70 = 0.30\tag{2.7}$$

3.2 Phân định dấu chấm với Logistic Regression

1. **Mục tiêu:** Phân loại dấu chấm (.) vào hai lớp $Y = \{\text{EOS}, \text{not-EOS}\}$.

- **EOS:** dấu chấm kết thúc câu.
- **not-EOS:** dấu chấm thuộc viết tắt, tên riêng, hoặc thực thể.

Ví dụ minh họa:

The meeting with Prof. Smith was moved to Main St. tomorrow.

Trong câu trên, dấu chấm sau Prof. và St. là **not-EOS**, còn dấu chấm cuối câu là **EOS**.

2. **Thiết kế đặc trưng:**

Đặc trưng	Định nghĩa
x_1 (Kiểu chữ sau dấu chấm)	1 nếu $\text{Case}(w_{i+1}) = \text{Lower}$
x_2 (Từ điển viết tắt)	1 nếu $w_i \in \text{AcronymDict}$
x_3 (Đặc trưng tương tác)	1 nếu $w_i = \text{St.}$ và $\text{Case}(w_{i-1}) = \text{Upper}$

3. **Quyết định:** Dựa trên xác suất

$$P(y = \text{EOS} \mid x) = \sigma(w \cdot x + b). \quad (2.8)$$

- Nếu $P(y = \text{EOS} \mid x) > 0.5$ thì dự đoán **EOS**, ngược lại là **not-EOS**.

- **Thiết kế thủ công (Classic NLP):** Chuyên gia tự thiết kế đặc trưng dựa trên trực giác ngôn ngữ và phân tích lỗi. Việc này tốn rất nhiều công sức con người .

Khuôn mẫu Đặc trưng - Khái niệm & Ví dụ

- **Ý tưởng:** Thay vì "nặn" từng đặc trưng bằng tay, ta tạo ra một **cái khuôn** (quy tắc chung) để máy tự áp dụng vào dữ liệu.

Ví dụ cụ thể:

- **Khuôn mẫu (Template):** "Tạo đặc trưng cho mọi cặp từ (bigram) đứng trước dấu chấm".
- **Dữ liệu thực tế:** "...ate an American breakfast."
- **Đặc trưng sinh ra:** `bigram(American, breakfast)`.
- **Lợi ích:** Giảm thiểu tối đa công sức của con người trong việc thiết kế đặc trưng.

Khuôn mẫu Đặc trưng - Tính Thừa thớt & Cơ chế Băm

1. Tại sao gọi là "Không gian thừa thớt"(Sparse)?

- Ta không tạo đặc trưng cho mọi cặp từ có thể có trong từ điển (hàng tỷ cặp tiềm năng).
- Ta chỉ tạo đặc trưng cho những cặp **thực sự xuất hiện** trong tập huấn luyện.

2. Cơ chế Băm (Hashing) - Biến chữ thành số

Máy tính cần số thứ tự (Index) thay vì chuỗi ký tự dài dòng:

"bigram(American breakfast)" $\xrightarrow{\text{Hàm Băm}}$ **42**

⇒ Đặc trưng thứ **42** trong vector $\times (f_{42})$ sẽ được gán giá trị 1.

Học Biểu diễn (Representation Learning)

NLP Hiện đại (Representation Learning)

- **Tự động hóa:** Mô hình tự tìm ra các đặc trưng quan trọng trực tiếp từ dữ liệu thô (từ ngữ, câu văn).
- **Vector hóa ngữ nghĩa:** Biến các từ thành các vector toán học giàu thông tin mà không cần quy tắc viết tay.

Chuẩn hóa Đặc trưng Đầu vào (Scaling Input Features)

- **Vấn đề:** Các đặc trưng có dải giá trị quá chênh lệch nhau.
- **Giải pháp:** Chuẩn hóa giúp dễ so sánh các giá trị và đặc biệt giúp thuật toán Gradient Descent hội tụ nhanh hơn trong quá trình huấn luyện mô hình đặc biệt là các mạng học sâu.

3 Phương pháp phổ biến:

- ① **Standardize (Z-score):** Căn giữa dữ liệu sao cho trung bình $\mu = 0$ và độ lệch chuẩn $\sigma = 1$.

$$x'_i = \frac{x_i - \mu_i}{\sigma_i} \quad (3.1)$$

- ② **Normalize (Min-Max):** Thu hẹp giá trị nằm trong khoảng từ 0 đến 1.

$$x'_i = \frac{x_i - \min(x_i)}{\max(x_i) - \min(x_i)} \quad (3.2)$$

- ③ **Lấy Logarit (Log scaling):** Áp dụng cho các giá trị như số lượng từ (tuân theo phân phối Zipfian) để giảm độ lệch.

3.3 Xử lý Dữ liệu Hàng loạt (Batch Processing)

- **Thực tế bài toán:** Chúng ta cần dự đoán cho một tập kiểm tra (test set) gồm m ví dụ, chứ không chỉ một ví dụ đơn lẻ.
- **Cách tiếp cận cơ bản (Sử dụng vòng lặp for):**
 - Tính toán từng ví dụ $x^{(i)}$ một cách tuần tự.
 - $\hat{y}^{(i)} = P(y^{(i)} = 1) = \sigma(w \cdot x^{(i)} + b)$ (3.3)
- **Hạn chế:** Việc lặp qua m ví dụ (như tính riêng $\hat{y}^{(1)}, \hat{y}^{(2)}, \hat{y}^{(3)}$) sẽ cực kỳ chậm khi tập dữ liệu lên tới hàng triệu mẫu.

Giải pháp: Toán học Ma trận

- **Đóng gói dữ liệu:** Gộp dữ liệu của m ví dụ vào các ma trận và vector:
 - Ma trận đầu vào X có kích thước $[m \times f]$ (m hàng dữ liệu, f cột đặc trưng).
 - Vector trọng số w là một vector cột $[f \times 1]$.
 - **Vector bias** b : Là vector có độ dài m , bao gồm giá trị vô hướng b (bias) được lặp lại m lần, $b = [b, b, \dots, b]$.
- **Tính toán tất cả trong 1 phép tính:**

$$\hat{y}_{(m \times 1)} = \sigma \left(\underset{(m \times f)}{X} \underset{(f \times 1)}{w} + \underset{(m \times 1)}{b} \right) \quad (3.4)$$

- Phép nhân ma trận Xw khớp kích thước sẽ sinh ra vector $(m \times 1)$, cộng với b cho ra vector $\hat{y}$ chứa m xác suất dự đoán.
- **Tại sao lại quan trọng?** Phần cứng máy tính hiện đại (như GPU) được tối ưu hóa để thực hiện phép toán ma trận này cực kỳ hiệu quả và chớp nhoáng.