

Learning in Logistic and Cross Entropy Loss

CS221 - Natural Language Processing

Duy Dang Phu Anh Mai Quoc Bao Luong Huynh Gia Lac
Tran Nguyen Khai

University of Information Technology, VNU-HCM

March 2026

Giảng viên hướng dẫn: TS. Nguyễn Thị Quý

Learning in Logistic: Mục tiêu

- **Dự đoán:** Mô hình tính toán $\hat{y} = P(y = 1)$, đóng vai trò là giá trị ước lượng cho nhãn y thực tế.
- **Mục tiêu học:** Tìm ra các tham số của mô hình (bao gồm $\mathbf{w}$ và b) sao cho giá trị xác suất $\hat{y}$ càng gần với y thực tế càng tốt:
 - Nếu $y = 1$, ta muốn $\hat{y}$ có giá trị tiến gần đến 1 nhất có thể
 - Nếu $y = 0$, ta muốn $\hat{y}$ có giá trị tiến gần đến 0 nhất có thể

Learning in Logistic: Hai thành phần cốt lõi

Chúng ta quan tâm đến hai thành phần:

- **Hàm mất mát (Loss Function):**
 - Thước đo khoảng cách giữa dự đoán $\hat{y}$ và nhãn chuẩn y .
 - Thường dùng: **Cross-entropy loss**
- **Thuật toán tối ưu (Optimization Algorithm):**
 - Dùng để cập nhật tham số nhằm **tối thiểu hóa** hàm mất mát.
 - Thuật toán tiêu chuẩn: **Gradient Descent**

Learning in Logistic Regression

- Ta sẽ thực hiện các bước xây dựng hàm mất mát thông qua conditional MLE.
- Hay nói cách khác, chúng ta cần chọn tham số $\mathbf{w}$ và $\mathbf{b}$ sao cho tối đa hóa xác suất của các nhãn thật $\mathbf{y}$ khi đã biết dữ liệu $\mathbf{x}$.

Learning in Logistic Regression

- Cụ thể, chúng ta cần học các tham số sao cho xác suất $p(\mathbf{y}|\mathbf{x})$ là lớn nhất có thể.
- Do đầu ra của bài toán là 2 giá trị rời rạc (0 hoặc 1), $p(\mathbf{y}|\mathbf{x})$ tuân theo phân phối Bernoulli, từ đây ta có công thức:

$$p(y|x) = \hat{y}^y (1 - \hat{y})^{1-y} \quad (4.17)$$

- Lấy logarit 2 vế:

$$\begin{aligned} \log p(y|x) &= \log[\hat{y}^y (1 - \hat{y})^{1-y}] \\ &= y \log \hat{y} + (1 - y) \log(1 - \hat{y}) \end{aligned} \quad (4.18)$$

Learning in Logistic Regression

- Đổi dấu để biến thành hàm mất mát:

$$L_{CE} = -\log p(y|x) = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})] \quad (4.19)$$

- Cuối cùng, thay hàm $\hat{y} = \sigma(\mathbf{w} \cdot \mathbf{x} + b)$ vào:

$$L_{CE} = -[y \log \sigma(\mathbf{w} \cdot \mathbf{x} + b) + (1 - y) \log(1 - \sigma(\mathbf{w} \cdot \mathbf{x} + b))] \quad (4.20)$$

Kiểm tra Hàm Cross-Entropy

- **Mục tiêu:** Hàm loss cần có giá trị:
 - **Nhỏ:** Nếu mô hình đưa ra ước lượng gần với nhãn chuẩn.
 - **Lớn:** Nếu mô hình đưa ra ước lượng sai lệch.
- **Trường hợp dự đoán đúng:** Giả sử nhãn chuẩn thực tế là **positive**, tức là $y = 1$
- Mô hình đưa ra dự đoán đúng $\sigma(\mathbf{w} \cdot \mathbf{x} + b) = 0.70$.
- Thay $y = 1$ vào phương trình, ta có:

$$\begin{aligned}L_{CE}(\hat{y}, y) &= -[y \log \sigma(\mathbf{w} \cdot \mathbf{x} + b) + (1 - y) \log(1 - \sigma(\mathbf{w} \cdot \mathbf{x} + b))] \\&= -[\log \sigma(\mathbf{w} \cdot \mathbf{x} + b)] \\&= -\log(0.70) \\&= 0.36\end{aligned}$$

Kiểm tra Hàm Cross-Entropy

- **Trường hợp dự đoán sai:** Giả sử nhãn chuẩn thực tế là **negative**, tức là $y = 0$.
- Lúc này, mô hình đưa ra dự đoán sai $\sigma(\mathbf{w} \cdot \mathbf{x} + b) = 0.70$.
- Khi thay $y = 0$ vào phương trình, ta có:

$$\begin{aligned} L_{CE}(\hat{y}, y) &= -[y \log \sigma(\mathbf{w} \cdot \mathbf{x} + b) + (1 - y) \log(1 - \sigma(\mathbf{w} \cdot \mathbf{x} + b))] \\ &= -[\log(1 - \sigma(\mathbf{w} \cdot \mathbf{x} + b))] \\ &= -\log(0.30) \\ &= 1.2 \end{aligned}$$

- **Kết luận:** Mức mất mát (loss) khi dự đoán đúng (0.36) nhỏ hơn so với dự đoán sai (1.2). Điều này chứng tỏ hàm mất mát đang hoạt động hoàn toàn chính xác.

Tại sao sử dụng Negative Log Probability?

- Nếu $y = 1$: $\hat{y}$ càng cao (gần 1) $\Rightarrow$ phân loại càng tốt.
- Nếu $y = 0$: $1 - \hat{y}$ càng cao (gần 1) $\Rightarrow$ phân loại càng tốt.
- **Tính chất của thang đo loss:** Negative log của $\hat{y}$ hoặc $1 - \hat{y}$ là một thước đo thuận tiện vì nó chạy từ **0** đến ∞ .
- **Tính đảm bảo:** Khi xác suất cho câu trả lời đúng tăng lên đến mức tối đa, xác suất cho câu trả lời sai sẽ bị giảm xuống mức tối thiểu (do tổng của chúng luôn bằng 1).

Tại sao không dùng Mean Squared Error (MSE)?

- **Đồ thị không lồi (Non-convexity):**
 - Hàm MSE kết hợp với Sigmoid tạo ra đồ thị có nhiều cực tiểu địa phương.
 - Hậu quả: Gradient Descent dễ bị kẹt, khó tìm được nghiệm tối ưu toàn cục.
- **Triệt tiêu Gradient (Vanishing Gradient):**
 - Đạo hàm tiến về 0 ngay cả khi mô hình dự đoán sai hoàn toàn (VD: $\hat{y} \approx 0$ nhưng $y = 1$).
 - Hậu quả: Trọng số không được cập nhật, mô hình ngừng học.
- **Bản chất bài toán:**
 - Hồi quy Logistic (phân loại) dựa trên phân phối Bernoulli $\Rightarrow$ Tối ưu bằng **Cross-Entropy**.
 - MSE vốn chỉ phù hợp cho Hồi quy tuyến tính.

Tại sao không dùng Mean Squared Error (MSE)?

- Ta có thể chứng minh tính lồi (convex) của hàm Cross Entropy thông qua ma trận Hessian
- Đạo hàm bậc 1:

$$\begin{aligned}\frac{\partial L}{\partial z} &= \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z} \\ &= -\left(\frac{y}{\hat{y}} + \frac{1-y}{1-\hat{y}}\right) \cdot \hat{y}(1-\hat{y}) \\ &= \hat{y} - y\end{aligned}$$

$$\rightarrow \frac{\partial L}{\partial \mathbf{w}_i} = (\hat{y} - y)\mathbf{x}_i$$

- Đạo hàm bậc 2:

$$\begin{aligned}\frac{\partial^2 L}{\partial \mathbf{w}_i \partial \mathbf{w}_j} &= \frac{\partial}{\partial \mathbf{w}_j} [(\hat{y} - y)\mathbf{x}_i] \\ &= \mathbf{x}_i \cdot \frac{\partial \hat{y}}{\partial z} \cdot \frac{\partial z}{\partial \mathbf{w}_j} = \mathbf{x}_i \cdot [\hat{y}(1-\hat{y})] \cdot \mathbf{x}_j\end{aligned}$$

Tại sao không dùng Mean Squared Error (MSE)?

- Viết dưới dạng ma trận:

$$H = \hat{y}(1 - \hat{y})\mathbf{x}\mathbf{x}^T$$

- Với mọi vector v khác rỗng:

$$\begin{aligned}v^T H v &= v^T [\hat{y}(1 - \hat{y})\mathbf{x}\mathbf{x}^T] v \\&= \hat{y}(1 - \hat{y}) v^T \mathbf{x}\mathbf{x}^T v \\&= \hat{y}(1 - \hat{y}) \cdot (v^T \mathbf{x})(v^T \mathbf{x})^T \geq 0\end{aligned}$$

Vậy hàm trên là hàm lồi.

Tại sao không dùng Mean Squared Error (MSE)?

- Ngược lại, ta chứng minh hàm MSE kết hợp Sigmoid là **không lồi** (non-convex) qua ma trận Hessian.
- Đạo hàm bậc 1 (với $L = \frac{1}{2}(\hat{y} - y)^2$):

$$\begin{aligned}\frac{\partial L}{\partial z} &= \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z} \\ &= (\hat{y} - y) \cdot \hat{y}(1 - \hat{y}) \\ \rightarrow \frac{\partial L}{\partial \mathbf{w}_i} &= (\hat{y} - y)\hat{y}(1 - \hat{y})\mathbf{x}_i\end{aligned}$$

- Đạo hàm bậc 2:

$$\begin{aligned}\frac{\partial^2 L}{\partial \mathbf{w}_i \partial \mathbf{w}_j} &= \frac{\partial}{\partial \mathbf{w}_j} [(\hat{y} - y)\hat{y}(1 - \hat{y})\mathbf{x}_i] \\ &= \mathbf{x}_i \cdot \frac{\partial}{\partial z} [(\hat{y} - y)\hat{y}(1 - \hat{y})] \cdot \frac{\partial z}{\partial \mathbf{w}_j} \\ &= \mathbf{x}_i \cdot \{\hat{y}(1 - \hat{y}) [\hat{y}(1 - \hat{y}) + (\hat{y} - y)(1 - 2\hat{y})]\} \cdot \mathbf{x}_j\end{aligned}$$

Tại sao không dùng Mean Squared Error (MSE)?

- Viết dưới dạng ma trận:

$$H = \underbrace{\hat{y}(1 - \hat{y}) [\hat{y}(1 - \hat{y}) + (\hat{y} - y)(1 - 2\hat{y})]}_{S(\hat{y})} \mathbf{x}\mathbf{x}^T$$

- Với mọi vector $v \neq 0$:

$$\begin{aligned} v^T H v &= v^T [S(\hat{y}) \mathbf{x}\mathbf{x}^T] v \\ &= S(\hat{y}) v^T \mathbf{x}\mathbf{x}^T v \\ &= S(\hat{y}) \cdot (v^T \mathbf{x})(v^T \mathbf{x})^T \end{aligned}$$

- Xét dấu của $v^T H v$: Do $(v^T \mathbf{x})(v^T \mathbf{x})^T \geq 0$, dấu phụ thuộc vào $S(\hat{y})$.
 - Giả sử $y = 1$, ta có $S(\hat{y}) = \hat{y}(1 - \hat{y})(-3\hat{y}^2 + 4\hat{y} - 1)$.
 - Nếu $\hat{y} = 0.1$ (dự đoán sai), $S(0.1) < 0 \rightarrow v^T H v < 0$.
- Vậy ma trận Hessian không bán xác định dương, hàm MSE là **không lồi**.