

Hồi quy Logistic và Phân loại văn bản

Báo cáo nhóm - Chương 4.11 - 4.13

Bùi Huỳnh Tây - 24521589

Đoàn Hồng Bảo - 24520005

Nguyễn Thành Sơn

Nguyễn Quốc Phú - 24520025

Ngày 9 tháng 3 năm 2026

4.11 Kiểm tra ý nghĩa thống kê

- **Mục tiêu:** So sánh hiệu suất giữa bộ phân loại A và B trên cùng một số liệu đo lường (như F_1 hoặc độ chính xác).
- **Kích thước hiệu ứng (Effect size):** Ký hiệu là $\delta(x)$, thể hiện sự khác biệt về hiệu suất trên tập kiểm tra x .

Kích thước hiệu ứng

$$\delta(x) = M(A, x) - M(B, x) \quad (4.45)$$

- **Câu hỏi đặt ra:** Liệu $\delta(x) > 0$ có thực sự chứng minh A tốt hơn B, hay chỉ là do ngẫu nhiên trên tập x cụ thể này?

Giả thuyết Null và P-value

Để kiểm tra, ta thiết lập hai giả thuyết:

$$\begin{aligned} H_0 : \delta(x) &\leq 0 \quad (\text{Null hypothesis - A không tốt hơn B}) \\ H_1 : \delta(x) &> 0 \end{aligned} \tag{4.46}$$

Định nghĩa P-value:

$$P(\delta(X) \geq \delta(x) \mid H_0 \text{ is true}) \tag{4.47}$$

- Là xác suất nhìn thấy sự khác biệt $\delta(x)$ (hoặc lớn hơn) nếu giả định H_0 là đúng.
- **Quy tắc:** Nếu $p < 0.05$ hoặc 0.01 , ta bác bỏ H_0 . Khi đó kết quả được gọi là **có ý nghĩa thống kê** (statistically significant).

Kiểm tra Paired Bootstrap

- NLP thường dùng các bài kiểm tra **không tham số** dựa trên việc lấy mẫu lại (sampling).
- **Bootstrapping:** Tạo ra các tập kiểm tra ảo bằng cách lấy mẫu lặp lại (sampling with replacement) từ tập gốc.

	1	2	3	4	5	6	7	8	9	10	A%	B%	$\delta()$
x	AB	AB	AB	AB	AB	AB	AB	AB	AB	AB	.70	.50	.20
$x^{(1)}$	AB	AB	AB	AB	AB	AB	AB	AB	AB	AB	.60	.60	.00
$x^{(2)}$	AB	AB	AB	AB	AB	AB	AB	AB	AB	AB	.60	.70	-.10
...													
$x^{(b)}$													

Hình: Tạo các mẫu ảo $x^{(i)}$ có kích thước $n = 10$ tương đương tập gốc

- Phương pháp này chỉ giả định rằng mẫu gốc đại diện đúng cho quần thể thực tế.

Cách tính P-value trong Bootstrap

- **Vấn đề:** Tập mẫu ảo được tạo từ tập gốc x vốn đã bị lệch (bias) một khoảng $\delta(x)$.
- **Giải pháp:** Ta cần đếm tần suất $\delta(x^{(i)})$ vượt qua giá trị kỳ vọng là $2\delta(x)$.
$$p\text{-value}(x) = \frac{1}{b} \sum_{i=1}^b \mathbb{I}(\delta(x^{(i)}) \geq 2\delta(x)) \quad (4.48)$$
- b : Số lượng tập mẫu ảo (vd: 10^5). $\mathbb{I}(x)$: Hàm chỉ thị (bằng 1 nếu đúng, 0 nếu sai).

function BOOTSTRAP(test set x , num of samples b) **returns** $p\text{-value}(x)$

Calculate $\delta(x)$ # how much better does algorithm A do than B on x
 $s = 0$

for $i = 1$ **to** b **do**

for $j = 1$ **to** n **do** # Draw a bootstrap sample $x^{(i)}$ of size n

 Select a member of x at random and add it to $x^{(i)}$

 Calculate $\delta(x^{(i)})$ # how much better does algorithm A do than B on $x^{(i)}$

$s \leftarrow s + 1$ **if** $\delta(x^{(i)}) \geq 2\delta(x)$

$p\text{-value}(x) \approx \frac{s}{b}$ # on what % of the b samples did algorithm A beat expectations?

return $p\text{-value}(x)$ # if very few did, our observed δ is probably not accidental

4.12.1. Nghiên cứu của Kiritchenko & Mohammad (2018)

Nghiên cứu của Kiritchenko & Mohammad (2018):

- Thử nghiệm trên **219** hệ thống phân tích cảm xúc.
- Cùng một câu văn, chỉ thay đổi tên riêng:

Thí nghiệm đối chứng

- Câu A: "My name is **Stephanie**, I'm feeling good." (Tên người Mỹ gốc Âu)
- Câu B: "My name is **Shaniqua**, I'm feeling good." (Tên người Mỹ gốc Phi)

Kết quả: Hầu hết các hệ thống gán mức độ tiêu cực cao hơn cho câu B.

4.12.2. Vấn đề

Nhận định quan trọng

"Việc tránh các tác hại từ mô hình ngôn ngữ là **vô cùng quan trọng**. AI không được phép trở thành công cụ duy trì sự bất công."

Tác hại biểu đạt (Representational Harms):

- Xảy ra khi hệ thống làm hạ thấp giá trị của một nhóm xã hội.
- Duy trì và khuếch đại các định kiến tiêu cực có sẵn.

Nghiên cứu của K & M (2018)

- **75% - 86%** hệ thống có định kiến giới tính rõ rệt.
- Chỉ **8% - 24%** hệ thống vượt qua bài kiểm tra định kiến chủng tộc.

4.12.3. Silencing Harms

Một hệ thống được thiết kế để bảo vệ người dùng đôi khi lại gây hại:

- **Nhiệm vụ:** Phát hiện ngôn từ độc hại (Toxicity Detection).
- **Sai lầm:** Gán nhãn sai cho các nhóm yếu thế do định kiến về cảm xúc.

Số liệu từ nghiên cứu K & M (2018)

- Đa số hệ thống mặc định gán điểm **Giận dữ (Anger)** và **Sợ hãi (Fear)** cao hơn cho tên người Mỹ gốc Phi.
- Định kiến chủng tộc phổ biến và nghiêm trọng hơn cả định kiến giới tính.

→ *Hậu quả: Khiến các cộng đồng yếu thế bị im lặng vì các cuộc thảo luận lành mạnh bị bộ lọc AI khóa nhãn nhầm là "độc hại".*

4.12.4. Căn nguyên và Giải pháp

Tại sao AI lại định kiến?

- **Dữ liệu:** Thiếu sự đại diện của các nhóm thiểu số.
- **Con người:** Nhấn dữ liệu mang định kiến chủ quan của người gán.
- **Thuật toán:** Tối ưu hóa "độ chính xác tổng thể" mà bỏ qua các nhóm nhỏ.

Giải pháp: Model Card (Mitchell et al., 2019)

- **Nguồn dữ liệu & Thuật toán:** Làm rõ dữ liệu đến từ đâu và cách mô hình được "dạy" (ví dụ: có sử dụng kỹ thuật khử định kiến không?).
- **Đánh giá đa nhóm:** Không chỉ nhìn vào con số trung bình, mà soi xét sai số trên từng giới tính, sắc tộc, độ tuổi.
- **Phạm vi sử dụng:** Xác định rõ mô hình an toàn ở đâu và **nguy hiểm** ở đâu.

4.12.5. Model Card

1. Định nghĩa: Model Card là một tài liệu chuẩn hóa đi kèm với mô hình machine learning, cung cấp cái nhìn minh bạch về năng lực và hạn chế của nó.

Tại sao lại tốt?

- **Phát hiện điểm mù:** Ép buộc báo cáo sai số trên từng nhóm (giới tính, sắc tộc...).
- **Ngăn chặn lạm dụng:** Nêu rõ mô hình **không** được dùng trong bối cảnh nào.
- **Xây dựng niềm tin:** Người dùng biết rõ "thành phần" và "độ tươi" của dữ liệu.

Tác động: Chuyển từ tư duy "*Mô hình này đúng bao nhiêu ?*" sang "*Mô hình này an toàn và công bằng cho ai?*"

4.13 Model Interpretability

Interpretability là gì?

Interpretability là khả năng con người có thể hiểu được **tại sao một mô hình** lại đưa ra một dự đoán hoặc quyết định cụ thể.

- Trong nhiều bài toán, việc dự đoán đúng là **chưa đủ**.
- Chúng ta cũng cần hiểu **lý do đằng sau** quyết định của mô hình.
- Các mô hình có khả năng diễn giải giúp tăng **tính minh bạch** và **độ tin cậy** của hệ thống.

Interpretability in Logistic Regression

- **Logistic Regression** thường được xem là một mô hình có **tính diễn giải cao**.
- Các đặc trưng đầu vào (**features**) thường được **con người thiết kế**, vì vậy ý nghĩa của chúng tương đối dễ hiểu.

Phân tích thông qua trọng số (w)

Ta có thể đánh giá mức độ ảnh hưởng của một feature bằng cách quan sát **độ lớn của trọng số** gắn với feature đó.

- $|w|$ **lớn**: feature có ảnh hưởng mạnh đến kết quả dự đoán.
- $|w|$ **gần 0**: feature có ảnh hưởng rất nhỏ hoặc gần như không tác động đến quyết định của mô hình.

Statistical Significance of Features

Ngoài việc quan sát độ lớn của trọng số, ta còn có thể sử dụng các **kiểm định thống kê** để xác định một feature có **thực sự quan trọng** đối với mô hình hay không.

Các phép kiểm định phổ biến:

- **Likelihood Ratio Test**
- **Wald Test**

Ý nghĩa

Các kiểm định này giúp xác định liệu hệ số w của một feature có khác 0 một cách **có ý nghĩa thống kê** hay không. Nếu hệ số khác 0 một cách có ý nghĩa, ta có thể kết luận rằng feature đó thực sự có ảnh hưởng đến kết quả dự đoán.

Logistic Regression as an Analytical Tool

Ngoài việc sử dụng để dự đoán, Logistic Regression còn được dùng như một **công cụ phân tích dữ liệu** và **kiểm định giả thuyết**.

Ví dụ trong NLP

Kiểm tra giả thuyết: *Các từ mang nghĩa phủ định (no, not, never) có liên quan đến sentiment tiêu cực hay không?*

Ứng dụng mở rộng:

- Phân tích mối liên hệ giữa các đặc trưng ngôn ngữ và **sentiment**.
- Nghiên cứu các yếu tố ảnh hưởng đến **tỷ lệ tái nhập viện**.
- Phân tích các yếu tố liên quan đến **kết quả bầu cử**.
- Tìm hiểu các yếu tố ảnh hưởng đến **doanh số sản phẩm**.

Controlling Confounding Variables

Khi phân tích tác động của một feature, chúng ta cần kiểm soát các **biến nhiễu (confounding variables)**.

Confounding Variable

Biến nhiễu là những yếu tố khác có thể ảnh hưởng đến kết quả, từ đó làm sai lệch việc đánh giá tác động của feature mà chúng ta đang nghiên cứu.

Ví dụ trong Sentiment Analysis:

Các bài review tiêu cực có thể bị ảnh hưởng bởi nhiều yếu tố khác như:

- *Thể loại phim*
- *Năm sản xuất*
- *Độ dài bài review*

→ Logistic Regression cho phép đưa các biến này vào mô hình để **kiểm soát ảnh hưởng của chúng** và từ đó đánh giá chính xác **tác động độc lập của từng feature**.

Cảm ơn quý thầy cô và các bạn đã
lắng nghe!