

Embeddings

Thành viên nhóm 1:

Bảo Quý Định Tân - 24520028

Lê Văn Thức - 24521748

Lê Phạm Thành Nhân - 24520022

University of Information Technology - VNUHCM

Ngày 17 tháng 3 năm 2026

- **Nguồn gốc (1950s):** Sự giao thoa của hai tư tưởng lớn:
 - **Osgood (1957):** Dùng điểm trong không gian 3 chiều để biểu diễn sắc thái từ.

- **Nguồn gốc (1950s):** Sự giao thoa của hai tư tưởng lớn:
 - **Osgood (1957):** Dùng điểm trong không gian 3 chiều để biểu diễn sắc thái từ.
 - **Firth (1957):** “Xác định ý nghĩa của một từ bằng cách nhìn vào phân phối (distribution) của các từ xung quanh nó”

- **Nguồn gốc (1950s):** Sự giao thoa của hai tư tưởng lớn:
 - **Osgood (1957):** Dùng điểm trong không gian 3 chiều để biểu diễn sắc thái từ.
 - **Firth (1957):** “Xác định ý nghĩa của một từ bằng cách nhìn vào phân phối (distribution) của các từ xung quanh nó”
- **Giả thuyết phân phối (Distributional Hypothesis):** Hai từ xuất hiện trong ngữ cảnh tương tự nhau (các từ lân cận giống nhau) thì có ý nghĩa tương đương nhau.

Giả sử bạn không biết *ongchoi* (*rau muống*) là gì, nhưng thấy nó xuất hiện trong:

- ① *Ongchoi* is delicious sauteed with **garlic**.
- ② *Ongchoi* is superb over **rice**.
- ③ ...*ongchoi* **leaves** with salty sauces...

Giả sử bạn không biết *ongchoi* (*rau muống*) là gì, nhưng thấy nó xuất hiện trong:

- ❶ *Ongchoi* is delicious sauteed with **garlic**.
- ❷ *Ongchoi* is superb over **rice**.
- ❸ ...*ongchoi* **leaves** with salty sauces...

So sánh với các từ đã biết:

- ...**spinach** sauteed with **garlic** over **rice**...
- ...**chard** stems and **leaves** are delicious...

Giả sử bạn không biết *ongchoi* (*rau muống*) là gì, nhưng thấy nó xuất hiện trong:

- ❶ *Ongchoi* is delicious sauteed with **garlic**.
- ❷ *Ongchoi* is superb over **rice**.
- ❸ ...*ongchoi* **leaves** with salty sauces...

So sánh với các từ đã biết:

- ...**spinach** sauteed with **garlic** over **rice**...
- ...**chard** stems and **leaves** are delicious...

Trực giác: Vì *ongchoi* xuất hiện cùng tỏi, cơm, lá... nó có khả năng cao là một loại rau ăn lá giống rau chân vịt (*spinach*).

5.2 Vector semantics

- Ý tưởng: Biểu diễn các từ như một điểm trong không gian nhiều chiều từ phân phối của các từ xung quanh nó.

5.2 Vector semantics

- Ý tưởng: Biểu diễn các từ như một điểm trong không gian nhiều chiều từ phân phối của các từ xung quanh nó.
- Các vector đại diện cho từ gọi là **Embedding**

- Mỗi từ là một điểm trong không gian đa chiều (VD: 200 chiều).

- Mỗi từ là một điểm trong không gian đa chiều (VD: 200 chiều).
- Chiếu không gian này xuống không gian **2 chiều** để hiển thị.




Figure 5.1 A two-dimensional (t-SNE) visualization of 200-dimensional word2vec embeddings for some words close to the word *sweet*, showing that words with similar meanings are nearby in space. Visualization created using the TensorBoard Embedding Projector <https://projector.tensorflow.org/>.

Minh họa : Word2Vec




Figure 5.1 A two-dimensional (t-SNE) visualization of 200-dimensional word2vec embeddings for some words close to the word *sweet*, showing that words with similar meanings are nearby in space. Visualization created using the TensorBoard Embedding Projector <https://projector.tensorflow.org/>.

- Các từ gần giống nhau sẽ ở gần nhau.

- Có thể phân loại sắc thái (Semantics) của các từ chưa xuất hiện trong từ điển.

- Có thể phân loại sắc thái (Semantics) của các từ chưa xuất hiện trong từ điển.
- Học không cần sự giám sát của con người (Supervision).

Cách đơn giản nhất để tạo vector **Embedding** là đếm số lần đồng xuất hiện (co-occurrence).

Cách đơn giản nhất để tạo vector **Embedding** là đếm số lần đồng xuất hiện (co-occurrence).

- **Cửa sổ ngữ cảnh (context window):** Ví dụ ± 4 từ xung quanh.

Cách đơn giản nhất để tạo vector **Embedding** là đếm số lần đồng xuất hiện (co-occurrence).

- **Cửa sổ ngữ cảnh (context window):** Ví dụ ± 4 từ xung quanh.
- **Ma trận $|V| \times |V|$:** Mỗi hàng là một từ mục tiêu, mỗi cột là một từ ngữ cảnh.

Cách đơn giản nhất để tạo vector **Embedding** là đếm số lần đồng xuất hiện (co-occurrence).

- **Cửa sổ ngữ cảnh (context window):** Ví dụ ± 4 từ xung quanh.
- **Ma trận $|V| \times |V|$:** Mỗi hàng là một từ mục tiêu, mỗi cột là một từ ngữ cảnh.
- Mỗi ô là **tổng** số lần từ ngữ cảnh (neighbor word) xuất hiện trong phạm vi cửa sổ ngữ cảnh của từ mục tiêu.

Ví dụ về Ma trận đồng xuất hiện

Ngữ cảnh (Context window ± 4):

is traditionally followed by
often mixed, such as
computer peripherals and personal
a computer. This includes

cherry pie, a traditional dessert
strawberry rhubarb pie. Apple pie
digital assistants. These devices usually
information available on the internet

Ví dụ về Ma trận đồng xuất hiện

Ngữ cảnh (Context window ± 4):

is traditionally followed by	cherry pie, a traditional dessert
often mixed, such as	strawberry rhubarb pie. Apple pie
computer peripherals and personal	digital assistants. These devices usually
a computer. This includes	information available on the internet

Bảng 5.2: Ví dụ ma trận đồng xuất hiện rút gọn

	a	computer	pie
cherry	1	0	1
strawberry	0	0	1
digital	0	1	0
information	1	1	0

Vector Space & Dimensionality

- Mỗi từ được biểu diễn bởi **vector** hàng tương ứng trong ma trận.

- Mỗi từ được biểu diễn bởi **vector** hàng tương ứng trong ma trận.

Trực giác hình học

Từ *digital* và *information* sẽ có giá trị cao ở chiều “computer”, khiến chúng nằm gần nhau trong không gian vector.

- Mỗi từ được biểu diễn bởi **vector** hàng tương ứng trong ma trận.

Trực giác hình học

Từ *digital* và *information* sẽ có giá trị cao ở chiều “computer”, khiến chúng nằm gần nhau trong không gian vector.

Bảng 5.2: Ví dụ ma trận đồng xuất hiện rút gọn

	a	computer	pie
cherry	1	0	1
strawberry	0	0	1
digital	0	1	0
information	1	1	0

Lưu ý: Tính toán trên toàn bộ Corpus

- Trong thực tế, một từ mục tiêu (*target word*) xuất hiện rất nhiều lần.

Lưu ý: Tính toán trên toàn bộ Corpus

- Trong thực tế, một từ mục tiêu (*target word*) xuất hiện rất nhiều lần.
- Ma trận đồng xuất hiện là kết quả **cộng dồn** từ tất cả các cửa sổ ngữ cảnh trong tập dữ liệu.

Lưu ý: Tính toán trên toàn bộ Corpus

- Trong thực tế, một từ mục tiêu (*target word*) xuất hiện rất nhiều lần.
- Ma trận đồng xuất hiện là kết quả **cộng dồn** từ tất cả các cửa sổ ngữ cảnh trong tập dữ liệu.

Ví dụ nhỏ: Xét Corpus gồm 2 câu (Window size ± 1):

- 1 Câu 1: "...ăn **cherry** pie rất ngon ..."
- 2 Câu 2: "...thích **cherry** pie mùa hè ..."

Lưu ý: Tính toán trên toàn bộ Corpus

- Trong thực tế, một từ mục tiêu (*target word*) xuất hiện rất nhiều lần.
- Ma trận đồng xuất hiện là kết quả **cộng dồn** từ tất cả các cửa sổ ngữ cảnh trong tập dữ liệu.

Ví dụ nhỏ: Xét Corpus gồm 2 câu (Window size ± 1):

- 1 Câu 1: "...ăn **cherry** pie rất ngon ..."
- 2 Câu 2: "...thích **cherry** pie mùa hè ..."

Quá trình cộng dồn cho cặp (cherry, pie):

Vị trí	Ngữ cảnh quan sát được	Giá trị cộng thêm
Câu 1	(cherry , <u>pie</u>) xuất hiện 1 lần	+1
Câu 2	(cherry , <u>pie</u>) xuất hiện 1 lần	+1
Tổng kết	Vector cherry tại chiều pie	2

	aardvark	...	computer	data	result	pie	sugar	...
cherry	0	...	2	8	9	442	25	...
strawberry	0	...	0	0	1	60	19	...
digital	0	...	1670	1683	85	5	4	...
information	0	...	3325	3982	378	5	13	...

Figure 5.3 Co-occurrence vectors for four words in the Wikipedia corpus, showing six of the dimensions (hand-picked for pedagogical purposes). The vector for *digital* is outlined in red. Note that a real vector would have vastly more dimensions and thus be much sparser, i.e. would have zero values in most dimensions.




Figure 5.4 A spatial visualization of word vectors for *digital* and *information*, showing just two of the dimensions, corresponding to the words *data* and *computer*.

Đặc điểm của Vector Semantics

- Số chiều (Dimensionality) $|V|$:
 - Thường dao động từ 10,000 đến 50,000 từ.

Đặc điểm của Vector Semantics

- **Số chiều (Dimensionality) $|V|$:**
 - Thường dao động từ **10,000 đến 50,000** từ.
 - Chọn lọc từ những từ xuất hiện thường xuyên nhất trong corpus.

- **Số chiều (Dimensionality) $|V|$:**

- Thường dao động từ **10,000 đến 50,000** từ.
- Chọn lọc từ những từ xuất hiện thường xuyên nhất trong corpus.
- *Lưu ý:* Giữ lại quá 50,000 từ thường không mang lại thêm nhiều giá trị thông tin.

Đặc điểm của Vector Semantics

- **Số chiều (Dimensionality) $|V|$:**

- Thường dao động từ **10,000 đến 50,000** từ.
- Chọn lọc từ những từ xuất hiện thường xuyên nhất trong corpus.
- *Lưu ý*: Giữ lại quá 50,000 từ thường không mang lại thêm nhiều giá trị thông tin.

- **Vector thưa (Sparse Vectors):**

- Hầu hết các con số trong ma trận là **0**.

Đặc điểm của Vector Semantics

- **Số chiều (Dimensionality) $|V|$:**

- Thường dao động từ **10,000 đến 50,000** từ.
- Chọn lọc từ những từ xuất hiện thường xuyên nhất trong corpus.
- *Lưu ý*: Giữ lại quá 50,000 từ thường không mang lại thêm nhiều giá trị thông tin.

- **Vector thưa (Sparse Vectors):**

- Hầu hết các con số trong ma trận là **0**.
- Cần các thuật toán hiệu quả để lưu trữ và tính toán với ma trận thưa.

Đặc điểm của Vector Semantics

- **Số chiều (Dimensionality) $|V|$:**

- Thường dao động từ **10,000 đến 50,000** từ.
- Chọn lọc từ những từ xuất hiện thường xuyên nhất trong corpus.
- *Lưu ý*: Giữ lại quá 50,000 từ thường không mang lại thêm nhiều giá trị thông tin.

- **Vector thưa (Sparse Vectors):**

- Hầu hết các con số trong ma trận là **0**.
- Cần các thuật toán hiệu quả để lưu trữ và tính toán với ma trận thưa.

Gán trọng số (Weighting Functions)

Thay vì chỉ đếm số lần xuất hiện thuần túy, ta có thể áp dụng các hàm trọng số để làm nổi bật ý nghĩa:

- **TF-IDF**: Phương pháp phổ biến nhất (sẽ học kỹ ở Chương 11).