

Embeddings

Thành viên nhóm 1:

Bảo Quý Định Tân - 24520028

Lê Văn Thức - 24521748

Lê Phạm Thành Nhân - 24520022

University of Information Technology - VNUHCM

Ngày 16 tháng 3 năm 2026

5.4 Cosine for measuring similarity

- Để đo độ tương đồng giữa hai từ v và w , ta cần một **độ đo** (metric) áp dụng cho hai vector đại diện (**cùng kích thước**) của chúng.

5.4 Cosine for measuring similarity

- Để đo độ tương đồng giữa hai từ v và w , ta cần một **độ đo** (metric) áp dụng cho hai vector đại diện (**cùng kích thước**) của chúng.
- Sử dụng **tích vô hướng** (dot product / inner product) trong đại số tuyến tính:

5.4 Cosine for measuring similarity

- Để đo độ tương đồng giữa hai từ v và w , ta cần một **độ đo** (metric) áp dụng cho hai vector đại diện (**cùng kích thước**) của chúng.
- Sử dụng **tích vô hướng** (dot product / inner product) trong đại số tuyến tính:

5.4 Cosine for measuring similarity

- Để đo độ tương đồng giữa hai từ v và w , ta cần một **độ đo** (metric) áp dụng cho hai vector đại diện (**cùng kích thước**) của chúng.
- Sử dụng **tích vô hướng** (dot product / inner product) trong đại số tuyến tính:

Dot Product

$$\text{dot product}(\mathbf{v}, \mathbf{w}) = \mathbf{v} \cdot \mathbf{w} = \sum_{i=1}^N v_i w_i = v_1 w_1 + v_2 w_2 + \cdots + v_N w_N \quad (5.7)$$

5.4 Cosine for measuring similarity

- Để đo độ tương đồng giữa hai từ v và w , ta cần một **độ đo** (metric) áp dụng cho hai vector đại diện (**cùng kích thước**) của chúng.
- Sử dụng **tích vô hướng** (dot product / inner product) trong đại số tuyến tính:

Dot Product

$$\text{dot product}(\mathbf{v}, \mathbf{w}) = \mathbf{v} \cdot \mathbf{w} = \sum_{i=1}^N v_i w_i = v_1 w_1 + v_2 w_2 + \cdots + v_N w_N \quad (5.7)$$

- Tích vô hướng có giá trị **cao** khi hai vector cùng có giá trị **lớn** trong cùng các chiều.

5.4 Cosine for measuring similarity

- Để đo độ tương đồng giữa hai từ v và w , ta cần một **độ đo** (metric) áp dụng cho hai vector đại diện (**cùng kích thước**) của chúng.
- Sử dụng **tích vô hướng** (dot product / inner product) trong đại số tuyến tính:

Dot Product

$$\text{dot product}(\mathbf{v}, \mathbf{w}) = \mathbf{v} \cdot \mathbf{w} = \sum_{i=1}^N v_i w_i = v_1 w_1 + v_2 w_2 + \cdots + v_N w_N \quad (5.7)$$

- Tích vô hướng có giá trị **cao** khi hai vector cùng có giá trị **lớn** trong cùng các chiều.
- Nếu hai vector **trực giao** (orthogonal), tích vô hướng bằng **0**, thể hiện sự khác biệt hoàn toàn (strong dissimilarity).

Vấn đề của Tích vô hướng & Chiều dài vector

Vector Length

$$|\mathbf{v}| = \sqrt{\sum_{i=1}^N v_i^2} \quad (5.8)$$

- **Vấn đề**: Tích vô hướng thuần túy (raw dot product) **thiên vị các vector dài** (giá trị các thành phần lớn).

Vấn đề của Tích vô hướng & Chiều dài vector

Vector Length

$$|\mathbf{v}| = \sqrt{\sum_{i=1}^N v_i^2} \quad (5.8)$$

- **Vấn đề:** Tích vô hướng thuần túy (raw dot product) **thiên vị các vector dài** (giá trị các thành phần lớn).
- Những từ xuất hiện **thường xuyên** (frequent words).
 - ⇒ Thường xuất hiện cùng với nhiều từ khác.
 - ⇒ Giá trị thành phần v_i **lớn** (higher co-occurrence values) / **vector dài**.
 - ⇒ **Tích vô hướng lớn**.

Vấn đề của Tích vô hướng & Chiều dài vector

Vector Length

$$|\mathbf{v}| = \sqrt{\sum_{i=1}^N v_i^2} \quad (5.8)$$

- **Vấn đề:** Tích vô hướng thuần túy (raw dot product) **thiên vị các vector dài** (giá trị các thành phần lớn).
- Những từ xuất hiện **thường xuyên** (frequent words).
 - ⇒ Thường xuất hiện cùng với nhiều từ khác.
 - ⇒ Giá trị thành phần v_i **lớn** (higher co-occurrence values) / **vector dài**.
 - ⇒ **Tích vô hướng lớn**.

Vấn đề của Tích vô hướng & Chiều dài vector

Vector Length

$$|\mathbf{v}| = \sqrt{\sum_{i=1}^N v_i^2} \quad (5.8)$$

- **Vấn đề:** Tích vô hướng thuần túy (raw dot product) **thiên vị các vector dài** (giá trị các thành phần lớn).
- Những từ xuất hiện **thường xuyên** (frequent words).
 - ⇒ Thường xuất hiện cùng với nhiều từ khác.
 - ⇒ Giá trị thành phần v_i **lớn** (higher co-occurrence values) / **vector dài**.
 - ⇒ **Tích vô hướng lớn**.

$$\text{dot product}(\mathbf{v}, \mathbf{w}) = \mathbf{v} \cdot \mathbf{w} = \sum_{i=1}^N v_i w_i = v_1 w_1 + v_2 w_2 + \cdots + v_N w_N \quad (5.7)$$

Ví dụ: Vấn đề của Tích vô hướng (Raw Dot Product)

- Giả sử ta có các vector đếm tần suất đồng xuất hiện (co-occurrence) dựa trên 4 từ ngữ cảnh: *[drive, engine, road, wheel]*.

Ví dụ: Vấn đề của Tích vô hướng (Raw Dot Product)

- Giả sử ta có các vector đếm tần suất đồng xuất hiện (co-occurrence) dựa trên 4 từ ngữ cảnh: *[drive, engine, road, wheel]*.
- **car** (từ phổ biến): $\mathbf{v}_{\text{car}} = [20, 15, 30, 25]$

Ví dụ: Vấn đề của Tích vô hướng (Raw Dot Product)

- Giả sử ta có các vector đếm tần suất đồng xuất hiện (co-occurrence) dựa trên 4 từ ngữ cảnh: *[drive, engine, road, wheel]*.
- **car** (từ phổ biến): $\mathbf{v}_{\text{car}} = [20, 15, 30, 25]$
- **automobile** (đồng nghĩa nhưng hiếm): $\mathbf{v}_{\text{auto}} = [2, 1, 3, 2]$

Ví dụ: Vấn đề của Tích vô hướng (Raw Dot Product)

- Giả sử ta có các vector đếm tần suất đồng xuất hiện (co-occurrence) dựa trên 4 từ ngữ cảnh: *[drive, engine, road, wheel]*.
- **car** (từ phổ biến): $\mathbf{v}_{\text{car}} = [20, 15, 30, 25]$
- **automobile** (đồng nghĩa nhưng hiếm): $\mathbf{v}_{\text{auto}} = [2, 1, 3, 2]$
- **bicycle** (khác nghĩa, phổ biến): $\mathbf{v}_{\text{bike}} = [15, 0, 25, 10]$

Ví dụ: Vấn đề của Tích vô hướng (Raw Dot Product)

- Giả sử ta có các vector đếm tần suất đồng xuất hiện (co-occurrence) dựa trên 4 từ ngữ cảnh: *[drive, engine, road, wheel]*.
- **car** (từ phổ biến): $\mathbf{v}_{\text{car}} = [20, 15, 30, 25]$
- **automobile** (đồng nghĩa nhưng hiếm): $\mathbf{v}_{\text{auto}} = [2, 1, 3, 2]$
- **bicycle** (khác nghĩa, phổ biến): $\mathbf{v}_{\text{bike}} = [15, 0, 25, 10]$

Ví dụ: Vấn đề của Tích vô hướng (Raw Dot Product)

- Giả sử ta có các vector đếm tần suất đồng xuất hiện (co-occurrence) dựa trên 4 từ ngữ cảnh: *[drive, engine, road, wheel]*.
- **car** (từ phổ biến): $\mathbf{v}_{\text{car}} = [20, 15, 30, 25]$
- **automobile** (đồng nghĩa nhưng hiếm): $\mathbf{v}_{\text{auto}} = [2, 1, 3, 2]$
- **bicycle** (khác nghĩa, phổ biến): $\mathbf{v}_{\text{bike}} = [15, 0, 25, 10]$

$$\mathbf{v}_{\text{car}} \cdot \mathbf{v}_{\text{auto}} = (20 \times 2) + (15 \times 1) + (30 \times 3) + (25 \times 2) = \mathbf{195}$$

$$\mathbf{v}_{\text{car}} \cdot \mathbf{v}_{\text{bike}} = (20 \times 15) + (15 \times 0) + (30 \times 25) + (25 \times 10) = \mathbf{1300}$$

Ví dụ: Vấn đề của Tích vô hướng (Raw Dot Product)

- Giả sử ta có các vector đếm tần suất đồng xuất hiện (co-occurrence) dựa trên 4 từ ngữ cảnh: *[drive, engine, road, wheel]*.
- **car** (từ phổ biến): $\mathbf{v}_{\text{car}} = [20, 15, 30, 25]$
- **automobile** (đồng nghĩa nhưng hiếm): $\mathbf{v}_{\text{auto}} = [2, 1, 3, 2]$
- **bicycle** (khác nghĩa, phổ biến): $\mathbf{v}_{\text{bike}} = [15, 0, 25, 10]$

$$\mathbf{v}_{\text{car}} \cdot \mathbf{v}_{\text{auto}} = (20 \times 2) + (15 \times 1) + (30 \times 3) + (25 \times 2) = \mathbf{195}$$

$$\mathbf{v}_{\text{car}} \cdot \mathbf{v}_{\text{bike}} = (20 \times 15) + (15 \times 0) + (30 \times 25) + (25 \times 10) = \mathbf{1300}$$

Nhận xét

Tích vô hướng cho rằng **car** giống **bicycle** hơn **automobile** ($1300 > 195$).

Vấn đề của Tích vô hướng & Chiều dài vector

- Nên ta muốn có một **độ đo sự tương đồng** (similarity metric) có thể đo được sự tương đồng giữa hai từ mà **không bị ảnh hưởng bởi tần suất xuất hiện**.

Vấn đề của Tích vô hướng & Chiều dài vector

- Nên ta muốn có một **độ đo sự tương đồng** (similarity metric) có thể đo được sự tương đồng giữa hai từ mà **không bị ảnh hưởng bởi tần suất xuất hiện**.
- Ta chia tích vô hướng cho tích chiều dài của hai vector để có **normalized dot product**.

Vấn đề của Tích vô hướng & Chiều dài vector

- Nên ta muốn có một **độ đo sự tương đồng** (similarity metric) có thể đo được sự tương đồng giữa hai từ mà **không bị ảnh hưởng bởi tần suất xuất hiện**.
- Ta chia tích vô hướng cho tích chiều dài của hai vector để có **normalized dot product**.
- Việc chuẩn hóa tích vô hướng bằng chiều dài vector chính là việc tính **cosine** của góc θ giữa hai vector **a** và **b**:

$$\frac{\mathbf{a} \cdot \mathbf{b}}{|\mathbf{a}||\mathbf{b}|} = \cos \theta \quad (5.9)$$

- Công thức tính **độ tương đồng Cosine** giữa hai vector v và w :

$$\text{cosine}(\mathbf{v}, \mathbf{w}) = \frac{\mathbf{v} \cdot \mathbf{w}}{|\mathbf{v}| |\mathbf{w}|} = \frac{\sum_{i=1}^N v_i w_i}{\sqrt{\sum_{i=1}^N v_i^2} \sqrt{\sum_{i=1}^N w_i^2}} \quad (5.10)$$

Độ đo Cosine (Cosine Similarity)

- Công thức tính **độ tương đồng Cosine** giữa hai vector v và w :

$$\text{cosine}(\mathbf{v}, \mathbf{w}) = \frac{\mathbf{v} \cdot \mathbf{w}}{|\mathbf{v}| |\mathbf{w}|} = \frac{\sum_{i=1}^N v_i w_i}{\sqrt{\sum_{i=1}^N v_i^2} \sqrt{\sum_{i=1}^N w_i^2}} \quad (5.10)$$

- Cosine nhận giá trị từ 1 (cùng hướng) đến -1 (ngược hướng). Tuy nhiên, vì tần suất đếm từ luôn không âm, giá trị cosine trong trường hợp này chỉ nằm trong khoảng từ 0 đến 1.

Giải pháp: Chuẩn hóa bằng Cosine Similarity

- 4 từ ngữ cảnh: *[drive, engine, road, wheel]*.
- **car** (từ phổ biến): $\mathbf{v}_{\text{car}} = [20, 15, 30, 25]$
- **automobile** (đồng nghĩa nhưng hiếm): $\mathbf{v}_{\text{auto}} = [2, 1, 3, 2]$
- **bicycle** (khác nghĩa, phổ biến): $\mathbf{v}_{\text{bike}} = [15, 0, 25, 10]$

Giải pháp: Chuẩn hóa bằng Cosine Similarity

- 4 từ ngữ cảnh: *[drive, engine, road, wheel]*.
- **car** (từ phổ biến): $\mathbf{v}_{\text{car}} = [20, 15, 30, 25]$
- **automobile** (đồng nghĩa nhưng hiếm): $\mathbf{v}_{\text{auto}} = [2, 1, 3, 2]$
- **bicycle** (khác nghĩa, phổ biến): $\mathbf{v}_{\text{bike}} = [15, 0, 25, 10]$

Tính toán lại với Cosine

Tính chiều dài vector: $|\mathbf{v}_{\text{car}}| \approx 46.4$, $|\mathbf{v}_{\text{auto}}| \approx 4.2$, $|\mathbf{v}_{\text{bike}}| \approx 30.8$

$$\cos(\text{car}, \text{auto}) = \frac{195}{46.4 \times 4.2} \approx \mathbf{0.99}$$

$$\cos(\text{car}, \text{bike}) = \frac{1300}{46.4 \times 30.8} \approx \mathbf{0.91}$$

Giải pháp: Chuẩn hóa bằng Cosine Similarity

- 4 từ ngữ cảnh: *[drive, engine, road, wheel]*.
- **car** (từ phổ biến): $\mathbf{v}_{\text{car}} = [20, 15, 30, 25]$
- **automobile** (đồng nghĩa nhưng hiếm): $\mathbf{v}_{\text{auto}} = [2, 1, 3, 2]$
- **bicycle** (khác nghĩa, phổ biến): $\mathbf{v}_{\text{bike}} = [15, 0, 25, 10]$

Tính toán lại với Cosine

Tính chiều dài vector: $|\mathbf{v}_{\text{car}}| \approx 46.4$, $|\mathbf{v}_{\text{auto}}| \approx 4.2$, $|\mathbf{v}_{\text{bike}}| \approx 30.8$

$$\cos(\text{car}, \text{auto}) = \frac{195}{46.4 \times 4.2} \approx \mathbf{0.99}$$

$$\cos(\text{car}, \text{bike}) = \frac{1300}{46.4 \times 30.8} \approx \mathbf{0.91}$$

Kết luận

Bây giờ $\cos(\text{car}, \text{auto}) > \cos(\text{car}, \text{bike})$. Phản ánh chính xác sự tương đồng về ngữ nghĩa (góc giữa các vector).

Mở rộng: Vector đơn vị (Unit Vector)

- Trong một số ứng dụng, ta **tiền chuẩn hóa** (pre-normalize) mỗi vector **a** bằng cách chia nó cho chiều dài của chính nó $|\mathbf{a}|$:

$$\hat{\mathbf{a}} = \frac{\mathbf{a}}{|\mathbf{a}|}$$

Mở rộng: Vector đơn vị (Unit Vector)

- Trong một số ứng dụng, ta **tiền chuẩn hóa** (pre-normalize) mỗi vector **a** bằng cách chia nó cho chiều dài của chính nó $|\mathbf{a}|$:

$$\hat{\mathbf{a}} = \frac{\mathbf{a}}{|\mathbf{a}|}$$

- Việc này tạo ra một **vector đơn vị** (unit vector) có chiều dài bằng 1.

Mở rộng: Vector đơn vị (Unit Vector)

- Trong một số ứng dụng, ta **tiền chuẩn hóa** (pre-normalize) mỗi vector **a** bằng cách chia nó cho chiều dài của chính nó $|\mathbf{a}|$:

$$\hat{\mathbf{a}} = \frac{\mathbf{a}}{|\mathbf{a}|}$$

- Việc này tạo ra một **vector đơn vị** (unit vector) có chiều dài bằng 1.
- Đặc điểm:** Đối với các vector đơn vị, **tích vô hướng** (dot product) có giá trị hoàn toàn bằng với **cosine**:

$$\text{cosine}(\hat{\mathbf{a}}, \hat{\mathbf{b}}) = \frac{\hat{\mathbf{a}} \cdot \hat{\mathbf{b}}}{|\hat{\mathbf{a}}||\hat{\mathbf{b}}|} = \frac{\hat{\mathbf{a}} \cdot \hat{\mathbf{b}}}{1 \times 1} = \hat{\mathbf{a}} \cdot \hat{\mathbf{b}}$$

Ví dụ tính toán Cosine Similarity

	pie	data	computer
cherry	442	8	2
digital	5	1683	1670
information	5	3982	3325

Ví dụ tính toán Cosine Similarity

	pie	data	computer
cherry	442	8	2
digital	5	1683	1670
information	5	3982	3325

Tính toán độ tương đồng giữa *information* với *cherry* và *digital*:

Ví dụ tính toán Cosine Similarity

	pie	data	computer
cherry	442	8	2
digital	5	1683	1670
information	5	3982	3325

Tính toán độ tương đồng giữa *information* với *cherry* và *digital*:

$$\cos(\text{cherry}, \text{info}) = \frac{442 \cdot 5 + 8 \cdot 3982 + 2 \cdot 3325}{\sqrt{442^2 + 8^2 + 2^2} \sqrt{5^2 + 3982^2 + 3325^2}} \approx 0.018$$

$$\cos(\text{digital}, \text{info}) = \frac{5 \cdot 5 + 1683 \cdot 3982 + 1670 \cdot 3325}{\sqrt{5^2 + 1683^2 + 1670^2} \sqrt{5^2 + 3982^2 + 3325^2}} \approx 0.996$$

Ví dụ tính toán Cosine Similarity

	pie	data	computer
cherry	442	8	2
digital	5	1683	1670
information	5	3982	3325

Tính toán độ tương đồng giữa *information* với *cherry* và *digital*:

$$\cos(\text{cherry}, \text{info}) = \frac{442 \cdot 5 + 8 \cdot 3982 + 2 \cdot 3325}{\sqrt{442^2 + 8^2 + 2^2} \sqrt{5^2 + 3982^2 + 3325^2}} \approx 0.018$$
$$\cos(\text{digital}, \text{info}) = \frac{5 \cdot 5 + 1683 \cdot 3982 + 1670 \cdot 3325}{\sqrt{5^2 + 1683^2 + 1670^2} \sqrt{5^2 + 3982^2 + 3325^2}} \approx 0.996$$

- **Kết luận:** Mô hình cho thấy *information* gần nghĩa với *digital* hơn rất nhiều so với *cherry*.




Figure 5.5 A (rough) graphical demonstration of cosine similarity, showing vectors for three words (*cherry*, *digital*, and *information*) in the two dimensional space defined by counts of the words *computer* and *pie* nearby. The figure doesn't show the cosine, but it highlights the angles; note that the angle between *digital* and *information* is smaller than the angle between *cherry* and *information*. When two vectors are more similar, the cosine is larger but the angle is smaller; the cosine has its maximum (1) when the angle between two vectors is smallest (0°); the cosine of all other angles is less than 1.