

Câu 1 Kiến trúc mạng nào sau đây là kiến trúc sinh văn bản (generative models), xử lý thông tin từ trái sang phải và được sử dụng để tạo ra các mô hình như GPT, Claude, Llama?

- A. Encoder
- B. Decoder
- C. Encoder-Decoder
- D. Masked Language Models

Đáp án: B

Câu 2: Mô hình kiến trúc Encoder (như họ BERT) thường KHÔNG được sử dụng cho mục đích nào sau đây?

- A. Sinh văn bản mới (Generative text).
- B. Phân loại cảm xúc (Sentiment classification).
- C. Phân loại chủ đề (Topic classification).
- D. Tạo biểu diễn vector (vector representation) cho mỗi token.

Đáp án: A

Câu 3: Khái niệm "In-context learning" (Học theo ngữ cảnh) thông qua prompt được định nghĩa như thế nào?

- A. Là quá trình cập nhật các trọng số (weights) của mô hình bằng phương pháp gradient descent.
- B. Là quá trình pretraining mô hình trên một lượng dữ liệu văn bản khổng lồ.
- C. Là sự cải thiện hiệu suất thông qua các ví dụ trong prompt, nhưng không làm thay đổi các tham số (parameters/weights) gốc của mô hình.
- D. Là quá trình thay thế kiến trúc Decoder thành Encoder để phù hợp với ngữ cảnh.

Đáp án: C

Câu 4: Một người dùng đưa ra prompt cho mô hình như sau: "Dịch sang tiếng Pháp. Apple -> Pomme. Cat -> Chat. Dog -> ". Việc cung cấp sẵn các ví dụ mẫu như thế này được gọi là kỹ thuật gì?

- A. Zero-shot prompting
- B. Few-shot prompting
- C. System prompting
- D. Instruction-tuning

Đáp án: B

Câu 5: Giả sử mô hình nhận prompt: 'Tình cảm của câu "Tôi thích Jackie Chan" là:'. Mô hình tính toán xác suất từ tiếp theo như sau: $P(\text{tích cực} \mid \text{prompt}) = 0.8$, $P(\text{tiêu cực} \mid \text{prompt}) = 0.15$, $P(\text{trung tính} \mid \text{prompt}) = 0.05$. Nếu dùng giải mã tham lam (greedy decoding), token nào sẽ được sinh ra?

- A. tích cực
- B. tiêu cực
- C. trung tính
- D. tôi

Đáp án: A

Câu 6: Lý do chính khiến phương pháp "Greedy decoding" (Giải mã tham lam) không được sử dụng phổ biến trong sinh văn bản của LLM (Large Language Models) là gì?

- A. Vì nó đòi hỏi sức mạnh tính toán quá lớn.
- B. Vì nó thường chọn những từ có xác suất rất thấp.
- C. Vì nó chọn từ có xác suất cao nhất ở mỗi bước, dẫn đến văn bản tạo ra mang tính tắt định, chung chung và hay lặp đi lặp lại.
- D. Vì nó sinh ra quá nhiều từ kỳ lạ, khó hiểu.

Đáp án: C

Câu 7: Điều gì sẽ xảy ra khi ta thiết lập tham số Temperature (τ) tiến dần về 0 trong quá trình Temperature sampling?

- A. Phân phối xác suất trở nên đồng đều cho tất cả các từ trong từ vựng.
- B. Phương pháp sinh văn bản sẽ tiến gần đến Greedy decoding.
- C. Mô hình sẽ chọn từ một cách hoàn toàn ngẫu nhiên.
- D. Hàm softmax sẽ bị lỗi chia cho 0.

Đáp án: B

Câu 8: Giả sử mạng neural xuất ra một vector điểm số (logits) $u=[1.5, 0.8, -0.2]$. Dựa vào công thức $y=\text{softmax}(u)$, phát biểu nào sau đây là ĐÚNG về vector xác suất y nhận được?

- A. Từ có logit là -0.2 sẽ có xác suất bằng số âm.

- B. Tổng các xác suất trong vector y sẽ lớn hơn 1.
- C. Từ có logit 1.5 sẽ có giá trị xác suất lớn nhất
- D. Khoảng cách xác suất giữa từ đầu tiên và từ thứ hai bằng đúng 0.7 (1.5–0.8).

Đáp án: C

Câu 9: Cho vector logits ban đầu của mô hình là $u = [2.0, 0.5, 0.0]$. Nếu áp dụng kỹ thuật temperature sampling với $\tau = 0.4$, vector logits mới trước khi đưa vào hàm softmax sẽ là gì?

- A. $[0.8, 0.2, 0.0]$
- B. $[1.6, 0.1, -0.4]$
- C. $[5.0, 1.25, 0.0]$
- D. $[1.0, 0.25, -0.4]$

Đáp án: C

Câu 10: Giả sử token A có điểm logit cao hơn token B đôi chút. Nếu ta thay vì dùng $\tau = 1$ (softmax chuẩn) mà tăng τ lên một giá trị lớn (ví dụ $\tau = 10$), hiện tượng gì sẽ xảy ra với phân phối xác suất?

- A. Tổng các xác suất sẽ lớn hơn 1
- B. Xác suất của token B sẽ lớn hơn xác suất của token A
- C. Token A sẽ có xác suất gần bằng 1 và token B sẽ có xác suất gần bằng 0
- D. Xác suất của token A và token B sẽ xấp xỉ bằng nhau

Đáp án: D