

Chapter 7 – Large Language Models

Sections 7.5, 7.6, 7.7, 7.8

Group 8

Dương Hoàng Việt Hồ Hữu Tây Phạm Ngọc Thọ Lê Thiên Quân

Môn học: CS221

Trường Đại học Công nghệ Thông tin, DHQG-HCM

Ngày 31 tháng 3 năm 2026

Mục tiêu của bài thuyết trình

- **Section 7.5:** mô tả pipeline huấn luyện, objective của pretraining, dữ liệu pretraining và finetuning.
- **Section 7.6:** đi từ xác suất của whole text tới log likelihood, perplexity và downstream evaluation.
- **Section 7.7:** phân loại các rủi ro chính của LLM và các hướng giảm thiểu có cơ sở trong sách.
- **Section 7.8:** nén lại toàn bộ chương thành các điểm nhớ cốt lõi.

- 1 7.5 Training Large Language Models
- 2 7.6 Evaluating Large Language Models
- 3 7.7 Ethical and Safety Issues with Language Models
- 4 7.8 Summary

7.5 Quy trình huấn luyện mô hình ngôn ngữ lớn (LLMs)

Để xây dựng một mô hình ngôn ngữ hiện đại, quy trình huấn luyện thường trải qua **3 giai đoạn chiến lược**:

- ❶ **Pretraining (Tiền huấn luyện)**: Xây dựng nền tảng kiến thức từ dữ liệu khổng lồ.
- ❷ **Instruction Tuning (SFT)**: Dạy mô hình cách tuân thủ mệnh lệnh và phản hồi người dùng.
- ❸ **Alignment (Căn chỉnh)**: Tối ưu hóa sự hữu ích và đảm bảo tính an toàn (Helpful Harmless).

Nguyên lý chung

Mỗi giai đoạn sử dụng các loại dữ liệu và phương pháp tối ưu hóa khác nhau để đạt được mục tiêu cụ thể.

Giai đoạn 1: Pretraining (Tiền huấn luyện)

Mục tiêu: Huấn luyện mô hình dự đoán từ tiếp theo (next-word prediction) một cách tuần tự.

- **Dữ liệu:** Tập hợp văn bản khổng lồ (*enormous text corpora*) từ Internet (Web data).
- **Hàm mất mát:** Sử dụng **Cross-entropy loss** (còn gọi là *language modeling loss*).
- **Cơ chế:** Lan truyền ngược (*backpropagated*) qua toàn bộ mạng lưới thần kinh.

Kết quả

Tạo ra một mô hình có khả năng hiểu cấu trúc ngôn ngữ tốt và có thể tạo ra văn bản trôi chảy.

Giai đoạn 2: Instruction Tuning (SFT)

Còn gọi là **Supervised Fine-tuning (SFT)** – Tinh chỉnh có giám sát.

Đặc điểm chính:

- **Mục tiêu:** Dạy mô hình cách *làm theo hướng dẫn* (trả lời câu hỏi, tóm tắt, viết mã nguồn, dịch thuật...).
- **Dữ liệu huấn luyện:** Một tập dữ liệu đặc biệt chứa các cặp: **[Câu lệnh] + [Phản hồi mẫu chuẩn xác]**.

Phương pháp: Tiếp tục sử dụng Cross-entropy loss nhưng trên dữ liệu có cấu trúc hướng dẫn cụ thể thay vì văn bản thô.

Giai đoạn 3: Alignment (Preference Alignment)

Giai đoạn cuối cùng để đảm bảo mô hình **tối đa sự hữu ích** và **tối thiểu sự độc hại**.

- **Dữ liệu ưu tiên (Preference data):** Gồm một ngữ cảnh và hai phương án phản hồi, được con người đánh nhãn là "Chấp nhận" (*accepted*) hoặc "Từ chối" (*rejected*).
- **Thuật toán:** Sử dụng Học tăng cường (**Reinforcement Learning**) hoặc các thuật toán dựa trên phần thưởng (*reward-based*).

Kết quả cuối cùng

Mô hình ưu tiên đưa ra các phản hồi mà con người ưa thích và loại bỏ các nội dung không phù hợp.

Pipeline of training large language model




Figure 7.12 Three stages of training large language models: pretraining, instruction tuning, and preference alignment.

7.5.1 Thuật toán Self-supervised cho Pretraining

1. Khái niệm Self-training / Self-supervision:

- Là phương pháp tự huấn luyện dựa trên cấu trúc tự nhiên của dữ liệu.

2. Nhiệm vụ dự báo từ tiếp theo:

- Tại mỗi thời điểm t , mô hình được yêu cầu dự đoán từ tiếp theo trong một tập văn bản (*corpus*).
- **Tại sao gọi là "Tự giám sát"?** Vì ta không cần dán nhãn thủ công (gold labels). Trình tự tự nhiên của các từ chính là sự giám sát tốt nhất.

Nguyên lý học

Mô hình tự học để cực tiểu hóa sai số giữa từ nó dự báo và từ thực tế xuất hiện trong văn bản.

Cơ chế cập nhật trọng số

1. Kiến trúc mô hình:

- Sử dụng kiến trúc **Transformer** (sẽ học kỹ ở chương sau).
- Chứa các ma trận trọng số cho các thành phần *feedforward* và *attention*.

2. Quá trình tối ưu hóa:

- **Backpropagation (Lan truyền ngược):** Tính toán sai số và truyền ngược lại mạng lưới.
- **Gradient Descent:** Cập nhật các tham số dựa trên đạo hàm để giảm hàm mất mát.

Mục tiêu: Tìm bộ tham số tối ưu sao cho xác suất dự báo từ đúng là cao nhất.

Toán học của Pretraining: Hàm cross-entropy loss

Sai số được đo lường bằng sự khác biệt giữa phân phối xác suất dự báo ($\hat{y}_t$) và phân phối thực tế (y_t):

$$L_{CE}(\hat{y}_t, y_t) = - \sum_{w \in V} y_t[w] \log \hat{y}_t[w] \quad (7.5)$$

Trong đó:

- $\hat{y}_t$: Phân phối xác suất dự báo trên toàn bộ từ vựng (V).
- y_t (**One-hot vector**): Vector có giá trị **1** tại vị trí từ đúng và **0** tại tất cả vị trí khác.

Bản chất toán học

Vì y_t chỉ có một vị trí bằng 1, hàm Loss thực tế chỉ phụ thuộc vào xác suất mà mô hình gán cho từ **đúng duy nhất**. Xác suất này càng cao, Loss càng thấp.

Đơn giản hóa hàm Loss cho LLM

Trong thực tế huấn luyện LLM, hàm Cross-entropy ở phương trình (7.5) có thể đơn giản hóa thành **Negative Log Probability**:

$$L_{CE}(\hat{y}_t, y_t) = -\log \hat{y}_t[w_{t+1}] \quad (7.6)$$

Giải thích:

- Vì nhãn thực tế y_t là một vector *one-hot* (chỉ có giá trị 1 tại vị trí từ đúng tiếp theo w_{t+1}).
- Do đó, mô hình chỉ tập trung tính toán sai số dựa trên xác suất mà nó gán cho từ đúng nhất trong từ điển.

Mục tiêu: Ép mô hình phải tăng xác suất cho từ thực tế w_{t+1} lên mức cao nhất có thể.

Khái niệm

Trong quá trình huấn luyện, tại mỗi bước t , ta luôn cung cấp cho mô hình **chuỗi từ đúng thực tế** ($w_{1:t}$) làm đầu vào để dự đoán từ tiếp theo (w_{t+1}).

Tại sao cần Teacher Forcing?

- Thay vì để mô hình lấy kết quả dự báo của chính nó ở bước trước (vốn có thể sai) làm đầu vào cho bước sau.
- **Lợi ích:** Ngăn chặn sai số tích lũy, giúp quá trình huấn luyện ổn định và hội tụ nhanh hơn rất nhiều.

Ví dụ: Để dự đoán từ "thanks", mô hình được nạp chính xác cụm "So long and" thay vì những gì nó vừa lỗi đoán sai trước đó.

Kỹ thuật Teacher Forcing




Figure 7.13 Training an LLM. At each token position, the model passes up $\hat{y}$, its probability estimate for all possible next words. The negative log of the model's probability estimate for the correct token is used as the loss, which is then backpropagated through the model to train all the weights, including the embeddings. Losses are averaged over all the tokens in a batch.

Hàm Loss cho Batch (Chuỗi độ dài T)

Trong thực tế, mô hình không chỉ học từng từ mà học trên cả một chuỗi (*batch*). Sai số tổng quát là trung bình cộng sai số tại từng vị trí:

$$L_{CE}(\text{batch length } T) = \frac{1}{T} \sum_{t=1}^T -\log \hat{y}_t[w_{t+1}] \quad (7.7)$$

Ý nghĩa của công thức:

- Tính toán xác suất log âm cho mỗi token trong chuỗi.
- Lấy trung bình cộng ($\frac{1}{T}$) để đảm bảo giá trị Loss ổn định, không phụ thuộc vào độ dài của câu.

Mục tiêu: Cực tiểu hóa sai số trung bình này trên toàn bộ dữ liệu huấn luyện.

7.5.2 Tập dữ liệu tiền huấn luyện (Pretraining Corpora)

1. Nguồn dữ liệu chính:

- Chủ yếu là văn bản được thu thập (scraped) từ mạng Internet.
- Được bổ trợ bởi các tập dữ liệu được chọn lọc kỹ lưỡng (*curated data*).

2. Lợi ích của quy mô khổng lồ:

- Chứa đựng vô số ví dụ tự nhiên cho các nhiệm vụ NLP mà không cần dán nhãn thủ công:
 - Các cặp Câu hỏi - Đáp án (từ danh sách FAQ).
 - Các bản dịch giữa nhiều ngôn ngữ khác nhau.
 - Các tài liệu đi kèm với bản tóm tắt của chúng.

Ghi chú: Nhờ quy mô này, mô hình có thể học được nhiều kỹ năng phức tạp ngay từ giai đoạn Pretraining.

Common Crawl và Tập dữ liệu C4

1. Common Crawl:

- Một tổ chức phi lợi nhuận cung cấp các bản "snapshot" của toàn bộ trang web với hàng tỷ trang nội dung.

2. Tập dữ liệu C4 (Colossal Clean Crawled Corpus):

- **Quy mô:** Gồm 156 tỷ token tiếng Anh (Raffel et al. 2020).
- **Quy trình làm sạch dữ liệu:**
 - Loại bỏ các nội dung trùng lặp (*Deduplicated*).
 - Loại bỏ ngôn ngữ không tự nhiên (ví dụ: mã nguồn phần mềm).
 - Sử dụng *blocklist* để lọc bỏ các từ ngữ xúc phạm hoặc độc hại.
- **Thành phần:** Chủ yếu từ Wikipedia, trang tin tức và tài liệu bằng sáng chế.

Các tập dữ liệu quy mô lớn (The Pile & Dolma)

Ngoài Common Crawl, các mô hình hiện đại còn được huấn luyện trên các bộ dữ liệu "khủng" khác:

- **The Pile (825 GB):** Một tập hợp dữ liệu tiếng Anh đa dạng bao gồm mã nguồn (code), sách, Wikipedia và các văn bản thu thập từ web.
- **Dolma (3 nghìn tỷ tokens):** Tập dữ liệu mở quy mô lớn hơn, bao gồm:
 - Bài báo học thuật (Academic papers).
 - Mã nguồn phần mềm (Code).
 - Nội dung từ mạng xã hội (Social media).
 - Tài liệu bách khoa toàn thư.

Nhận xét

Sự đa dạng về nguồn dữ liệu giúp mô hình không chỉ giỏi ngôn ngữ đời thường mà còn hiểu biết về khoa học, lập trình và văn hóa.

Các tập dữ liệu quy mô lớn (The Pile & Dolma)




Figure 7.14 The Pile corpus, showing the size of different components, color coded as **academic** (articles from PubMed and ArXiv, patents from the USPTA; **internet** (webtext including a subset of the common crawl as well as Wikipedia), **prose** (a large corpus of books), **dialogue** (including movie subtitles and chat data), and **misc.** Figure from [Gao et al. \(2020\)](#).

Lọc dữ liệu vì Chất lượng và An toàn

Dữ liệu thô từ Web rất nhiều, do đó cần quy trình lọc nghiêm ngặt:

- **Bộ lọc chất lượng (Quality Filters):** Sử dụng các bộ phân lớp để chấm điểm tài liệu. Ưu tiên các nguồn chuẩn như Wikipedia, sách và các website uy tín.
- **Loại bỏ nội dung không phù hợp:**
 - **PII (Personal Identifiable Information):** Xóa thông tin cá nhân để bảo vệ quyền riêng tư.
 - **Adult content:** Loại bỏ các nội dung người lớn.
 - **Boilerplate text:** Xóa các văn bản thừa (như mã HTML, menu điều hướng).
- **Deduplication (Khử trùng lặp):** Loại bỏ các trang web hoặc đoạn văn bản lặp lại nhiều lần để tránh lãng phí tài nguyên huấn luyện.

Thách thức trong việc lọc nội dung độc hại (Toxicity)

Việc lọc dữ liệu không chỉ là kỹ thuật mà còn là một quyết định mang tính chủ quan:

- **Sai lầm của bộ phân lớp (Classifiers):** Các công cụ lọc thường nhầm lẫn dữ liệu không độc hại là độc hại, đặc biệt là với các phương ngữ thiểu số (ví dụ: tiếng Anh của người Mỹ gốc Phi).
- **Nghịch lý huấn luyện:** Mô hình được huấn luyện trên dữ liệu đã lọc sạch đôi khi lại trở nên **kém hơn** trong việc tự nhận biết và phát hiện các nội dung độc hại mới.

Vấn đề mở

Làm thế nào để lọc an toàn mà không gây định kiến hoặc làm giảm năng lực của mô hình vẫn là một bài toán khó chưa có lời giải hoàn hảo.

Các vấn đề Đạo đức và Pháp lý

Sử dụng dữ liệu thu thập từ Web quy mô lớn đặt ra 4 câu hỏi lớn:

- ❶ **Bản quyền (Copyright):** Dữ liệu chứa nhiều sách và tác phẩm có bản quyền. Liệu việc AI học từ chúng có được coi là "sử dụng hợp lý" (*fair use*) hay là hành vi xâm phạm?
- ❷ **Sự đồng thuận (Data consent):** Nhiều chủ trang web không muốn bị thu thập dữ liệu (thông qua *robots.txt*), nhưng tính pháp lý và hiệu lực hồi tố của các hạn chế này vẫn chưa rõ ràng.
- ❸ **Quyền riêng tư (Privacy):** Nguy cơ rò rỉ thông tin cá nhân (PII) như email, số điện thoại ẩn trong các bộ dữ liệu khổng lồ.
- ❹ **Sự thiên lệch (Skew):** Dữ liệu chủ yếu đến từ Mỹ và các nước phát triển, khiến AI dễ mang quan điểm phiên diện của nhóm này.

7.5.3 Finetuning

1. Tại sao cần Finetuning?

- Dữ liệu Pretraining dù khổng lồ nhưng có thể thiếu hụt kiến thức ở các lĩnh vực chuyên sâu hoặc nhiệm vụ mới.
- **Ví dụ:** Cần một mô hình chuyên biệt về văn bản Pháp luật (*Legal*), Y tế (*Medical*), hoặc một ngôn ngữ cụ thể ít phổ biến.

2. Khái niệm Finetuning:

- Là quá trình lấy một mô hình đã được huấn luyện (*pretrained model*) và tiếp tục huấn luyện để thích nghi với dữ liệu mới.
- Điều chỉnh một phần hoặc toàn bộ các tham số của mạng lưới thần kinh.

Pretraining and finetuning.




Figure 7.15 Pretraining and finetuning. A pre-trained model can be finetuned to a particular domain or dataset. There are many different ways to finetune, depending on exactly which parameters are updated from the finetuning data: all the parameters, some of the parameters, or only the parameters of specific extra circuitry, as we'll see in future chapters.

- 1 7.5 Training Large Language Models
- 2 7.6 Evaluating Large Language Models**
- 3 7.7 Ethical and Safety Issues with Language Models
- 4 7.8 Summary

7.6 Evaluating Large Language Models

Để đánh giá một mô hình ngôn ngữ lớn, chúng ta không chỉ nhìn vào một chỉ số duy nhất mà cần xem xét **đa khía cạnh**:

- **Độ chính xác (Accuracy)**: Khả năng dự báo chính xác các văn bản chưa từng thấy (*unseen text*).
- **Hiệu suất tác vụ**: Khả năng thực hiện các nhiệm vụ cụ thể như trả lời câu hỏi (Q&A) hoặc dịch thuật.
- **Hiệu quả vận hành**: Tốc độ chạy (*latency*) và năng lượng tiêu thụ.
- **Tính công bằng (Fairness)**: Đảm bảo mô hình không đưa ra kết quả định kiến hoặc phân biệt đối xử.

7.6.1 Perplexity (Độ bối rối)

1. Ý tưởng cốt lõi:

- Đo lường khả năng dự báo từ tiếp theo trên tập dữ liệu kiểm tra (*test set*).
- Một mô hình tốt là mô hình **ít bị bất ngờ nhất** (*less surprised*) khi gặp các từ trong thực tế.

2. Mối quan hệ với Xác suất:

- Mô hình tốt sẽ gán xác suất cao hơn cho từ thực sự xuất hiện.
- **Log Likelihood:** Trong thực tế, chúng ta tính toán trên không gian log để ổn định về mặt toán học.

Quy tắc vàng

Mô hình gán xác suất cho từ càng cao $\rightarrow$ Độ bất ngờ càng thấp $\rightarrow$ **Perplexity càng thấp.**

Xác suất của từ tiếp theo

Sử dụng quy tắc chuỗi (*chain rule*), xác suất của cả một văn bản $P(w_{1:n})$ là tích các xác suất có điều kiện của từng token:

$$P(w_{1:n}) = P(w_1)P(w_2|w_1)P(w_3|w_{1:2}) \dots P(w_n|w_{1:n-1}) \quad (1)$$

Dạng tổng quát (7.8):

$$P(w_{1:n}) = \prod_{i=1}^n P(w_i|w_{<i}) \quad (7.8)$$

Giải thích: $w_{<i}$ đại diện cho toàn bộ ngữ cảnh phía trước token thứ i . Mô hình dự báo dựa trên ngữ cảnh này để tính toán xác suất cho token tiếp theo.

Log Likelihood: Thước đo sự tương đồng

Để so sánh hai mô hình ngôn ngữ, chúng ta tính toán khả năng (*likelihood*) của một văn bản dựa trên các xác suất có điều kiện:

$$\log \text{likelihood}(w_{1:n}) = \log \prod_{i=1}^n P(w_i | w_{<i}) \quad (7.9)$$

Tại sao dùng Log?

- **Ổn định tính toán:** Tránh hiện tượng *underflow* khi nhân quá nhiều số xác suất nhỏ (≤ 1).
- **Biến tích thành tổng:** Giúp việc tính toán đạo hàm và tối ưu hóa trở nên dễ dàng hơn.

Nguyên lý: Mô hình nào gán giá trị Log Likelihood cao hơn cho cùng một văn bản thì mô hình đó tốt hơn.

Tuy nhiên nếu như vậy thì giữa các câu có độ dài khác nhau sẽ không thể so sánh với nhau được.

Vấn đề về độ dài và sự cần thiết của Chuẩn hóa

1. Hiệu ứng chiều dài (Length Bias):

- Theo quy tắc chuỗi, xác suất của một văn bản là tích của các số ≤ 1 .
- **Hệ quả:** Văn bản càng dài, xác suất tổng thể càng nhỏ dần về 0.

2. Khó khăn khi so sánh:

- Chúng ta không thể so sánh trực tiếp một mô hình đọc câu 5 từ với một mô hình đọc câu 50 từ dựa trên xác suất tổng.

Giải pháp: Per-token Metric

Cần một thước đo **trên mỗi token** (*per-token*) và được **chuẩn hóa theo độ dài** (*normalized by length*). Điều này cho phép so sánh công bằng giữa các văn bản có độ dài khác nhau.

7.6.1 Định nghĩa toán học của Perplexity

Perplexity là một thước đo xác suất được chuẩn hóa theo độ dài (*length-normalized*).

Đối với một tập kiểm tra gồm n token $w_{1:n}$, Perplexity của mô hình θ được tính bằng **nghịch đảo của xác suất** tập kiểm tra, lũy thừa bậc $1/n$:

$$\text{Perplexity}_{\theta}(w_{1:n}) = P_{\theta}(w_{1:n})^{-\frac{1}{n}} = \sqrt[n]{\frac{1}{P_{\theta}(w_{1:n})}} \quad (7.10)$$

- **Xác suất cao $\rightarrow$ Perplexity thấp**: Mô hình càng dự báo đúng thực tế thì càng ít "bối rối".
- **Càng thấp càng tốt**: Mục tiêu huấn luyện là cực tiểu hóa Perplexity.

Triển khai toán học và Quy tắc chuỗi

Để tính toán cụ thể dựa trên xác suất của từng từ mà mô hình đưa ra, chúng ta sử dụng quy tắc chuỗi (*chain rule*) để mở rộng phương trình (7.10):

$$Perplexity_{\theta}(w_{1:n}) = \sqrt[n]{\prod_{i=1}^n \frac{1}{P_{\theta}(w_i|w_{<i})}} \quad (7.11)$$

Mối liên hệ với dự báo :

- $P_{\theta}(w_i|w_{<i})$ chính là thành phần tương ứng trong vector dự báo của mô hình tại mỗi bước.
- Cực tiểu hóa Perplexity tương đương với việc cực đại hóa xác suất mà mô hình gán cho các từ đúng trong tập kiểm tra.

Ý nghĩa và Cảnh báo về Tokenization

1. Bản chất của Perplexity:

- Bắt nguồn từ khái niệm *cross-entropy rate* trong lý thuyết thông tin.
- Đo lường mức độ "bất ngờ" của mô hình.

Ý nghĩa và Cảnh báo về Tokenization

1. Bản chất của Perplexity:

- Bắt nguồn từ khái niệm *cross-entropy rate* trong lý thuyết thông tin.
- Đo lường mức độ "bất ngờ" của mô hình.

Lưu ý

Perplexity phụ thuộc vào số lượng token n . Do đó, nó cực kỳ nhạy cảm với thuật toán **Tokenization**.

- Không thể so sánh Perplexity giữa hai mô hình nếu chúng dùng hai bộ Tokenizer khác nhau.
- **Quy tắc:** Chỉ dùng Perplexity để so sánh các mô hình sử dụng **cùng một Tokenizer**.

7.6.2 Đánh giá qua các tác vụ Downstream

1. Tại sao Perplexity là chưa đủ?

- Perplexity đo khả năng dự báo từ, nhưng không đo được khả năng giải quyết vấn đề.
- Một mô hình có thể nói rất trôi chảy nhưng vẫn sai kiến thức thực tế.

2. Các tác vụ ứng dụng (Downstream Tasks):

- **Reasoning (Suy luận):** Giải toán, logic, suy luận đa bước.
- **World Knowledge (Kiến thức thế giới):** Trả lời câu hỏi về lịch sử, khoa học, pháp luật.
- **Các tác vụ chuyên biệt:** Dịch thuật (Chương 12), Truy vấn thông tin (Chương 11).

Góc nhìn mới

Đánh giá LLM hiện đại tập trung vào việc mô hình "thông minh" đến đâu thay vì chỉ "thuộc từ" đến đâu.

MMLU: Massive Multitask Language Understanding

MMLU là gì?

- Là bộ dữ liệu gồm **15,908 câu hỏi trắc nghiệm**.
- Bao quát **57 lĩnh vực** khác nhau: Từ kinh tế vi mô, toán học đến y tế và luật pháp.

Tại sao MMLU quan trọng?

- Nó là "thước đo thay thế" (*proxy*) cực tốt cho khả năng suy luận và kiến thức thực tế của mô hình.
- Điểm số MMLU phản ánh trực tiếp chất lượng của vector dự báo khi đối mặt với các lựa chọn (A, B, C, D).

Cơ chế N-shot Prompting trong Đánh giá

Để mô hình làm bài tốt hơn, ta dùng kỹ thuật **N-shot Prompting** (đưa ra N ví dụ mẫu):

- **Cấu trúc Prompt:**

- ❶ Cung cấp hướng dẫn tác vụ.
- ❷ Đưa ra vài ví dụ đã có đáp án chuẩn (*demonstrations*).
- ❸ Đưa ra câu hỏi thực tế cần giải quyết.

- **Ý nghĩa:** Giúp mô hình hiểu được định dạng câu trả lời mong muốn (ví dụ: chỉ chọn A, B, C hoặc D).

Kết quả: Mô hình sẽ tính toán xác suất cho các token A, B, C, D và chọn token có xác suất cao nhất làm đáp án.

Sample 2-shot Prompting

MMLU mathematics prompt

The following are multiple choice questions about high school mathematics.
How many numbers are in the list 25, 26, ..., 100?

(A) 75 (B) 76 (C) 22 (D) 23

Answer: B

Compute $i + i^2 + i^3 + \dots + i^{258} + i^{259}$.

(A) -1 (B) 1 (C) i (D) -i

Answer: A

If 4 daps = 7 yaps, and 5 yaps = 3 baps, how many daps equal 42 baps?

(A) 28 (B) 21 (C) 40 (D) 30

Answer:

Figure 7.16 Sample 2-shot prompt from MMLU testing high-school mathematics. (The correct answer is (C)).

Thách thức: Data Contamination (Nhiễm độc dữ liệu)

Định nghĩa

Xảy ra khi các câu hỏi của tập kiểm tra (như MMLU) **vô tình lọt vào** tập dữ liệu huấn luyện khổng lồ từ Web.

Tại sao đây là vấn đề nghiêm trọng?

- **Thối phòng kết quả:** Mô hình đạt điểm cao vì nó đã "nhìn thấy đề" trước đó, không phải do khả năng suy luận thật.
- **Mất tính khách quan:** Rất khó để biết AI thực sự giỏi hay chỉ đang "nhắc lại" kiến thức đã thuộc lòng.

Giải pháp: Các nhà phát triển cần kiểm tra sự chồng lấn (*overlap*) giữa tập Train và Test và báo cáo minh bạch.

7.6.3 Các yếu tố đánh giá khác

Đánh giá một mô hình hiện đại cần nhìn xa hơn chỉ số dự báo thuần túy:

1. Hiệu năng Tài nguyên

- **Kích thước:** Dung lượng bộ nhớ (GPU RAM).
- **Thời gian:** Tốc độ huấn luyện và suy luận (*inference*).
- **Môi trường:** Tiêu thụ điện năng (kWh) và phát thải CO_2 .
- **Tài chính:** Chi phí xây dựng và vận hành.

2. Tính công bằng (Fairness)

- **Định kiến:** Phát hiện thiên kiến về giới tính, sắc tộc (*StereoSet*, *BBQ*).
- **Độc hại:** Lọc các phản hồi gây hại (*RealToxicityPrompts*).
- **Bình đẳng:** Đảm bảo hiệu suất tốt trên mọi nhóm nhân khẩu học.

Tiêu chuẩn đánh giá tổng thể

Sử dụng các bảng xếp hạng (Leaderboards) như **HELM** hoặc **Dynabench** để có cái nhìn toàn diện về năng lực mô hình.

- 1 7.5 Training Large Language Models
- 2 7.6 Evaluating Large Language Models
- 3 7.7 Ethical and Safety Issues with Language Models**
- 4 7.8 Summary

7.7 Vấn đề Đạo đức và An toàn với Mô hình Ngôn ngữ

1. Bối cảnh lịch sử

- Các nhà nhân văn học đã nghiên cứu về đạo đức và an toàn của các thực thể nhân tạo từ trước khi có các mô hình ngôn ngữ lớn (LLMs).
- **Frankenstein (Mary Shelley, 1818):** Tác phẩm mô tả sự ngạo mạn và mù quáng về đạo đức khi tạo ra một thực thể nhân tạo mà không cân nhắc các nguyên tắc đạo đức cơ bản.

2. Tính mất an toàn của LLMs

- LLMs có thể gây mất an toàn theo nhiều phương thức khác nhau.
- Các thuật toán huấn luyện tối ưu hóa việc tạo văn bản mạch lạc và có tính dự báo (y), nhưng chưa có cơ chế thực thi tính chính xác hoặc xác thực của nội dung.

Hiện tượng Ảo giác (Hallucination)

Định nghĩa

Các mô hình ngôn ngữ có xu hướng đưa ra những thông tin sai lệch, hiện tượng này được gọi là **ảo giác** (hallucination).

Đặc điểm và rủi ro:

- Mô hình tạo ra văn bản mang tính nhất quán và dễ dự báo dựa trên ý, nhưng không đảm bảo tính đúng đắn.
- Gây ra những vấn đề nghiêm trọng cho bất kỳ ứng dụng nào đòi hỏi tính xác thực của dữ liệu và sự thật khách quan.

Đề xuất các hành động không an toàn (Unsafe Actions)

1. Các hành vi nguy hiểm

- LLMs có thể gợi ý trực tiếp các hành động nguy hiểm hoặc bất hợp pháp, bao gồm việc gây hại cho bản thân hoặc người khác.
- **Ngữ cảnh nguy cấp:** Rủi ro đặc biệt cao khi người dùng tìm kiếm thông tin trong các tình huống như tư vấn y tế, cấp cứu hoặc có ý định tự gây thương tích.

2. Minh chứng từ thực tế (Bickmore et al., 2018)

- Nghiên cứu trên các hệ thống đối thoại thương mại (Siri, Alexa, Google Assistant).
- Kết quả: Các hệ thống này đưa ra các đề xuất hành động y tế mà nếu thực hiện theo có thể dẫn đến tổn hại hoặc tử vong.

Tính nịnh nọt và đồng tình thái quá (Sycophancy)

1. Đặc điểm kỹ thuật:

- Các mô hình ngôn ngữ thường có xu hướng đồng tình thái quá hoặc nịnh nọt người dùng.
- Khi người dùng đưa ra thông tin sai lệch về mặt thực tế, mô hình thường chọn cách đồng ý thay vì đính chính.

2. Hệ quả đối với các ứng dụng thực tiễn:

- Gây trở ngại lớn cho các ứng dụng trong giáo dục và chăm sóc sức khỏe.
- củng cố các quan điểm sai lệch và ảo tưởng của người dùng về bản thân cũng như thế giới.
- Có nguy cơ làm gia tăng các hành vi phản xã hội (Cheng et al., 2025).

Ghi chú: Bản chất dự báo ý bị điều chỉnh để ưu tiên sự hài lòng của người dùng hơn tính xác thực.

Tổn hại về mặt biểu đạt (Representational Harms)

1. Tấn công ngôn từ và Định kiến:

- Mô hình có thể gây hại thông qua tấn công ngôn từ hoặc tạo ra các tổn hại về mặt biểu đạt (Blodgett et al., 2020).
- Tạo ra các định kiến độc hại và thái độ tiêu cực làm hạ thấp các nhóm đối tượng cụ thể (Sheng et al., 2019; Brown et al., 2020).
- Các định kiến này gây ra những tổn thương tâm lý cho người dùng.

2. Tính chất phức tạp của phản hồi độc hại:

- Nghiên cứu của Gehman et al. (2020) cho thấy ngay cả những câu lệnh (*prompts*) không độc hại cũng có thể dẫn đến đầu ra chứa ngôn từ thù ghét.

Sự phân biệt đối xử và Định kiến hệ thống

1. Định kiến về giới tính và chủng tộc:

- Thử nghiệm của Liu et al. (2020) cho thấy các thay đổi nhỏ (như dùng "she" thay cho "he") khiến hệ thống phản hồi xúc phạm và tiêu cực hơn.

2. Định kiến đối với phương ngữ (Dialects):

- Hofmann et al. (2024): LLMs có xu hướng phân biệt đối xử với người dùng sử dụng các phương ngữ đặc thù (ví dụ: tiếng Anh của người Mỹ gốc Phi).

3. Tính kế thừa lịch sử:

- Các vấn đề này đã tồn tại từ trước thời kỳ LLM, ví dụ tiêu biểu là chatbot của Microsoft năm 2016 đã phải ngừng hoạt động do tạo ra nội dung xúc phạm.

Ví dụ thực tế: Sự cố Tay và Vấn đề Quyền riêng tư

1. Bài học từ Chatbot Tay (2016):

- Bị gỡ bỏ sau 16 giờ do phát ngôn phân biệt chủng tộc và tấn công cá nhân.
- Nguyên nhân: Học từ dữ liệu huấn luyện độc hại và tương tác tiêu cực từ người dùng.

2. Quyền riêng tư (Privacy):

- Hệ thống càng giống người, người dùng càng dễ tiết lộ thông tin cá nhân.
- Nguy cơ rò rỉ dữ liệu (PII): Kẻ xấu có thể trích xuất tên, SĐT, địa chỉ trực tiếp từ trọng số mô hình.

1. Nhân cách hóa (Anthropomorphism):

- Người dùng có xu hướng tương tác với máy tính như với con người.
- Dẫn đến sự lệ thuộc về mặt cảm xúc và thay đổi trạng thái nhận thức.

2. Sử dụng sai mục đích (Malicious use):

- Lừa đảo, giả mạo (*phishing*), tuyên truyền tin giả.
- Khuếch đại tư tưởng cực đoan và lôi kéo thành viên cho các tổ chức cực đoan trực tuyến.

Các phương pháp giảm thiểu rủi ro

- **Minh bạch dữ liệu:** Sử dụng **Datasheets** và **Model cards** để công khai thông tin chi tiết về tập dữ liệu huấn luyện.
- **Thiết kế nhạy cảm giá trị:** Cân nhắc các tác hại tiềm tàng ngay từ giai đoạn thiết kế hệ thống (*Value sensitive design*).
- **Quy chuẩn đạo đức:**
 - Lấy sự đồng thuận của người tham gia (*Informed consent*).
 - Vai trò của Hội đồng Đánh giá Nội bộ (**IRB**) trong việc bảo vệ an toàn cho người dùng thực nghiệm.

1. Sự đồng thuận có nhận thức (Informed consent):

- Cần có sự đồng ý của người tham gia, dù họ đóng góp dữ liệu huấn luyện hay tương tác với các LLMs đã triển khai.

Quy trình Đạo đức trong nghiên cứu

1. Sự đồng thuận có nhận thức (Informed consent):

- Cần có sự đồng ý của người tham gia, dù họ đóng góp dữ liệu huấn luyện hay tương tác với các LLMs đã triển khai.

2. Vai trò của Hội đồng Đánh giá Nội bộ (IRB):

- Do việc nghiên cứu các đặc tính tương tác của LLMs có sự tham gia của con người, các nhà nghiên cứu cần làm việc chặt chẽ với các **Institutional Review Boards (IRB)**.
- Nhiệm vụ: Đảm bảo an toàn và bảo vệ quyền lợi cho những người tham gia thực nghiệm.

Kết luận chương

Việc tìm cách giảm thiểu các vấn đề đạo đức và an toàn là một lĩnh vực nghiên cứu trọng tâm và cấp thiết trong xử lý ngôn ngữ tự nhiên hiện nay.

- 1 7.5 Training Large Language Models
- 2 7.6 Evaluating Large Language Models
- 3 7.7 Ethical and Safety Issues with Language Models
- 4 7.8 Summary

7.8 Tổng kết: Định nghĩa và Kiến trúc LLM

- **Mô hình ngôn ngữ lớn (LLM):** Là hệ thống có khả năng dự báo từ tiếp theo dựa trên một ngữ cảnh hoặc tiền tố cho trước, từ đó tạo ra văn bản có điều kiện.
- **Ba kiến trúc chính:**
 - **Encoder** (Bộ mã hóa).
 - **Decoder** (Bộ giải mã) – hầu hết các LLM tạo văn bản hiện nay đều thuộc loại này.
 - **Encoder-Decoder.**
- **Ứng dụng rộng rãi:** Nhiều tác vụ NLP như trả lời câu hỏi hay phân tích cảm xúc đều có thể được chuyển đổi thành bài toán dự báo từ.

Tương tác và Kỹ thuật Prompt

- **Prompt (Câu lệnh):** Là chuỗi văn bản người dùng đưa vào để điều khiển mô hình thực hiện các tác vụ hữu ích thông qua việc tạo token lặp lại.
- **Prompt Engineering:** Quá trình tìm kiếm và thiết kế các câu lệnh hiệu quả nhất cho một tác vụ cụ thể.
- **Cơ chế tạo từ:** Việc lựa chọn từ để tạo ra được thực hiện bằng cách **lấy mẫu (sampling)** từ phân phối xác suất của các từ kế tiếp tiềm năng.

Chiến lược Lấy mẫu (Sampling)

- **Temperature sampling:** Một phương pháp lấy mẫu phổ biến nằm giữa *greedy decoding* (luôn chọn từ có xác suất cao nhất) và *random sampling* (chọn từ ngẫu nhiên theo xác suất).
- **Cơ chế hoạt động:** Tham số nhiệt độ (*temperature*) điều chỉnh phân phối xác suất:
 - Tăng xác suất cho các từ có khả năng cao.
 - Giảm xác suất cho các từ có khả năng thấp.
- Điều này giúp cân bằng giữa tính ổn định và tính sáng tạo của nội dung đầu ra $\odot$.

Huấn luyện và Đánh giá LLM

1. Quá trình huấn luyện:

- Tiềm huấn luyện trên tập dữ liệu khổng lồ (hàng trăm tỷ từ) thu thập từ Web.
- Dữ liệu cần được lọc sạch để đảm bảo chất lượng.
- Thuật toán dựa trên **Cross-entropy loss**: cực tiểu hóa xác suất log âm của từ thực tế tiếp theo.

2. Phương pháp đánh giá:

- Sử dụng chỉ số **Perplexity** (Độ bối rối).
- Đánh giá độ chính xác trên các tác vụ downstream thông qua các bộ benchmark như **MMLU**.
- Xem xét các yếu tố khác như tính công bằng và năng lực tiêu thụ.

Các thách thức về Đạo đức và An toàn

LLM đối mặt với nhiều vấn đề phức tạp cần được giải quyết:

- **Ảo giác (Hallucinations):** Đưa ra thông tin sai lệch một cách thuyết phục.
- **Nội dung độc hại:** Các chỉ dẫn không an toàn, thiên kiến, định kiến và thông tin sai lệch.
- **Tuyên truyền:** Nguy cơ bị lợi dụng cho các chiến dịch tuyên truyền và tin giả.
- **Quyền riêng tư Bản quyền:** Vi phạm quyền riêng tư của người dùng và các quy định về bản quyền dữ liệu.

Cảm ơn cô và các bạn đã lắng nghe!

Q & A