



bảng tính

Chương 8

Tổng cộng câu hỏi: 14

Thời gian làm bài tập trên phiếu bài tập: 7 phút

Tên

Lớp học

Ngày

1. Theo kiến trúc tiêu chuẩn, một khối Transformer bao gồm 4 thành phần cốt lõi nào?

- a) Lớp tự chú ý đa đầu, mạng nơ-ron hồi quy (RNN), lớp giải nhúng, lớp chuẩn hóa.
- b) Attention đa đầu, mạng truyền thẳng, kết nối thặng dư, layer norm.
- c) Lớp attention đơn đầu, mạng truyền thẳng, kết nối thặng dư, hàm Softmax.
- d) Mạng chập (CNN), kết nối thặng dư, layer norm, cơ chế attention đa đầu.

2. Trong Transformer, mục đích chính của việc gộp N token vào một ma trận X duy nhất có kích thước $[N \times d]$ là gì?

- a) Để giảm số lượng tham số của mô hình.
- b) Để tận dụng khả năng tính toán song song hiệu năng cao của GPU.
- c) Để loại bỏ nhu cầu sử dụng Residual Connections (Kết nối thặng dư).
- d) Để tăng độ chính xác của lớp Layer Norm.

3. Tại sao cần sử dụng cơ chế Masking (áp dụng các giá trị -oo trong ma trận QK^T của các mô hình ngôn ngữ Causal)?

- a) Để tăng cường trọng số cho các token đứng cách xa nhau.
- b) Để giảm độ phức tạp tính toán từ $O(N^2)$ xuống $O(N)$.
- c) Để ngăn mô hình nhìn thấy thông tin của các token ở tương lai.
- d) Để chuẩn hóa tổng của các trọng số attention luôn bằng 1.

4. Phát biểu nào sau đây là đúng nhất về độ phức tạp tính toán của cơ chế Self-Attention khi song song hóa?

- a) Độ phức tạp là tuyến tính $O(N)$ theo độ dài chuỗi.
- b) Độ phức tạp là bậc hai $O(N^2)$ theo độ dài chuỗi.
- c) Độ phức tạp không phụ thuộc vào độ dài chuỗi đầu vào.
- d) Độ phức tạp là logarit $O(\log N)$.

5. Trong cơ chế Causal Self-Attention, tại sao việc gán giá trị $-\infty$ cho các vị trí tương lai (masking) trước khi đưa vào hàm Softmax lại là yếu tố sống còn?
- Để tăng tốc độ tính toán song song của GPU bằng cách loại bỏ các phép nhân không cần thiết.
 - Để hàm Softmax triệt tiêu trọng số chú ý (về 0) tại các vị trí đó, ngăn mô hình "nhìn trộm" dữ liệu tương lai.
 - Để tránh hiện tượng bùng nổ Gradient khi huấn luyện với các câu có độ dài quá lớn.
 - Để ép mô hình chỉ tập trung vào từ đứng ngay trước nó thay vì toàn bộ ngữ cảnh quá khứ.
6. Vai trò thực sự của ma trận W^O (Output Projection) trong Multi-head Attention là gì?
- Dùng để chia vector đầu vào $d=512$ thành các phần nhỏ $d_k=64$ cho mỗi head.
 - Thực hiện phép chiếu để tổng hợp và "hòa trộn" thông tin từ tất cả các attention heads độc lập về lại không gian vector ban đầu.
 - Có nhiệm vụ tính toán điểm tương đồng (score) giữa Query và Key.
 - Giúp mô hình loại bỏ các từ hư từ (stopwords) trong câu văn thông qua cơ chế lọc.
7. Tại sao trong công thức tính toán Scaled Dot-Product Attention, chúng ta phải chia tích vô hướng cho $\sqrt{d_k}$?
- Để đảm bảo rằng tổng các trọng số α luôn bằng 1 sau khi đi qua Softmax.
 - Để giảm bớt số lượng tham số cần huấn luyện trong mỗi lớp Attention.
 - Để kiểm soát độ lớn của tích vô hướng, tránh làm hàm Softmax rơi vào vùng bão hòa có gradient cực nhỏ (triệt tiêu gradient).
 - Để chuẩn hóa dữ liệu đầu vào về phân phối chuẩn (0, 1) trước khi thực hiện Attention.
8. Theo kiến trúc tiêu chuẩn, một khối Transformer bao gồm 4 thành phần cốt lõi nào?
- Lớp tự chú ý đa đầu, mạng nơ-ron hồi quy (RNN), lớp giải nhúng, lớp chuẩn hóa.
 - Attention đa đầu, mạng truyền thẳng, kết nối thặng dư, layer norm.
 - Lớp attention đơn đầu, mạng truyền thẳng, kết nối thặng dư, hàm Softmax.
 - Mạng chập (CNN), kết nối thặng dư, layer norm, cơ chế attention đa đầu.

9. Theo kiến trúc Prenorm, luồng dữ liệu của một token khi đi qua mỗi thành phần trong khối sẽ diễn ra theo thứ tự nào?
- Dữ liệu qua Attention, rồi tới FFN, sau đó mới qua Chuẩn hóa lớp và cuối cùng là cộng thẳng dư.
 - Dữ liệu qua Attention/FFN trước, sau đó qua Chuẩn hóa lớp, và cuối cùng cộng thẳng dư vào luồng gốc.
 - Dữ liệu qua lớp chuẩn hóa trước, xử lý qua Attention/FFN, và kết quả được cộng thẳng dư vào luồng.
 - Dữ liệu được cộng thẳng dư trước khi đi qua Layer Norm và Attention/FFN.
10. Trong một khối Transformer, thành phần nào đóng vai trò trộn token (token-mixing)?
- Kết nối thẳng dư (Residual Connection).
 - Cơ chế Chú ý đa đầu (Multi-Head Attention).
 - Chuẩn hóa lớp (Layer Normalization).
 - Mạng nơ-ron truyền thẳng (Feedforward Layer).
11. Đặc điểm cốt lõi nào giúp các khối Transformer có thể xếp chồng (stacking) lên nhau thành nhiều tầng?
- Số chiều đầu vào và đầu ra của mỗi khối hoàn toàn khớp nhau.
 - Các khối Transformer phía sau sử dụng lại toàn bộ bộ trọng số của khối trước.
 - Lớp truyền thẳng làm nhiệm vụ nén dữ liệu từ nhiều chiều về một chiều duy nhất.
 - Số lượng token trong ngữ cảnh sẽ tự động giảm đi một nửa qua mỗi khối.
12. Khi di chuyển từ các khối Transformer thấp nhất lên các khối cao nhất, ý nghĩa của luồng thẳng dư thay đổi như thế nào?
- Luồng thẳng dư luôn giữ nguyên việc đại diện cho token hiện tại ở mọi khối.
 - Chuyển từ đại diện token tiếp theo sang đại diện của token hiện tại.
 - Từ đại diện cho token hiện tại chuyển sang đại diện cho token tiếp theo.
 - Dữ liệu chuyển hóa từ việc phân tích cú pháp sang phân tích hình ảnh tĩnh.
13. Tại sao nếu bỏ positional embedding thì Transformer sẽ gặp vấn đề?
- Transformer không thể phân biệt được thứ tự các từ trong câu
 - Transformer không thể học được embedding của từ
 - Transformer không thể tính toán attention
 - Transformer không thể xử lý chuỗi dài

14. Tại sao trong Transformer, positional embedding thường được cộng với word embedding thay vì nối (concatenate)?
- a) Để giữ nguyên kích thước vector đầu vào d cho mô hình
 - b) Vì phép cộng giúp mô hình học nhanh hơn luôn
 - c) Vì phép nối không thể thực hiện được trong Transformer
 - d) Vì positional embedding không chứa thông tin quan trọng

Đáp án

1. b) Attention đa đầu, mạng truyền thẳng, kết nối thặng dư, layer norm.
2. b) **Để tận dụng khả năng tính toán song song hiệu năng cao của GPU.**
3. c) **Để ngăn mô hình nhìn thấy thông tin của các token ở tương lai.**
4. b) **Độ phức tạp là bậc hai $O(N^2)$ theo độ dài chuỗi.**
5. b) Để hàm Softmax triệt tiêu trọng số chú ý (về 0) tại các vị trí đó, ngăn mô hình "nhìn trộm" dữ liệu tương lai.
6. b) Thực hiện phép chiếu để tổng hợp và "hòa trộn" thông tin từ tất cả các attention heads độc lập về lại không gian vector ban đầu.
7. c) Để kiểm soát độ lớn của tích vô hướng, tránh làm hàm Softmax rơi vào vùng bão hòa có gradient cực nhỏ (triệt tiêu gradient).
8. b) Attention đa đầu, mạng truyền thẳng, kết nối thặng dư, layer norm.
9. c) Dữ liệu qua lớp chuẩn hóa trước, xử lý qua Attention/FFN, và kết quả được cộng thặng dư vào luồng.
10. b) Cơ chế Chú ý đa đầu (Multi-Head Attention).
11. a) Số chiều đầu vào và đầu ra của mỗi khối hoàn toàn khớp nhau.
12. c) Từ đại diện cho token hiện tại chuyển sang đại diện cho token tiếp theo.
13. a) Transformer không thể phân biệt được thứ tự các từ trong câu
14. a) Để giữ nguyên kích thước vector đầu vào d cho mô hình

