

Untitled Quiz

Total questions: 10

Worksheet time: 3mins

Name Class Date

1. Việc sử dụng một giá trị k cố định trong top-k sampling không hợp lý trong hoàn cảnh nào sau đây?

- a) Khi context quá ngắn để dự đoán tốt
- b) Khi độ nhọn của phân phối thay đổi nhiều theo context
- c) Khi vocabulary đủ nhỏ để top-k ít ý nghĩa
- d) Khi logits đã qua temperature scaling

2. Ở hai context khác nhau, model cho hai phân phối sau:

Context 1: một token chiếm gần hết xác suất

Context 2: xác suất trải đều trên nhiều token hợp lý

Nếu dùng cùng $k = 10$ cho cả hai, chuyện gì sẽ xảy ra ?

- a) Top-k có thể quá rộng ở context 1 nhưng quá hẹp ở context 2
- b) Top-k sẽ trở thành greedy ở context 2 nhưng ngẫu nhiên hơn ở context 1
- c) Top-k sẽ giữ đúng 10% mass ở cả hai context
- d) Top-k sẽ tự điều chỉnh k để giữ tính đa dạng ở context 1

3. Trong scaled dot-product attention, vì sao người ta chia cho căn bậc hai của chiều key trước khi áp dụng softmax?

- a) Để tránh score quá lớn làm softmax quá sắc và khó tối ưu
- b) Để đưa attention score về đúng khoảng từ 0 đến 1
- c) Để mọi head có cùng số tham số
- d) Để Q và K có cùng phân phối với V

4. Multi-head attention thường có lợi hơn một head lớn đơn lẻ vì lý do nào?

- a) Các head khác nhau có thể học những kiểu quan hệ khác nhau giữa các token
- b) Multi-head khiến feedforward layers không còn cần thiết
- c) Multi-head tự động làm mô hình nhìn được chuỗi dài hơn context window
- d) Mỗi head có thể nhìn dữ liệu qua một phép chiếu riêng, rồi kết hợp lại ở cuối

5. Nếu hai câu có cùng tập token nhưng khác thứ tự, điều gì có khả năng xảy ra với một transformer không có bất kỳ thông tin vị trí nào?
- a) Mô hình vẫn phân biệt được nhờ residual connections b) Mô hình chỉ nhầm nếu hai câu có cùng độ dài
- c) Mô hình vẫn phân biệt được vì softmax phụ thuộc vị trí d) Mô hình khó phân biệt hai câu vì attention gần như không biết trật tự
6. Giả sử ta tăng rank r trong LoRA từ 8 lên 64. hiện tượng nào sau đây xảy ra ?
- a) Adapter bắt đầu thay thế luôn W gốc b) Adapter ít linh hoạt hơn nhưng inference nhanh hơn nhiều
- c) Adapter giữ nguyên chi phí train nhưng giảm hẳn chi phí inference d) Adapter linh hoạt hơn nhưng số tham số train tăng lên
7. Vì sao weight tying giữa embedding matrix và output projection matrix được xem là hợp lý?
- a) Vì nó làm softmax không còn cần thiết b) Vì nó buộc input và output cùng chia sẻ một không gian từ vựng
- c) Vì nó làm hidden state cuối trở thành one-hot d) Vì nó giúp giảm số lượng tham số cần học
8. Trong decoder-only transformer, vì sao query của token mới vẫn phải được tính lại dù đã có KV cache?
- a) Vì cache chỉ giữ logits b) Vì query bị thay bởi Value
- c) Vì query phụ thuộc softmax cũ d) Vì token mới chưa có Q
9. Vì sao không thể kết luận rằng chỉ cần tăng số lượng tham số là loss sẽ tự động giảm theo scaling laws ?
- a) Vì scaling laws không liên quan loss b) Vì scaling laws chỉ nói về inference
- c) Vì data và compute cũng là biến chính d) Vì scaling laws chỉ áp dụng cho CNN
10. Induction heads thường được nhắc tới để giải thích kiểu hành vi nào của transformer?
- a) Hoàn tất pattern lặp trong chuỗi b) Giảm số layer cần train
- c) Học cách thực hiện task mới từ các ví dụ trong prompt d) Tăng context window hiệu quả

Answer Keys

1. b) Khi độ nhon của phân phối thay đổi nhiều theo context
2. a) Top-k có thể quá rộng ở context 1 nhưng quá hẹp ở context 2
3. a) Để tránh score quá lớn làm softmax quá sắc và khó tối ưu
4. a) Các head khác nhau, Mỗi head khác nhau d) có thể nhìn có thể học dữ liệu qua những kiểu một phép quan hệ chiếu khác nhau riêng, rồi giữa các kết hợp lại token ở cuối
5. d) Mô hình khó phân biệt hai câu vì attention gần như không biết trật tự
6. d) Adapter linh hoạt hơn nhưng số tham số train tăng lên
7. b) Vì nó buộc input và output cùng chia sẻ một không gian từ vựng, Vì nó d) giúp giảm số lượng tham số cần học
8. d) Vì token mới chưa có Q
9. c) Vì data và compute cũng là biến chính
10. a) Hoàn tất pattern lặp trong chuỗi

