

Masked Language Models

Chapters 9.4 & 9.5

Nhóm 3

Phạm Ngọc Phú Thịnh Phạm Nguyễn Duy Anh
Nguyễn Trường Giang Hà Bùi Trọng Nghĩa

Khoa Khoa học Máy tính
Trường Đại học Công nghệ Thông tin - UIT **Xử lý ngôn ngữ tự nhiên**

Ngày 20 tháng 4 năm 2026

1 Fine-Tuning for Classification

- Sequence Classification
- Sequence-Pair Classification

2 9.5 Fine-Tuning for Sequence Labeling: Named Entity Recognition

- Named Entities
- BIO Tagging
- Sequence Labeling
- Evaluating Named Entity Recognition

Table of Contents

1 Fine-Tuning for Classification

- Sequence Classification
- Sequence-Pair Classification

2 9.5 Fine-Tuning for Sequence Labeling: Named Entity Recognition

- Named Entities
- BIO Tagging
- Sequence Labeling
- Evaluating Named Entity Recognition

9.4 Fine-Tuning for Classification

Pretrained Language Models (PLMs)

- Khả năng: Trích xuất **general features** từ tập văn bản khổng lồ.
- Mục tiêu: Giải quyết các **downstream tasks**.

Approaches

- **Prompting**: Sử dụng ngôn ngữ tự nhiên (phổ biến với LLMs).
- **Fine-Tuning**: Phương pháp kỹ thuật chuyên biệt

Fine-Tuning for Classification

Architecture (MLM focus)

- Thêm **special head**: Nhận trực tiếp output từ mô hình gốc.
- Chiến lược huấn luyện:
 - Đóng băng tham số Pretrained Language Model.
 - Hoặc chỉ điều chỉnh rất nhỏ tham số của Pretrained Language Model.

Common Fine-Tuning Applications

- **Sequence classification**
- **Sentence-pair classification**
- **Sequence labeling**

9.4.1 Sequence Classification

Definition

- Phân loại toàn bộ chuỗi văn bản bằng một nhãn duy nhất.
- **Examples:** Text classification, Sentiment analysis, Spam detection.
- **General approach:** Tính Sum hoặc Mean của các word vectors.

BERT Solution

- Thêm token [CLS] vào đầu chuỗi đầu vào.
- Vector đầu ra lớp cuối cùng (h_{CLS}^L) đại diện cho toàn bộ chuỗi.

Sequence Classification




Figure 10.9 Sequence classification with a bidirectional transformer encoder. The output vector for the [CLS] token serves as input to a simple classifier.

Classification Formula

$$y = \text{softmax}(h_{\text{CLS}}^L W_C)$$

- y : Xác suất thuộc về từng lớp.
- h_{CLS}^L : Vector đầu ra của token [CLS].
- W_C : Weight matrix kích thước $[d \times k]$ (d : model dimension, k : num classes).

Training Process

- **Data**: Yêu cầu Supervised training data.
- **Loss function**: Cross-entropy loss.
- **Optimization**: Cập nhật W_C và tinh chỉnh các tham số PLM (thường ở các lớp ngoài cùng).

9.4.2 Sequence-Pair Classification

Definition

- Phân loại mối quan hệ hoặc sự tương tác giữa hai chuỗi văn bản.
- **Applications:** Paraphrase detection, Logical entailment, Discourse coherence.

Mechanism

- Tương tự quá trình pretraining với mục tiêu **Next Sentence Prediction (NSP)**.
- **Input format:** [CLS] Sentence A [SEP] Sentence B
- Sử dụng vector đầu ra liên kết với token [CLS] làm đại diện cho cặp câu.
- Thực hiện phân loại tương tự Sequence Classification thông thường.

Sequence-Pair Classification

Task: Entailment classification.

- **Neutral:**

- a: Jon walked back to the town to the smithy.
- b: Jon traveled back to his hometown.

- **Contradicts:**

- a: Tourist Information offices can be very helpful.
- b: Tourist Information offices are never of any help.

- **Entails:**

- a: I'm confused.
- b: Not all of it is very clear to me.

Sentence-Pair Classification




Table of Contents

1 Fine-Tuning for Classification

- Sequence Classification
- Sequence-Pair Classification

2 9.5 Fine-Tuning for Sequence Labeling: Named Entity Recognition

- Named Entities
- BIO Tagging
- Sequence Labeling
- Evaluating Named Entity Recognition

9.5.1 Named Entities

Definitions

- **Named Entity**: Bất kỳ đối tượng nào định danh bằng danh từ riêng.
- **NER Task**: Tìm các *NER spans* và gán nhãn loại thực thể tương ứng.

Common Entity Tags

Tag	Description
PER	Person (Người)
LOC	Location (Địa điểm)
ORG	Organization (Tổ chức)
GPE	Geo-political entity (Thực thể địa chính trị)

Extensions: Bao gồm TIME (thời gian) và MONEY (giá cả).

NER Tagger Example

Citing high fuel prices, [ORG United Airlines] said [TIME Friday] it has increased fares by [MONEY \$6] per round trip on flights to some cities also served by lower-cost carriers. [ORG American Airlines], a unit of [ORG AMR Corp.], immediately matched the move, spokesman [PER Tim Wagner] said. [ORG United], a unit of [ORG UAL Corp.], said the increase took effect [TIME Thursday] and applies to most routes where it competes against discount carriers, such as [LOC Chicago] to [LOC Dallas] and [LOC Denver] to [LOC San Francisco].

Statistics:

- Tổng cộng: **13** thực thể có tên.
- Phân bố: 5 Organizations, 4 Locations, 2 Time expressions, 1 Person, 1 Money.

Named Entities


Type	Tag	Sample Categories	Example sentences
People	PER	people, characters	Turing is a giant of computer science.
Organization	ORG	companies, sports teams	The IPCC warned about the cyclone.
Location	LOC	regions, mountains, seas	Mt. Sanitas is in Sunshine Canyon .
Geo-Political Entity	GPE	countries, states	Palo Alto is raising the fees for parking.

Figure 10.10 A list of generic named entity types with the kinds of entities they refer to.

Domain-specific Entities

- Proteins, Genes.
- Sản phẩm thương mại.
- Tác phẩm nghệ thuật.

TẦM QUAN TRỌNG CỦA NHẬN DẠNG THỰC THỂ CÓ TÊN (NER) TRONG NLP



NER: BƯỚC HỮU ÍCH TRONG NHIỀU TÁC VỤ NLP KHÁC NHAU

Segmentation Ambiguity

- Khó khăn trong việc phân đoạn các **NER spans**.
- Xác định ranh giới giữa token thực thể và token thông thường.

Type Ambiguity

- Một thực thể có thể thuộc nhiều loại tùy ngữ cảnh.
- **Example:** "*Washington*"
 - Person (George Washington)
 - Location (Washington State / D.C.)
 - Organization (Washington government / sports team)

[PER Washington] was born into slavery on the farm of James Burroughs.
[ORG Washington] went up 2 games to 1 in the four-game series.
Blair arrived in [LOC Washington] for what may well be his last state visit.
In June, [GPE Washington] passed a primary seatbelt law.

Figure 10.11 Examples of type ambiguities in the use of the name *Washington*.

9.5.2 BIO Tagging: Khái niệm

Định nghĩa

- Là tiêu chuẩn cho bài toán **span-recognition**.
- Xử lý NER như một tác vụ gán nhãn chuỗi từng từ (*word-by-word sequence labeling*).
- Nắm bắt đồng thời ranh giới (boundary) và loại thực thể (type).

Quy tắc gán nhãn BIO

- B (Begin): Token bắt đầu một thực thể.
- I (Inside): Token nằm bên trong một thực thể.
- O (Outside): Token nằm ngoài mọi thực thể.

Tổng số nhãn:

$$\text{Total Labels} = 2n + 1$$

(Với n là số loại thực thể)

Ưu điểm

- Mô hình hóa chuỗi đơn giản như **Part-of-Speech (POS) tagging**.
- Gán một nhãn duy nhất y_i cho mỗi từ đầu vào x_i .

Câu ví dụ:

[PER Jane Villanueva] of [ORG United], a unit of [ORG United Airlines Holding], said the fare applies to the [LOC Chicago] route.

Words	IO Label
Jane	I-PER
Villanueva	I-PER
of	O
United	I-ORG
Airlines	I-ORG
Holding	I-ORG
discussed	O
the	O
Chicago	I-LOC
route	O
.	O

1. Biến thể IO (Inside-Outside)

- Loại bỏ nhãn B.
- **Hạn chế:** Mất thông tin ranh giới khi có hai thực thể cùng loại đứng cạnh nhau.

2. Biến thể BIOES

- B (Begin), I (Inside).
- E (End): Token kết thúc một thực thể.
- S (Single): Thực thể chỉ gồm một từ duy nhất.

BIOES cung cấp nhiều thông tin ranh giới chi tiết hơn cho mô hình.

BIO Tagging

Words	IO Label	BIO Label	BIOES Label
Jane	I-PER	B-PER	B-PER
Villanueva	I-PER	I-PER	E-PER
of	O	O	O
United	I-ORG	B-ORG	B-ORG
Airlines	I-ORG	I-ORG	I-ORG
Holding	I-ORG	I-ORG	E-ORG
discussed	O	O	O
the	O	O	O
Chicago	I-LOC	B-LOC	S-LOC
route	O	O	O
.	O	O	O

Figure 10.12 NER as a sequence model, showing IO, BIO, and BIOES taggings.

So sánh cách gán nhãn giữa BIO, IO và BIOES.

9.5.3 Sequence Labeling

Quy trình gán nhãn

- Đưa vector đầu ra cuối cùng (h_i^L) qua một bộ phân loại (*classifier*).
- Tạo ra phân phối xác suất Softmax trên tập nhãn k .

Công thức toán học

$$y_i = \text{softmax}(h_i^L W_K) \quad (1)$$

$$t_i = \text{argmax}_k(y_i) \quad (2)$$

Thông số kỹ thuật

- W_K : Ma trận trọng số kích thước $[d \times k]$.
- d : Số chiều của mô hình (Hidden size).
- k : Số lượng nhãn (VD: 9 nhãn cho bộ PER, LOC, ORG, GPE).

Tiếp cận bằng phương pháp Greedy

Sequence Labeling




Figure 10.13 Sequence labeling for named entity recognition with a bidirectional transformer encoder. The output vector for each input token is passed to a simple k-way classifier.

Vấn đề của Softmax + Argmax:

- Thiếu sự ràng buộc logic giữa các nhãn.
- Ví dụ: Nhãn I-PER không bao giờ được đứng sau nhãn O. Nhưng Softmax đứng đơn lẻ có thể mắc lỗi này.

Giải pháp: Lớp CRF

- Tính toán các bước chuyển đổi nhãn toàn cục (*global tag-level transitions*).
- CRF xem xét xác suất của cả chuỗi nhãn thay vì từng từ riêng lẻ.

"CRF giúp mô hình học được quy luật: O không được đứng trước I."

Tokenization and NER

Thực trạng dữ liệu

- Dữ liệu huấn luyện có giám sát thường ở cấp độ **Từ (Word level)**.
- Các nhãn BIO được liên kết trực tiếp với từng từ đơn lẻ.

Vấn đề nảy sinh

- Các mô hình hiện đại (BERT, RoBERTa) sử dụng **Subword Tokenization** (WordPiece).
- Một word có thể bị cắt thành nhiều subword.

(10.14) *Mt. Sanitas is in Sunshine Canyon .*

B-LOC I-LOC O O B-LOC I-LOC O

WordPiece Tokens

['Mt', '.', 'San', '##itas', 'is', 'in', 'Sunshine', 'Canyon', '.']

Tokenization and NER

Phương pháp: Gán nhãn lan truyền

- Lấy gold-standard tag của từ gốc.
- Gán nhãn đó cho **tất cả** các token từ phụ được phân tách ra.

Ví dụ cụ thể:

Từ gốc	Từ phụ (Tokens)	Nhãn gán
Sanitas	San	I-LOC
	itas	I-LOC
Mt.	Mt	B-LOC
	.	B-LOC

Cách tiếp cận đơn giản nhất

- Sử dụng nhãn của **token từ phụ đầu tiên** làm nhãn cho cả từ.
- Bỏ qua thông tin từ các token từ phụ phía sau.

Ví dụ:

- Mt ($\text{argmax} \rightarrow \text{B-LOC}$) $\Rightarrow$ Từ "**Mt.**" là B-LOC.
- San ($\text{argmax} \rightarrow \text{I-LOC}$) $\Rightarrow$ Từ "**Sanitas**" là I-LOC.
- Các token . và itas bị bỏ qua trong bước này.

Tokenization and NER

- **Hạn chế của cách đơn giản:** Lãng phí thông tin từ các từ phụ phía sau.
- **Cách tiếp cận phức tạp hơn:**
 - Kết hợp phân phối xác suất nhẵn trên **toàn bộ** các từ phụ của một từ.
 - Tìm ra nhẵn cấp độ từ tối ưu nhất dựa trên sự đồng thuận của các subwords.

"Việc xử lý tốt Subword giúp mô hình NER mạnh mẽ hơn với các từ hiếm hoặc từ ngoài từ điển (OOV)."

9.5.4 Evaluating Named Entity Recognition

Các chỉ số cơ bản (Metrics)

- **Recall (Độ phủ):** Tỷ lệ thực thể đúng mô hình tìm được / Tổng thực thể thực tế. → *Đo lường mức độ "bỏ sót".*
- **Precision (Độ chính xác):** Tỷ lệ thực thể đúng / Tổng thực thể mô hình dự đoán. → *Đo lường mức độ "đoán mò".*
- **F1-Measure:** Trung bình điều hòa giữa Precision và Recall.

Kiểm định thống kê (Statistical Significance)

- Sử dụng **Paired Bootstrap** hoặc **Randomization test**.
- Mục tiêu: Khẳng định sự chênh lệch giữa các mô hình là thực tế, không phải ngẫu nhiên.

Evaluating Named Entity Recognition

- **Nguyên tắc:** Đơn vị đánh giá là **Thực thể**, không phải từng từ (word).
- **Ví dụ:** Cụm "*Jane Villanueva*" được tính là **01** kết quả đơn lẻ.

Tác vụ	Đơn vị huấn luyện	Đơn vị đánh giá
POS Tagging	Từ (Word)	Từ (Word)
NER	Từ (Word)	Thực thể (Entity)

⇒ Sự không khớp (**Mismatch**) giữa điều kiện huấn luyện và kiểm tra là một thách thức đặc thù của NER.

Evaluating Named Entity Recognition

Việc gán nhãn NER khó hơn phân loại văn bản vì có thành phần **phân đoạn (segmentation)**.

Hệ quả của việc khớp một phần (Partial Match):

- Giả sử mô hình chỉ nhận diện được *"Jane"* thay vì toàn bộ *"Jane Villanueva"*.
- **Gây ra 02 lỗi đồng thời:**
 - ❶ **False Positive:** Cho nhãn O (từ *"Villanueva"* bị bỏ sót).
 - ❷ **False Negative:** Cho nhãn I-PER (thực thể đúng bị mất).

"Chỉ cần sai 1 token trong cụm, toàn bộ thực thể bị tính là sai."

① Foundation: Bidirectional Encoders & MLM

- **Contextual Reps:** Tạo vector đặc trưng từ toàn bộ ngữ cảnh hai chiều (trái + phải).
- **MLM Objective:** Pretrain bằng cách đoán thông tin bị che (*masked information*).

② Contextual Embeddings vs. Word Senses

- **Nature:** Biểu diễn liên tục, đa chiều, giàu thông tin hơn các nghĩa từ rời rạc (*discrete senses*).
- **Similarity:** Dùng *Cosine similarity* để đo độ tương đồng trong ngữ cảnh (cần biến đổi vector trước).

③ Fine-tuning & Applications

- Tích hợp lớp *classifier* nhẹ trên mô hình pretrained cho các bài toán:
- **Classification:** Phân tích cảm xúc (Sentiment), Suy luận ngôn ngữ (NLI).
- **Sequence Labeling:** Nhận dạng thực thể có tên (NER).

CẢM ƠN CÁC BẠN!

Nhóm 3

QUIZ TIME!

Mời các bạn tham gia quizz để ôn lại kiến thức.