

Information Retrieval & Retrieval-Augmented Generation

Thành viên nhóm 1:

Bảo Quý Định Tân - 24520028

Lê Văn Thức - 24521748

Lê Phạm Thành Nhân - 24520022

University of Information Technology - VNUHCM

Ngày 22 tháng 4 năm 2026


Nội dung bài thuyết trình

- ➊ 11.0 Introduction
- ➋ 11.1 Information Retrieval
- ➌ 11.1.1 Vector Space Model
- ➍ 11.1.2 Term Weighting

- **Needs for Knowledge:** Con người luôn đặt câu hỏi cho máy tính ngay từ khi chúng xuất hiện.

Information Need: A Brief History

- **Needs for Knowledge:** Con người luôn đặt câu hỏi cho máy tính ngay từ khi chúng xuất hiện.



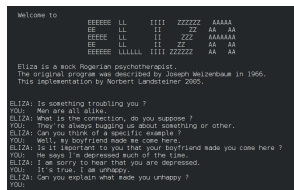

```
Welcome to
EEEEEE LL IIII ZZZZZZ AAAA
EE LL II ZZ AA AA
EEEE LL II ZZ AAAAAA
EE LL II ZZ AA AA
EEEE LLLLLL IIII ZZZZZZ AA AA

Eliza is a mock Rogerian psychotherapist.
The original program was described by Joseph Weizenbaum in 1966.
This implementation by Norbert Landsteiner 2005.

ELIZA: Is something troubling you ?
YOU: Men are all alike.
ELIZA: What is the connection, do you suppose ?
YOU: They're always bugging us about something or other.
ELIZA: Can you think of a specific example ?
YOU: Well, my boyfriend made me come here.
ELIZA: Is it important to you that your boyfriend made you come here ?
YOU: He says I'm depressed much of the time.
ELIZA: I am sorry to hear that you are depressed.
YOU: It's true. I am unhappy.
ELIZA: Can you explain what made you unhappy ?
YOU:
```

Information Need: A Brief History

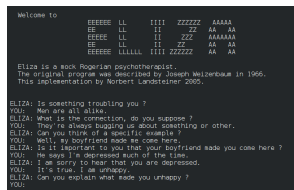

- **Needs for Knowledge:** Con người luôn đặt câu hỏi cho máy tính ngay từ khi chúng xuất hiện.



- LLM hiện nay đóng vai trò lớn trong việc đáp ứng nhu cầu thông tin của con người.

Information Need: A Brief History

- **Needs for Knowledge:** Con người luôn đặt câu hỏi cho máy tính ngay từ khi chúng xuất hiện.



- LLM hiện nay đóng vai trò lớn trong việc đáp ứng nhu cầu thông tin của con người.
- Chức năng giữa LLM và Công cụ tìm kiếm đang dần xóa nhòa.

How LLMs Answer Factoid Questions

Factoid Questions

Là các câu hỏi về sự thật có thể trả lời ngắn gọn:

- *"Bảo tàng Louvre nằm ở đâu?"*
- *"Năng lượng trong vụ nổ hạt nhân đến từ đâu?"*

How LLMs Answer Factoid Questions

Factoid Questions

Là các câu hỏi về sự thật có thể trả lời ngắn gọn:

- "*Bảo tàng Louvre nằm ở đâu?*"
- "*Năng lượng trong vụ nổ hạt nhân đến từ đâu?*"
- **Mechanism:** LLM trả lời trực tiếp thông qua việc dự đoán chuỗi từ tiếp theo (*conditional generation*) dựa trên prompt.

How LLMs Answer Factoid Questions

Factoid Questions

Là các câu hỏi về sự thật có thể trả lời ngắn gọn:

- "*Bảo tàng Louvre nằm ở đâu?*"
- "*Năng lượng trong vụ nổ hạt nhân đến từ đâu?*"
- **Mechanism:** LLM trả lời trực tiếp thông qua việc dự đoán chuỗi từ tiếp theo (*conditional generation*) dựa trên prompt.
- **Parametric Knowledge:**
 - Thông tin không nằm ở database ngoài mà được **embedding vào tham số** của mô hình.
 - Kiến thức thực tế được lưu trữ trong các lớp *feedforward* của Transformer Models (Geva et al., 2021).

How LLMs Answer Factoid Questions


Factoid Questions

Là các câu hỏi về sự thật có thể trả lời ngắn gọn:

- "*Bảo tàng Louvre nằm ở đâu?*"
- "*Năng lượng trong vụ nổ hạt nhân đến từ đâu?*"
- **Mechanism:** LLM trả lời trực tiếp thông qua việc dự đoán chuỗi từ tiếp theo (*conditional generation*) dựa trên prompt.
- **Parametric Knowledge:**
 - Thông tin không nằm ở database ngoài mà được **embedding vào tham số** của mô hình.
 - Kiến thức thực tế được lưu trữ trong các lớp *feedforward* của Transformer Models (Geva et al., 2021).

Vấn đề của LLMs: Static Knowledge & Hallucination


- **Knowledge Cut-off:** LLM chỉ biết những gì có trong dữ liệu huấn luyện.
- **Hallucination:** LLM tự tin tạo và đưa ra thông tin sai lệch khi thiếu dữ liệu, thậm chí khi đã từng được train qua.
- **Data Privacy:** LLM không được train từ dữ liệu nội bộ/cá nhân mang tính bảo mật.



Giải pháp: Retrieval-Augmented Generation (RAG)

Retrieval-Augmented Generation

Cung cấp cho LLM các tài liệu liên quan để mô hình trả lời dựa trên đó một cách đáng tin cậy.



Hình: Quy Trình RAG

11.1 Định nghĩa Information Retrieval (IR)

Information Retrieval là việc tìm kiếm các tài liệu có bản chất không cấu trúc (thường là văn bản) thỏa mãn nhu cầu thông tin từ một tập hợp lớn.

- **Ad hoc retrieval:** Người dùng đưa ra một *Query*, hệ thống trả về các *Documents* liên quan.


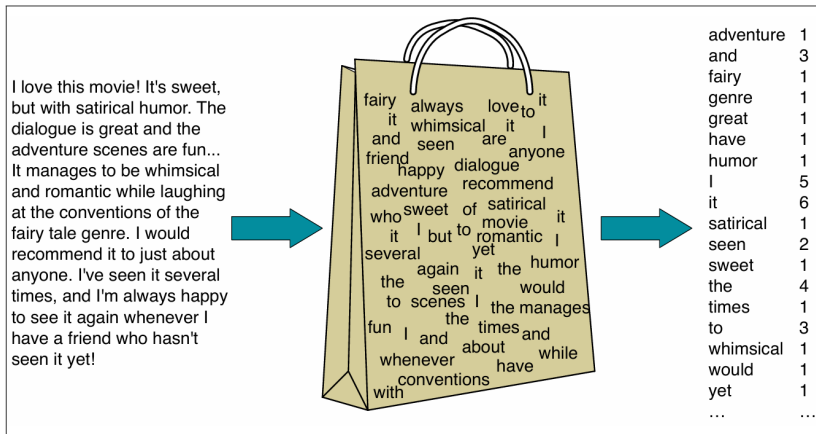


Figure 11.1 The architecture of an ad hoc IR system. Document ranking is based on computing a score for each candidate document given the query, expressing how **relevant** it is likely to be to meet the users information need. There are two classes of IR systems, based on the two classes of vectors that are used to represent queries and documents: sparse vectors and dense vectors. These two kinds of retrieval differ in the details of the indexing and scoring mechanisms.

11.1.1 Biểu diễn văn bản: Vector Space Model

- Mỗi tài liệu được biểu diễn như một điểm (Vector) trong không gian nhiều chiều.
- **Bag-of-Words:** Biểu diễn văn bản qua vector tần số các từ.
- **Term-Document Matrix** Một tập các documents có thể biểu diễn dưới dạng ma trận với mỗi documents là một vector cột và mỗi hàng là tần số của từ trong từng văn bản.

Bag-of-Words



Hình: Bag-of-Words

Term-Document Matrix

	As You Like It	Twelfth Night	Julius Caesar	Henry V
battle	1	0	7	13
good	114	80	62	89
fool	36	58	1	4
wit	20	15	2	3

- Mỗi cột là một **Document Vector**.
- Các tài liệu giống nhau có Document Vector tương đồng.

Term-Document Matrix




Figure 11.5 A spatial visualization of the document vectors for the four Shakespeare play documents, showing just two of the dimensions, corresponding to the words *battle* and *fool*. The comedies have high values for the *fool* dimension and low values for the *battle* dimension.

Hình: Các vở hài kịch có tần số "fool" cao và "battle" thấp, và ngược lại.

Term-Document Matrix




Figure 11.5 A spatial visualization of the document vectors for the four Shakespeare play documents, showing just two of the dimensions, corresponding to the words *battle* and *fool*. The comedies have high values for the *fool* dimension and low values for the *battle* dimension.

Hình: Các vở hài kịch có tần số "fool" cao và "battle" thấp, và ngược lại.

Đo độ tương đồng bằng?

Vấn đề với Term Frequency thuần

- "good" xuất hiện rất nhiều ở mọi tài liệu
- "battle" và "fool" có tính phân biệt rõ hơn
- Các từ phổ biến → **làm nhiễu**
- Raw count → **không phản ánh tầm quan trọng**

Hệ quả:

Similarity tính bằng count → dễ sai lệch

11.1.2 Trọng số Term: Tại sao đếm là chưa đủ?

Các từ phổ biến (the, a, and, good,...) xuất hiện ở mọi nơi nhưng không mang giá trị phân loại cao. Ta cần một phương pháp tăng trọng số cho các từ **đặc trưng**.

TF-IDF (Term Frequency - Inverse Document Frequency)

Kết hợp giữa tần suất xuất hiện trong tài liệu và độ hiếm trong toàn bộ collection.

1. Term Frequency (tf): Thường dùng Log để giảm ảnh hưởng của việc lặp từ quá nhiều.

$$tf_{t,d} = \log_{10}(\text{count}(t, d) + 1)$$

Inverse Document Frequency (idf)

idf giúp giảm trọng số các từ xuất hiện quá phổ biến trong nhiều tài liệu.

$$\text{idf}_t = \log_{10} \left(\frac{N}{\text{df}_t} \right)$$

- N : Tổng số tài liệu trong collection.
- df_t : Số tài liệu có chứa từ t .


Kết quả cuối cùng

$$w_{t,d} = \text{tf}_{t,d} \times \text{idf}_t$$

BM25 (Best Matching 25) là cải tiến của TF-IDF, được sử dụng rộng rãi trong Lucene, Elasticsearch, Solr.

Hai cải tiến chính:

- 1 **TF Saturation:** Giới hạn mức độ ảnh hưởng của TF (đường cong bão hòa nhanh hơn Log).
- 2 **Length Normalization:** Phạt các tài liệu quá dài (vì tài liệu dài dễ chứa nhiều từ ngẫu nhiên).



Hình: BM25 & log-tf.

Tiếp theo là

Tân

Cảm ơn Cô và các bạn đã lắng nghe!