

11.1.3 Document Scoring & Biểu thể tf-idf

Thành viên nhóm 1:

Bảo Quý Định Tân - 24520028

Lê Văn Thức - 24521748

Lê Phạm Thành Nhân - 24520022

University of Information Technology - VNUHCM

Ngày 22 tháng 4 năm 2026

11.1.3 Document Scoring

- Ta đã biểu diễn document và query dưới dạng vector.

11.1.3 Document Scoring

- Ta đã biểu diễn document và query dưới dạng vector.
- **Mục tiêu:** Đo độ liên quan (**relevance**) của **documents** đối với truy vấn (**query**) của người dùng.

11.1.3 Document Scoring

- Ta đã biểu diễn document và query dưới dạng vector.
- **Mục tiêu:** Đo độ liên quan (**relevance**) của **documents** đối với truy vấn (**query**) của người dùng.
- Trong mô hình **tf-idf** cổ điển, sử dụng: **độ tương đồng hình học (geometric similarity)** trong không gian vector.

11.1.3 Document Scoring

- Ta đã biểu diễn document và query dưới dạng vector.
- **Mục tiêu:** Đo độ liên quan (**relevance**) của **documents** đối với truy vấn (**query**) của người dùng.
- Trong mô hình **tf-idf** cổ điển, sử dụng: **độ tương đồng hình học (geometric similarity)** trong không gian vector.
- **Giả định:** Các document chứa **các từ tương đồng (similar words)** với truy vấn thì càng liên quan với nhau.

Sử dụng Cosine cho Document Scoring

- **Cosine similarity** để chấm điểm document d với query q :

$$\text{score}(q, d) = \cos(\mathbf{q}, \mathbf{d}) = \frac{\mathbf{q} \cdot \mathbf{d}}{|\mathbf{q}| |\mathbf{d}|} \quad (11.7)$$

Sử dụng Cosine cho Document Scoring

- **Cosine similarity** để chấm điểm document d với query q :

$$\text{score}(q, d) = \cos(\mathbf{q}, \mathbf{d}) = \frac{\mathbf{q} \cdot \mathbf{d}}{|\mathbf{q}| |\mathbf{d}|} \quad (11.7)$$

- Cosine là tích vô hướng của các **vector đơn vị** (chuẩn hóa vector trước bằng cách chia cho chiều dài của chúng):

$$\text{score}(q, d) = \cos(\mathbf{q}, \mathbf{d}) = \frac{\mathbf{q}}{|\mathbf{q}|} \cdot \frac{\mathbf{d}}{|\mathbf{d}|} \quad (11.8)$$

Sử dụng Cosine cho Document Scoring

- **Cosine similarity** để chấm điểm document d với query q :

$$\text{score}(q, d) = \cos(\mathbf{q}, \mathbf{d}) = \frac{\mathbf{q} \cdot \mathbf{d}}{\|\mathbf{q}\| \|\mathbf{d}\|} \quad (11.7)$$

- Cosine là tích vô hướng của các **vector đơn vị** (chuẩn hóa vector trước bằng cách chia cho chiều dài của chúng):

$$\text{score}(q, d) = \cos(\mathbf{q}, \mathbf{d}) = \frac{\mathbf{q}}{\|\mathbf{q}\|} \cdot \frac{\mathbf{d}}{\|\mathbf{d}\|} \quad (11.8)$$

- Khai triển công thức với giá trị **tf-idf**:

$$\text{score}(q, d) = \sum_{t \in q} \frac{\text{tf-idf}(t, q)}{\sqrt{\sum_{q_i \in q} \text{tf-idf}^2(q_i, q)}} \cdot \frac{\text{tf-idf}(t, d)}{\sqrt{\sum_{d_i \in d} \text{tf-idf}^2(d_i, d)}} \quad (11.9)$$

Ví dụ: Tính toán điểm tf-idf cosine

Query						
word	cnt	tf	df	idf	tf-idf	n'lized = tf-idf/ q
sweet	1	1	3	0.125	0.125	0.383
nurse	0	0	2	0.301	0	0
love	1	1	2	0.301	0.301	0.924
how	0	0	1	0.602	0	0
sorrow	0	0	1	0.602	0	0
is	0	0	1	0.602	0	0

$$|q| = \sqrt{.125^2 + .301^2} = .326$$

Query: sweet love

Doc 1: Sweet sweet nurse! Love?

Doc 2: Sweet sorrow

Doc 3: How sweet is love?

Doc 4: Nurse!

Document 1						Document 2				
word	cnt	tf	tf-idf	n'lized	× q	cnt	tf	tf-idf	n'lized	× q
sweet	2	1.301	0.163	0.357	0.137	1	1.000	0.125	0.203	0.0779
nurse	1	1.000	0.301	0.661	0	0	0	0	0	0
love	1	1.000	0.301	0.661	0.610	0	0	0	0	0
how	0	0	0	0	0	0	0	0	0	0
sorrow	0	0	0	0	0	1	1.000	0.602	0.979	0
is	0	0	0	0	0	0	0	0	0	0

$$|d_1| = \sqrt{.163^2 + .301^2 + .301^2} = .456$$

$$|d_2| = \sqrt{.125^2 + .602^2} = .615$$

Cosine: $\sum$ of column: **0.747**

Cosine: $\sum$ of column: **0.0779**

Figure 11.6 Computation of tf-idf cosine score between the query and nano-documents 1 (0.747) and 2 (0.0779), using Eq. 11.4, Eq. 11.5, Eq. 11.6 and Eq. 11.9.

Bảng tính toán TF-IDF Cosine (Doc 3 & Doc 4)

word	cnt	tf	df	Query		
				idf	tf-idf	n'lized (= tf-idf/ q)
sweet	1	1	3	0.125	0.125	0.383
nurse	0	0	2	0.301	0	0
love	1	1	2	0.301	0.301	0.924
how	0	0	1	0.602	0	0
sorrow	0	0	1	0.602	0	0
is	0	0	1	0.602	0	0

$|q| = \sqrt{0.125^2 + 0.301^2} = 0.326$

Query: sweet love

Doc 1: Sweet sweet nurse! Love?

Doc 2: Sweet sorrow

Doc 3: How sweet is love?

Doc 4: Nurse!

Document 3					
word	cnt	tf	tf-idf	n'lized	$\times q$
sweet	1	1	0.125	0.137	0.052
nurse	0	0	0	0	0
love	1	1	0.301	0.330	0.305
how	1	1	0.602	0.660	0
sorrow	0	0	0	0	0
is	1	1	0.602	0.660	0

$|d_3| = \sqrt{0.125^2 + \dots + 0.602^2} = 0.912$

Cosine: $\sum$ of column: **0.357**

Document 4					
word	cnt	tf	tf-idf	n'lized	$\times q$
sweet	0	0	0	0	0
nurse	1	1	0.301	1.000	0
love	0	0	0	0	0
how	0	0	0	0	0
sorrow	0	0	0	0	0
is	0	0	0	0	0

$|d_4| = \sqrt{0.301^2} = 0.301$

Cosine: $\sum$ of column: **0**

Các biến thể của tf-idf cosine

- Trong thực tế, có nhiều **biến thể và phép xấp xỉ** của Eq 11.9 để đơn giản hóa tính toán. Ta bắt đầu bằng cách tách rõ tf và idf:

$$\text{score}(q, d) = \sum_{t \in q} \frac{\text{tf-idf}(t, q)}{\sqrt{\sum_{q_i \in q} \text{tf-idf}^2(q_i, q)}} \cdot \frac{\text{tf-idf}(t, d)}{\sqrt{\sum_{d_i \in d} \text{tf-idf}^2(d_i, d)}} \quad (11.9)$$

$$= \sum_{t \in q} \frac{\text{tf}_{t,q} \cdot \text{idf}_t}{\sqrt{\sum_{q_i \in q} \text{tf-idf}^2(q_i, q)}} \cdot \frac{\text{tf}_{t,d} \cdot \text{idf}_t}{\sqrt{\sum_{d_i \in d} \text{tf-idf}^2(d_i, d)}} \quad (11.10)$$

Các biến thể của tf-idf cosine

- Trong thực tế, có nhiều **biến thể và phép xấp xỉ** của Eq 11.9 để đơn giản hóa tính toán. Ta bắt đầu bằng cách tách rõ tf và idf:

$$\text{score}(q, d) = \sum_{t \in q} \frac{\text{tf-idf}(t, q)}{\sqrt{\sum_{q_i \in q} \text{tf-idf}^2(q_i, q)}} \cdot \frac{\text{tf-idf}(t, d)}{\sqrt{\sum_{d_i \in d} \text{tf-idf}^2(d_i, d)}} \quad (11.9)$$

$$= \sum_{t \in q} \frac{\text{tf}_{t,q} \cdot \text{idf}_t}{\sqrt{\sum_{q_i \in q} \text{tf-idf}^2(q_i, q)}} \cdot \frac{\text{tf}_{t,d} \cdot \text{idf}_t}{\sqrt{\sum_{d_i \in d} \text{tf-idf}^2(d_i, d)}} \quad (11.10)$$

- Một biến thể phổ biến là **loại bỏ thành phần idf của document**. Điều này đôi khi mang lại **hiệu suất tốt hơn**:

$$\text{score}(q, d) = \sum_{t \in q} \frac{\text{tf}_{t,q} \cdot \text{idf}_t}{\sqrt{\sum_{q_i \in q} \text{tf-idf}^2(q_i, q)}} \cdot \frac{\text{tf}_{t,d}}{\sqrt{\sum_{d_i \in d} \text{tf-idf}^2(d_i, d)}} \quad (11.11)$$

Các biến thể khác: Smooth IDF (Làm mịn IDF)

- **Vấn đề của raw IDF:** Nhắc lại công thức gốc $\text{idf}_t = \log(\frac{N}{\text{df}_t})$.

Các biến thể khác: Smooth IDF (Làm mịn IDF)

- **Vấn đề của raw IDF:** Nhắc lại công thức gốc $\text{idf}_t = \log(\frac{N}{\text{df}_t})$.
- Nếu người dùng tìm một từ **chưa từng xuất hiện** trong tập dữ liệu (Out-of-Vocabulary), $\text{df}_t = 0$. Điều này gây ra lỗi toán học **chia cho 0** (Divide by Zero).

Các biến thể khác: Smooth IDF (Làm mịn IDF)

- **Vấn đề của raw IDF:** Nhắc lại công thức gốc $\text{idf}_t = \log(\frac{N}{\text{df}_t})$.
- Nếu người dùng tìm một từ **chưa từng xuất hiện** trong tập dữ liệu (Out-of-Vocabulary), $\text{df}_t = 0$. Điều này gây ra lỗi toán học **chia cho 0** (Divide by Zero).
- **Giải pháp:** Kỹ thuật **Làm mịn (Smoothing)** - cộng thêm 1 vào tử số và mẫu số.

Các biến thể khác: Smooth IDF (Làm mịn IDF)

- **Vấn đề của raw IDF:** Nhắc lại công thức gốc $\text{idf}_t = \log(\frac{N}{\text{df}_t})$.
- Nếu người dùng tìm một từ **chưa từng xuất hiện** trong tập dữ liệu (Out-of-Vocabulary), $\text{df}_t = 0$. Điều này gây ra lỗi toán học **chia cho 0** (Divide by Zero).
- **Giải pháp:** Kỹ thuật **Làm mịn (Smoothing)** - cộng thêm 1 vào tử số và mẫu số.

Các biến thể khác: Smooth IDF (Làm mịn IDF)

- **Vấn đề của raw IDF:** Nhắc lại công thức gốc $\text{idf}_t = \log(\frac{N}{\text{df}_t})$.
- Nếu người dùng tìm một từ **chưa từng xuất hiện** trong tập dữ liệu (Out-of-Vocabulary), $\text{df}_t = 0$. Điều này gây ra lỗi toán học **chia cho 0** (Divide by Zero).
- **Giải pháp:** Kỹ thuật **Làm mịn (Smoothing)** - cộng thêm 1 vào tử số và mẫu số.

Công thức Smooth IDF (Thường dùng trong Scikit-learn)

$$\text{idf}_t = \log\left(\frac{1 + N}{1 + \text{df}_t}\right) + 1$$

Các biến thể khác: Smooth IDF (Làm mịn IDF)

- **Vấn đề của raw IDF:** Nhắc lại công thức gốc $\text{idf}_t = \log(\frac{N}{\text{df}_t})$.
- Nếu người dùng tìm một từ **chưa từng xuất hiện** trong tập dữ liệu (Out-of-Vocabulary), $\text{df}_t = 0$. Điều này gây ra lỗi toán học **chia cho 0** (Divide by Zero).
- **Giải pháp:** Kỹ thuật **Làm mịn (Smoothing)** - cộng thêm 1 vào tử số và mẫu số.

Công thức Smooth IDF (Thường dùng trong Scikit-learn)

$$\text{idf}_t = \log\left(\frac{1 + N}{1 + \text{df}_t}\right) + 1$$

- **Ý nghĩa:** Giống như ta giả định luôn có thêm một "document ảo" chứa toàn bộ các từ trong từ vựng, giúp mô hình luôn ổn định trong thực tế.

Hệ số trọng lượng BM25 (Okapi BM25)

- **BM25** là một biến thể phức tạp hơn thuộc họ tf-idf.

Hệ số trọng lượng BM25 (Okapi BM25)

- **BM25** là một biến thể phức tạp hơn thuộc họ tf-idf.
- BM25 thêm hai tham số: k (điều chỉnh sự cân bằng giữa term frequency và IDF) và b (kiểm soát mức độ quan trọng của việc chuẩn hóa độ dài document).

Hệ số trọng lượng BM25 (Okapi BM25)

- **BM25** là một biến thể phức tạp hơn thuộc họ tf-idf.
- BM25 thêm hai tham số: k (điều chỉnh sự cân bằng giữa term frequency và IDF) và b (kiểm soát mức độ quan trọng của việc chuẩn hóa độ dài document).
- Công thức tính điểm BM25 của document d với truy vấn q :

$$\sum_{t \in q} \log \left(\frac{N}{df_t} \right) \frac{tf_{t,d}(k+1)}{k \left(1 - b + b \left(\frac{|d|}{|d_{avg}|} \right) \right) + tf_{t,d}} \quad (11.12)$$

Hệ số trọng lượng BM25 (Okapi BM25)

- **BM25** là một biến thể phức tạp hơn thuộc họ tf-idf.
- BM25 thêm hai tham số: k (điều chỉnh sự cân bằng giữa term frequency và IDF) và b (kiểm soát mức độ quan trọng của việc chuẩn hóa độ dài document).
- Công thức tính điểm BM25 của document d với truy vấn q :

$$\sum_{t \in q} \log \left(\frac{N}{df_t} \right) \frac{\text{tf}_{t,d}(k+1)}{k \left(1 - b + b \left(\frac{|d|}{|d_{\text{avg}}|} \right) \right) + \text{tf}_{t,d}} \quad (11.12)$$

- $|d_{\text{avg}}|$: là chiều dài trung bình của các document ta có.

Động lực cho BM25: Tại sao cần giải quyết Term Saturation?

- **Trực giác (Intuition):** Sự khác biệt giữa việc một từ khóa xuất hiện 0 lần và 1 lần là tín hiệu **rất mạnh**. Nhưng sự khác biệt giữa 99 lần và 100 lần gần như **không mang thêm thông tin mới** (Diminishing Returns).

Động lực cho BM25: Tại sao cần giải quyết Term Saturation?

- **Trực giác (Intuition):** Sự khác biệt giữa việc một từ khóa xuất hiện 0 lần và 1 lần là tín hiệu **rất mạnh**. Nhưng sự khác biệt giữa 99 lần và 100 lần gần như **không mang thêm thông tin mới** (Diminishing Returns).
- **Vấn đề của TF-IDF:** Dù dùng $\log_{10}$ trong công thức, nhưng điểm số vẫn tăng mãi mãi. Chỉ cần copy-paste từ khóa liên tục để thao túng thứ hạng.

Động lực cho BM25: Tại sao cần giải quyết Term Saturation?

- **Chứng minh Toán:** Điều gì xảy ra khi số lần xuất hiện (tf) tiến tới vô cực?

So sánh Giới hạn (Asymptote) khi $tf \rightarrow \infty$

TF-IDF (Log):

$$\lim_{\text{count}(t,d) \rightarrow \infty} (1 + \log_{10}(\text{count}(t, d))) = \infty \quad (\text{Không chặn})$$

BM25 TF:

$$\lim_{tf \rightarrow \infty} \frac{(k+1) \cdot tf}{k + tf} = k + 1 \quad (\text{Bị chặn trên})$$

BM25: Giải quyết Term Saturation (Tham số k)

Sự ra đời của tham số k

BM25 tạo ra một **giới hạn trên** cho tf tại $k + 1$. Tham số k chính là **tham số** được sinh ra để điều chỉnh cận trên này!

BM25: Giải quyết Term Saturation (Tham số k)

Sự ra đời của tham số k

BM25 tạo ra một **giới hạn trên** cho tf tại $k + 1$. Tham số k chính là **tham số** được sinh ra để điều chỉnh cận trên này!

- Tác động của tham số k :

BM25: Giải quyết Term Saturation (Tham số k)

Sự ra đời của tham số k

BM25 tạo ra một **giới hạn trên** cho tf tại $k + 1$. Tham số k chính là **tham số** được sinh ra để điều chỉnh cận trên này!

- **Tác động của tham số k :**
 - $k = 0$: Phớt lờ TF. Chỉ dựa trên IDF.

BM25: Giải quyết Term Saturation (Tham số k)

Sự ra đời của tham số k

BM25 tạo ra một **giới hạn trên** cho tf tại $k + 1$. Tham số k chính là **tham số** được sinh ra để điều chỉnh cận trên này!

- **Tác động của tham số k :**

- $k = 0$: Phớt lờ TF. Chỉ dựa trên IDF.
- $k \rightarrow \infty$: BM25 trở thành TF-IDF thông thường, điểm tiếp tục tăng không giới hạn.

BM25: Giải quyết Term Saturation (Tham số k)

Sự ra đời của tham số k

BM25 tạo ra một **giới hạn trên** cho tf tại $k + 1$. Tham số k chính là **tham số** được sinh ra để điều chỉnh cận trên này!

- **Tác động của tham số k :**

- $k = 0$: Phớt lờ TF. Chỉ dựa trên IDF.
- $k \rightarrow \infty$: BM25 trở thành TF-IDF thông thường, điểm tiếp tục tăng không giới hạn.
- k **tiêu chuẩn** (1.2 $\rightarrow$ 2.0): Điểm tăng nhanh ở 1-3 lần xuất hiện đầu, sau đó **saturate** (bão hòa) và đi ngang.

BM25: Giải quyết Term Saturation (Tham số k)

Sự ra đời của tham số k

BM25 tạo ra một **giới hạn trên** cho tf tại $k + 1$. Tham số k chính là **tham số** được sinh ra để điều chỉnh cận trên này!

- **Tác động của tham số k :**

- $k = 0$: Phớt lờ TF. Chỉ dựa trên IDF.
- $k \rightarrow \infty$: BM25 trở thành TF-IDF thông thường, điểm tiếp tục tăng không giới hạn.
- k **tiêu chuẩn** (1.2 $\rightarrow$ 2.0): Điểm tăng nhanh ở 1-3 lần xuất hiện đầu, sau đó **saturate** (bão hòa) và đi ngang.

BM25: Giải quyết Term Saturation (Tham số k)

Sự ra đời của tham số k

BM25 tạo ra một **giới hạn trên** cho tf tại $k + 1$. Tham số k chính là **tham số** được sinh ra để điều chỉnh cận trên này!

- **Tác động của tham số k :**

- $k = 0$: Phớt lờ TF. Chỉ dựa trên IDF.
- $k \rightarrow \infty$: BM25 trở thành TF-IDF thông thường, điểm tiếp tục tăng không giới hạn.
- k **tiêu chuẩn** (1.2 $\rightarrow$ 2.0): Điểm tăng nhanh ở 1-3 lần xuất hiện đầu, sau đó **saturate** (bão hòa) và đi ngang.

Kết luận

Tham số k chặn đứng keyword stuffing. Dù lặp lại bao nhiêu lần, Term Score không bao giờ vượt qua ngưỡng ($k + 1$).

BM25: Giải quyết Term Saturation (Tham số k)

Minh họa trên Geogebra :o

Động lực cho BM25: Tại sao cần giải quyết Document Length Bias?

- **Trực giác (Intuition):** Cùng chứa 5 từ "apple".

Động lực cho BM25: Tại sao cần giải quyết Document Length Bias?

- **Trực giác (Intuition):** Cùng chứa 5 từ "apple".
 - **Dòng Tweet (10 từ):** Mật độ 50%. Tín hiệu **cực mạnh** về chủ đề.

Động lực cho BM25: Tại sao cần giải quyết Document Length Bias?

- **Trực giác (Intuition):** Cùng chứa 5 từ "apple".
 - **Dòng Tweet (10 từ):** Mật độ 50%. Tín hiệu **cực mạnh** về chủ đề.
 - **Cuốn tiểu thuyết (10,000 từ):** Mật độ 0.05%, chỉ vô tình nhắc đến.

Động lực cho BM25: Tại sao cần giải quyết Document Length Bias?

- **Trực giác (Intuition):** Cùng chứa 5 từ "apple".
 - **Dòng Tweet (10 từ):** Mật độ 50%. Tín hiệu **cực mạnh** về chủ đề.
 - **Cuốn tiểu thuyết (10,000 từ):** Mật độ 0.05%, chỉ vô tình nhắc đến.
- **Vấn đề của TF-IDF:** Thuật toán chỉ đếm **số lượng** mà phớt lờ độ dài ngữ cảnh. Do đó, nó đánh giá Dòng Tweet và Cuốn tiểu thuyết **bằng điểm nhau**.

Động lực cho BM25: Tại sao cần giải quyết Document Length Bias?

- **Trực giác (Intuition):** Cùng chứa 5 từ "apple".
 - **Dòng Tweet (10 từ):** Mật độ 50%. Tín hiệu **cực mạnh** về chủ đề.
 - **Cuốn tiểu thuyết (10,000 từ):** Mật độ 0.05%, chỉ vô tình nhắc đến.
- **Vấn đề của TF-IDF:** Thuật toán chỉ đếm **số lượng** mà phớt lờ độ dài ngữ cảnh. Do đó, nó đánh giá Dòng Tweet và Cuốn tiểu thuyết **bằng điểm nhau**.
- **Giải pháp Toán học:** Cần một cơ chế chuẩn hóa (Normalization) để "phạt" các document dài dòng.

Động lực cho BM25: Tại sao cần giải quyết Document Length Bias?

So sánh Tỷ lệ Chiều dài $\frac{|d|}{|d_{avg}|}$

BM25 đặt tỷ lệ giữa **chiều dài document hiện tại** ($|d|$) và **chiều dài trung bình** ($|d_{avg}|$) vào dưới mẫu số:

- Nếu $\frac{|d|}{|d_{avg}|} > 1 \rightarrow$ Document dài hơn mức bình thường $\rightarrow$ **Bị Phạt** (Mẫu số tăng, Điểm giảm).
- Nếu $\frac{|d|}{|d_{avg}|} < 1 \rightarrow$ Document ngắn gọn, súc tích $\rightarrow$ **Được Thưởng** (Mẫu số giảm, Điểm tăng).

Động lực cho BM25: Tại sao cần giải quyết Document Length Bias?

So sánh Tỷ lệ Chiều dài $\frac{|d|}{|d_{avg}|}$

BM25 đặt tỷ lệ giữa **chiều dài document hiện tại** ($|d|$) và **chiều dài trung bình** ($|d_{avg}|$) vào dưới mẫu số:

- Nếu $\frac{|d|}{|d_{avg}|} > 1 \rightarrow$ Document dài hơn mức bình thường $\rightarrow$ **Bị Phạt** (Mẫu số tăng, Điểm giảm).
- Nếu $\frac{|d|}{|d_{avg}|} < 1 \rightarrow$ Document ngắn gọn, súc tích $\rightarrow$ **Được Thưởng** (Mẫu số giảm, Điểm tăng).

Sự ra đời của tham số b

Tuy nhiên, không phải document dài nào cũng là "spam" (ví dụ: bài nghiên cứu khoa học). Vì vậy, BM25 tạo ra **tham số b** cho phép chúng ta quyết định mức độ **ngghiêm khắc** của hình phạt chiều dài này.

BM25: Giải quyết Document Length Bias (Tham số b)

- Tác động của tham số b (Length normalization):

BM25: Giải quyết Document Length Bias (Tham số b)

- **Tác động của tham số b (Length normalization):**
 - $b = 1$: Full penalty. Phạt tối đa các document dài.

BM25: Giải quyết Document Length Bias (Tham số b)

- **Tác động của tham số b (Length normalization):**
 - $b = 1$: Full penalty. Phạt tối đa các document dài.
 - $b = 0$: No penalty. Bỏ qua hoàn toàn yếu tố chiều dài document.

BM25: Giải quyết Document Length Bias (Tham số b)

- **Tác động của tham số b (Length normalization):**
 - $b = 1$: Full penalty. Phạt tối đa các document dài.
 - $b = 0$: No penalty. Bỏ qua hoàn toàn yếu tố chiều dài document.
 - b **tiêu chuẩn** (0.75): Partial penalty. Công nhận document dài có thể chứa nhiều thông tin thật, nhưng vẫn normalize để document ngắn có cơ hội cạnh tranh công bằng.

BM25: Giải quyết Document Length Bias (Tham số b)

- **Tác động của tham số b (Length normalization):**
 - $b = 1$: Full penalty. Phạt tối đa các document dài.
 - $b = 0$: No penalty. Bỏ qua hoàn toàn yếu tố chiều dài document.
 - b **tiêu chuẩn** (0.75): Partial penalty. Công nhận document dài có thể chứa nhiều thông tin thật, nhưng vẫn normalize để document ngắn có cơ hội cạnh tranh công bằng.

BM25: Giải quyết Document Length Bias (Tham số b)

- **Tác động của tham số b (Length normalization):**
 - $b = 1$: Full penalty. Phạt tối đa các document dài.
 - $b = 0$: No penalty. Bỏ qua hoàn toàn yếu tố chiều dài document.
 - b **tiêu chuẩn** (0.75): Partial penalty. Công nhận document dài có thể chứa nhiều thông tin thật, nhưng vẫn normalize để document ngắn có cơ hội cạnh tranh công bằng.

Kết luận

Tham số b đòi hỏi một document dài thì phải có **Term Density** (mật độ từ khóa) tương xứng với chiều dài của nó.

BM25: Giải quyết Document Length Bias (Tham số b)

Minh họa trên Geogebra :o

Từ dừng (Stop words)

- **Stop list:** Danh sách các từ có **tần suất xuất hiện cao** bị loại bỏ khỏi truy vấn và document trước khi biểu diễn chúng.

Từ dừng (Stop words)

- **Stop list:** Danh sách các từ có **tần suất xuất hiện cao** bị loại bỏ khỏi truy vấn và document trước khi biểu diễn chúng.
- **Trực giác:** Các từ chức năng (như *the*, *a*, *to*):

Từ dừng (Stop words)

- **Stop list:** Danh sách các từ có **tần suất xuất hiện cao** bị loại bỏ khỏi truy vấn và document trước khi biểu diễn chúng.
- **Trực giác:** Các từ chức năng (như *the*, *a*, *to*):
 - Mang ít trọng lượng ngữ nghĩa.

Từ dừng (Stop words)

- **Stop list:** Danh sách các từ có **tần suất xuất hiện cao** bị loại bỏ khỏi truy vấn và document trước khi biểu diễn chúng.
- **Trực giác:** Các từ chức năng (như *the*, *a*, *to*):
 - Mang ít trọng lượng ngữ nghĩa.
 - Không giúp ích nhiều cho việc truy xuất thông tin.

Từ dừng (Stop words)

- **Stop list:** Danh sách các từ có **tần suất xuất hiện cao** bị loại bỏ khỏi truy vấn và document trước khi biểu diễn chúng.
- **Trực giác:** Các từ chức năng (như *the, a, to*):
 - Mang ít trọng lượng ngữ nghĩa.
 - Không giúp ích nhiều cho việc truy xuất thông tin.
 - Loại bỏ chúng giúp thu nhỏ chỉ mục (inverted index).

Từ dừng (Stop words)

- **Stop list:** Danh sách các từ có **tần suất xuất hiện cao** bị loại bỏ khỏi truy vấn và document trước khi biểu diễn chúng.
- **Trực giác:** Các từ chức năng (như *the, a, to*):
 - Mang ít trọng lượng ngữ nghĩa.
 - Không giúp ích nhiều cho việc truy xuất thông tin.
 - Loại bỏ chúng giúp thu nhỏ chỉ mục (inverted index).
- **Nhược điểm:** Gây khó khăn khi tìm kiếm các cụm từ chứa từ trong stop list (ví dụ: *to be or not to be* sẽ chỉ còn *not*).

Từ dừng (Stop words)

- **Stop list:** Danh sách các từ có **tần suất xuất hiện cao** bị loại bỏ khỏi truy vấn và document trước khi biểu diễn chúng.
- **Trực giác:** Các từ chức năng (như *the, a, to*):
 - Mang ít trọng lượng ngữ nghĩa.
 - Không giúp ích nhiều cho việc truy xuất thông tin.
 - Loại bỏ chúng giúp thu nhỏ chỉ mục (inverted index).
- **Nhược điểm:** Gây khó khăn khi tìm kiếm các cụm từ chứa từ trong stop list (ví dụ: *to be or not to be* sẽ chỉ còn *not*).
- **Hiện nay:** Việc sử dụng stop list **ít phổ biến hơn** do hiệu năng hệ thống được cải thiện và chức năng của nó phần lớn đã được xử lý bởi **IDF weighting**, giảm trọng số các từ **xuất hiện trong mọi document** (không có ý nghĩa nhiều trong việc phân biệt các document).

- Để có thể tính được các loại điểm như trên thì ta cần phải tìm ra được các document $d \in C$ có chứa các term $q \in Q$ trong query.

- Để có thể tính được các loại điểm như trên thì ta cần phải tìm ra được các document $d \in C$ có chứa các term $q \in Q$ trong query.
- Cấu trúc dữ liệu: **inverted index**

- Để có thể tính được các loại điểm như trên thì ta cần phải tìm ra được các document $d \in C$ có chứa các term $q \in Q$ trong query.
- Cấu trúc dữ liệu: **inverted index**
 - Tìm kiếm **hiệu quả**.

- Để có thể tính được các loại điểm như trên thì ta cần phải tìm ra được các document $d \in C$ có chứa các term $q \in Q$ trong query.
- Cấu trúc dữ liệu: **inverted index**
 - Tìm kiếm **hiệu quả**.
 - Lưu trữ thêm các **thông tin hữu ích** (df, tf, ...).

Inverted Index

- Đầu vào: 1 query term

Inverted Index

- Đầu vào: 1 query term
- Đầu ra: Danh sách các document chứa term đó

Inverted Index

- Đầu vào: 1 query term
- Đầu ra: Danh sách các document chứa term đó
 - Dictionary: các term trong query và $\{df\}$

Inverted Index

- Đầu vào: 1 query term
- Đầu ra: Danh sách các document chứa term đó
 - Dictionary: các term trong query và $\{df\}$
 - Postings list: document ID và $[tf]$ hoặc vị trí chính xác của term trong document.

Inverted Index

- Đầu vào: 1 query term
- Đầu ra: Danh sách các document chứa term đó
 - Dictionary: các term trong query và $\{df\}$
 - Postings list: document ID và $[tf]$ hoặc vị trí chính xác của term trong document.

Inverted Index

- Đầu vào: 1 query term
- Đầu ra: Danh sách các document chứa term đó
 - Dictionary: các term trong query và $\{df\}$
 - Postings list: document ID và $[tf]$ hoặc vị trí chính xác của term trong document.

how {1}	→	3 [1]
is {1}	→	3 [1]
love {2}	→	1 [1] → 3 [1]
nurse {2}	→	1 [1] → 4 [1]
sorrow {1}	→	2 [1]
sweet {3}	→	1 [2] → 2 [1] → 3 [1]