

RNNs and LSTMs

CS221 - Natural Language Processing


Duy Dang Phu Anh Mai Quoc Bao Luong Huynh Gia Lac
Tran Nguyen Khai

University of Information Technology, VNU-HCM

March 2026


Giảng viên hướng dẫn: TS. Nguyễn Thị Quý

Các kiến trúc phổ biến



Hình: Các kiến trúc RNN phổ biến cho tác vụ NLP

Kiến trúc mạng Encoder-Decoder



Hình: Mạng Encoder-Decoder

Kiến trúc mạng Encoder-Decoder

Một mạng Encoder-Decoder gồm ba thành phần chính:

- **Encoder:** Chuyển đổi chuỗi đầu vào $x_{1:n}$ thành các biểu diễn ngữ cảnh $h_{1:n}$ tương ứng
- **Context vector (c):** Được tính toán từ $h_{1:n}$, đóng vai trò là nút thắt giúp nén và truyền tải thông tin của dữ liệu đầu vào sang Decoder.
- **Decoder:** Giải mã c để sinh ra chuỗi trạng thái ẩn $h_{1:m}$, từ đó thu được các đầu ra $y_{1:m}$ tương ứng với độ dài tùy ý.

Kiến trúc mạng Encoder-Decoder

- **Đặc điểm:** Còn được gọi là mạng **Sequence-to-Sequence (seq2seq)**, cho phép tạo ra các chuỗi đầu ra có độ dài tùy ý từ một chuỗi đầu vào.
- **Ứng dụng:** Được triển khai rộng rãi trong các bài toán dịch máy (machine translation), tóm tắt văn bản (summarization), hệ thống hỏi đáp (QA) và hội thoại tự động (dialogue).

Mô hình ngôn ngữ với RNN

- Với mô hình ngôn ngữ RNN $p(y)$

$$p(y) = p(y_1)p(y_2|y_1) \dots p(y_m|y_1, \dots, y_{m-1}) \quad (13.28)$$

- Tại mỗi bước t , mạng RNN nén thông tin từ các token đứng trước (prefix) vào trạng thái ẩn $\mathbf{h}_t$, dùng để dự đoán token kế tiếp.
- Quá trình cập nhật trạng thái và tính toán đầu ra tại bước t được thực hiện thông qua hàm kích hoạt g và hàm softmax:

$$\mathbf{h}_t = g(\mathbf{h}_{t-1}, \mathbf{x}_t) \quad (13.29)$$

$$\hat{\mathbf{y}}_t = \text{softmax}(\mathbf{h}_t) \quad (13.30)$$

Vấn đề

Làm sao để biến một mô hình ngôn ngữ tự hồi quy (Autoregressive LM) thành mô hình dịch máy (Translation Model)?


Mô hình dịch máy

- **Cơ chế chuyển đổi:** Ta thêm một **token phân tách** câu (ví dụ: $\langle s \rangle$) vào cuối văn bản nguồn rồi nối tiếp văn bản đích.
- **Cấu trúc dữ liệu:**
 - Gọi x là tổ hợp của văn bản nguồn và token phân tách $\langle s \rangle$.
 - Gọi y là văn bản đích (ví dụ: dịch từ tiếng Anh sang tiếng Tây Ban Nha).
- **Xác suất điều kiện:** Mô hình tính toán xác suất của chuỗi đích y khi đã biết ngữ cảnh nguồn x theo công thức:

$$p(y|x) = p(y_1|x)p(y_2|y_1, x) \dots p(y_m|y_1, \dots, y_{m-1}, x) \quad (13.31)$$

Mô hình dịch máy


- **Mã hóa:** Chuỗi nguồn được xử lý qua mạng để trích xuất các trạng thái ẩn cho đến khi chạm tới token phân tách <s>.
- **Giải mã:** Thực hiện sinh tự hồi quy chuỗi đích dựa trên trạng thái ẩn h_n và từ đã được tạo trước đó.



Cơ chế giải mã

- Mô hình toán học:** Tại mỗi bước t , trạng thái ẩn được cập nhật dựa theo:

$$\begin{aligned}c &= h_n^e \\h_0^d &= c \\h_t^d &= g(\hat{y}_{t-1}, h_{t-1}^d, c) \\\hat{y}_t &= \text{softmax}(h_t^d)\end{aligned}\tag{13.33}$$




Mô hình ngôn ngữ với RNN

Mô hình còn có thể được áp dụng cho các bài toán khác:

- **Hỏi-Đáp:** [Câu hỏi] <s> [Câu trả lời]
- **Tóm tắt văn bản:** [Đoạn văn bản dài] <s> [Câu tóm tắt]
- **Dịch máy:** [Câu ở ngôn ngữ A] <s> [Câu này ở ngôn ngữ B]

Huấn luyện Kiến trúc Encoder-Decoder

- **Cơ chế End-to-End:** Toàn bộ kiến trúc được huấn luyện như một khối thống nhất, tối ưu hóa đồng thời các tham số của cả Encoder và Decoder.



Hình: Minh họa quy trình huấn luyện với hàm mất mát Cross-Entropy

Kỹ thuật Teacher Forcing trong Huấn luyện

- **Vấn đề:** Trong quá trình suy luận, Decoder sử dụng kết quả dự báo $\hat{y}_t$ làm đầu vào cho bước x_{t+1} , dẫn đến sai số tích lũy dần so với chuỗi chuẩn.

Cơ chế Teacher Forcing

$$x_{t+1} = \text{gold_target}_t \quad (\text{Thay vì } x_{t+1} = \hat{y}_t)$$

- **Lợi ích cốt lõi:** Giúp ổn định quá trình học và tăng tốc độ hội tụ của mô hình bằng cách cung cấp tín hiệu đúng tại mỗi bước thời gian.