

Chapter 17 – Sequence Labeling for Parts of Speech and Named Entities

Sections 17.4.5 - 17.8

Group 8

Dương Hoàng Việt Hồ Hữu Tây Phạm Ngọc Thọ Lê Thiên Quân

Môn học: CS221

Trường Đại học Công nghệ Thông tin, ĐHQG-HCM

Ngày 11 tháng 5 năm 2026

- 1 17.4.5 The Viterbi Algorithm
- 2 17.5 Conditional Random Fields (CRFs)
- 3 17.6 Evaluation of Named Entity Recognition
- 4 17.7 Further Details

HMM Decoding Problem

HMM Decoding

Cho chuỗi quan sát (words) $w_1, \dots, w_n$, ta cần tìm chuỗi tags có xác suất lớn nhất:

$$\hat{t}_{1:n} = \arg \max_{t_1 \dots t_n} P(t_1 \dots t_n \mid w_1 \dots w_n) \approx \arg \max_{t_1 \dots t_n} \prod_{i=1}^n P(w_i \mid t_i) P(t_i \mid t_{i-1}) \quad (17.17)$$

Problem: Brute Force Search

Nếu: k = number of tags, n = sentence length

thì: số tag sequences cần xét là: k^n

HMM Decoding Problem

HMM Decoding

Cho chuỗi quan sát (words) $w_1, \dots, w_n$, ta cần tìm chuỗi tags có xác suất lớn nhất:

$$\hat{t}_{1:n} = \arg \max_{t_1 \dots t_n} P(t_1 \dots t_n \mid w_1 \dots w_n) \approx \arg \max_{t_1 \dots t_n} \prod_{i=1}^n P(w_i \mid t_i) P(t_i \mid t_{i-1}) \quad (17.17)$$

Problem: Brute Force Search

Nếu: k = number of tags, n = sentence length

thì: số tag sequences cần xét là: k^n

Question

Làm thế nào để tìm chuỗi tags **tối ưu**?

Viterbi Algorithm

Key Idea

Viterbi Algorithm là một thuật toán **Dynamic Programming** được sử dụng để tìm chuỗi hidden states tốt nhất.

Brute Force

- Thử toàn bộ paths
- Complexity:
 $O(k^n)$
- Không khả thi với sequence dài

Viterbi

- Chỉ lưu **best path**
- Reuse kết quả trước đó
- Complexity:
 $O(nk^2)$

Core Intuition

Tại mỗi thời điểm, Viterbi chỉ giữ lại:

best path to each state

thay vì lưu tất cả paths.

Meaning of a Viterbi Cell

Viterbi Value

Mỗi ô trong lattice được ký hiệu là:

$$v_t(j)$$

Biểu diễn **xác suất lớn nhất của mọi path có thể**, khi đã xét đến từ thứ t và tag của từ thứ t là j .

$$v_t(j) = \max_{q_1, \dots, q_{t-1}} P(q_1 \dots q_{t-1}, o_1, o_2 \dots o_t, q_t = j \mid \lambda) \quad (17.18)$$

- λ : HMM model
- $q_t = j$: tag của từ thứ t là j
- max: chọn path có xác suất lớn nhất

Recursive Equation of Viterbi

Recursive Step

Giá trị của mỗi cell được tính từ:

- 1 best path trước đó
- 2 transition probability
- 3 emission probability

$$v_t(j) = \max_{i=1}^N v_{t-1}(i) a_{ij} b_j(o_t) \quad (17.19)$$

$v_{t-1}(i)$ best path probability trước đó

a_{ij} transition probability ($a_{ij} = P(q_j | q_i)$, tương ứng với $P(t_i | t_{i-1})$ trong HMM tagging)

$b_j(o_t)$ observation likelihood ($b_j(o_t) = P(o_t | q_j)$, tương ứng với $P(w_i | t_i)$)

Viterbi Lattice Representation




Figure 17.11 A sketch of the lattice for *Janet will back the bill*, showing the possible tags (q_i) for each word and highlighting the path corresponding to the correct tag sequence through the hidden states. States (parts of speech) which have a zero probability of generating a particular word according to the B matrix (such as the probability that a determiner DT will be realized as *Janet*) are greyed out.

Viterbi Algorithm Pseudocode

```
function VITERBI(observations of len  $T$ , state-graph of len  $N$ ) returns best-path, path-prob

create a path probability matrix viterbi[ $N, T$ ]
create a backpointer matrix backpointer[ $N, T$ ]
for each state  $s$  from 1 to  $N$  do                                ; initialization step
    viterbi[ $s, 1$ ]  $\leftarrow \pi_s * b_s(o_1)$ 
    backpointer[ $s, 1$ ]  $\leftarrow 0$ 
for each time step  $t$  from 2 to  $T$  do                            ; recursion step
    for each state  $s$  from 1 to  $N$  do
        viterbi[ $s, t$ ]  $\leftarrow \max_{s'=1}^N \text{viterbi}[s', t-1] * a_{s',s} * b_s(o_t)$ 
        backpointer[ $s, t$ ]  $\leftarrow \operatorname{argmax}_{s'=1}^N \text{viterbi}[s', t-1] * a_{s',s} * b_s(o_t)$ 

bestpathprob  $\leftarrow \max_{s=1}^N \text{viterbi}[s, T]$                         ; termination step

bestpathpointer  $\leftarrow \operatorname{argmax}_{s=1}^N \text{viterbi}[s, T]$                 ; termination step

bestpath  $\leftarrow$  the path starting at state bestpathpointer, that follows backpointer[] to states back in time
return bestpath, bestpathprob
```

Figure 17.10 Viterbi algorithm for finding the optimal sequence of tags. Given an observation sequence and an HMM $\lambda = (A, B)$, the algorithm returns the state path through the HMM that assigns maximum likelihood to the observation sequence.

Key Takeaways of Viterbi

Why Viterbi?

Viterbi giúp HMM decoding trở nên feasible bằng cách:

- Không duyệt toàn bộ tag sequences
- Reuse kết quả từ timestep trước
- Chỉ lưu **best partial path**

Complexity Reduction

$$O(k^n) \rightarrow O(nk^2)$$

17.4.6 Working through an example

Bài toán & Công thức Viterbi

Mục tiêu: Tìm chuỗi nhãn POS tối ưu ($\hat{t}_{1:n}$) cho chuỗi quan sát sau:

"Janet will back the bill"

17.4.6 Working through an example

Bài toán & Công thức Viterbi

Mục tiêu: Tìm chuỗi nhãn POS tối ưu ($\hat{t}_{1:n}$) cho chuỗi quan sát sau:

"Janet will back the bill"

Công thức tính toán tại mỗi ô (Cell):

$$v_t(j) = \max_{i=1}^N v_{t-1}(i) \times a_{ij} \times b_j(o_t)$$

Tham số Ma trận Transition và Emission

Để thực hiện thuật toán Viterbi cho câu "*Janet will back the bill*", chúng ta cần trích xuất các giá trị xác suất từ ma trận A (Transition) và B (Emission) đã được huấn luyện từ tập dữ liệu WSJ.

Tham số Ma trận Transition và Emission

Để thực hiện thuật toán Viterbi cho câu "*Janet will back the bill*", chúng ta cần trích xuất các giá trị xác suất từ ma trận A (Transition) và B (Emission) đã được huấn luyện từ tập dữ liệu WSJ.

	NNP	MD	VB	JJ	NN	RB	DT
< <i>s</i> >	0.2767	0.0006	0.0031	0.0453	0.0449	0.0510	0.2026
NNP	0.3777	0.0110	0.0009	0.0084	0.0584	0.0090	0.0025
MD	0.0008	0.0002	0.7968	0.0005	0.0008	0.1698	0.0041
VB	0.0322	0.0005	0.0050	0.0837	0.0615	0.0514	0.2231
JJ	0.0366	0.0004	0.0001	0.0733	0.4509	0.0036	0.0036
NN	0.0096	0.0176	0.0014	0.0086	0.1216	0.0177	0.0068
RB	0.0068	0.0102	0.1011	0.1012	0.0120	0.0728	0.0479
DT	0.1147	0.0021	0.0002	0.2157	0.4744	0.0102	0.0017

Figure 17.12: Xác suất chuyển đổi
(Transition A)

	Janet	will	back	the	bill
NNP	0.000032	0	0	0.000048	0
MD	0	0.308431	0	0	0
VB	0	0.000028	0.000672	0	0.000028
JJ	0	0	0.000340	0	0
NN	0	0.000200	0.000223	0	0.002337
RB	0	0	0.010446	0	0
DT	0	0	0	0.506099	0

Figure 17.13: Xác suất phát xạ
(Emission B)

Note: Các giá trị được tính toán bằng phương pháp MLE dựa trên số lần đếm trong corpus.

Mô phỏng Viterbi Algorithm





Figure 17.14 The first few entries in the individual state columns for the Viterbi algorithm. Each cell keeps the probability of the best path so far and a pointer to the previous cell along that path. We have only filled out columns 1 and 2; to avoid clutter most cells with value 0 are left empty. The rest is left as an exercise for the reader. After the cells are filled in, backtracing from the *end* state, we should be able to reconstruct the correct state sequence NNP MD VB DT NN.

Kết quả cho ví dụ



Optimal: Janet/NNP $\rightarrow$ will/MD $\rightarrow$ back/VB $\rightarrow$ the/DT $\rightarrow$ bill/NN

- 1 17.4.5 The Viterbi Algorithm
- 2 17.5 Conditional Random Fields (CRFs)**
- 3 17.6 Evaluation of Named Entity Recognition
- 4 17.7 Further Details

17.5 Conditional Random Fields (CRFs)

Mặc dù HMM là một mô hình mạnh mẽ, nó vẫn cần những cải tiến để đạt được độ chính xác cao hơn trong các tác vụ như POS tagging:

17.5 Conditional Random Fields (CRFs)

Mặc dù HMM là một mô hình mạnh mẽ, nó vẫn cần những cải tiến để đạt được độ chính xác cao hơn trong các tác vụ như POS tagging:

- **Vấn đề từ chưa biết (Unknown words):** Các tên riêng, từ viết tắt mới xuất hiện liên tục trong ngôn ngữ.

17.5 Conditional Random Fields (CRFs)

Mặc dù HMM là một mô hình mạnh mẽ, nó vẫn cần những cải tiến để đạt được độ chính xác cao hơn trong các tác vụ như POS tagging:

- **Vấn đề từ chưa biết (Unknown words):** Các tên riêng, từ viết tắt mới xuất hiện liên tục trong ngôn ngữ.
- **Nhu cầu về đặc trưng tùy ý (Arbitrary features):** HMM khó tích hợp các đặc trưng như:
 - **Hình thái (Morphology):** Chữ viết hoa, hậu tố (-ed, -ing).
 - **Ngữ cảnh (Context):** Thông tin về các từ đứng trước hoặc đứng sau từ hiện tại.

17.5 Conditional Random Fields (CRFs)

Mặc dù HMM là một mô hình mạnh mẽ, nó vẫn cần những cải tiến để đạt được độ chính xác cao hơn trong các tác vụ như POS tagging:

- **Vấn đề từ chưa biết (Unknown words):** Các tên riêng, từ viết tắt mới xuất hiện liên tục trong ngôn ngữ.
- **Nhu cầu về đặc trưng tùy ý (Arbitrary features):** HMM khó tích hợp các đặc trưng như:
 - **Hình thái (Morphology):** Chữ viết hoa, hậu tố (*-ed*, *-ing*).
 - **Ngữ cảnh (Context):** Thông tin về các từ đứng trước hoặc đứng sau từ hiện tại.
- **Hạn chế của mô hình sinh (Generative):** Khó khăn trong việc tích hợp các đặc trưng chồng chéo một cách nhất quán.

17.5 Conditional Random Fields (CRFs)

Mặc dù HMM là một mô hình mạnh mẽ, nó vẫn cần những cải tiến để đạt được độ chính xác cao hơn trong các tác vụ như POS tagging:

- **Vấn đề từ chưa biết (Unknown words):** Các tên riêng, từ viết tắt mới xuất hiện liên tục trong ngôn ngữ.
- **Nhu cầu về đặc trưng tùy ý (Arbitrary features):** HMM khó tích hợp các đặc trưng như:
 - **Hình thái (Morphology):** Chữ viết hoa, hậu tố (-ed, -ing).
 - **Ngữ cảnh (Context):** Thông tin về các từ đứng trước hoặc đứng sau từ hiện tại.
- **Hạn chế của mô hình sinh (Generative):** Khó khăn trong việc tích hợp các đặc trưng chồng chéo một cách nhất quán.

Giải pháp: Conditional Random Field (CRF) - một mô hình phân biệt (discriminative) dựa trên mô hình log-linear (tương tự logistic regression).

HMM vs. CRF: Generative vs. Discriminative

Trong HMM, chúng ta dựa trên quy tắc Bayes và likelihood để tìm chuỗi nhãn tốt nhất:

$$\hat{Y} = \operatorname{argmax}_Y \prod_i p(x_i | y_i) \prod_i p(y_i | y_{i-1}) \quad (17.21)$$

HMM vs. CRF: Generative vs. Discriminative

Trong HMM, chúng ta dựa trên quy tắc Bayes và likelihood để tìm chuỗi nhãn tốt nhất:

$$\hat{Y} = \operatorname{argmax}_Y \prod_i p(x_i|y_i) \prod_i p(y_i|y_{i-1}) \quad (17.21)$$

Ngược lại, CRF tính toán xác suất hậu nghiệm $p(Y|X)$ trực tiếp bằng cách huấn luyện mô hình phân biệt giữa các chuỗi nhãn khả dĩ:

$$\hat{Y} = \operatorname{argmax}_{Y \in \mathcal{Y}} P(Y|X) \quad (17.22)$$

HMM vs. CRF: Generative vs. Discriminative

Trong HMM, chúng ta dựa trên quy tắc Bayes và likelihood để tìm chuỗi nhãn tốt nhất:

$$\hat{Y} = \operatorname{argmax}_Y \prod_i p(x_i|y_i) \prod_i p(y_i|y_{i-1}) \quad (17.21)$$

Ngược lại, CRF tính toán xác suất hậu nghiệm $p(Y|X)$ trực tiếp bằng cách huấn luyện mô hình phân biệt giữa các chuỗi nhãn khả dĩ:

$$\hat{Y} = \operatorname{argmax}_{Y \in \mathcal{Y}} P(Y|X) \quad (17.22)$$

Nguyên lý CRF

CRF không tính xác suất cho từng nhãn tại mỗi bước thời gian. Thay vào đó, nó tính các hàm log-linear trên các đặc trưng và chuẩn hóa để tạo ra xác suất toàn cục cho toàn bộ chuỗi.

Mô hình CRF

Hàm F ánh xạ toàn bộ chuỗi đầu vào X và toàn bộ chuỗi đầu ra Y thành một vectơ đặc trưng. Giả sử chúng ta có K đặc trưng, với trọng số w_k cho mỗi đặc trưng F_k :

$$p(Y|X) = \frac{\exp\left(\sum_{k=1}^K w_k F_k(X, Y)\right)}{\sum_{Y' \in \mathcal{Y}} \exp\left(\sum_{k=1}^K w_k F_k(X, Y')\right)} \quad (17.23)$$

Mô hình CRF

Hàm F ánh xạ toàn bộ chuỗi đầu vào X và toàn bộ chuỗi đầu ra Y thành một vectơ đặc trưng. Giả sử chúng ta có K đặc trưng, với trọng số w_k cho mỗi đặc trưng F_k :

$$p(Y|X) = \frac{\exp\left(\sum_{k=1}^K w_k F_k(X, Y)\right)}{\sum_{Y' \in \mathcal{Y}} \exp\left(\sum_{k=1}^K w_k F_k(X, Y')\right)} \quad (17.23)$$

Công thức này có thể được đơn giản hóa bằng cách tách mẫu số thành hàm chuẩn hóa $Z(X)$:

$$p(Y|X) = \frac{1}{Z(X)} \exp\left(\sum_{k=1}^K w_k F_k(X, Y)\right) \quad (17.24)$$

Mô hình CRF

Hàm F ánh xạ toàn bộ chuỗi đầu vào X và toàn bộ chuỗi đầu ra Y thành một vectơ đặc trưng. Giả sử chúng ta có K đặc trưng, với trọng số w_k cho mỗi đặc trưng F_k :

$$p(Y|X) = \frac{\exp\left(\sum_{k=1}^K w_k F_k(X, Y)\right)}{\sum_{Y' \in \mathcal{Y}} \exp\left(\sum_{k=1}^K w_k F_k(X, Y')\right)} \quad (17.23)$$

Công thức này có thể được đơn giản hóa bằng cách tách mẫu số thành hàm chuẩn hóa $Z(X)$:

$$p(Y|X) = \frac{1}{Z(X)} \exp\left(\sum_{k=1}^K w_k F_k(X, Y)\right) \quad (17.24)$$

Trong đó, Hàm $Z(X)$ đảm bảo tổng xác suất bằng 1:

$$Z(X) = \sum_{Y' \in \mathcal{Y}} \exp\left(\sum_{k=1}^K w_k F_k(X, Y')\right) \quad (17.25)$$

Đặc trưng Toàn cục và Cục bộ (Features)

Chúng ta gọi K hàm $F_k(X, Y)$ là các **đặc trưng toàn cục** (global features). Mỗi đặc trưng toàn cục được tính bằng cách cộng các **đặc trưng cục bộ** (f_k) tại mỗi vị trí i :

$$F_k(X, Y) = \sum_{i=1}^n f_k(y_{i-1}, y_i, X, i) \quad (17.26)$$

Đặc trưng Toàn cục và Cục bộ (Features)

Chúng ta gọi K hàm $F_k(X, Y)$ là các **đặc trưng toàn cục** (global features). Mỗi đặc trưng toàn cục được tính bằng cách cộng các **đặc trưng cục bộ** (f_k) tại mỗi vị trí i :

$$F_k(X, Y) = \sum_{i=1}^n f_k(y_{i-1}, y_i, X, i) \quad (17.26)$$

Đặc điểm của hàm đặc trưng cục bộ f_k :

- Phụ thuộc vào nhãn hiện tại y_i và nhãn trước đó y_{i-1} .
- Có thể sử dụng toàn bộ chuỗi đầu vào X (hoặc bất kỳ phần nào của nó).
- Sử dụng vị trí hiện tại i trong chuỗi.

- **Đặc tính:** Ràng buộc chỉ phụ thuộc vào y_i và y_{i-1} tạo nên cấu trúc **linear chain CRF**.

Linear Chain CRF

- **Đặc tính:** Ràng buộc chỉ phụ thuộc vào y_i và y_{i-1} tạo nên cấu trúc **linear chain CRF**.
- **Hiệu quả tính toán:** Hạn chế này cho phép chúng ta áp dụng các phiên bản hiệu quả của thuật toán **Viterbi** và **Forward-Backward** từ HMM.

Linear Chain CRF

- **Đặc tính:** Ràng buộc chỉ phụ thuộc vào y_i và y_{i-1} tạo nên cấu trúc **linear chain CRF**.
- **Hiệu quả tính toán:** Hạn chế này cho phép chúng ta áp dụng các phiên bản hiệu quả của thuật toán **Viterbi** và **Forward-Backward** từ HMM.
- **So sánh:**
 - **General CRF:** Có thể phụ thuộc vào các nhãn xa hơn (ví dụ y_{i-4}), nhưng yêu cầu suy diễn (inference) rất phức tạp.
 - **Linear Chain CRF:** Phổ biến nhất trong xử lý ngôn ngữ vì sự cân bằng giữa tính linh hoạt và hiệu suất.

- **Đặc tính:** Ràng buộc chỉ phụ thuộc vào y_i và y_{i-1} tạo nên cấu trúc **linear chain CRF**.
- **Hiệu quả tính toán:** Hạn chế này cho phép chúng ta áp dụng các phiên bản hiệu quả của thuật toán **Viterbi** và **Forward-Backward** từ HMM.
- **So sánh:**
 - **General CRF:** Có thể phụ thuộc vào các nhãn xa hơn (ví dụ y_{i-4}), nhưng yêu cầu suy diễn (inference) rất phức tạp.
 - **Linear Chain CRF:** Phổ biến nhất trong xử lý ngôn ngữ vì sự cân bằng giữa tính linh hoạt và hiệu suất.

Lưu ý

Dù CRF linh hoạt hơn, Lattice (lưới) của nó vẫn có cấu trúc tương tự Hình 17.14, giúp việc triển khai thuật toán không quá xa lạ so với HMM.

17.5.1 Đặc trưng trong CRF POS Tagger

Lý do chính để sử dụng mô hình chuỗi phân biệt (discriminative sequence model) là khả năng tích hợp linh hoạt một lượng lớn các đặc trưng.

Trong một linear-chain CRF, mỗi đặc trưng cục bộ f_k tại vị trí i có thể phụ thuộc vào bất kỳ thông tin nào từ bộ: (y_{i-1}, y_i, X, i) .

17.5.1 Đặc trưng trong CRF POS Tagger

Lý do chính để sử dụng mô hình chuỗi phân biệt (discriminative sequence model) là khả năng tích hợp linh hoạt một lượng lớn các đặc trưng.

Trong một linear-chain CRF, mỗi đặc trưng cục bộ f_k tại vị trí i có thể phụ thuộc vào bất kỳ thông tin nào từ bộ: (y_{i-1}, y_i, X, i) .

Các ví dụ về đặc trưng hợp lệ

- $\mathbb{1}\{x_i = \text{the}, y_i = \text{DET}\}$
- $\mathbb{1}\{y_i = \text{PROPN}, x_{i+1} = \text{Street}, y_{i-1} = \text{NUM}\}$
- $\mathbb{1}\{y_i = \text{VERB}, y_{i-1} = \text{AUX}\}$

Để đơn giản, chúng ta giả định các đặc trưng CRF nhận giá trị 1 (nếu đúng) hoặc 0 (nếu sai).

Thay vì tạo thủ công, các đặc trưng cụ thể thường được sinh ra tự động từ các **Feature Templates**.

Ví dụ các template phổ biến:

$\langle y_i, x_i \rangle$, $\langle y_i, y_{i-1} \rangle$, $\langle y_i, x_{i-1}, x_{i+2} \rangle$

Thay vì tạo thủ công, các đặc trưng cụ thể thường được sinh ra tự động từ các **Feature Templates**.

Ví dụ các template phổ biến:

$$\langle y_i, x_i \rangle, \langle y_i, y_{i-1} \rangle, \langle y_i, x_{i-1}, x_{i+2} \rangle$$

Xét ví dụ với từ “back” trong câu *Janet/NNP will/MD back/VB the/DT bill/NN*:

- $f_{3743} : y_i = \text{VB}$ và $x_i = \text{back}$
- $f_{156} : y_i = \text{VB}$ và $y_{i-1} = \text{MD}$
- $f_{99732} : y_i = \text{VB}$ và $x_{i-1} = \text{will}$ và $x_{i+2} = \text{bill}$

Trong đó, f là hàm đặc trưng cục bộ. Các đặc trưng này sẽ nhận giá trị 1 khi các điều kiện tương ứng được thỏa mãn.

Xử lý từ chưa biết qua hình dạng từ (Word Shape)

Để đối phó với từ chưa biết (unknown words), chúng ta sử dụng các đặc trưng về **word shape** để biểu diễn cấu trúc chữ cái của từ:

Xử lý từ chưa biết qua hình dạng từ (Word Shape)

Để đối phó với từ chưa biết (unknown words), chúng ta sử dụng các đặc trưng về **word shape** để biểu diễn cấu trúc chữ cái của từ:

- **Word shape:** Chuyển chữ thường thành 'x', chữ hoa thành 'X', số thành 'd' và giữ nguyên dấu câu. Ví dụ:
 - *I.M.F.* → **X.X.X.**
 - *DC10-30* → **XXdd-dd**

Xử lý từ chưa biết qua hình dạng từ (Word Shape)

Để đối phó với từ chưa biết (unknown words), chúng ta sử dụng các đặc trưng về **word shape** để biểu diễn cấu trúc chữ cái của từ:

- **Word shape:** Chuyển chữ thường thành 'x', chữ hoa thành 'X', số thành 'd' và giữ nguyên dấu câu. Ví dụ:
 - *I.M.F.* → **X.X.X.**
 - *DC10-30* → **XXdd-dd**
- **Short word shape:** Loại bỏ các loại ký tự lặp lại liên tiếp.
 - *DC10-30* → **Xd-d**

Xử lý từ chưa biết qua hình dạng từ (Word Shape)

Để đối phó với từ chưa biết (unknown words), chúng ta sử dụng các đặc trưng về **word shape** để biểu diễn cấu trúc chữ cái của từ:

- **Word shape:** Chuyển chữ thường thành 'x', chữ hoa thành 'X', số thành 'd' và giữ nguyên dấu câu. Ví dụ:
 - *I.M.F.* → **X.X.X.**
 - *DC10-30* → **XXdd-dd**
- **Short word shape:** Loại bỏ các loại ký tự lặp lại liên tiếp.
 - *DC10-30* → **Xd-d**

Template cho từ chưa biết

Bao gồm: tiền tố (prefix), hậu tố (suffix) độ dài ≤ 2 , word shape và short word shape.

Xử lý từ chưa biết qua hình dạng từ (Word Shape)

Để đối phó với từ chưa biết (unknown words), chúng ta sử dụng các đặc trưng về **word shape** để biểu diễn cấu trúc chữ cái của từ:

- **Word shape:** Chuyển chữ thường thành 'x', chữ hoa thành 'X', số thành 'd' và giữ nguyên dấu câu. Ví dụ:
 - *I.M.F.* → **X.X.X.**
 - *DC10-30* → **XXdd-dd**
- **Short word shape:** Loại bỏ các loại ký tự lặp lại liên tiếp.
 - *DC10-30* → **Xd-d**

Template cho từ chưa biết

Bao gồm: tiền tố (prefix), hậu tố (suffix) độ dài ≤ 2 , word shape và short word shape.

Lưu ý:

Đây là một đặc trưng rất quan trọng cho CRF

Ví dụ: Đặc trưng cho từ “well-dressed”

Xét từ quan sát $x_i = \text{“well-dressed”}$, các đặc trưng hình thái sau sẽ nhận giá trị 1 (non-zero):

Đặc trưng	Giá trị cụ thể
$\text{prefix}(x_i)$	w, we
$\text{suffix}(x_i)$	ed, d
$\text{word-shape}(x_i)$	xxxx-xxxxxxx
$\text{short-word-shape}(x_i)$	x-x

- **Feature Cutoff:** Để giảm kích thước mô hình, các đặc trưng xuất hiện < 5 lần trong tập huấn luyện thường bị loại bỏ.
- **Global Feature:** Các giá trị đặc trưng cục bộ f_k không được học mà được cộng dồn trên toàn câu để tạo thành đặc trưng toàn cục F_k trước khi nhân với trọng số w_k .

17.5.2 Features for CRF Named Entity Recognizers

Mô hình CRF cho bài toán NER sử dụng các tập đặc trưng tương tự như POS tagger nhưng được mở rộng để tối ưu cho việc nhận diện thực thể.

17.5.2 Features for CRF Named Entity Recognizers

Mô hình CRF cho bài toán NER sử dụng các tập đặc trưng tương tự như POS tagger nhưng được mở rộng để tối ưu cho việc nhận diện thực thể.

Tóm tắt đặc trưng điển hình (Figure 17.15)

Nhóm đặc trưng	Chi tiết đặc trưng
Từ vựng (Lexical)	Identity/Embeddings của w_i và các từ lân cận
Ngữ pháp (Syntactic)	Nhãn POS của w_i và các từ lân cận
Hình thái (Morphology)	Word shape, Short word shape, Prefix/Suffix (≤ 4)
Tri thức (Knowledge)	Sự xuất hiện trong Gazetteer (địa danh, tên tổ chức)

17.5.2 Features for CRF Named Entity Recognizers

Mô hình CRF cho bài toán NER sử dụng các tập đặc trưng tương tự như POS tagger nhưng được mở rộng để tối ưu cho việc nhận diện thực thể.

Tóm tắt đặc trưng điển hình (Figure 17.15)

Nhóm đặc trưng	Chi tiết đặc trưng
Từ vựng (Lexical)	Identity/Embeddings của w_i và các từ lân cận
Ngữ pháp (Syntactic)	Nhãn POS của w_i và các từ lân cận
Hình thái (Morphology)	Word shape, Short word shape, Prefix/Suffix (≤ 4)
Tri thức (Knowledge)	Sự xuất hiện trong Gazetteer (địa danh, tên tổ chức)

Một tính năng đặc biệt hữu ích cho việc định vị địa điểm là **Gazetteer** - là một danh sách chứa hàng triệu mục dữ liệu về địa danh và thông tin chính trị, cực kỳ hữu ích để nhận diện các vị trí địa lý.

Cơ chế trích xuất đặc trưng trong CRF

Thay vì nhìn nhận toàn bộ từ như một đơn vị duy nhất, CRF phân rã từ thành các đặc trưng hình thái (*morphological features*). Ví dụ:

Cơ chế trích xuất đặc trưng trong CRF

Thay vì nhìn nhận toàn bộ từ như một đơn vị duy nhất, CRF phân rã từ thành các đặc trưng hình thái (*morphological features*). Ví dụ:

$\text{prefix}(x_i) = \text{L}$

$\text{prefix}(x_i) = \text{L}'$

$\text{prefix}(x_i) = \text{L}'\text{O}$

$\text{prefix}(x_i) = \text{L}'\text{Oc}$

$\text{word-shape}(x_i) = \text{X}'\text{Xxxxxxxxx}$

$\text{suffix}(x_i) = \text{tane}$

$\text{suffix}(x_i) = \text{ane}$

$\text{suffix}(x_i) = \text{ne}$

$\text{suffix}(x_i) = \text{e}$

$\text{short-word-shape}(x_i) = \text{X}'\text{Xx}$

Các đặc trưng sinh ra cho “L’Occitane”

Cơ chế trích xuất đặc trưng trong CRF

Thay vì nhìn nhận toàn bộ từ như một đơn vị duy nhất, CRF phân rã từ thành các đặc trưng hình thái (*morphological features*). Ví dụ:

$\text{prefix}(x_i) = L$

$\text{prefix}(x_i) = L'$

$\text{prefix}(x_i) = L'O$

$\text{prefix}(x_i) = L'Oc$

$\text{word-shape}(x_i) = X'Xxxxxxxx$

$\text{suffix}(x_i) = \mathbf{tane}$

$\text{suffix}(x_i) = \mathbf{ane}$

$\text{suffix}(x_i) = \mathbf{ne}$

$\text{suffix}(x_i) = \mathbf{e}$

$\text{short-word-shape}(x_i) = X'Xx$

Các đặc trưng sinh ra cho “L’Occitane”

Lý giải cơ chế: Ngay cả khi từ này chưa từng xuất hiện, các đặc trưng như hậu tố “-ane” hoặc định dạng chữ hoa đặc biệt giúp mô hình liên kết với các thực thể tương tự đã học, từ đó gán nhãn chính xác (ví dụ: *B-ORG* hoặc *B-LOC*).

Minh họa đặc trưng NER cho một mẫu câu

Xét câu mẫu: *“Jane Villanueva of United Airlines discussed the Chicago route.”*.

Minh họa đặc trưng NER cho một mẫu câu

Xét câu mẫu: “Jane Villanueva of United Airlines discussed the Chicago route.”.

Words	POS	Short shape	Gazetteer	BIO Label
Jane	NNP	Xx	0	B-PER
Villanueva	NNP	Xx	1	I-PER
of	IN	x	0	O
United	NNP	Xx	0	B-ORG
Airlines	NNP	Xx	0	I-ORG
Holding	NNP	Xx	0	I-ORG
discussed	VBD	x	0	O
the	DT	x	0	O
Chicago	NNP	Xx	1	B-LOC
route	NN	x	0	O
.	.	.	0	O

Figure 17.16 Some NER features for a sample sentence, assuming that Chicago and Villanueva are listed as locations in a gazetteer.

- Các đặc trưng chỉ nhận giá trị 0 hoặc 1. Ví dụ, đặc trưng POS đầu tiên được biểu diễn là $1\{\text{POS} = \text{NNP}\}$.
- Hệ thống sẽ tự động tổng hợp tất cả các đặc trưng cục bộ này thành đặc trưng toàn cục F_k để tiến hành học trọng số w_k .

17.5.3 Inference and Training for CRFs

Mục tiêu của suy diễn là tìm chuỗi nhãn tối ưu $\hat{Y}$ cho một chuỗi đầu vào X cho trước. Quá trình biến đổi từ công thức xác suất sang dạng tối ưu hóa tổng trọng số được thực hiện như sau:

17.5.3 Inference and Training for CRFs

Mục tiêu của suy diễn là tìm chuỗi nhãn tối ưu $\hat{Y}$ cho một chuỗi đầu vào X cho trước. Quá trình biến đổi từ công thức xác suất sang dạng tối ưu hóa tổng trọng số được thực hiện như sau:

$$\begin{aligned}\hat{Y} &= \operatorname{argmax}_{Y \in \mathcal{Y}} P(Y|X) \\ &= \operatorname{argmax}_{Y \in \mathcal{Y}} \frac{1}{Z(X)} \exp \left(\sum_{k=1}^K w_k F_k(X, Y) \right)\end{aligned}\tag{17.27}$$

(17.30)

Lưu ý: Chúng ta bỏ qua hàm exp và hằng số chuẩn hóa $Z(X)$ vì chúng không làm thay đổi kết quả argmax.

17.5.3 Inference and Training for CRFs

Mục tiêu của suy diễn là tìm chuỗi nhãn tối ưu $\hat{Y}$ cho một chuỗi đầu vào X cho trước. Quá trình biến đổi từ công thức xác suất sang dạng tối ưu hóa tổng trọng số được thực hiện như sau:

$$\begin{aligned}\hat{Y} &= \operatorname{argmax}_{Y \in \mathcal{Y}} P(Y|X) \\ &= \operatorname{argmax}_{Y \in \mathcal{Y}} \frac{1}{Z(X)} \exp \left(\sum_{k=1}^K w_k F_k(X, Y) \right)\end{aligned}\tag{17.27}$$

$$= \operatorname{argmax}_{Y \in \mathcal{Y}} \exp \left(\sum_{k=1}^K w_k \sum_{i=1}^n f_k(y_{i-1}, y_i, X, i) \right)\tag{17.28}$$

$$\tag{17.30}$$

Lưu ý: Chúng ta bỏ qua hàm exp và hằng số chuẩn hóa $Z(X)$ vì chúng không làm thay đổi kết quả argmax.

17.5.3 Inference and Training for CRFs

Mục tiêu của suy diễn là tìm chuỗi nhãn tối ưu $\hat{Y}$ cho một chuỗi đầu vào X cho trước. Quá trình biến đổi từ công thức xác suất sang dạng tối ưu hóa tổng trọng số được thực hiện như sau:

$$\begin{aligned}\hat{Y} &= \operatorname{argmax}_{Y \in \mathcal{Y}} P(Y|X) \\ &= \operatorname{argmax}_{Y \in \mathcal{Y}} \frac{1}{Z(X)} \exp \left(\sum_{k=1}^K w_k F_k(X, Y) \right)\end{aligned}\tag{17.27}$$

$$= \operatorname{argmax}_{Y \in \mathcal{Y}} \exp \left(\sum_{k=1}^K w_k \sum_{i=1}^n f_k(y_{i-1}, y_i, X, i) \right)\tag{17.28}$$

$$= \operatorname{argmax}_{Y \in \mathcal{Y}} \sum_{k=1}^K w_k \sum_{i=1}^n f_k(y_{i-1}, y_i, X, i)\tag{17.29}$$

$$\tag{17.30}$$

Lưu ý: Chúng ta bỏ qua hàm exp và hằng số chuẩn hóa $Z(X)$ vì chúng không làm thay đổi kết quả argmax.

17.5.3 Inference and Training for CRFs

Mục tiêu của suy diễn là tìm chuỗi nhãn tối ưu $\hat{Y}$ cho một chuỗi đầu vào X cho trước. Quá trình biến đổi từ công thức xác suất sang dạng tối ưu hóa tổng trọng số được thực hiện như sau:

$$\begin{aligned}\hat{Y} &= \operatorname{argmax}_{Y \in \mathcal{Y}} P(Y|X) \\ &= \operatorname{argmax}_{Y \in \mathcal{Y}} \frac{1}{Z(X)} \exp \left(\sum_{k=1}^K w_k F_k(X, Y) \right)\end{aligned}\tag{17.27}$$

$$= \operatorname{argmax}_{Y \in \mathcal{Y}} \exp \left(\sum_{k=1}^K w_k \sum_{i=1}^n f_k(y_{i-1}, y_i, X, i) \right)\tag{17.28}$$

$$= \operatorname{argmax}_{Y \in \mathcal{Y}} \sum_{k=1}^K w_k \sum_{i=1}^n f_k(y_{i-1}, y_i, X, i)\tag{17.29}$$

$$= \operatorname{argmax}_{Y \in \mathcal{Y}} \sum_{i=1}^n \sum_{k=1}^K w_k f_k(y_{i-1}, y_i, X, i)\tag{17.30}$$

Lưu ý: Chúng ta bỏ qua hàm exp và hằng số chuẩn hóa $Z(X)$ vì chúng không làm thay đổi kết quả argmax.

Giải mã với thuật toán Viterbi

Tương tự như HMM, chúng ta sử dụng **thuật toán Viterbi** để tìm chuỗi nhãn tối ưu. Điều này khả thi vì linear-chain CRF tại mỗi bước thời gian chỉ phụ thuộc vào một nhãn đầu ra phía trước y_{i-1} .

Giải mã với thuật toán Viterbi

Tương tự như HMM, chúng ta sử dụng **thuật toán Viterbi** để tìm chuỗi nhãn tối ưu. Điều này khả thi vì linear-chain CRF tại mỗi bước thời gian chỉ phụ thuộc vào một nhãn đầu ra phía trước y_{i-1} .

So sánh công thức đệ quy Viterbi

Trong HMM (Tính toán dựa trên tích xác suất):

$$v_t(j) = \max_{i=1}^N v_{t-1}(i) a_{ij} b_j(o_t) \quad (17.31)$$

Giải mã với thuật toán Viterbi

Tương tự như HMM, chúng ta sử dụng **thuật toán Viterbi** để tìm chuỗi nhãn tối ưu. Điều này khả thi vì linear-chain CRF tại mỗi bước thời gian chỉ phụ thuộc vào một nhãn đầu ra phía trước y_{i-1} .

So sánh công thức đệ quy Viterbi

Trong HMM (Tính toán dựa trên tích xác suất):

$$v_t(j) = \max_{i=1}^N v_{t-1}(i) a_{ij} b_j(o_t) \quad (17.31)$$

Trong CRF (Tính toán dựa trên tổng trọng số đặc trưng):

$$v_t(j) = \max_{i=1}^N \left[v_{t-1}(i) + \sum_{k=1}^K w_k f_k(y_{t-1}, y_t, X, t) \right] \quad (17.33)$$

Giải mã với thuật toán Viterbi

Tương tự như HMM, chúng ta sử dụng **thuật toán Viterbi** để tìm chuỗi nhãn tối ưu. Điều này khả thi vì linear-chain CRF tại mỗi bước thời gian chỉ phụ thuộc vào một nhãn đầu ra phía trước y_{i-1} .

So sánh công thức đệ quy Viterbi

Trong HMM (Tính toán dựa trên tích xác suất):

$$v_t(j) = \max_{i=1}^N v_{t-1}(i) a_{ij} b_j(o_t) \quad (17.31)$$

Trong CRF (Tính toán dựa trên tổng trọng số đặc trưng):

$$v_t(j) = \max_{i=1}^N \left[v_{t-1}(i) + \sum_{k=1}^K w_k f_k(y_{t-1}, y_t, X, t) \right] \quad (17.33)$$

Quá trình này bao gồm việc điền vào mảng $N \times T$ và sử dụng các con trỏ ngược (*backpointers*) để khôi phục chuỗi nhãn có tổng điểm cao nhất từ cột cuối cùng.

Huấn luyện mô hình CRF

Việc học các trọng số w_k trong CRF dựa trên các thuật toán học có giám sát tương tự như *logistic regression*:

Huấn luyện mô hình CRF

Việc học các trọng số w_k trong CRF dựa trên các thuật toán học có giám sát tương tự như *logistic regression*:

- **Tối ưu hóa:** Sử dụng thuật toán **Stochastic Gradient Descent (SGD)** để huấn luyện các trọng số nhằm tối đa hóa log-likelihood của tập dữ liệu huấn luyện.

Huấn luyện mô hình CRF

Việc học các trọng số w_k trong CRF dựa trên các thuật toán học có giám sát tương tự như *logistic regression*:

- **Tối ưu hóa:** Sử dụng thuật toán **Stochastic Gradient Descent (SGD)** để huấn luyện các trọng số nhằm tối đa hóa log-likelihood của tập dữ liệu huấn luyện.
- **Tính toán đạo hàm:** Nhờ cấu trúc cục bộ của linear-chain CRF, thuật toán **Forward-Backward** từ HMM có thể được mở rộng cho CRF để tính toán các đạo hàm cần thiết một cách hiệu quả.

Huấn luyện mô hình CRF

Việc học các trọng số w_k trong CRF dựa trên các thuật toán học có giám sát tương tự như *logistic regression*:

- **Tối ưu hóa:** Sử dụng thuật toán **Stochastic Gradient Descent (SGD)** để huấn luyện các trọng số nhằm tối đa hóa log-likelihood của tập dữ liệu huấn luyện.
- **Tính toán đạo hàm:** Nhờ cấu trúc cục bộ của linear-chain CRF, thuật toán **Forward-Backward** từ HMM có thể được mở rộng cho CRF để tính toán các đạo hàm cần thiết một cách hiệu quả.
- **Regularization:** Tương tự hồi quy logistic, việc áp dụng **L1 hoặc L2 regularization** là rất quan trọng để tránh hiện tượng (*overfitting*).

Cơ chế hoạt động

Mô hình sẽ học cách gán trọng số dương lớn cho các đặc trưng "tốt" (phù hợp với dữ liệu huấn luyện) và trọng số âm cho các đặc trưng "xấu" (phi lý trong ngôn ngữ).

- 1 17.4.5 The Viterbi Algorithm
- 2 17.5 Conditional Random Fields (CRFs)
- 3 17.6 Evaluation of Named Entity Recognition**
- 4 17.7 Further Details

17.6 Đánh giá hệ thống nhận dạng thực thể (NER)

Khác với bài toán gán nhãn từ loại (POS tagging) thường sử dụng tiêu chuẩn **accuracy**, hệ thống NER được đánh giá dựa trên các chỉ số **recall**, **precision** và **F₁ measure**.

Các chỉ số đánh giá cơ bản

- **Recall:** Tỷ lệ số phản hồi được gán nhãn đúng trên tổng số lượng thực thể cần được gán nhãn.
 - **Precision:** Tỷ lệ số phản hồi được gán nhãn đúng trên tổng số lượng nhãn mà hệ thống đã gán.
 - **F-measure:** Trung bình điều hòa của Precision và Recall.
-
- **Đơn vị phản hồi (Unit of response):** Trong NER, **thực thể** (entity) chứ không phải từ (word) là đơn vị để đánh giá.
 - **Kiểm định thống kê:** Sử dụng *paired bootstrap test* hoặc *randomization test* để xác định sự khác biệt có ý nghĩa giữa các hệ thống.

Thách thức trong việc đánh giá NER

Việc sử dụng thực thể làm đơn vị phản hồi gây ra các vấn đề phức tạp về phân đoạn (segmentation):

- **Lỗi gán nhãn một phần:** Nếu hệ thống chỉ nhận diện được “Jane” thay vì cả cụm “Jane Villanueva”, điều này sẽ gây ra hai lỗi:
 - Một lỗi *false positive* cho nhãn O.
 - Một lỗi *false negative* cho nhãn I-PER.
- **Sự không tương xứng (Mismatch):** Có sự khác biệt về điều kiện giữa huấn luyện (theo từng từ) và kiểm thử (theo thực thể), gây khó khăn cho việc tối ưu hóa hệ thống.

Bài toán	Đơn vị đánh giá	Chỉ số chính
POS Tagging	Word	Accuracy
NER	Entity	Precision, Recall, F_1

Giải pháp cho thách thức trong đánh giá NER

Để khắc phục các hạn chế về lỗi phân đoạn và sự không tương xứng, các giải pháp sau đã được đề xuất:

1. Đánh giá đa chiều (Tiêu chuẩn SemEval-2013)

Thay vì chỉ dùng khớp tuyệt đối, ta sử dụng các tiêu chuẩn linh hoạt hơn:

- **Partial Match:** Chấp nhận các kết quả có sự chồng lấn (*overlap*) ranh giới.
- **Ghi điểm theo kịch bản:** Phân tách lỗi sai ranh giới và lỗi sai loại thực thể để hiểu rõ điểm yếu của mô hình.

2. Mô hình dựa trên cụm (Span-based Models)

Thay đổi đơn vị huấn luyện từ cấp độ từ (*token*) sang cấp độ cụm (*span*):

- Mô hình dự đoán trực tiếp trên các phân đoạn văn bản thay vì từng từ đơn lẻ.
- **Ưu điểm:** Loại bỏ sự không tương xứng (*mismatch*) giữa mục tiêu tối ưu hóa khi huấn luyện và các chỉ số đánh giá thực tế.

- 1 17.4.5 The Viterbi Algorithm
- 2 17.5 Conditional Random Fields (CRFs)
- 3 17.6 Evaluation of Named Entity Recognition
- 4 17.7 Further Details

17.7 Further Details

Ý chính của Section 17.7

Sau HMM, CRF và evaluation, section này bổ sung một số vấn đề thực tế khi áp dụng POS tagging và NER.

- Vì các thuật toán đã học là **supervised**, dữ liệu gán nhãn là yếu tố rất quan trọng.
- POS tagging và NER có nhiều dataset khác nhau cho nhiều ngôn ngữ và miền dữ liệu.
- Hai vấn đề được nhấn mạnh:
 - **Rule-based methods**
 - **Morphologically rich languages**

Examples of datasets

UD có POS-tagged corpora cho hơn 100 ngôn ngữ; OntoNotes có named entities cho English, Chinese và Arabic.

17.7.1 Rule-based Methods

Motivation

Mặc dù neural models và CRF là chuẩn phổ biến trong nghiên cứu, các hệ thống thương mại cho NER vẫn thường kết hợp:

- danh sách tên riêng
- luật thủ công
- regular expressions
- dictionaries
- một lượng nhỏ supervised machine learning

Insight

Trong thực tế, NER system thường là **hybrid system**, không chỉ dựa hoàn toàn vào machine learning.

Rule-based Pipeline for NER

Một pipeline rule-based thường gặp

Một hệ thống NER rule-based thường gồm nhiều bước xử lý:

- 1 **High-precision rules**
Gán nhãn các entity rõ ràng.
- 2 **Name matching**
Tìm các tên liên quan đã xuất hiện trước đó.
- 3 **Domain dictionaries**
Sử dụng danh sách tên theo domain.
- 4 **Sequence labeling**
Kết hợp supervised models như CRF / Neural Models.

Key Insight

NER trong thực tế thường là **hybrid system** (rule-based + machine learning).

Rule-based Methods for POS Tagging

Earliest POS Taggers

Rule-based methods cũng là các phương pháp sớm nhất cho POS tagging.

Ví dụ: English Constraint Grammar system dùng quy trình hai bước:

- ➊ A morphological analyzer trả về tất cả possible parts of speech cho một word.
- ➋ A large set of constraints được áp dụng để loại bỏ các POS không phù hợp với context.

Key Idea

Thay vì chọn tag bằng xác suất như HMM/CRF, rule-based POS tagger loại bỏ dần các tag không hợp lệ dựa trên constraints.

17.7.2 POS Tagging for Morphologically Rich Languages

Motivation

Các thuật toán tagging cần được mở rộng khi xử lý những ngôn ngữ có **rich morphology**, như:

- Czech
- Hungarian
- Turkish

Vấn đề

Các quá trình tạo từ phức tạp làm vocabulary lớn hơn nhiều, dẫn đến:

- nhiều word types hơn
- nhiều unknown words hơn
- tagging khó hơn so với tiếng Anh

Why Rich Morphology Makes Tagging Harder

Không chỉ là POS tag

Trong các ngôn ngữ có morphology phức tạp, một từ có thể chứa nhiều thông tin ngữ pháp hơn tiếng Anh:

- case
- gender
- number
- possessive information
- agreement information

Consequence

Tagset không còn là một tập nhỏ các POS tags, mà trở thành chuỗi các **morphological tags**.

Turkish Example: Multiple Analyses

Example from the PDF

Trong Turkish, từ *izin* có thể xuất hiện với nhiều cách phân tích khác nhau:

Yerdeki izin temizlenmesi gerek.

The trace on the floor should be cleaned.

Üzerinde parmak izin kalmış.

Your fingerprint is left on it.

İçeri girmek için izin alman gerekiyor.

You need **permission** to enter.

Key Point

Cùng một surface form có thể cần các morphological/POS analyses khác nhau tùy context.

Morphological Tags and Tagset Size

Example morphological tags

Một số phân tích trong ví dụ Turkish có dạng:

- `iz + Noun + A3sg + Pnon + Gen`
- `iz + Noun + A3sg + P2sg + Nom`
- `izin + Noun + A3sg + Pnon + Nom`

Important Consequence

Khi dùng morphological parse sequence làm part-of-speech tag, số lượng possible tags tăng rất mạnh:

4 to 10×

lớn hơn tagset tiếng Anh.

Cảm ơn cô và các bạn đã lắng nghe!

Q & A