

MiniRAG: Towards Extremely Simple Retrieval-Augmented Generation

Thành viên thực hiện:

Hà Thanh Phong 24520024

Hà Xuân Thiện 24520031

Trần Quang Trường 24521901

University of Information Technology VNUHCM

Ngày 27 tháng 5 năm 2026

- ➊ Bối cảnh bài toán
- ➋ MiniRAG
 - Heterogeneous Graph Indexing
 - Lightweight Graph-Based Knowledge Retrieval
- ➌ Kết quả thực nghiệm
- ➍ Phân tích ưu nhược điểm
- ➎ Phân tích

1. Bối cảnh bài toán

Retrieval-Augmented Generation (RAG) là một hướng tiếp cận kết hợp giữa **truy xuất thông tin** từ kho tri thức bên ngoài và **sinh ngôn ngữ tự nhiên** của mô hình ngôn ngữ.

1. Bối cảnh bài toán

Retrieval-Augmented Generation (RAG) là một hướng tiếp cận kết hợp giữa **truy xuất thông tin** từ kho tri thức bên ngoài và **sinh ngôn ngữ tự nhiên** của mô hình ngôn ngữ.

Nhu cầu triển khai các hệ thống RAG có **hiệu quả tính toán cao** và **chi phí tài nguyên thấp** ngày càng trở nên cấp thiết, đặc biệt trong các môi trường triển khai bị giới hạn về phần cứng.

Tuy nhiên, khi các kiến trúc RAG hiện có được áp dụng cho **Small Language Models (SLMs)**, hiệu năng có thể suy giảm nghiêm trọng hoặc thậm chí thất bại hoàn toàn do các hạn chế cố hữu của SLMs trong việc hiểu ngữ nghĩa sâu và diễn giải nhiều bước.

2. MiniRAG


Nhằm khắc phục các thách thức nêu trên, bài báo đề xuất **MiniRAG**, một hệ thống RAG được thiết kế theo định hướng đơn giản hóa kiến trúc và tối ưu hiệu quả tính toán.

MiniRAG giới thiệu hai thành phần kỹ thuật chính:

- **Heterogeneous Graph Indexing**
- **Lightweight Graph-Based Knowledge Retrieval**

Link bài báo: <https://arxiv.org/abs/2501.06713>

2. MiniRAG




Hình 1: MiniRAG Workflow

2.1 Heterogeneous Graph Indexing

Ý tưởng chính: biểu diễn kho tri thức dưới dạng một **đồ thị dị thể** thay vì chỉ lưu trữ các đoạn văn bản độc lập.

- **Text chunks:** các đoạn văn bản được phân tách từ tài liệu gốc.
- **Named entities:** các thực thể định danh quan trọng được trích xuất từ văn bản.
- **Edges:** các liên kết biểu diễn quan hệ giữa chunks, entities và các thành phần liên quan.

2.1 Heterogeneous Graph Indexing



Hình 2: Heterogeneous Graph Indexing


2.1 Heterogeneous Graph Indexing

Quá trình lập chỉ mục trong MiniRAG được hình thức hóa bằng một đồ thị dị thể:

$$D = \mathcal{G} = (\{\mathcal{V}_c, \mathcal{V}_e\}, \{\mathcal{E}_\alpha, (e_\beta, d_{e_\beta}) \in \mathcal{E}_\beta\}) \quad (1)$$

- $\mathcal{V}_c$: tập các nút biểu diễn **text chunks**.
- $\mathcal{V}_e$: tập các nút biểu diễn **named entities**.
- $\mathcal{E}_\alpha$: các cạnh giữa thực thể với thực thể.
- (e_β, d_{e_β}) : cạnh giữa thực thể và chunk, kèm mô tả ngữ nghĩa của cạnh.

2.2 Lightweight Graph-Based Knowledge Retrieval



Hình 3: Lightweight Graph-Based Knowledge Retrieval

2.2.1 Query Semantic Mapping

Mục tiêu: ánh xạ truy vấn tự nhiên q vào đồ thị dị thể $\mathcal{G}$ để xác định các thực thể và đoạn văn bản có liên quan.

- Trích xuất tập thực thể truy vấn $\mathcal{V}_q$ từ câu hỏi đầu vào q .
- So khớp $\mathcal{V}_q$ với các entity nodes $\mathcal{V}_e$ trong đồ thị $\mathcal{G}$.
- Xác định các nút khởi đầu $\hat{\mathcal{V}}_s$ và các nút ứng viên câu trả lời $\hat{\mathcal{V}}_a$ cho bước truy xuất theo topology.

2.2.2 Topology-Enhanced Graph Retrieval

- **Key Relationship Identification:** xác định các cạnh quan trọng giữa nút khởi đầu $\hat{\mathcal{V}}_s$ và nút ứng viên câu trả lời $\hat{\mathcal{V}}_a$.

$$\omega_e(e) = \sum_{\hat{v}_s \in \hat{\mathcal{V}}_s} \text{count}(\hat{v}_s, \hat{\mathcal{G}}_{e,k}) + \sum_{\hat{v}_a \in \hat{\mathcal{V}}_a} \text{count}(\hat{v}_a, \hat{\mathcal{G}}_{e,k}) \quad (2)$$

- **Query-Guided Path Discovery:** xây dựng các đường suy luận liên quan đến truy vấn dựa trên cả độ tương đồng ngữ nghĩa và cấu trúc graph.

$$\omega_p(p \mid v_q) = \omega_v(\hat{v}_s \mid v_q) \left(1 + \sum_{v \in (p \cap \hat{\mathcal{V}}_a)} \text{count}(v, p) + \sum_{e \in (p \cap \hat{\mathcal{E}}_\alpha)} \omega_e(e) \right) \quad (3)$$

- $\omega_e(e)$: điểm quan trọng của cạnh trong lân cận k -hop.
- $\omega_p(p \mid v_q)$: điểm của đường suy luận ứng với thực thể truy vấn v_q .

3. Kết quả thực nghiệm

Table 1: Performance evaluation using accuracy (acc) and error (err) rates, measured as percentages (%). Higher accuracy and lower error rates indicate better RAG performance. Results compare various baseline methods against our MiniRAG across multiple datasets. Bold values indicate best performance, while “/” denotes cases where methods failed to generate effective responses.

LiHuaWorld	NaiveRAG		GraphRAG		LightRAG		MiniRAG	
	acc↑	err↓	acc↑	err↓	acc↑	err↓	acc↑	err↓
Phi-3.5-mini-instruct	41.22%	23.20%	/	/	39.81%	25.39%	53.29%	23.35%
GLM-Edge-1.5B-Chat	42.79%	24.76%	/	/	35.74%	25.86%	52.51%	25.71%
Qwen2.5-3B-Instruct	43.73%	24.14%	/	/	39.18%	28.68%	48.75%	26.02%
MiniCPM3-4B	43.42%	17.08%	/	/	35.42%	21.94%	51.25%	21.79%
gpt-4o-mini	46.55%	19.12%	35.27%	37.77%	56.90%	20.85%	54.08%	19.44%

MultiHop-RAG	NaiveRAG		GraphRAG		LightRAG		MiniRAG	
	acc↑	err↓	acc↑	err↓	acc↑	err↓	acc↑	err↓
Phi-3.5-mini-instruct	42.72%	31.34%	/	/	27.03%	11.78%	49.96%	28.44%
GLM-Edge-1.5B-Chat	44.44%	24.26%	/	/	/	/	51.41%	23.44%
Qwen2.5-3B-Instruct	39.48%	31.69%	/	/	21.91%	13.73%	48.55%	33.10%
MiniCPM3-4B	39.24%	31.42%	/	/	19.48%	10.41%	47.77%	26.88%
gpt-4o-mini	53.60%	27.19%	60.92%	16.86%	64.91%	19.37%	68.43%	19.41%

3. Kết quả thực nghiệm

OpenBookQA là tập dữ liệu hỏi đáp trắc nghiệm khoa học, thường dùng để đánh giá khả năng kết hợp giữa fact ngắn và suy luận commonsense.

- Mỗi câu hỏi có 4 lựa chọn đáp án, trong đó các phương án sai thường chứa từ khóa gây nhiễu.
- Các fact trong OpenBookQA thường ngắn và rời rạc, nên không phải lúc nào cũng tạo thành chuỗi suy luận rõ ràng.
- Với MiniRAG, đây là một thiết lập khó vì graph của OpenBookQA thưa hơn MultiHop-RAG và dễ bị distractor kéo lệch hướng truy xuất.
- Do đó, OpenBookQA phù hợp để kiểm tra khả năng lọc nhiễu, nổi bật bằng chứng và grounding của hệ thống RAG.

3. Kết quả thực nghiệm

- Đánh giá hiệu năng của **NaiveRAG** và **MiniRAG** trên các tập dữ liệu **MultiHop-RAG** và tập dữ liệu mới **OpenBookQA**.
- Sử dụng mô hình **GLM-Edge-1.5B-Chat**.

3. Kết quả thực nghiệm

Dataset	NaiveRAG		MiniRAG	
	<i>acc</i> ↑	<i>err</i> ↓	<i>acc</i> ↑	<i>err</i> ↓
MultiHop-RAG	60.99%	37.64%	63.41%	32.44%
OpenBookQA	67.60%	32.40%	57.80%	42.20%

Bảng 1: Đánh giá so sánh khi sử dụng mô hình GLM-Edge-1.5B-Chat.

3. Kết quả thực nghiệm

- Đánh giá hiệu năng của **MiniRAG** trên các tập dữ liệu **MultiHop-RAG** và tập dữ liệu mới **OpenBookQA**.
- Sử dụng mô hình **gemma-4-26b-a4b-it**.

3. Kết quả thực nghiệm

Dataset	MiniRAG	
	<i>acc</i> ↑	<i>err</i> ↓
MultiHop-RAG	83.10%	14.75%
OpenBookQA	91.40%	8.60%

Bảng 2: Đánh giá MiniRAG khi sử dụng mô hình gemma-4-26b-a4b-it.

4. Phân tích

Question

Endangered pandas are sometimes

- (A) accidentally dropped into volcanoes
- (B) confined to enclosures to be viewed by the public
- (C) found eating corn in the middle of North America
- (D) made into delicious rare steaks

- Gold answer label: 'B'
- Gold answer text: 'confined to enclosures to be viewed by the public'
- Original MiniRAG prediction: 'A'
- Fresh rerun prediction: 'C'

4. Phân tích

MiniRAG có lợi khi:

- graph giàu liên kết
- entity mapping chính xác
- câu hỏi cần suy luận nhiều bước
- mô hình sinh đủ mạnh để lọc và nối bằng chứng

MiniRAG bất lợi khi:

- fact ngắn và rời rạc
- graph thưa
- distractor có từ khóa mạnh
- đáp án đúng cần commonsense bridge không có sẵn trong graph