

Đại học Quốc gia TP.HCM
Trường Đại học Công nghệ Thông tin



BÁO CÁO ĐỒ ÁN CUỐI KỲ

THỊ GIÁC MÁY TÍNH

ĐỀ TÀI: BÀI TOÁN PHÂN LOẠI CẢM XÚC

Lớp: CS231.Q21.KHTN

GVHD: TS. Mai Tiến Dũng

Thành viên:

1. Trần Quang Trường - 24521901
2. Hà Xuân Thiện - 24520031
3. Phạm Ngọc Phú Thịnh - 24521703
4. Nguyễn Trường Giang - 24520011
5. Hà Thanh Phong - 24520024

Contents

1	Lý do chọn đề tài	4
2	Phát biểu bài toán	4
2.1	Input	4
2.2	Output	4
3	Phương pháp	5
3.1	Hybrid ViT	5
3.1.1	Tổng quan	5
3.1.2	Backbone	5
3.1.3	Local Attention Module	6
3.1.4	Tokenization & Positional Embedding	6
3.1.5	Transformer Encoder	6
3.1.6	Sequence Pooling & MLP Head	6
3.1.7	Data Augmentation	7
3.2	Advanced FER CNN	7
3.2.1	Base / Stem Block	8
3.2.2	Separable Convolution & Residual Block	8
3.2.3	Squeeze-and-Excitation (SE) Block	9
3.2.4	Classifier Head	10
3.2.5	Data Balancing & Augmentation	10
3.3	EfficientNetV2-S	10
3.3.1	Tổng quan	10
3.3.2	Mobile Inverted Bottleneck Convolution	11
3.3.3	Fused Mobile Inverted Bottleneck Convolution	12
3.4	ResNet-18 kết hợp Affinity Loss	13
3.4.1	Backbone ResNet-18	13
3.4.2	Khởi tạo từ trọng số pretrained trên MS-Celeb-1M	14
3.4.3	Classifier Head	14
3.4.4	Không gian đặc trưng của ResNet-18 pretrained	15
3.4.5	Affinity Loss	15
3.4.6	Hàm mất mát tổng hợp	16
3.4.7	Không gian đặc trưng sau khi dùng Affinity Loss	16
3.5	LNSU	17
3.5.1	Tổng quan	17
3.5.2	Re-balanced Attention Consistency (RAC)	17
3.5.3	Re-balanced Smooth Labels (RSL)	18
4	Kết quả thực nghiệm	19
4.1	Tập dữ liệu	19
4.2	Độ đo đánh giá	19
4.3	Quá trình huấn luyện và Kết quả thực nghiệm	20
4.3.1	Hybrid ViT	20
4.3.2	Advanced FER CNN	24
4.3.3	EfficientNetV2-S	27
4.3.4	ResNet-18 kết hợp Affinity Loss	31
4.3.5	LNSU	34
4.3.6	Tổng hợp kết quả thực nghiệm	36

5	Đánh giá và nhận xét ưu điểm, nhược điểm về các Phương pháp	37
5.1	Phương pháp HybridViT	37
5.2	Phương pháp Advanced FER CNN	37
5.3	Phương pháp EfficientNetV2-S	38
5.4	Phương pháp ResNet-18 kết hợp Affinity Loss	38
5.5	Phương pháp Leave No Stone Unturned (LNSU)	39

Thông tin các thành viên và đánh giá mức độ hoàn thành

Mỗi thành viên trong nhóm soạn nội dung, soạn slide, thuyết trình cho phần "Phương pháp" và "Kết quả thực nghiệm" của phương pháp mà mỗi thành viên lựa chọn.

Bên cạnh đó, mỗi thành viên sẽ đảm nhận một số nhiệm vụ đặc thù sau:

Họ và tên	MSSV	Nhiệm vụ từng thành viên	Mức độ hoàn thành
Trần Quang Trường	24521901	- Soạn và hoàn thiện slide - Soạn nội dung phần "Lý do chọn đề tài", "Tập dữ liệu", và "Độ đo"	100%
Hà Xuân Thiện	24520031	- Tạo demo thực nghiệm với từng phương pháp - Kiểm tra và hoàn thiện bài báo cáo	100%
Phạm Ngọc Phú Thịnh	24521703	- Soạn nội dung phần "Phát biểu bài toán" - Thuyết trình phần "Lý do chọn đề tài", "Phát biểu bài toán", "Tập dữ liệu", và "Độ đo"	100%
Nguyễn Trường Giang	24520011	- Tạo repository source code và readme hướng dẫn cách chạy.	100%
Hà Thanh Phong	24520024	- Tổng kết các phương pháp và soạn nội dung phần "Đánh giá, nhận xét những ưu điểm và hạn chế"	100%

1 Lý do chọn đề tài

Trong những năm gần đây, bài toán phân loại cảm xúc từ khuôn mặt là một hướng nghiên cứu có ý nghĩa lớn, vì cảm xúc là một phần quan trọng trong quá trình giao tiếp và phản ánh trạng thái tâm lý của con người. Việc xây dựng hệ thống có khả năng tự động nhận diện cảm xúc giúp máy tính hiểu con người tốt hơn, từ đó hỗ trợ tạo ra các ứng dụng thông minh và thân thiện hơn với người dùng. Trong đề tài này, nhóm chúng em tập trung nghiên cứu và xây dựng mô hình phân loại cảm xúc.

2 Phát biểu bài toán

Bài toán phân loại cảm xúc khuôn mặt được xem là bài toán **phân loại ảnh đa lớp**.

Bài toán phân loại 7 nhãn cảm xúc sau: Surprise, Fear, Disgust, Happiness, Sadness, Anger, Neutral.

Cho tập dữ liệu:

$$D = \{(X_i, y_i)\}_{i=1}^N$$

Trong đó:

- $X_i \in \mathbb{R}^{H \times W \times C}$ là ảnh khuôn mặt đầu vào.
- $y_i \in \{0, 1, 2, 3, 4, 5, 6\}$ là nhãn cảm xúc tương ứng.

Mục tiêu là xây dựng mô hình f_θ sao cho:

$$\hat{y}_i = f_\theta(X_i)$$

với $\hat{y}_i$ là cảm xúc dự đoán thuộc một trong 7 lớp nhãn cảm xúc tương ứng.

2.1 Input

Đầu vào của mô hình là một ảnh màu X :

$$X \in \mathbb{R}^{H \times W \times C}$$

Trong đó:

- H : chiều cao ảnh
- W : chiều rộng ảnh
- C : số kênh màu RGB

2.2 Output

Đầu ra của mô hình là một nhãn phân loại cảm xúc:

$$\hat{y} \in \{0, 1, 2, 3, 4, 5, 6\}$$

3 Phương pháp

3.1 Hybrid ViT

3.1.1 Tổng quan

Kiến trúc tổng quan của mô hình đề xuất được thể hiện chi tiết thông qua luồng xử lý dữ liệu dưới đây. Thiết kế kiến trúc lai kết hợp này được kế thừa và lấy cảm hứng từ các nghiên cứu tiên phong về việc tích hợp mạng tích chập cùng cơ chế Transformer [1, 2].




Figure 1: Sơ đồ pipeline dữ liệu và luồng xử lý của kiến trúc HybridViT.

Nhìn chung, luồng xử lý dữ liệu của kiến trúc HybridViT được chia thành ba giai đoạn chính:

- **Trích xuất đặc trưng cục bộ:** Ảnh đầu vào được đưa qua Backbone ResNet50 [3] để lấy feature map không gian, sau đó tiếp tục qua khối Local Attention (giảm chiều và áp dụng CBAM [4]) để tinh lọc và tập trung vào các vùng biểu cảm trọng tâm.
- **Học ngữ cảnh toàn cục:** Các đặc trưng sau đó được làm phẳng (flatten) thành chuỗi token, tích hợp Positional Embedding và đi qua 4 lớp Transformer Encoder [5] nhằm khai thác mối tương quan xa giữa các chi tiết trên khuôn mặt.
- **Tổng hợp và Phân loại:** Thay vì dùng CLS token, chuỗi đầu ra được gộp lại bằng Sequence Pooling thành một vector ngữ cảnh duy nhất, cuối cùng đi qua MLP Head để đưa ra dự đoán cho 7 nhãn cảm xúc.

3.1.2 Backbone

Ảnh đầu vào $x \in \mathbb{R}^{B \times 224 \times 224 \times 3}$ được đưa qua mạng ResNet50 [3] (đã loại bỏ lớp fully-connected cuối). Bước này giúp trích xuất feature map:

$$f_{cnn} = \text{ResNet50}(x) \quad \text{với } f_{cnn} \in \mathbb{R}^{B \times 7 \times 7 \times 2048} \quad (1)$$

3.1.3 Local Attention Module

Để giảm khối lượng tính toán và tập trung vào các đặc trưng quan trọng, mạng sử dụng một khối chiếu tuyến tính kết hợp với cơ chế CBAM [4]:

1. **Projection Block:** Dùng Conv2d 1×1 kết hợp Batch Normalization và ReLU để hạ số lượng channel từ 2048 xuống 512.

$$f_{proj} = \text{ReLU}(\text{BN}(\text{Conv2d}_{1 \times 1}(f_{cnn}))) \in \mathbb{R}^{B \times 7 \times 7 \times 512} \quad (2)$$

2. **Channel Attention:** Khai thác mối tương quan giữa các channel thông qua Global Average Pooling và Global Max Pooling:

$$M_c(f) = \sigma(\text{FC}_2(\text{ReLU}(\text{FC}_1(\text{AvgPool}(f)))) + \text{FC}_2(\text{ReLU}(\text{FC}_1(\text{MaxPool}(f))))) \quad (3)$$

3. **Spatial Attention:** Xác định vị trí chứa các đặc trưng quan trọng thông qua bộ lọc Conv2d 7×7 :

$$M_s(f) = \sigma(\text{Conv2d}_{7 \times 7}([\text{AvgPool}_{channel}(f); \text{MaxPool}_{channel}(f)])) \quad (4)$$

3.1.4 Tokenization & Positional Embedding

Feature map không gian sau đó được Flatten để chuyển thành chuỗi 49 token, mỗi token là một vector 512 chiều:

$$f_{flatten} = \text{Flatten}_{2D}(f_{attention}) \in \mathbb{R}^{B \times 49 \times 512} \quad (5)$$

Do mạng Transformer [5] không phụ thuộc vào thứ tự chuỗi, Positional Embedding $E_{pos} \in \mathbb{R}^{1 \times 49 \times 512}$ được cộng trực tiếp vào token để lưu giữ thông tin vị trí:

$$z_0 = f_{flatten_transposed} + E_{pos} \quad (6)$$

Một lớp Dropout với $p = 0.2$ được áp dụng để giảm thiểu overfitting.

3.1.5 Transformer Encoder

Dữ liệu tiếp tục đi qua 4 lớp Transformer Encoder [5] xếp chồng. Mỗi lớp sử dụng Multi-Head Self-Attention với 8 head và Feed Forward Network có chiều ẩn 1024:

$$\hat{z}_l = \text{MHSA}(\text{LN}(z_{l-1})) + z_{l-1}, \quad l \in \{1, 2, 3, 4\} \quad (7)$$

$$z_l = \text{FFN}(\text{LN}(\hat{z}_l)) + \hat{z}_l \quad (8)$$

Dropout trong các lớp Encoder được thiết lập ở mức 0.3. Đầu ra cuối cùng được đi qua một lớp Layer Normalization.

3.1.6 Sequence Pooling & MLP Head

Thay vì dùng CLS token, mô hình áp dụng Sequence Pooling để gom 49 token thành một vector ngữ cảnh duy nhất $g \in \mathbb{R}^{B \times 512}$:

$$\alpha = \text{Softmax}(\text{Linear}(z_4)) \in \mathbb{R}^{B \times 49 \times 1} \quad (9)$$

$$g = \sum_{i=1}^{49} \alpha_i \cdot z_{4,i} \quad (10)$$

Vector g cuối cùng đi qua MLP Head để phân loại thành 7 nhãn:

$$\text{Output} = \text{Linear}_{512 \rightarrow 7}(\text{Dropout}_{0.5}(\text{GELU}(\text{BN}(\text{Linear}_{512 \rightarrow 512}(g))))) \quad (11)$$

3.1.7 Data Augmentation

Để giải quyết bài toán mất cân bằng mẫu và tăng tính tổng quát hóa, tập huấn luyện được áp dụng các kỹ thuật sau:

- **Resize:** Ảnh đầu vào được đưa về kích thước chuẩn 224×224 .
- **RandAugment [6]:** Tự động áp dụng chuỗi 3 phép biến đổi ngẫu nhiên với cường độ $magnitude = 9$ nhằm đa dạng hóa ảnh mà không cần tinh chỉnh thủ công từng tham số.
- **Normalize:** Chuẩn hóa giá trị pixel theo phân phối của tập ImageNet ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$).
- **RandomErasing [7]:** Xóa ngẫu nhiên một mảng hình chữ nhật trên ảnh với xác suất $p = 0.25$, diện tích che khuất từ 2% đến 10%. Kỹ thuật này ép mạng phải học dựa trên nhiều bộ phận khác nhau của khuôn mặt thay vì quá phụ thuộc vào một đặc trưng.

3.2 Advanced FER CNN

Kiến trúc mô hình đề xuất được phân rã thành ba giai đoạn xử lý cốt lõi, tối ưu hóa từ trích xuất đặc trưng hình thái thô đến phân loại cảm xúc tăng cao (Hình 2).




Figure 2: Sơ đồ pipeline dữ liệu và luồng xử lý tổng quan của kiến trúc Advanced FER CNN.

- **Khối Stem (Trích xuất sơ cấp):** Sử dụng cụm tích chập chuẩn (Standard Convolution) kết hợp Batch Normalization (BN) và ReLU để khai thác đặc trưng không gian thô ở tầng thấp (cạnh, kết cấu).
- **Khối Separable SE Block (Tăng cường đặc trưng):** Chuỗi 4 tầng xử lý tăng tiến bộ lọc ($32 \rightarrow 64 \rightarrow 128 \rightarrow 256$) ứng dụng tích chập tách biệt chiều sâu (Separable Convolution), cơ chế tự chú ý kênh (Squeeze-and-Excitation) và nhánh bỏ qua (Residual Connection) nhằm tối ưu tham số và chống biến mất đạo hàm.

- **Khối Classifier Head (Phân loại):** Nén không gian toàn cục qua Global Average Pooling (GAP) thành vector phẳng, điều hòa bằng Dense ẩn 256 chiều, BN và Dropout 0.4 trước khi phân loại qua tầng Softmax 7 cảm xúc.

3.2.1 Base / Stem Block

Ảnh đầu vào $x \in \mathbb{R}^{B \times 100 \times 100 \times 3}$ được tinh lọc cục bộ qua chuỗi hai tầng tích chập 3×3 với số kênh cố định là 16:

$$f_1 = \text{ReLU}(\text{BN}(\text{Conv2D}_{3 \times 3}(x))) \quad (12)$$

$$f_{stem} = \text{ReLU}(\text{BN}(\text{Conv2D}_{3 \times 3}(f_1))) \in \mathbb{R}^{B \times 100 \times 100 \times 16} \quad (13)$$

Khối Stem ổn định phân phối dữ liệu đầu vào và thiết lập không gian đặc trưng ban đầu $[100, 100, 16]$ trước khi chuyển tiếp sang các khối tăng kênh kế tiếp.

3.2.2 Separable Convolution & Residual Block

Sau khối Stem, đặc trưng dữ liệu tuần tự đi qua 4 khối nâng cao với số lượng bộ lọc $F \in \{32, 64, 128, 256\}$, thực hiện hạ mẫu không gian bằng Max Pooling 3×3 (stride = 2) và tính toán song hành trên hai nhánh (Hình 3):




Figure 3: Cấu trúc chi tiết bên trong của mô-đun Filter Block tích hợp SE-Block.

1. **Nhánh Skip Connection (Residual Path):** Đồng bộ kích thước không gian và số lượng kênh thông qua phép chiếu tích chập 1×1 , stride = 2 kết hợp chuẩn hóa:

$$f_{residual} = \text{BN}(\text{Conv2D}_{1 \times 1, \text{strides}=2}(f_{in})) \in \mathbb{R}^{B \times H_{out} \times W_{out} \times F} \quad (14)$$

2. **Nhánh Trích xuất chính (Main Branch):** Khai thác đặc trưng phi tuyến tầng sâu bằng hai lớp Separable Convolution liên tiếp nhằm tiết kiệm tài nguyên tính toán:

$$f_{sep1} = \text{ReLU}(\text{BN}(\text{SeparableConv2D}_{3 \times 3}(f_{in}))) \quad (15)$$

$$f_{sep2} = \text{BN}(\text{SeparableConv2D}_{3 \times 3}(f_{sep1})) \quad (16)$$

$$f_{pool} = \text{MaxPooling2D}_{3 \times 3, \text{strides}=2}(f_{sep2}) \quad (17)$$

3.2.3 Squeeze-and-Excitation (SE) Block

Để tái hiệu chỉnh động trọng số giữa các kênh đặc trưng, mô hình tích hợp khối chú ý Squeeze-and-Excitation (SE) ngay sau tầng Max Pooling của nhánh chính (Hình 4):

MÔ HÌNH TOÁN HỌC BÊN TRONG KHỐI "SQUEEZE-AND-EXCITATION" (SE-BLOCK)

Sự tương tác giữa luồng dữ liệu gốc đặc trưng không gian và luồng vector trọng số kênh




Figure 4: Mô hình toán học và các bước biến đổi tensor bên trong khối Squeeze-and-Excitation.

$$s = \text{GlobalAveragePooling2D}(f_{pool}) \in \mathbb{R}^{B \times 1 \times 1 \times F} \quad (18)$$

$$s_1 = \text{ReLU}(\text{Dense}_{F/8}(s)) \quad (19)$$

$$s_2 = \sigma(\text{Dense}_F(s_1)) \quad (\sigma : \text{Sigmoid}) \quad (20)$$

$$f_{attention} = f_{pool} \otimes s_2 \quad (21)$$

Mạng nén thông tin không gian (Squeeze) thành vector kênh $[C]$, thực hiện giảm chiều qua tầng Dense ẩn với tỷ lệ giảm thiểu $r = 8$ (Excitation R) để khai thác mối quan hệ liên kênh, và khôi phục số kênh gốc (Excitation E) qua hàm Sigmoid nhằm tạo mảng trọng số chú ý. Bản đồ đặc trưng được hiệu chỉnh bằng phép nhân Hadamard $\otimes$ trực tiếp.

Đầu ra của khối được điều hòa qua Spatial Dropout (0.15) và cộng hợp trực tiếp với nhánh Residual:

$$f_{out} = \text{SpatialDropout}_{0.15}(f_{attention}) + f_{residual} \quad (22)$$

3.2.4 Classifier Head

Tensor từ khối đặc trưng cuối cùng (256 bộ lọc) được ánh xạ thành vector phẳng và tối ưu hóa phân loại:

$$g = \text{GlobalAveragePooling2D}(f_{\text{final_block}}) \in \mathbb{R}^{B \times 256} \quad (23)$$

$$h = \text{Dropout}_{0.4}(\text{BN}(\text{ReLU}(\text{Dense}_{256}(g)))) \quad (24)$$

$$\text{Output} = \text{Softmax}(\text{Dense}_{256 \rightarrow 7}(h)) \quad (25)$$

3.2.5 Data Balancing & Augmentation

Chiến lược xử lý mất cân bằng dữ liệu trên tập dữ liệu được thực hiện đồng bộ qua hai giai đoạn:


- **Undersampling lớp đa số:** Khấu trừ ngẫu nhiên số lượng mẫu của lớp *happy* xuống ngưỡng cố định 3500 mẫu.
- **Offline Augmentation lớp thiểu số:** Tăng cường các lớp còn lại bằng cấu hình `ImageDataGenerator` (xoay 10° , dịch chuyển không gian 10%, phóng đại 10%, lật ngang và biến đổi dải màu $\text{channel_shift} = 50.0$) để cân bằng đồng đều tất cả các lớp ở mức 3500 mẫu/lớp.
- **Online Augmentation (Huấn luyện):** Áp dụng tăng cường động trực tiếp khi fit mạng: xoay ảnh 20° , dịch chuyển hình thái 10%, và lật ngang ngẫu nhiên.

3.3 EfficientNetV2-S

3.3.1 Tổng quan

Trong hướng tiếp cận này, mô hình EfficientNetV2-S [8] được sử dụng làm backbone để trích xuất đặc trưng từ ảnh khuôn mặt đầu vào. Sau đó, các vector đặc trưng thu được từ backbone EfficientNetV2-S được đưa qua một lớp Linear cuối cùng để ánh xạ sang không gian đầu ra gồm 7 lớp cảm xúc. Backbone này được khởi tạo từ trọng số đã được tiền huấn luyện trên tập dữ liệu ImageNet-1K, nhằm tận dụng các biểu diễn thị giác tổng quát đã học được từ dữ liệu quy mô lớn. Sau đó, toàn bộ tham số của EfficientNetV2-S được full fine-tune trên tập dữ liệu để thích nghi tốt hơn với bài toán phân loại cảm xúc khuôn mặt.

EfficientNetV2-S Architecture



Overall Architecture

Stage	Operator	Stride	#Channels	#Layers	Output Size
0	Conv3x3	2	24	1	112x112x24
1	Fused-MBConv1, k3x3	1	24	2	112x112x24
2	Fused-MBConv4, k3x3	2	48	4	56x56x48
3	Fused-MBConv4, k3x3	2	64	4	28x28x64
4	MBConv4, k3x3, SE0.25	2	128	6	14x14x128
5	MBConv6, k3x3, SE0.25	1	160	9	14x14x160
6	MBConv6, k3x3, SE0.25	2	256	15	7x7x256
7	Conv1x1 & Pooling & FC	-	1280	1	7x7x1280 → 1x1x1280 → 1x1x7




Figure 5: Tổng quan kiến trúc EfficientNetV2-S

3.3.2 Mobile Inverted Bottleneck Convolution

Mobile Inverted Bottleneck Convolution (MBConv) là một khối tích chập quan trọng trong EfficientNetV2-S, được kế thừa từ ý tưởng inverted residual của MobileNetV2 [9] và kết hợp thêm cơ chế Squeeze-and-Excitation (SE). Mục tiêu của khối này là tăng khả năng biểu diễn đặc trưng của mô hình nhưng vẫn giữ số lượng tham số và chi phí tính toán ở mức thấp.




Figure 6: Tổng quan khối MBConv

Với đầu vào là feature map:

$$x \in \mathbb{R}^{H \times W \times C_{in}},$$

khối MBConv trước hết sử dụng phép tích chập điểm 1 x 1 để mở rộng số kênh đặc trưng:

$$f_{expand} = \text{SiLU}(\text{BN}(\text{Conv1} \times 1(x))) \in \mathbb{R}^{H \times W \times C_{exp}},$$

trong đó $C_{exp} = t \cdot C_{in}$, với t là hệ số mở rộng kênh. Việc mở rộng số kênh trước khi tích chập giúp mô hình học được không gian đặc trưng giàu thông tin hơn so với việc xử lý trực tiếp trên số kênh ban đầu.

Sau bước mở rộng, khối MBConv áp dụng Depthwise Convolution $k \times k$ để trích xuất đặc trưng không gian trên từng kênh độc lập:

$$f_{dw} = \text{SiLU}(\text{BN}(\text{DWConv} k \times k(f_{expand}))).$$

Tiếp theo, cơ chế Squeeze-and-Excitation được sử dụng để tái hiệu chỉnh mức độ quan trọng của từng kênh đặc trưng:

$$s = \sigma(\text{FC}_2(\text{SiLU}(\text{FC}_1(\text{GAP}(f_{dw}))))),$$

$$f_{se} = f_{dw} \otimes s.$$

Cuối cùng, khối MBConv sử dụng một phép tích chập 1×1 để chiếu số kênh về kích thước đầu ra:

$$f_{proj} = \text{BN}(\text{Conv} 1 \times 1(f_{se})) \in \mathbb{R}^{H' \times W' \times C_{out}}.$$

Nếu kích thước đầu vào và đầu ra tương thích, khối MBConv sử dụng thêm skip connection để cộng trực tiếp đặc trưng đầu vào với đầu ra:

$$y = \begin{cases} f_{proj} + x, & \text{nếu } H' = H, W' = W, C_{out} = C_{in}, \\ \text{ngược lại.} \end{cases}$$

3.3.3 Fused Mobile Inverted Bottleneck Convolution

Fused Mobile Inverted Bottleneck Convolution (Fused-MBConv) là biến thể cải tiến của MBConv, được EfficientNetV2-S sử dụng chủ yếu ở các giai đoạn đầu của mạng. Điểm khác biệt chính của Fused-MBConv là thay vì tách riêng bước mở rộng kênh 1×1 và Depthwise Convolution, khối này gộp hai thao tác đó thành một phép tích chập thông thường $k \times k$. Cách thiết kế này giúp giảm chi phí truy cập bộ nhớ và tăng tốc độ huấn luyện, đặc biệt ở các tầng đầu khi feature map còn có kích thước không gian lớn.




Figure 7: Tổng quan khối Fused-MBConv

Với đầu vào:

$$x \in \mathbb{R}^{H \times W \times C_{in}},$$

Fused-MBConv trước hết áp dụng phép tích chập $k \times k$ để đồng thời trích xuất đặc trưng không gian và mở rộng số kênh:

$$f_{conv} = \text{SiLU}(\text{BN}(\text{Conv} * k \times k(x))) \in \mathbb{R}^{H' \times W' \times C_{exp}}.$$

Trong đó, C_{exp} là số kênh trung gian sau khi mở rộng. So với MBConv, việc sử dụng một phép tích chập chuẩn ở bước đầu giúp mô hình học trực tiếp các đặc trưng tầng thấp như cạnh, đường viền khuôn mặt, kết cấu da và các vùng biểu cảm cơ bản.

Sau đó, một phép tích chập điểm 1×1 được sử dụng để chiếu đặc trưng về số kênh đầu ra:

$$f_{proj} = \text{BN}(\text{Conv} * 1 \times 1(f * \text{conv})) \in \mathbb{R}^{H' \times W' \times C_{out}}.$$

Tương tự MBConv, nếu kích thước đầu vào và đầu ra không thay đổi, Fused-MBConv cũng có thể sử dụng skip connection:

$$y = \begin{cases} f_{proj} + x, & \text{nếu } H' = H, W' = W, C_{out} = C_{in}, f_{proj}, \\ \text{ngược lại.} \end{cases}$$

Trong EfficientNetV2-S, Fused-MBConv thường được đặt ở các stage đầu để tăng tốc quá trình học đặc trưng cơ bản từ ảnh đầu vào. Khi mạng đi sâu hơn, các khối MBConv được sử dụng để giảm chi phí tính toán và tăng hiệu quả biểu diễn ở những tầng có số kênh lớn hơn. Sự kết hợp giữa Fused-MBConv ở tầng nông và MBConv ở tầng sâu giúp EfficientNetV2-S đạt được tốc độ huấn luyện nhanh, khả năng tổng quát hóa tốt và phù hợp với bài toán phân loại cảm xúc khuôn mặt trên tập dữ liệu.

3.4 ResNet-18 kết hợp Affinity Loss

Trong hướng tiếp cận này, mô hình phân loại cảm xúc được xây dựng dựa trên backbone ResNet-18 kết hợp với Affinity Loss. Mục tiêu chính là tận dụng khả năng trích xuất đặc trưng khuôn mặt từ mô hình pretrained, đồng thời cải thiện cấu trúc không gian đặc trưng để các lớp cảm xúc trở nên dễ phân tách hơn.




Figure 8: Pipeline tổng quan của mô hình ResNet-18 kết hợp Affinity Loss.

Về tổng thể, ảnh khuôn mặt đầu vào được đưa qua ResNet-18 để trích xuất vector đặc trưng. Vector này sau đó được truyền qua classifier head để tạo ra logits tương ứng với 7 nhãn cảm xúc. Trong quá trình huấn luyện, mô hình được tối ưu bằng Cross-Entropy Loss kết hợp với Affinity Loss nhằm tổ chức lại không gian đặc trưng.

3.4.1 Backbone ResNet-18

ResNet-18 [3] là một kiến trúc mạng tích chập phổ biến, được sử dụng rộng rãi trong nhiều bài toán thị giác máy tính như phân loại ảnh, nhận dạng đối tượng và trích xuất đặc trưng. Điểm quan trọng

của ResNet-18 là cơ chế residual connection, giúp thông tin được truyền trực tiếp qua các tầng mạng và làm quá trình huấn luyện ổn định hơn.

Trong bài toán phân loại cảm xúc khuôn mặt, ResNet-18 được sử dụng như một bộ trích xuất đặc trưng. Với ảnh đầu vào:

$$x \in \mathbb{R}^{B \times 3 \times 224 \times 224}, \quad (26)$$

backbone ResNet-18 ánh xạ ảnh sang vector đặc trưng:

$$z = f_{\theta}(x) \in \mathbb{R}^{B \times 512}, \quad (27)$$

trong đó B là batch size, f_{θ} là backbone ResNet-18 và z là vector đặc trưng 512 chiều.

3.4.2 Khởi tạo từ trọng số pretrained trên MS-Celeb-1M

Thay vì khởi tạo trọng số ngẫu nhiên, phương pháp đề xuất sử dụng ResNet-18 đã được pretrained trên tập dữ liệu khuôn mặt MS-Celeb-1M [10]. Cách khởi tạo này giúp backbone có sẵn khả năng nhận biết các cấu trúc quan trọng trên khuôn mặt như mắt, mũi, miệng, đường viền khuôn mặt và các đặc trưng hình thái khác.

Việc sử dụng trọng số pretrained trên dữ liệu khuôn mặt phù hợp hơn với bài toán phân loại cảm xúc so với việc huấn luyện từ đầu. Sau khi khởi tạo, toàn bộ mô hình được fine-tune trên tập dữ liệu để thích nghi với nhiệm vụ phân loại 7 cảm xúc.



Figure 9: Một số ảnh minh họa từ tập dữ liệu MS-Celeb-1M.

3.4.3 Classifier Head

Vector đặc trưng z từ ResNet-18 được đưa qua classifier head để ánh xạ về 7 lớp cảm xúc. Classifier head được thiết kế đơn giản gồm hai tầng fully-connected: tầng đầu giảm chiều đặc trưng từ 512 xuống 256, sau đó áp dụng ReLU và Dropout; tầng cuối ánh xạ vector 256 chiều sang 7 logits tương ứng với 7 lớp cảm xúc.

$$h = \text{Dropout}_{0.3}(\text{ReLU}(\text{FC}_{512 \rightarrow 256}(z))), \quad (28)$$

$$o = \text{FC}_{256 \rightarrow 7}(h), \quad (29)$$

$$\hat{y} = \text{Softmax}(o). \quad (30)$$

Trong đó, h là vector ẩn 256 chiều, $o \in \mathbb{R}^{B \times 7}$ là vector logits đầu ra, và $\hat{y}$ là phân phối xác suất dự đoán trên 7 lớp cảm xúc. Lớp Softmax được sử dụng để chuyển logits thành xác suất, giúp xác định mức độ tin cậy của mô hình đối với từng lớp cảm xúc.

Nhãn dự đoán cuối cùng được xác định bằng lớp có xác suất lớn nhất:

$$\hat{c} = \arg \max_{k \in \{1, \dots, 7\}} \hat{y}_k. \quad (31)$$

Tập nhãn cảm xúc được sử dụng trong bài toán gồm:

$$\mathcal{Y} = \{surprise, fear, disgust, happy, sad, angry, neutral\}. \quad (32)$$

3.4.4 Không gian đặc trưng của ResNet-18 pretrained

Mặc dù ResNet-18 pretrained trên MS-Celeb-1M đã học được các đặc trưng khuôn mặt hữu ích, không gian đặc trưng ban đầu vẫn chưa được tối ưu trực tiếp cho bài toán phân loại cảm xúc. Khi trực quan hóa bằng t-SNE, các điểm dữ liệu của nhiều lớp cảm xúc vẫn còn chồng lấn, đặc biệt với những biểu cảm có hình thái gần nhau như *fear*, *sad*, *disgust* và *neutral*.




Figure 10: t-SNE của không gian đặc trưng từ ResNet-18 pretrained.

Quan sát này cho thấy Cross-Entropy Loss có thể giúp mô hình học ranh giới phân loại, nhưng chưa trực tiếp ràng buộc các đặc trưng cùng lớp phải nằm gần nhau trong không gian embedding. Vì vậy, cần bổ sung một cơ chế giúp không gian đặc trưng có cấu trúc rõ ràng hơn.

3.4.5 Affinity Loss

Từ nhận xét trên, phương pháp đề xuất sử dụng thêm Affinity Loss. Ý tưởng của Affinity Loss là mỗi lớp cảm xúc được đại diện bởi một tâm lớp, gọi là class center; trong quá trình huấn luyện, đặc trưng của các mẫu thuộc cùng một lớp sẽ được kéo về gần tâm của lớp đó.




Figure 11: Minh họa ý tưởng Affinity Loss trong không gian đặc trưng.

Giả sử batch huấn luyện có N mẫu, z_i là vector đặc trưng của mẫu thứ i , y_i là nhãn đúng và c_{y_i} là tâm của lớp tương ứng. Affinity Loss được định nghĩa như sau:

$$\mathcal{L}_{af} = \frac{\sum_{i=1}^N \|z_i - c_{y_i}\|_2^2}{\sigma_c^2}. \quad (33)$$

Trong đó:

- z_i là đặc trưng của mẫu thứ i ;
- c_{y_i} là class center của lớp đúng;
- $\|z_i - c_{y_i}\|_2^2$ đo khoảng cách giữa đặc trưng và tâm lớp;
- σ_c^2 biểu diễn độ phân tán giữa các class center.

Thành phần tử số giúp giảm khoảng cách nội lớp, tức là kéo các mẫu cùng cảm xúc lại gần nhau hơn. Thành phần σ_c^2 giúp chuẩn hóa theo độ phân tán giữa các tâm lớp, từ đó hạn chế việc toàn bộ đặc trưng bị co cụm vào cùng một vùng nhỏ.

3.4.6 Hàm mất mát tổng hợp

Mô hình được huấn luyện bằng cách kết hợp Cross-Entropy Loss và Affinity Loss:

$$\mathcal{L} = \mathcal{L}_{ce} + \lambda \mathcal{L}_{af}. \quad (34)$$

Trong đó, $\mathcal{L}_{ce}$ đảm nhiệm mục tiêu phân loại đúng nhãn cảm xúc, còn $\mathcal{L}_{af}$ giúp tổ chức lại không gian đặc trưng. Hệ số λ được sử dụng để điều chỉnh mức độ ảnh hưởng của Affinity Loss. Trong thực nghiệm, λ được đặt bằng 0.05.

3.4.7 Không gian đặc trưng sau khi dùng Affinity Loss

Sau khi bổ sung Affinity Loss, không gian đặc trưng trở nên có cấu trúc rõ ràng hơn. Các mẫu thuộc cùng một lớp có xu hướng gom cụm tốt hơn, trong khi sự chồng lấn giữa các lớp được giảm bớt.

Điều này cho thấy Affinity Loss hỗ trợ ResNet-18 không chỉ học cách phân loại ảnh, mà còn học được một không gian embedding phù hợp hơn cho bài toán nhận diện cảm xúc.




Figure 12: ResNet-18 pretrained.



Figure 13: ResNet-18 + Affinity Loss.

So với baseline chỉ sử dụng Cross-Entropy, mô hình kết hợp Affinity Loss tạo ra các cụm đặc trưng gọn hơn và dễ phân biệt hơn. Đây là cơ sở để classifier head đưa ra quyết định ổn định hơn, đặc biệt đối với các lớp cảm xúc có biểu hiện khuôn mặt tương đối gần nhau.

3.5 LNSU

3.5.1 Tổng quan

Phương pháp *Leave No Stone Unturned* (LNSU) được đề xuất nhằm giải quyết bài toán nhận diện cảm xúc khuôn mặt trong điều kiện dữ liệu mất cân bằng [11]. Ý tưởng chính của phương pháp là không chỉ học từ các mẫu thuộc lớp thiểu số, mà còn khai thác thêm tri thức tiềm ẩn từ các mẫu thuộc lớp đa số để hỗ trợ quá trình học biểu diễn cho các lớp hiếm xuất hiện. Theo bài báo gốc, mô hình được xây dựng dựa trên backbone ResNet-18 tiền huấn luyện trên MS-Celeb-1M và có thể mở rộng sang nhiều backbone khác như MobileNet, ResNet-50 và Swin Transformer.

Phương pháp bao gồm hai mô-đun chính:

- **Re-balanced Attention Consistency (RAC):** ép attention map trước và sau phép biến đổi hình học phải nhất quán, đồng thời gán trọng số lớn hơn cho các lớp thiểu số.
- **Re-balanced Smooth Labels (RSL):** điều chỉnh nhãn làm mượt theo phân phối mất cân bằng của dữ liệu huấn luyện để mô hình chú ý hơn đến các lớp thiểu số.

3.5.2 Re-balanced Attention Consistency (RAC)

RAC được xây dựng dựa trên giả thiết rằng attention map của cùng một khuôn mặt phải duy trì tính nhất quán dưới các phép biến đổi hình học như phép lật ngang (horizontal flip) [11]. Với một ảnh đầu vào x và ảnh phản chiếu $\tilde{x}$, mô hình trích xuất đặc trưng ở lớp convolution cuối cùng, sau đó tính CAM cho tất cả các lớp cảm xúc.

$$M(i, l, h, w) = B_l \cdot A(i, l, h, w), \quad (35)$$

trong đó $A(i, l, h, w)$ là attention map gốc của mẫu i , lớp l , tại vị trí (h, w) .

Trọng số tái cân bằng được tính theo số lượng mẫu của từng lớp:

$$B_l = \frac{1 - \beta}{1 - \beta^{n_l}}, \quad (36)$$




Figure 14: Kiến trúc tổng thể của phương pháp LNSU gồm hai thành phần Re-balanced Attention Consistency (RAC) và Re-balanced Smooth Label (RSL) [11].




Figure 15: So sánh Label Smoothing truyền thống và Re-balanced Smooth Labels được đề xuất trong LNSU [11].

với n_l là số mẫu của lớp l và β là hệ số điều khiển mức độ ưu tiên cho lớp thiểu số. Trong thực nghiệm của bài báo, $\beta = 0.9999$.

Loss của mô-đun RAC là khoảng cách giữa attention map của ảnh gốc và ảnh sau phép flip:

$$\mathcal{L}_{cons} = \frac{1}{NLHW} \sum_{i=1}^N \sum_{l=1}^L \sum_{h=1}^H \sum_{w=1}^W \|M(i, l, h, w) - Flip(M_f)(i, l, h, w)\|_2^2. \quad (37)$$

Loss huấn luyện tổng thể của RAC được viết thành:

$$\mathcal{L}_{train} = \mathcal{L}_{cls} + \lambda \mathcal{L}_{cons}, \quad (38)$$

trong đó λ là trọng số của consistency loss.

3.5.3 Re-balanced Smooth Labels (RSL)

Ngoài RAC, tác giả còn đề xuất RSL để điều chỉnh classification loss theo hướng ưu tiên lớp thiểu số. Với nhãn one-hot y_i và dự đoán p_i , nhãn làm mượt tái cân bằng được định nghĩa:

$$\tilde{y}(i, l) = (1 - \alpha)y(i, l) + \alpha \frac{B_l}{L}, \quad (39)$$

trong đó α là hệ số smoothing và L là số lớp cảm xúc. Cách làm này giúp mô hình không chỉ học nhãn đúng mà còn khai thác thêm prior về phân phối mất cân bằng của tập huấn luyện.

4 Kết quả thực nghiệm

4.1 Tập dữ liệu

Để đánh giá các phương pháp, nhóm chúng em thực hiện trên tập dữ liệu RAF-DB [12].

Tập dữ liệu RAF-DB (Real-world Affective Faces Database) là một bộ dữ liệu lớn được xây dựng cho bài toán nhận diện và phân loại cảm xúc khuôn mặt trong điều kiện thực tế. Khác với nhiều bộ dữ liệu được thu thập trong môi trường phòng thí nghiệm, RAF-DB bao gồm các ảnh khuôn mặt được thu thập từ Internet, do đó dữ liệu có tính đa dạng cao về điều kiện ánh sáng, góc chụp, độ tuổi, giới tính, chủng tộc, biểu cảm và mức độ tự nhiên của khuôn mặt.

Bộ dữ liệu RAF-DB ban đầu gồm 29,672 ảnh khuôn mặt thực tế. Mỗi ảnh được gán nhãn bởi nhiều người khác nhau, trung bình khoảng 40 lượt gán nhãn cho một ảnh. Các ảnh trong tập dữ liệu được tiền xử lý về cùng kích thước 224×224 nhằm đảm bảo đầu vào thống nhất cho mô hình. Tập dữ liệu được chia thành hai phần: tập huấn luyện và tập kiểm thử theo tỷ lệ xấp xỉ 80 : 20. Cụ thể, tập huấn luyện gồm 12,271 ảnh và tập kiểm thử gồm 3,068 ảnh.

4.2 Độ đo đánh giá

Để đánh giá hiệu năng của các mô hình phân loại cảm xúc trên tập dữ liệu RAF-DB, nhóm sử dụng các độ đo đánh giá gồm Accuracy, F1-macro và Confusion Matrix. Các độ đo này giúp đánh giá khả năng phân loại tổng thể của mô hình, đồng thời phân tích chi tiết mức độ nhầm lẫn giữa các lớp cảm xúc.

- **Accuracy:** Accuracy là độ đo đánh giá chính được sử dụng trong bài toán phân loại cảm xúc. Độ đo này cho biết tỷ lệ mẫu được mô hình dự đoán đúng so với tổng số mẫu trong tập kiểm thử. Accuracy càng cao cho thấy mô hình có khả năng phân loại chính xác càng tốt.

$$\text{Accuracy} = \frac{\sum_{i=1}^N c_{ii}}{\sum_{i=1}^N \sum_{j=1}^N c_{ij}}$$

Trong đó, N là số lớp cảm xúc, c_{ii} là số lượng mẫu thuộc lớp i được dự đoán đúng, và c_{ij} là số lượng mẫu có nhãn thực tế thuộc lớp i nhưng được mô hình dự đoán thuộc lớp j .

- **F1-macro:** F1-macro là độ đo được tính bằng cách lấy trung bình cộng F1-score của từng lớp cảm xúc. Với mỗi lớp, F1-score được tính dựa trên Precision và Recall của lớp đó. Khác với Accuracy, F1-macro đánh giá hiệu năng của mô hình trên từng lớp một cách bình đẳng, do đó phù hợp trong trường hợp dữ liệu giữa các lớp cảm xúc có sự mất cân bằng.

$$\text{F1-macro} = \frac{1}{N} \sum_{i=1}^N F1_i$$

Trong đó:

$$F1_i = 2 \cdot \frac{P_i \cdot R_i}{P_i + R_i}$$

$$P_i = \frac{TP_i}{TP_i + FP_i}$$

$$R_i = \frac{TP_i}{TP_i + FN_i}$$

Với P_i là Precision của lớp i , R_i là Recall của lớp i , TP_i là số mẫu thuộc lớp i được dự đoán đúng, FP_i là số mẫu không thuộc lớp i nhưng bị dự đoán nhầm thành lớp i , và FN_i là số mẫu thuộc lớp i nhưng bị dự đoán nhầm sang lớp khác.

- **Confusion Matrix:** Confusion Matrix, hay ma trận nhầm lẫn, được sử dụng để phân tích chi tiết kết quả phân loại của mô hình trên từng lớp cảm xúc. Trong ma trận này, mỗi hàng biểu diễn nhãn thực tế và mỗi cột biểu diễn nhãn dự đoán. Thông qua Confusion Matrix, có thể quan sát được mô hình thường dự đoán đúng ở lớp nào và thường nhầm lẫn giữa những lớp cảm xúc nào.

$$CM = \begin{bmatrix} c_{11} & c_{12} & \cdots & c_{1N} \\ c_{21} & c_{22} & \cdots & c_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ c_{N1} & c_{N2} & \cdots & c_{NN} \end{bmatrix}$$

Trong đó c_{ij} là số lượng mẫu có nhãn thực tế thuộc lớp i nhưng được mô hình dự đoán thuộc lớp j . Các phần tử trên đường chéo chính c_{ii} biểu diễn số mẫu được phân loại đúng ở từng lớp cảm xúc.

4.3 Quá trình huấn luyện và Kết quả thực nghiệm

4.3.1 Hybrid ViT

Cấu Hình Siêu Tham Số Cấu hình huấn luyện mô hình được tổng hợp trong Bảng 1.

Table 1: Hyperparameters

Tham số	Giá trị
Batch Size	64
Epochs	40
Max Learning Rate	3×10^{-4}
Weight Decay	5×10^{-2}
Optimizer	AdamW [13]
Scheduler	OneCycleLR [14]
Loss Function	Focal Loss [15] ($\gamma = 2.0$)
Label Smoothing	0.1

Bộ tối ưu AdamW [13] kết hợp với Weight Decay 5×10^{-2} giúp kiểm soát tốt các trọng số lớn. Scheduler OneCycleLR [14] được sử dụng để tăng tốc độ hội tụ trong các epoch đầu và ổn định nghiệm ở giai đoạn cuối.

Đồ Thị Huấn Luyện Hình 16 biểu diễn đồ thị Loss và Accuracy trong suốt 40 epochs.




Figure 16: Loss và Accuracy trên tập Train và Validation.

- **Loss:** Train Loss giảm mạnh và tiệm cận 0.1. Val Loss giảm ổn định trong 12 epochs đầu, sau đó dao động nhẹ quanh mức 0.5. Việc dùng Focal Loss [15] giúp tránh hiện tượng bùng nổ gradient.
- **Accuracy:** Train Acc nhanh chóng đạt ngưỡng trên 95%. Val Acc có nhịp tăng mạnh ở pha warm-up (epoch 0 – 5), đạt đỉnh sau epoch 30 và duy trì mức ổn định $> 85\%$.

Confusion Matrix Hình 17 thể hiện chi tiết phân phối dự đoán trên tập kiểm thử.




Figure 17: Confusion Matrix của HybridVisionFormer.

- **Happiness** đạt tỷ lệ nhận diện tốt nhất (1115 mẫu đúng), chỉ một lượng nhỏ bị nhầm sang *Neutral* (52 mẫu).
- Các lớp **Sadness** (411 mẫu), **Neutral** (577 mẫu) và **Surprise** (283 mẫu) có mật độ dự đoán đúng cao, cho thấy khả năng phân loại đặc trưng của module Transformer [5].
- Lớp **Fear** và **Disgust** bị nhầm lẫn đáng kể sang *Neutral* và *Sadness*.
- Điều này xảy ra do sự tương đồng lớn trong biểu cảm cơ mặt và hiện tượng mất cân bằng dữ liệu (số mẫu *Fear* gốc chỉ có 74).

Classification Report Hình 18 cung cấp chi tiết các chỉ số Precision, Recall và F1-score.

CLASSIFICATION REPORT:				
	precision	recall	f1-score	support
Surprise	0.8708	0.8602	0.8654	329
Fear	0.7000	0.5676	0.6269	74
Disgust	0.6797	0.5437	0.6042	160
Happiness	0.9284	0.9409	0.9346	1185
Sadness	0.8187	0.8598	0.8388	478
Anger	0.8519	0.7099	0.7744	162
Neutral	0.8047	0.8485	0.8261	680
accuracy			0.8572	3068
macro avg	0.8077	0.7615	0.7815	3068
weighted avg	0.8552	0.8572	0.8551	3068

Figure 18: Classification Report.

- **Accuracy:** Mô hình đạt độ chính xác tổng thể 85.72% trên 3068 mẫu thử nghiệm.
- **F1-score:** *Happiness* cao nhất (0.9346), tiếp theo là *Surprise* (0.8654), *Sadness* (0.8388) và *Neutral* (0.8261).
- Weighted Avg F1-score đạt 0.8551.
- Do giới hạn về dữ liệu, *Fear* và *Disgust* có F1-score thấp hơn, tương ứng là 0.6269 và 0.6042.

Trực Quan Hóa Kết Quả Hình 19 minh họa một số kết quả dự đoán đúng và sai trên thực tế.



Figure 19: Dự đoán đúng (hàng trên) và sai (hàng dưới).

- **Đoán đúng:** Mạng nhận diện tốt các biểu cảm đặc trưng rõ ràng như *Neutral* (ảnh 1) hoặc *Happiness* (ảnh 2, 3) nhờ cơ chế attention [4, 5] tập trung vào vùng mắt và miệng.
- **Đoán sai:**
 - Khuất góc nhìn, nhiễu hình học (ảnh dưới trái) làm mô hình nhầm *Neutral* thành *Sadness*.
 - Trạng thái cơ mặt mờ nhạt (ảnh dưới giữa) gây nhầm lẫn giữa *Neutral* và *Happiness*.
 - Nếp nhăn ở người lớn tuổi (ảnh dưới phải) bị mô hình trích xuất nhầm thành tín hiệu nụ cười, dẫn đến đoán sai từ *Neutral* thành *Happiness*.

4.3.2 Advanced FER CNN

Cấu hình Siêu tham số thực nghiệm Chi tiết thiết lập thực nghiệm mạng Advanced FER CNN được tổng hợp chi tiết tại Bảng 2.

Table 2: Siêu tham số huấn luyện mô hình Advanced FER CNN.

Tham số	Giá trị
Kích thước ảnh đầu vào (Input Size)	$100 \times 100 \times 3$
Batch Size	32
Epochs	120
Learning Rate	5×10^{-4}
Optimizer	Adam
Loss Function	Categorical Crossentropy
Label Smoothing	0.05
LR Scheduler Callback	ReduceLROnPlateau (patience = 6, factor = 0.5)
Early Stopping Callback	Patience = 50

Đồ thị tiến trình Huấn luyện (Training Curves) Hình 20 mô tả tiến trình hội tụ và tối ưu hóa độ chính xác của mạng qua 120 epochs.




Figure 20: Đồ thị Loss và Accuracy của mô hình Advanced FER CNN.

- **Đường Loss:** Train Loss hội tụ mịn màng từ 2.35 xuống tiệm cận ngưỡng 0.61. Validation Loss có biến động nhẹ ở các epoch đầu do tác động của dữ liệu tăng cường, nhưng nhanh chóng ổn định và đạt trạng thái bão hòa quanh mức 0.85 sau epoch 60.

- **Đường Accuracy:** Độ chính xác tập huấn luyện đạt xấp xỉ 90% ở epoch cuối cùng. Độ chính xác tập kiểm thử (Validation Accuracy) đạt ngưỡng ổn định ở mức **82.17%**. Khoảng cách hẹp giữa hai đường đồ thị chứng minh các lớp L2 Regularization và Spatial Dropout đã triệt tiêu hiện tượng Overfitting hiệu quả.

Ma trận nhầm lẫn (Confusion Matrix) Hình 21 phân tích phân phối kết quả dự đoán chi tiết trên 3068 mẫu thử nghiệm.




Figure 21: Confusion Matrix của mô hình Advanced FER CNN trên tập Test.

- Phân lớp *happy* đạt hiệu năng áp đảo với 1085 mẫu dự đoán chính xác và tỷ lệ nhiều sang các lớp khác tối thiểu.
- Các biểu cảm *neutral* (562 mẫu), *sad* (386 mẫu) và *surprise* (265 mẫu) giữ vững mật độ phân bố tập trung dọc theo đường chéo chính của ma trận.
- Ngược lại, phân lớp *fear* (đoán đúng 38 mẫu, nhầm sang *surprise* 13 mẫu và *sad* 10 mẫu) và lớp *disgust* (đoán đúng 73 mẫu, nhầm sang *neutral* 38 mẫu) bộc lộ hạn chế nhận dạng đáng kể, phản ánh sự tương đồng hình thái cơ mặt rất cao và sự thiếu hụt dữ liệu gốc của hai phân lớp này.

Báo cáo Đánh giá Mô hình (Classification Report) Hình 22 cung cấp các chỉ số đo lường định lượng phân lớp chi tiết của hệ thống.

BÁO CÁO ĐÁNH GIÁ MÔ HÌNH (CLASSIFICATION REPORT)				
	precision	recall	f1-score	support
surprise	0.8885	0.7751	0.8279	329
fear	0.7447	0.4730	0.5785	74
disgust	0.5535	0.5500	0.5517	160
happy	0.9099	0.9122	0.9111	1185
sad	0.7660	0.8013	0.7832	478
angry	0.6902	0.7840	0.7341	162
neutral	0.7781	0.8044	0.7910	680
accuracy			0.8201	3068
macro avg	0.7616	0.7286	0.7397	3068
weighted avg	0.8218	0.8201	0.8195	3068

Figure 22: Bảng chỉ số đánh giá Classification Report của mô hình Advanced FER CNN.

- **Accuracy toàn cục:** Mô hình đạt độ chính xác chung **82.01%** trên tổng số 3068 ảnh kiểm thử độc lập từ chuẩn RAF-DB.
- **F1-score từng lớp:** Biểu cảm *happy* dẫn đầu với F1-score đạt 0.9111, theo sau lần lượt bởi các phân lớp *surprise* (0.8279), *neutral* (0.7910), *sad* (0.7832), và *angry* (0.7341). Chỉ số Weighted Average F1-score toàn hệ thống đạt ngưỡng cân bằng cao 0.8195.
- Các phân lớp chịu ảnh hưởng nặng từ nhiễu hình thái học là *fear* và *disgust* có F1-score thấp hơn, đạt lần lượt 0.5785 và 0.5517.

Trực quan hóa và Phân tích Lỗi nhận diện Hình 23 và Hình 24 minh họa thực tế các hành vi đưa ra quyết định dự đoán của mô hình phân loại.



Figure 23: Một số mẫu mô hình đưa ra dự đoán ĐÚNG.

Mô hình phản hồi cực kỳ chính xác đối với các biểu cảm có cường độ rõ nét (Hình 23). Phân lớp *happy* đạt độ tự tin rất lớn từ 96.77% đến 99.58%. Hệ thống thể hiện tính bền vững tự tin cao khi nhận diện đúng cấu trúc vùng mắt và miệng bất kể các yếu tố nhiễu nhân khẩu học như trẻ em hoặc đối tượng đeo kính góc nghiêng.



Figure 24: Một số mẫu mô hình đưa ra dự đoán SAI kèm phân tích lỗi.

- **Biểu cảm cường độ thấp (Subtle Expression):** Đối tượng mỉm cười nhẹ (smirk) dễ bị nhận nhầm thành trạng thái *neutral* với độ tự tin cao (76.13% và 81.61%) do biên độ thay đổi cơ mặt quá nhỏ.
- **Yếu tố che khuất vật lý (Occlusion):** Hành vi che khuất vùng miệng làm mất đi đặc trưng cục bộ cốt lõi, khiến mạng nhận diện sai lệch từ *neutral* sang *happy* (38.94%) do vùng má bị đẩy lên.
- **Sự tương đồng nếp nhăn sinh học:** Nếp nhăn lão hóa tự nhiên của người lớn tuổi xung quanh mắt và khóe miệng bị mô hình trích xuất nhầm, dẫn đến việc bỏ sót tín hiệu biểu cảm *sad* thực tế và đưa ra phán đoán sai thành lớp *neutral*.

4.3.3 EfficientNetV2-S

Thiết lập siêu tham số huấn luyện Quá trình tinh chỉnh toàn bộ mô hình (full fine-tuning) EfficientNetV2-S trên tập dữ liệu RAF-DB được thiết lập với các siêu tham số thực nghiệm nghiêm ngặt nhằm đảm bảo tính hội tụ và tối ưu hóa không gian đặc trưng biểu cảm:

- **Kích thước lô (Batch size):** 32
- **Số lượng kỷ nguyên tối đa (Max Epoch):** 20
- **Thuật toán tối ưu (Optimizer):** Adam
- **Tốc độ học ban đầu (Initial Learning Rate):** 10^{-4}
- **Chiến lược điều chỉnh tốc độ học (LR Scheduler):** ReduceLROnPlateau (tự động giảm tốc độ học khi hàm mất mát trên tập kiểm định rơi vào trạng thái bão hòa).

- **Hàm mất mát (Loss function):** CrossEntropyLoss
- **Chiến lược dừng sớm (Early Stopping):** Cấu hình với `patience = 5` kỷ nguyên để theo dõi hàm mất mát kiểm định nhằm tránh hiện tượng quá khớp (overfitting).

Đường cong huấn luyện (Learning Curves) Động lực học của quá trình huấn luyện và hội tụ của mô hình được minh họa chi tiết thông qua các đường cong Loss và Accuracy tại Hình 25.




Figure 25: Đường cong hàm mất mát (Loss) và độ chính xác (Accuracy) của EfficientNetV2-S trên tập dữ liệu RAF-DB

- Dựa trên đồ thị, hàm mất mát trên tập huấn luyện (Train Loss) giảm mạnh và liên tục từ 1.1 (Epoch 1) xuống mức tối thiểu 0.08 (Epoch 8), đồng thời độ chính xác huấn luyện (Train Acc) tăng tiến vững chắc từ 59% lên vượt mức 97%.
- Đối với tập kiểm định, hàm mất mát (Val Loss) đạt điểm tối ưu cục bộ thấp nhất tại Epoch 3 (≈ 0.57). Kể từ Epoch 4 đến Epoch 8, Val Loss có xu hướng dao động tăng ngược trở lại (đạt khoảng 0.67 ở Epoch 8).
- Do cấu hình Early Stopping với `patience = 5`, hệ thống ghi nhận hàm mất mát kiểm định không cải thiện liên tiếp trong 5 kỷ nguyên (từ Epoch 3 đến Epoch 8) và tự động kích hoạt lệnh dừng sớm tại Epoch 8. Cơ chế này giúp khôi phục các trọng số tối ưu nhất tại điểm có hiệu năng kiểm định tốt nhất, bảo toàn khả năng tổng quát hóa của mô hình và đạt độ chính xác kiểm định (Val Acc) xấp xỉ 83.2% ngay trước thời điểm dừng.

Phân tích kết quả định lượng Mô hình EfficientNetV2-S đạt độ chính xác tổng thể (Accuracy) là **84.91%** trên toàn bộ tập dữ liệu thử nghiệm gồm 3068 mẫu. Bảng báo cáo kết quả chi tiết (Classification Report) của từng lớp cảm xúc được trình bày trong Hình 26.

EFFICIENTNETV2 ON RAF-DB - CLASSIFICATION REPORT				
	precision	recall	f1-score	support
Surprise	0.8690	0.8267	0.8474	329
Fear	0.7347	0.4865	0.5854	74
Disgust	0.5924	0.5813	0.5868	160
Happy	0.9557	0.9274	0.9413	1185
Sad	0.7976	0.8243	0.8107	478
Anger	0.7572	0.8086	0.7821	162
Neutral	0.7923	0.8529	0.8215	680
accuracy			0.8491	3068
macro avg	0.7856	0.7583	0.7679	3068
weighted avg	0.8508	0.8491	0.8489	3068

Figure 26: Báo cáo kết quả phân loại (Classification Report) của mô hình EfficientNetV2-S

Phân tích sâu các chỉ số Precision, Recall và F1-score phản ánh rõ tác động của việc mất cân bằng phân phối nhãn dữ liệu (Support) lên mô hình:

- **Happy (Vui vẻ):** Đạt hiệu năng phân loại cao nhất với Precision 0.9557, Recall 0.9274 và F1-score vượt trội 0.9413. Lớp này sở hữu tập mẫu lớn nhất (1185 mẫu), đồng thời các đặc trưng hình học vùng miệng (nụ cười) có tính phân tách cục bộ rất cao, giúp backbone dễ dàng trích xuất biểu diễn đặc trưng.
- **Surprise (Ngạc nhiên) và Neutral (Bình thường):** Đạt kết quả phân loại rất tốt với F1-score lần lượt là 0.8474 và 0.8215. Sự hỗ trợ dữ liệu dồi dào từ lớp Neutral (680 mẫu) giúp mô hình tối ưu hóa tốt cấu trúc cơ mặt ở trạng thái tĩnh (Recall đạt 0.8529).
- **Sad (Buồn) và Anger (Tức giận):** Đạt mức ổn định với F1-score tương ứng là 0.8107 và 0.7821, chứng tỏ khả năng nhận diện tốt các mẫu cơ mặt thu hẹp hoặc trĩu xuống đặc trưng của nỗi buồn và sự giận dữ.
- **Fear (Sợ hãi) và Disgust (Chán ghét/E ngại):** Đây là hai lớp có hiệu năng thấp nhất với F1-score lần lượt chỉ đạt 0.5854 và 0.5868. Đáng chú ý, lớp Fear có chỉ số Recall cực thấp (0.4865), cho thấy hơn một nửa số mẫu mang cảm xúc sợ hãi trong thực tế đã bị mô hình phân loại sai nhãn.

Nhằm làm rõ bản chất các sai số phân loại tuyến tính từ lớp Linear cuối cùng, ma trận nhầm lẫn (Confusion Matrix) dạng thô và chuẩn hóa được hiển thị tại Hình 27.




Figure 27: Ma trận nhầm lẫn thô (trái) và chuẩn hóa (phải) trên tập dữ liệu kiểm định RAF-DB

Dựa trên ma trận nhầm lẫn chuẩn hóa, các vùng nhầm lẫn cốt lõi được bóc tách như sau:

- **Sự nhầm lẫn của lớp Fear:** Mẫu thuộc lớp Fear bị nhận diện sai sang lớp **Sad** (16%), lớp **Surprise** (15%) và lớp **Anger** (11%). Bản chất của biểu cảm sợ hãi thường xuất hiện các đặc trưng biên độ lớn như trợn mắt (gần giống Surprise) hoặc co thắt nếp nhăn vùng trán (gần giống Sad, Anger), tạo ra sự chồng lấn trong không gian vector đặc trưng tầng sâu.
- **Sự nhầm lẫn của lớp Disgust:** Mẫu mang nhãn Disgust bị phân loại sai nhiều nhất sang lớp **Neutral** (14%) và lớp **Sad** (11%). Điều này xuất phát từ việc một số biến thể cơ mặt khi chán ghét nhẹ trong RAF-DB có biểu hiện khá mờ nhạt, khiến mô hình nhầm lẫn với trạng thái khuôn mặt không biểu cảm hoặc buồn nhẹ.

Đánh giá định tính và Phân tích mẫu lỗi Hình 28 trực quan hóa một số trường hợp phân loại sai tiêu biểu của mô hình EfficientNetV2-S, qua đó minh chứng cho tính thách thức phi tuyến tính của bài toán FER (Facial Expression Recognition):




Figure 28: Trực quan hóa một số trường hợp mẫu khuôn mặt bị dự đoán sai nhãn bởi mô hình

- **Mẫu thứ nhất (True: Fear, Pred: Surprise):** Đối tượng có khuôn miệng mở rộng và mắt mở to tối đa. Do biểu hiện hình học bên ngoài trùng khớp với phân phối mật độ của trạng thái ngạc nhiên, mạng backbone đã trích xuất các biểu diễn thiên lệch về phía lớp Surprise.

- **Mẫu thứ hai (True: Sad, Pred: Neutral):** Biểu cảm buồn của đối tượng diễn ra nội tâm, thiếu đi các dấu hiệu biên độ lớn (như khóe miệng hạ sâu hay nếp nhăn lông mày rõ rệt). Do đó, mô hình có xu hướng đưa dự đoán về lớp Neutral (vốn có phân phối dữ liệu nền lớn hơn) để tối ưu hóa hàm xác suất Softmax.
- **Mẫu thứ ba (True: Disgust, Pred: Sad):** Hành động nhăn mặt, nhe răng và hạ cơ môi khi chán ghét tạo ra cấu trúc hình học bất đối xứng, dễ bị lớp phân loại tuyến tính cuối cùng ánh xạ nhầm sang các đặc trưng biểu hiện của sự đau khổ hay buồn bã (Sad).

4.3.4 ResNet-18 kết hợp Affinity Loss

Phần này trình bày chi tiết về cấu hình siêu tham số, quá trình hội tụ tối ưu cùng các kết quả đánh giá thực nghiệm định lượng và định tính của mô hình ResNet-18 kết hợp Affinity Loss trên tập dữ liệu RAF-DB.

Cấu hình huấn luyện và Bộ điều chỉnh tốc độ học Các siêu tham số cấu hình chính phục vụ cho quá trình huấn luyện mô hình được tổng hợp chi tiết trong Bảng 3. Nhằm tối ưu hóa hiệu năng ở giai đoạn mạng gần hội tụ, cơ chế tự động giảm tốc độ học `ReduceLROnPlateau` được áp dụng với các thiết lập trong Bảng 4. Cơ chế này giám sát trực tiếp loss trên tập validation để tự động giảm tốc độ học khi mô hình có dấu hiệu chững lại, từ đó hạn chế dao động và giúp quá trình tối ưu diễn ra ổn định hơn.

Table 3: Cấu hình huấn luyện mô hình ResNet-18 kết hợp Affinity Loss.

Thành phần	Giá trị
Backbone	ResNet-18 pretrained MS-Celeb-1M
Input Size	224×224
Feature Dimension	512
Batch Size	64
Epochs	30
Optimizer	AdamW
Weight Decay	10^{-4}
Learning Rate	10^{-4}
LR Scheduler	ReduceLROnPlateau
Loss Function	Cross-Entropy + Affinity Loss
λ cho Affinity Loss	0.05

Table 4: Thiết lập ReduceLROnPlateau cho mô hình ResNet-18.

Thành phần	Giá trị
Minimum Learning Rate	10^{-5}
Reduce Factor	0.5
Patience	1
Threshold	5×10^{-3}

Đồ thị quá trình huấn luyện Sự thay đổi của hàm mất mát (Loss) và độ chính xác (Accuracy / F1) qua 30 epoch huấn luyện được trực quan hóa tại Hình 29. Qua đồ thị, hàm mất mát trên cả hai tập huấn luyện và kiểm thử đều giảm mạnh ở những epoch đầu và duy trì xu hướng hội tụ ổn

định ở giai đoạn sau. Sự chênh lệch nhỏ (gap) giữa các đường cong cho thấy mô hình có khả năng tổng quát hóa tốt và hạn chế tối đa hiện tượng quá khớp (overfitting).




Figure 29: Đồ thị Loss và Accuracy trong quá trình huấn luyện mô hình ResNet-18 kết hợp Affinity Loss.

So sánh hiệu năng các cấu hình thí nghiệm Để đánh giá toàn diện đóng góp của trọng số pretrained và hàm mất mát Affinity Loss, hiệu năng của ba cấu hình mạng được so sánh chi tiết trong Bảng 5.

Table 5: So sánh hiệu năng giữa các cấu hình ResNet-18.

ResNet-18 Weights	Training Loss	Accuracy	Macro F1
Random	Cross-Entropy	78.10%	68.58%
Pretrained MS-Celeb-1M	Cross-Entropy	86.08% (+7.98%)	78.29% (+9.71%)
Pretrained MS-Celeb-1M	Cross-Entropy + Affinity	86.90% (+0.82%)	79.17% (+0.88%)

Kết quả thực nghiệm minh chứng việc khởi tạo từ trọng số pretrained trên tập khuôn mặt lớn MS-Celeb-1M giúp tăng vọt hiệu năng so với khởi tạo ngẫu nhiên (Accuracy tăng 7.98%, Macro F1 tăng 9.71%). Khi bổ sung thêm Affinity Loss, mô hình tiếp tục cải thiện lên mức tối ưu nhất với 86.90% Accuracy và 79.17% Macro F1. Điều này khẳng định Affinity Loss đóng vai trò bổ trợ đắc lực cho Cross-Entropy bằng cách thu hẹp khoảng cách nội lớp và tối ưu hóa cấu trúc không gian embedding.

Báo cáo phân loại và Ma trận nhầm lẫn Do tập dữ liệu kiểm thử có sự mất cân bằng đáng kể giữa các lớp cảm xúc, hiệu năng chi tiết của mô hình được đánh giá sâu hơn qua Báo cáo phân loại (Hình 30) và Ma trận nhầm lẫn (Hình 31). Chỉ số Macro F1 được sử dụng nhằm đảm bảo tính khách quan cho các lớp có lượng mẫu ít.

	precision	recall	f1-score	support
Surprise	0.8707	0.8389	0.8545	329
Fear	0.6620	0.6351	0.6483	74
Disgust	0.5924	0.5813	0.5868	160
Happiness	0.9403	0.9570	0.9486	1185
Sadness	0.8443	0.8619	0.8530	478
Anger	0.8931	0.7222	0.7986	162
Neutral	0.8410	0.8632	0.8520	680
accuracy			0.8690	3068
macro avg	0.8062	0.7799	0.7917	3068
weighted avg	0.8685	0.8690	0.8681	3068

Figure 30: Classification Report của mô hình ResNet-18 kết hợp Affinity Loss trên tập kiểm thử.




Figure 31: Confusion Matrix của mô hình ResNet-18 kết hợp Affinity Loss trên tập kiểm thử.

Kết quả từ ma trận nhầm lẫn cho thấy mô hình nhận diện cực tốt các cảm xúc có đặc trưng hình thái rõ nét như *Happiness* (96%). Tuy nhiên, các lỗi nhầm lẫn vẫn xuất hiện ở những biểu cảm có cường độ thấp hoặc hình thái gần nhau, tiêu biểu như lớp *Fear* dễ bị nhầm sang *Surprise* (12%), hay xu hướng phân loại sai từ *Sadness* và *Disgust* sang nhãn *Neutral* (13%).

Trực quan hóa mẫu dự đoán thực tế Hình 32 minh họa một số mẫu dự đoán tiêu biểu của mô hình trên tập kiểm thử, bao gồm 3 trường hợp chính xác với độ tự tin (confidence) cao và 3 trường hợp sai lệch. Các mẫu lỗi thường rơi vào tình huống vùng mặt bị khuất, điều kiện ánh sáng phức tạp hoặc sắc thái biểu cảm nằm ở ranh giới mờ hồ giữa các lớp (như *Anger* nhầm sang *Happiness* do khẩu hình miệng, hay *Disgust* nhầm sang *Fear*).




Figure 32: Một số mẫu dự đoán của mô hình ResNet-18 kết hợp Affinity Loss, gồm 3 dự đoán đúng và 3 dự đoán sai.

4.3.5 LNSU

Thiết lập tham số thực nghiệm Toàn bộ các thực nghiệm trên tập dữ liệu RAF-DB được tiến hành với kích thước ảnh đầu vào là 224×224 pixel [11]. Mô hình sử dụng bộ tối ưu hóa Adam (Adam optimizer) với hệ số suy giảm trọng số (weight decay) được thiết lập ở mức 10^{-4} . Tốc độ học (learning rate) khởi tạo được đặt là 10^{-4} và được điều chỉnh động thông qua bộ lập lịch ExponentialLR với hệ số giảm $\gamma = 0.9$. Số lượng epoch huấn luyện tối đa được cấu hình là $T_{max} = 60$. Ngoài ra, các siêu tham số cốt lõi của hai mô-đun đề xuất bao gồm trọng số tính nhất quán dữ liệu $\lambda = 2$ cho RAC và hệ số làm mượt nhân $\alpha = 0.1$ cho RSL [11]. Để đảm bảo tính so sánh công bằng với các nghiên cứu tiền nhiệm, mô hình sử dụng cấu hình chuẩn dựa trên backbone ResNet-18 đã được tiền huấn luyện trên tập MS-Celeb-1M, đồng thời thể hiện khả năng tương thích và mở rộng tốt trên các mạng mã hóa đặc trưng khác như MobileNet, ResNet-50 hay Swin Transformer [11].

Đồ thị tiến trình huấn luyện (Training Curve) Hình 33 mô tả diễn biến chi tiết của giá trị hàm mất mát (loss) và các chỉ số độ chính xác (accuracy/F1-score) của mô hình LNSU trên tập dữ liệu RAF-DB qua các bước lặp. Về hàm tổn thất, giá trị loss giảm mạnh và nhanh chóng trong khoảng 5,000 step đầu tiên từ mức xấp xỉ 2.2 xuống dưới 1.4, sau đó tiếp tục tiệm cận đều đặn về trạng thái hội tụ ổn định quanh mức 1.15 tại step thứ 60,000.

Đối với chỉ số đánh giá trên tập validation, đồ thị bên phải cho thấy độ chính xác ('val acc') có xu hướng biến động mạnh ở các phiên validation đầu tiên do tác động của cơ chế gán trọng số tái cân bằng, nhưng nhanh chóng thiết lập quỹ đạo tăng tiến ổn định ở giai đoạn cuối, đạt các đỉnh hiệu năng rất cao (trên dưới 95.0




Figure 33: Diễn biến giá trị Loss trong quá trình huấn luyện (trái) và đồ thị chỉ số Accuracy/F1 trên tập Validation (phải) của mô hình LNSU.

Kết quả phân loại và Đánh giá chi tiết Kết quả kiểm thử định lượng chi tiết của phương pháp LNSU trên tập kiểm thử gồm 3068 mẫu của RAF-DB được tổng hợp tại Bảng 6 và Hình 34. Tổng thể, mô hình đạt độ chính xác toàn cục (Overall Accuracy) ở mức 93%, chỉ số trung bình Macro (Macro Avg) đạt 0.88 ở cả ba góc độ Precision, Recall và F1-score, vượt trội đáng kể so với mô hình baseline thuần ResNet-18 thông thường [11].

Table 6: Báo cáo hiệu năng phân loại chi tiết (Classification report) của mô hình LNSU trên tập dữ liệu RAF-DB.

Lớp cảm xúc (Class)	Precision	Recall	F1-score	Support
Surprise (Class 0)	0.92	0.93	0.93	329
Fear (Class 1)	0.69	0.74	0.71	74
Disgust (Class 2)	0.78	0.86	0.82	160
Happiness (Class 3)	0.97	0.97	0.97	1185
Sadness (Class 4)	0.91	0.90	0.91	478
Anger (Class 5)	0.93	0.86	0.90	162
Neutral (Class 6)	0.92	0.93	0.92	680
Accuracy			0.93	3068
Macro Avg	0.88	0.88	0.88	3068
Weighted Avg	0.93	0.93	0.93	3068

Phân tích sâu vào từng lớp biểu cảm, mô hình cho thấy khả năng nhận diện xuất sắc đối với các lớp có lượng mẫu lớn hoặc đặc trưng tường minh như *Happiness* (đạt F1-score tối đa 0.97, dự đoán chính xác 1148 trên tổng số 1185 mẫu) và *Neutral* (đạt F1-score 0.92, nhận diện đúng 629 mẫu). Đáng chú ý, tại các lớp dữ liệu thiếu số vốn cực kỳ khó phân loại trong bài toán FER mất cân bằng do thiếu hụt thông tin hình ảnh nghiêm trọng như *Fear* và *Disgust*, LNSU đã chứng minh được tính đột phá của mình:

- Lớp *Fear* (Class 1) đạt tỉ lệ Precision 0.69, Recall 0.74 và F1-score 0.71 (phân loại đúng 55/74 mẫu).
- Lớp *Disgust* (Class 2) đạt tỉ lệ Precision 0.78, Recall 0.86 và F1-score 0.82 (phân loại đúng 137/160 mẫu).




Figure 34: Ma trận nhầm lẫn dạng đếm số mẫu (trái) và Ma trận nhầm lẫn chuẩn hóa (phải) của mô hình LNSU trên tập kiểm thử RAF-DB.

Dựa trên ma trận nhầm lẫn chuẩn hóa (Hình 34), có thể quan sát thấy đường chéo chính có mật độ phân phối xác suất rất đậm màu và đồng đều. Mặc dù vẫn tồn tại một số sai số đặc trưng do sự tương đồng cao về mặt biểu hiện cơ mặt (ví dụ: 14% số mẫu thuộc lớp *Fear* bị nhận nhầm sang lớp *Surprise*, hoặc 8% bị nhầm sang *Sadness*), song nhìn chung cơ chế chú ý nhất quán tái cân bằng (RAC) cùng nhân làm mượt phân phối ngược (RSL) đã giúp cải thiện rõ rệt ranh giới phân quyết cho các lớp biên hiếm gặp [11].

4.3.6 Tổng hợp kết quả thực nghiệm

Dưới đây là tổng hợp kết quả thực nghiệm định lượng của 5 phương pháp trên tập kiểm thử chuẩn gồm 3068 mẫu của tập dữ liệu RAF-DB. Các cấu hình được đối sánh bao gồm độ chính xác toàn cục (Accuracy) và chỉ số F1-Score chi tiết cho từng nhóm cảm xúc cốt lõi.

Table 7: So sánh độ chính xác toàn cục (Accuracy) trên tập kiểm thử

Phương pháp / Kiến trúc mạng nền tảng	Accuracy (%)
LNSU	93.00
ResNet-18 kết hợp Affinity Loss	86.90
HybridViT	85.72
EfficientNetV2-S	84.91
Advanced FER CNN	82.01

Table 8: So sánh chỉ số F1-Score chi tiết theo từng phân lớp cảm xúc

Phương pháp	Surprise	Fear	Disgust	Happy	Sad	Anger	Neutral	Macro Avg	Weighted Avg
LNSU	0.9300	0.7100	0.8200	0.9700	0.9100	0.9000	0.9200	0.8800	0.9300
ResNet-18 + Affinity Loss	0.8545	0.6483	0.5868	0.9486	0.8530	0.7986	0.8520	0.7917	0.8681
HybridViT	0.8654	0.6269	0.6042	0.9346	0.8388	0.7744	0.8261	0.7815	0.8551
EfficientNetV2-S	0.8474	0.5854	0.5868	0.9413	0.8107	0.7821	0.8215	0.7679	0.8489
Advanced FER CNN	0.8279	0.5785	0.5517	0.9111	0.7832	0.7341	0.7910	0.7397	0.8195

5 Đánh giá và nhận xét ưu điểm, nhược điểm về các Phương pháp

Dựa trên kết quả định lượng thu được từ tập kiểm thử độc lập của tập dữ liệu RAF-DB và các phân tích đặc trưng hình thái, cấu trúc không gian đặc trưng của từng mô hình, phần này cung cấp một cái nhìn sâu sắc về ưu điểm và hạn chế cốt lõi của 5 phương pháp tiếp cận.

5.1 Phương pháp HybridViT

Mô hình lai hiện đại kết hợp sức mạnh trích xuất đặc trưng cục bộ của CNN với năng lực học ngữ cảnh toàn cục của kiến trúc Vision Transformer.

- **Ưu điểm:**

- **Kiến trúc lai tối ưu hóa luồng thông tin:** Sự kết hợp giữa ResNet50 và Transformer Encoder giúp mô hình vừa nắm bắt tốt các chi tiết cơ học cục bộ (mắt, mũi, miệng) vừa mô hình hóa xuất sắc mối tương quan ngữ cảnh tầm xa đa vị trí trên khuôn mặt.
- **Cơ chế Sequence Pooling linh hoạt:** Việc loại bỏ cấu trúc token phân loại cứng [CLS] truyền thống và thay thế bằng Attention Pooling giúp mạng tổng hợp thông tin chuỗi một cách động, phản ánh đúng phân phối đóng góp thực tế của từng vùng biểu cảm.
- **Chiến lược điều hòa đồng bộ mạnh mẽ:** Việc áp dụng đồng thời Focal Loss, RandAugment và đặc biệt là RandomErasing (xóa vùng ngẫu nhiên) đã ép mạng học các đa đối đặc trưng, mang lại tính tổng quát hóa cao.

- **Hạn chế:**

- **Vẫn nhạy cảm với sự mất cân bằng dữ liệu nặng:** Dù áp dụng Focal Loss nhưng hiệu năng của mô hình vẫn bộc lộ sự sụt giảm rõ rệt ở các lớp có ít mẫu hỗ trợ như *Fear* ($F1 = 0.6269$) và *Disgust* ($F1 = 0.6042$).
- **Chống nhiễu thực tế chưa toàn diện:** Luồng trích xuất đặc trưng và các bộ lọc chú ý vẫn có nguy cơ bị nhiễu do hiện tượng khuếch góc nhìn, nhiễu bóng đổ hình học phức tạp hoặc nhiễu sinh học từ nếp nhăn độ tuổi của người già.

5.2 Phương pháp Advanced FER CNN

Một kiến trúc mạng tích chập tùy chỉnh sâu (custom CNN) kết hợp cơ chế chú ý kênh và các chiến lược cân bằng dữ liệu nghiêm ngặt.

- **Ưu điểm:**

- **Tiết kiệm tài nguyên tính toán:** Việc thay thế các phép tích chập chuẩn bằng tích chập tách biệt chiều sâu (*Separable Convolution*) giúp giảm thiểu đáng kể số lượng tham số nhưng vẫn giữ được chiều sâu của mạng.
- **Khả năng chống Overfitting mạnh mẽ:** Sự phối hợp của nhiều kỹ thuật điều hòa bao gồm Spatial Dropout, L2 Regularization, và Label Smoothing giúp thu hẹp khoảng cách giữa đồ thị huấn luyện và kiểm thử.
- **Bền vững trước nhiễu nhân khẩu học:** Hệ thống thể hiện khả năng nhận diện đúng cấu trúc biểu cảm bất kể các yếu tố ngoại cảnh phức tạp như đối tượng là trẻ em hoặc người đeo kính ở góc chụp nghiêng.

- **Hạn chế:**

- **Dễ bị ảnh hưởng bởi che khuất vật lý (Occlusion):** Hành vi che khuất vùng miệng làm mất đi các đặc trưng cục bộ cốt lõi, khiến mạng đưa ra phán đoán sai lệch từ *Neutral* sang *Happy* (38.94%) do vùng má bị đẩy lên cao.
- **Bị nhiễu bởi nếp nhăn sinh học tự nhiên:** Các nếp nhăn lão hóa của người lớn tuổi xung quanh mắt và khóe miệng bị các bộ lọc trích xuất nhầm thành tín hiệu cơ cơ biểu cảm, dẫn đến việc phán đoán sai các khuôn mặt bình thường thành cảm xúc *Sad*.

5.3 Phương pháp EfficientNetV2-S

Phương pháp tận dụng một kiến trúc mạng tiên tiến được tối ưu hóa đồng thời về cả độ chính xác lẫn tốc độ tính toán trên phần cứng.

- **Ưu điểm:**

- **Hiệu năng cao trên các biểu cảm biên độ lớn:** Mô hình nhận diện rất nhạy bén các biểu cảm có đặc trưng hình thái rõ ràng như *Happy* (94.13%) và *Surprise* (84.74%).
- **Kiến trúc phân tầng tối ưu:** Sự kết hợp giữa các khối Fused-MBConv ở tầng nông (tăng tốc độ xử lý, trích xuất đặc trưng cạnh/đường viền) và khối MBConv ở tầng sâu giúp tối ưu hóa bộ nhớ và tăng cường khả năng học đặc trưng ngữ nghĩa.
- **Tốc độ hội tụ rất nhanh:** Tận dụng tốt tri thức từ ImageNet-1K giúp mô hình đạt trạng thái bão hòa tối ưu chỉ sau từ 3 đến 5 kỷ nguyên huấn luyện.

- **Hạn chế:**

- **Tỷ lệ bỏ sót cảm xúc nguy hiểm cực kỳ cao:** Lớp *Fear* có chỉ số Recall sụt giảm nghiêm trọng xuống mức 0.4865, nghĩa là hơn một nửa số trường hợp khuôn mặt thực tế đang sợ hãi bị mô hình phân loại sai sang các nhãn cảm xúc khác (như *Sad*, *Surprise*, *Anger*). **Hạn chế đối với biểu cảm nội tâm:** Khi đối tượng thể hiện cảm xúc với cường độ thấp hoặc biên độ biến đổi cơ mặt quá nhỏ (như buồn nhẹ), mô hình ngay lập tức bị thiên lệch dự đoán về lớp có phân phối nền lớn hơn là *Neutral*.

5.4 Phương pháp ResNet-18 kết hợp Affinity Loss

Giải pháp này tập trung vào việc định hình cấu trúc không gian hình học embedding thông qua việc bổ sung một ràng buộc khoảng cách vào hàm mất mát.

- **Ưu điểm:**

- **Tối ưu hóa cấu trúc không gian đặc trưng:** Affinity Loss hoạt động xuất sắc trong việc thu hẹp khoảng cách nội lớp (intra-class variance) đồng thời duy trì một khoảng cách an toàn giữa các tâm lớp khác nhau (inter-class margin), tạo ra các cụm dữ liệu phân tách rõ ràng.
- **Khai thác hiệu quả Transfer Learning:** Sử dụng trọng số tiền huấn luyện từ tập dữ liệu khuôn mặt quy mô lớn MS-Celeb-1M giúp mô hình nhanh chóng nắm bắt các đặc trưng hình thái tinh vi, mang lại bước nhảy vọt về hiệu năng so với khởi tạo ngẫu nhiên.
- **Trọng lượng nhẹ và tốc độ xử lý nhanh:** Mô hình giữ được cấu trúc tính toán gọn nhẹ của ResNet-18, đạt độ chính xác toàn cục ấn tượng (86.90%), rất phù hợp cho việc triển khai trên các ứng dụng thời gian thực.

- **Hạn chế:**

- **Suy giảm hiệu năng trên lớp dữ liệu thiếu số:** Ràng buộc hình học chưa đủ mạnh để bù đắp cho sự thiếu hụt nghiêm trọng về số lượng mẫu, dẫn đến việc chỉ số F1-score của hai lớp *Disgust* (58.68%) và *Fear* (64.83%) vẫn ở mức thấp.
- **Nhạy cảm với nhiễu ngoại cảnh:** Mô hình dễ bị đánh lừa hoặc phân loại sai lệch đáng kể dưới tác động của sự thay đổi góc chụp (góc nghiêng), điều kiện ánh sáng yếu hoặc khi khuôn mặt bị che khuất một phần.

5.5 Phương pháp Leave No Stone Unturned (LNSU)

Phương pháp LNSU đại diện cho hướng tiếp cận tối ưu hóa hàm mục tiêu và nhãn mục tiêu nhằm giải quyết trực tiếp bài toán dữ liệu đuôi dài (long-tailed).

- **Ưu điểm:**

- **Khắc phục triệt để hiện tượng học lệch do mất cân bằng dữ liệu:** Nhờ sự phối hợp đồng bộ giữa mô-đun RAC (nhất quán chú ý) và RSL (làm mượt nhãn tái cân bằng), hiệu năng nhận diện ở các lớp thiếu số như *Fear* và *Disgust* được cải thiện một cách rõ rệt.
- **Khai thác tri thức không phá vỡ phân phối gốc:** Khác với các kỹ thuật tăng cường mẫu nhân tạo truyền thống dễ gây hiện tượng quá khớp (overfitting), LNSU chủ động khai thác gián tiếp tri thức tiềm ẩn từ các lớp đa số để dẫn dắt mô hình học biểu diễn vững chắc cho lớp thiếu số.
- **Hiệu năng Macro-average vượt trội:** Đạt chỉ số Macro Average F1-score cân bằng lý tưởng ở mức 0.88, chứng minh mô hình có khả năng phân loại đồng đều trên mọi phân lớp biểu cảm.
- **Tính linh hoạt cao về mặt kiến trúc:** Thiết kế dạng mô-đun độc lập cho phép tích hợp giải pháp này vào bất kỳ mạng xương sống nào từ mạng tích chập (ResNet) đến các kiến trúc dựa trên tự chú ý (Swin Transformer).

- **Hạn chế:**

- **Tồn tại sai số ở các biểu cảm có hình thái tương đồng:** Mô hình vẫn chịu một tỷ lệ nhầm lẫn nhất định đối với các cặp cảm xúc có sự tương đồng lớn về cấu trúc chuyển động cơ mặt (ví dụ: 14% số lượng mẫu thuộc lớp *Fear* bị dự đoán sai sang lớp *Surprise* và 8% bị nhầm sang *Sadness*).
- **Biến động mạnh ở giai đoạn huấn luyện ban đầu:** Việc áp dụng hệ số gán trọng số tái cân bằng dựa trên số lượng mẫu thực tế khiến đồ thị độ chính xác trên tập Validation xảy ra hiện tượng dao động biên độ lớn trước khi đạt trạng thái hội tụ ổn định.

References

- [1] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, “An image is worth 16x16 words: Transformers for image recognition at scale,” in *International Conference on Learning Representations (ICLR)*, 2021.
- [2] H. Wu, B. Xiao, N. Codella, M. Liu, X. Dai, L. Yuan, and L. Zhang, “Cvt: Introducing convolutions to vision transformers,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 22–31, 2021.

- [3] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR)*, pp. 770–778, 2016.
- [4] S. Woo, J. Park, J.-Y. Lee, and I. S. Kweon, “Cbam: Convolutional block attention module,” in *Proceedings of the European conference on computer vision (ECCV)*, pp. 3–19, 2018.
- [5] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in neural information processing systems (NeurIPS)*, vol. 30, 2017.
- [6] E. D. Cubuk, B. Zoph, J. Shlens, and Q. V. Le, “Randaugment: Practical automated data augmentation with a reduced search space,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, pp. 18613–18624, 2020.
- [7] Z. Zhong, L. Zheng, G. Kang, S. Li, and Y. Yang, “Random erasing data augmentation,” in *Proceedings of the AAAI conference on artificial intelligence (AAAI)*, vol. 34, pp. 13001–13008, 2020.
- [8] M. Tan and Q. Le, “Efficientnetv2: Smaller models and faster training,” in *International conference on machine learning*, pp. 10096–10106, PMLR, 2021.
- [9] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, “Mobilenetv2: Inverted residuals and linear bottlenecks,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 4510–4520, 2018.
- [10] Y. Guo, L. Zhang, Y. Hu, X. He, and J. Gao, “Ms-celeb-1m: A dataset and benchmark for large-scale face recognition,” in *European conference on computer vision*, pp. 87–102, Springer, 2016.
- [11] Y. Zhang, Y. Li, I. Qin, X. Liu, and W. Deng, “Leave no stone unturned: Mine extra knowledge for imbalanced facial expression recognition,” in *Advances in Neural Information Processing Systems* (A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, and S. Levine, eds.), vol. 36, pp. 14414–14426, Curran Associates, Inc., 2023.
- [12] S. Li, W. Deng, and J. Du, “Reliable crowdsourcing and deep locality-preserving learning for expression recognition in the wild,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 2852–2861, 2017.
- [13] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *International Conference on Learning Representations (ICLR)*, 2019.
- [14] L. N. Smith and N. Topin, “Super-convergence: very fast training of neural networks using large learning rates,” in *Artificial Intelligence and Machine Learning for Multi-Domain Operations Applications*, vol. 11006, pp. 369–386, SPIE, 2019.
- [15] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *Proceedings of the IEEE international conference on computer vision (ICCV)*, pp. 2980–2988, 2017.