

Mục lục

1	Tổng Hợp Quy Tắc: Đạo Hàm Ma Trận (Matrix Calculus)	2
2	Tổng Hợp Công Thức: Hồi Quy Tuyến Tính & Gradient Descent	3
2.1	Bài tập :	3
2.1.1	Đề Bài (Question 3)	3
2.1.2	Lời Giải Chi Tiết	4
3	Tổng Hợp: Hồi Quy Đa Thức & Regularization	4
3.1	Ma trận chiếu - Projection Matrix	5
3.1.1	Công thức Tổng quát	5
3.2	Chứng minh (Dẫn xuất công thức)	5
3.3	Trường hợp đặc biệt: Chiếu lên vector (1D)	6
3.4	Tính chất của Ma trận Chiếu P	6
3.5	Liên hệ với Machine Learning (Hat Matrix)	6
4	Tổng Hợp Kiến Thức: Đại Số Tuyến Tính cho Khoa học Dữ liệu	7
5	Tổng Hợp: Mô Hình Xác Suất & Suy Diễn Bayes	8
6	Tổng Hợp: Công Thức Xác Suất & Ma Trận Thống Kê	9
7	Tổng Hợp: Ước Lượng Tham Số (MLE/MAP) & Tối Ưu Hóa	10
8	Tổng Hợp: Phân Tích Độ Chênh - Phương Sai (Bias-Variance Trade-off)	11
9	Tổng Hợp: Hồi Quy Logistic & Tối Ưu Hóa Gradient Descent	12
10	Tổng Hợp: Hồi Quy Softmax (Phân Loại Đa Lớp)	13
11	Tổng Hợp: Mạng Nơ-ron & Lan Truyền Ngược	14
12	Tổng Hợp: Cơ Sở Toán Học Cho Tối Ưu Hóa (Optimization Basis)	15
12.1	Ma trận Hessian và Cực trị	15
12.1.1	1. Điểm dừng (Critical Point)	15
12.1.2	2. Ma trận Hessian	16
12.1.3	3. Định thức Hessian (Biệt thức)	16
12.2	Quy tắc phân loại cực trị (Cực quan trọng)	16
12.3	Ví dụ áp dụng (Bài Câu 15)	16
12.3.1	Bước 1: Tính đạo hàm riêng cấp 1	16
12.3.2	Bước 2: Tính đạo hàm riêng cấp 2	16
12.3.3	Bước 3: Lập ma trận Hessian và tính D	16
12.3.4	Bước 4: Kết luận	17
13	Tổng Hợp: Các Phương Pháp Tối Ưu Bậc Nhất (First-Order Methods)	18
14	Công thức Tính Số Lượng Tham Số (Softmax/Linear Layer)	19
15	Công thức Tính Tham Số Mạng Nơ-ron Đa Tầng (MLP)	20
16	Confusion Matrix (Ma trận nhầm lẫn)	20
16.1	Bài tập ví dụ	21

1 Tổng Hợp Quy Tắc: Đạo Hàm Ma Trận (Matrix Calculus)

Ký hiệu:

- s : Số vô hướng (Scalar).
- $\mathbf{x}, \mathbf{y}, \mathbf{a}, \mathbf{b}$: Vector (mặc định là vector cột).
- A, B, X, W : Ma trận.
- $\frac{\partial y}{\partial \mathbf{x}}$: Gradient (Vector đạo hàm).

Hàm số $f(\mathbf{x})$	Đạo hàm $\nabla_{\mathbf{x}} f(\mathbf{x})$
1. Đạo hàm theo Vector (Scalar-by-Vector)	
$\mathbf{a}^T \mathbf{x} = \mathbf{x}^T \mathbf{a}$ (Tích vô hướng - Dot product)	$\mathbf{a}$
$\mathbf{x}^T \mathbf{x} = \ \mathbf{x}\ _2^2$ (Bình phương độ dài - L2 Norm)	$2\mathbf{x}$
$\mathbf{x}^T A \mathbf{x}$ (Dạng toàn phương - Quadratic Form)	$(A + A^T)\mathbf{x}$ Nếu A đối xứng: $2A\mathbf{x}$
$(A\mathbf{x} - \mathbf{b})^T (A\mathbf{x} - \mathbf{b})$ (Hàm lỗi MSE dạng ma trận)	$2A^T(A\mathbf{x} - \mathbf{b})$
2. Đạo hàm theo Ma trận (Scalar-by-Matrix)	
$\text{Tr}(W^T A)$ hoặc $\text{Tr}(AW^T)$ (Vết của ma trận)	A
$\text{Tr}(WAW^T)$	$W(A + A^T)$
$\ A\mathbf{x} - \mathbf{b}\ ^2$ (Đạo hàm theo A)	$2(A\mathbf{x} - \mathbf{b})\mathbf{x}^T$ (Tích ngoài của vector lỗi và đầu vào)
3. Quy tắc chuỗi (Chain Rule) trong Backprop	
Giả sử $\mathbf{z} = W\mathbf{x} + \mathbf{b}$ và $L = f(\mathbf{z})$	Gradient truyền về: $\frac{\partial L}{\partial \mathbf{x}} = W^T \frac{\partial L}{\partial \mathbf{z}}$ $\frac{\partial L}{\partial W} = \frac{\partial L}{\partial \mathbf{z}} \mathbf{x}^T$

Bảng 1: Các công thức đạo hàm phổ biến trong Machine Learning

2 Tổng Hợp Công Thức: Hồi Quy Tuyến Tính & Gradient Descent

Bảng dưới đây hệ thống hóa các công thức cốt lõi từ việc xây dựng mô hình, xác định hàm mất mát đến thuật toán tối ưu hóa.

Khái niệm	Công thức Toán học
1. Mô hình Hồi quy Tuyến tính (Linear Regression Model)	Tổng quát: $y = f_w(x) = w_0 + w_1x$ Qua gốc tọa độ: $y = w_1x$
2. Quan hệ dữ liệu thực tế (Data & Noise)	$t^{(i)} = f(x^{(i)}) + \epsilon^{(i)}$ Trong đó nhiễu: $\epsilon \sim \mathcal{N}(0, \sigma^2)$
3. Hàm mất mát MSE (Mean Squared Error)	$L(w) = \frac{1}{N} \sum_{i=1}^N \left(t^{(i)} - f_w(x^{(i)}) \right)^2$
4. Quy tắc cập nhật GD (Update Rule)	$w_{k+1} = w_k - \eta \nabla L(w_k)$ Dừng khi: $\ \nabla L(w_k)\ < \epsilon$
5. Điều kiện hội tụ (Convergence Condition)	Ví dụ cho hàm $f(x) = 3x^2 + \dots$: $ 1 - 6\eta < 1 \implies \eta < \frac{1}{3}$
6. Đạo hàm riêng theo w_0 (Partial Derivative bias)	$\frac{\partial L}{\partial w_0} = \frac{2}{N} \sum_{i=1}^N (w_0 + w_1x^{(i)} - t^{(i)})$
7. Đạo hàm riêng theo w_1 (Partial Derivative slope)	$\frac{\partial L}{\partial w_1} = \frac{2}{N} \sum_{i=1}^N (w_0 + w_1x^{(i)} - t^{(i)}) \cdot x^{(i)}$
8. Vector hóa Gradient (Vectorization Form)	$\nabla_w L(w) = \frac{2}{N} X^T (Xw - t)$ (Tận dụng tính toán SIMD trên phần cứng)
9. Xấp xỉ Taylor & GD (Theoretical Basis)	Xấp xỉ bậc hai tại điểm a : $Q(x) = f(a) + \nabla f(a)^T (x - a) + \frac{1}{2\eta} \ x - a\ ^2$ Cực tiểu hóa $Q(x)$ dẫn đến công thức GD.

Bảng 2: Hệ thống công thức Hồi quy Tuyến tính và Tối ưu hóa Gradient Descent

2.1 Bài tập :

2.1.1 Đề Bài (Question 3)

Cho tập dữ liệu huấn luyện D gồm N mẫu $(\mathbf{x}_i, y_i)$, trong đó $\mathbf{x}_i$ là vector đặc trưng và $y_i \in \mathbb{R}$ là giá trị mục tiêu của mẫu thứ i .

Hàm mất mát (Cost function) cho mô hình Hồi quy tuyến tính với vector tham số $\mathbf{w}$ được định nghĩa là:

$$J(\mathbf{w}) = \frac{1}{2N} \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x}_i)^2 = \frac{1}{2N} \sum_{i=1}^N (\mathbf{w}^T \mathbf{x}_i - y_i)^2 = \frac{1}{2N} (\mathbf{X}\mathbf{w} - \mathbf{y})^T (\mathbf{X}\mathbf{w} - \mathbf{y})$$

Ta có ma trận X (mỗi hàng là một vector đặc trưng chuyển vị) và vector $\mathbf{y}$:

$$X = \begin{bmatrix} -\mathbf{x}_1^T & - \\ -\mathbf{x}_2^T & - \\ \vdots & \\ -\mathbf{x}_N^T & - \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$

Câu hỏi: Dựa trên thông tin trên, hãy tính vector gradient $\nabla J(\mathbf{w})$?

- A. $\frac{1}{N}(X^T X \mathbf{w} - X^T \mathbf{y})$
- B. $\frac{1}{N} \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x}_i) \mathbf{x}_i$
- C. $-\frac{1}{N} \sum_{i=1}^N (\mathbf{w}^T \mathbf{x}_i - y_i) \mathbf{x}_i$
- D. Tất cả đều đúng.

2.1.2 Lời Giải Chi Tiết

1. Khai triển hàm mất mát dưới dạng ma trận

Ta có hàm mất mát:

$$J(\mathbf{w}) = \frac{1}{2N} (\mathbf{X}\mathbf{w} - \mathbf{y})^T (\mathbf{X}\mathbf{w} - \mathbf{y})$$

Sử dụng tính chất chuyển vị $(AB)^T = B^T A^T$ và phân phối tích vô hướng:

$$\begin{aligned} J(\mathbf{w}) &= \frac{1}{2N} (\mathbf{w}^T X^T - \mathbf{y}^T) (\mathbf{X}\mathbf{w} - \mathbf{y}) \\ &= \frac{1}{2N} (\mathbf{w}^T X^T X \mathbf{w} - \mathbf{w}^T X^T \mathbf{y} - \mathbf{y}^T X \mathbf{w} + \mathbf{y}^T \mathbf{y}) \end{aligned}$$

Lưu ý: $\mathbf{w}^T X^T \mathbf{y}$ là một số vô hướng (scalar), do đó nó bằng chuyển vị của chính nó:

$$(\mathbf{w}^T X^T \mathbf{y})^T = \mathbf{y}^T X \mathbf{w}$$

Thay vào biểu thức trên, ta gộp hai số hạng giữa:

$$J(\mathbf{w}) = \frac{1}{2N} (\mathbf{w}^T (X^T X) \mathbf{w} - 2(\mathbf{y}^T X) \mathbf{w} + \mathbf{y}^T \mathbf{y})$$

2. Tính đạo hàm theo $\mathbf{w}$

Sử dụng các quy tắc đạo hàm ma trận (Matrix Calculus):

- $\nabla_{\mathbf{w}}(\mathbf{w}^T A \mathbf{w}) = (A + A^T) \mathbf{w}$. Vì $X^T X$ là ma trận đối xứng nên đạo hàm là $2X^T X \mathbf{w}$.
- $\nabla_{\mathbf{w}}(\mathbf{b}^T \mathbf{w}) = \mathbf{b}$. Ở đây $\mathbf{b}^T = -2\mathbf{y}^T X$, vậy đạo hàm là $(-2\mathbf{y}^T X)^T = -2X^T \mathbf{y}$.
- $\nabla_{\mathbf{w}}(\text{const}) = 0$.

Áp dụng vào $J(\mathbf{w})$:

$$\begin{aligned} \nabla J(\mathbf{w}) &= \frac{1}{2N} (2X^T X \mathbf{w} - 2X^T \mathbf{y}) \\ &= \frac{1}{N} (X^T X \mathbf{w} - X^T \mathbf{y}) \end{aligned}$$

Có thể đặt nhân tử chung X^T ra ngoài:

$$\nabla J(\mathbf{w}) = \frac{1}{N} X^T (\mathbf{X}\mathbf{w} - \mathbf{y})$$

3 Tổng Hợp: Hồi Quy Đa Thức & Regularization

Bảng dưới đây hệ thống hóa các công thức cốt lõi từ hồi quy tuyến tính đơn giản, biểu diễn ma trận đến các kỹ thuật điều chuẩn (Regularization).

Khái niệm	Công thức / Định nghĩa Toán học
1. Hồi quy Tuyến tính Đơn giản (Simple Linear Regression)	Mô hình: $f(x) = w_0 + w_1x$ Hàm mất mát (MSE): $\frac{1}{N} \sum_{i=1}^N (y_i - f(x_i))^2$
2. Nghiệm tối ưu (Đơn biến) (Closed-form Solution)	$w_1 = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^N (x_i - \bar{x})^2}$ $w_0 = \bar{y} - w_1\bar{x}$
3. Ma trận Dữ liệu X (Design Matrix Definition)	$X = \begin{bmatrix} 1 & x_{11} & \dots & x_{1n} \\ 1 & x_{21} & \dots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{N1} & \dots & x_{Nn} \end{bmatrix}_{N \times (n+1)}$ (Lưu ý: Cột đầu tiên luôn là 1 ứng với bias w_0)
4. Phương trình Chuẩn (Normal Equations)	Nghiệm tối ưu cho hồi quy đa biến: $w^* = (X^T X)^{-1} X^T y$ (Phép chiếu trực giao của y lên không gian cột X)
5. Hồi quy Đa thức (Polynomial Regression)	Mô hình bậc d : $f(x) = w^T \phi(x)$ Vector đặc trưng: $\phi(x) = [1, x, x^2, \dots, x^d]^T$
6. Ridge Regression (L2 Regularization)	Loss: $J(w) = RSS(w) + \lambda \sum_{j=1}^n w_j^2$ Nghiệm: $w^* = (X^T X + \lambda I)^{-1} X^T y$ (Giúp ma trận khả nghịch, giảm phương sai)
7. Lasso Regression (L1 Regularization)	Loss: $J(w) = RSS(w) + \lambda \sum_{j=1}^n w_j $ (Tạo tính thưa - Sparsity, giúp chọn đặc trưng)

Bảng 3: Tổng hợp công thức Hồi quy Tuyến tính, Đa thức và Regularization

3.1 Ma trận chiếu - Projection Matrix

3.1.1 Công thức Tổng quát

Giả sử ta cần chiếu một vector $\mathbf{b} \in \mathbb{R}^m$ xuống không gian cột (Column Space) của ma trận $A \in \mathbb{R}^{m \times n}$ (với các cột độc lập tuyến tính).

Ma trận chiếu P được định nghĩa là:

$$P = A(A^T A)^{-1} A^T$$

Khi đó, hình chiếu vuông góc $\mathbf{p}$ của $\mathbf{b}$ lên không gian của A là:

$$\mathbf{p} = P\mathbf{b} = A(A^T A)^{-1} A^T \mathbf{b}$$

3.2 Chứng minh (Dẫn xuất công thức)

Mục tiêu là tìm một vector $\mathbf{p}$ nằm trong không gian cột của A (tức là $\mathbf{p} = A\mathbf{x}$ với $\mathbf{x}$ nào đó) sao cho khoảng cách tới $\mathbf{b}$ là nhỏ nhất.

Theo nguyên lý hình học, khoảng cách ngắn nhất đạt được khi vector sai số $\mathbf{e} = \mathbf{b} - \mathbf{p}$ vuông góc với không gian chiếu (không gian cột của A).

1. Điều kiện trực giao:

$$\mathbf{e} \perp \mathcal{C}(A) \implies A^T \mathbf{e} = 0$$

2. Thiết lập phương trình: Thay $\mathbf{e} = \mathbf{b} - A\mathbf{x}$ vào:

$$A^T(\mathbf{b} - A\mathbf{x}) = 0$$

3. Giải phương trình tìm $\mathbf{x}$:

$$A^T \mathbf{b} - A^T A \mathbf{x} = 0$$

$$A^T A \mathbf{x} = A^T \mathbf{b}$$

$$\mathbf{x} = (A^T A)^{-1} A^T \mathbf{b} \quad (*)$$

(*) Đây chính là công thức nghiệm của Hồi quy tuyến tính.

4. Tìm hình chiếu $\mathbf{p}$: Thay $\mathbf{x}$ trở lại biểu thức $\mathbf{p} = A\mathbf{x}$:

$$\mathbf{p} = A \left[(A^T A)^{-1} A^T \mathbf{b} \right] = \underbrace{A(A^T A)^{-1} A^T}_{P} \mathbf{b}$$

3.3 Trường hợp đặc biệt: Chiếu lên vector (1D)

Khi ma trận A chỉ là một vector cột $\mathbf{a}$ duy nhất, công thức trở thành:

$$P = \frac{\mathbf{a}\mathbf{a}^T}{\mathbf{a}^T \mathbf{a}}$$

Lúc này, hình chiếu của $\mathbf{b}$ lên đường thẳng chứa $\mathbf{a}$ là:

$$\mathbf{p} = \mathbf{a} \frac{\mathbf{a}^T \mathbf{b}}{\|\mathbf{a}\|^2}$$

3.4 Tính chất của Ma trận Chiếu P

Để là một ma trận chiếu trực giao hợp lệ, P phải thỏa mãn 2 tính chất:

- **Lũy đẳng (Idempotent):** Chiếu 2 lần kết quả không đổi.

$$P^2 = P \cdot P = P$$

Chứng minh:

$$\begin{aligned} P^2 &= [A(A^T A)^{-1} A^T] [A(A^T A)^{-1} A^T] \\ &= A(A^T A)^{-1} \underbrace{(A^T A)(A^T A)^{-1}}_I A^T \\ &= A(A^T A)^{-1} A^T = P \end{aligned}$$

- **Đối xứng (Symmetric):**

$$P^T = P$$

3.5 Liên hệ với Machine Learning (Hat Matrix)

Trong thống kê và mô hình Hồi quy (Regression), ma trận này thường được ký hiệu là H (Hat Matrix) vì nó biến đổi giá trị thực y thành giá trị dự đoán $\hat{y}$ (y-hat):

$$\hat{\mathbf{y}} = H\mathbf{y} = X(X^T X)^{-1} X^T \mathbf{y}$$

4 Tổng Hợp Kiến Thức: Đại Số Tuyến Tính cho Khoa học Dữ liệu

Bảng dưới đây hệ thống hóa các nền tảng từ Vector, Ma trận, Không gian con đến các phép phân rã ma trận quan trọng (SVD, Eigenvalue) theo tư duy Khoa học máy tính.

Khái niệm & Ý nghĩa	Công thức / Định nghĩa Toán học
I. Vector & Các Phép Đo (Vector Space)	
1. Tích vô hướng (Dot Product)	$x \cdot y = x^T y = \sum_{i=1}^d x_i y_i$ Ý nghĩa: Đo độ tương đồng. Nếu $x^T y = 0 \Rightarrow x \perp y$ (Trực giao/Độc lập).
2. Chuẩn Vector (Norms - Độ lớn dữ liệu)	Chuẩn L_2 (Euclidean): $\ x\ _2 = \sqrt{x^T x} = \sqrt{\sum x_i^2}$ Chuẩn L_1 (Manhattan): $\ x\ _1 = \sum x_i $ (Hỗ trợ mô hình thưa).
3. Bất đẳng thức nền tảng	Cauchy-Schwarz: $ x \cdot y \leq \ x\ \ y\ $ Tam giác: $\ x - y\ \leq \ x\ + \ y\ $
II. Ma trận & Phép Biến Đổi (Matrix Operations)	
4. Nhân Ma trận - Vector (Linear Combination)	$Ax = x_1 \mathbf{a}_1 + x_2 \mathbf{a}_2 + \dots + x_n \mathbf{a}_n$ Insight: Ax luôn nằm trong không gian cột $C(A)$.
5. Ma trận Hạng 1 (Rank-1 Matrix)	$A = uv^T$ Cấu trúc đơn vị của dữ liệu. Mọi ma trận là tổng các ma trận hạng 1.
III. Không Gian Con & Cấu Trúc (Subspaces)	
6. Bốn Không gian cơ bản (Fundamental Subspaces)	1. Không gian cột $C(A)$: $\text{Dim} = r$ (Hạng của ma trận). 2. Không gian hàng $C(A^T)$: $\text{Dim} = r$. 3. Không gian Null $N(A)$: $\text{Dim} = n - r$ (Nghiệm của $Ax = 0$). 4. Null trái $N(A^T)$: $\text{Dim} = m - r$.
7. Tính Trực giao (Orthogonal Complements)	$N(A) \perp C(A^T)$ và $N(A^T) \perp C(A)$ Mọi vector x đều có thể phân tách thành thành phần thuộc hàng và null.
IV. Phân Rã Ma Trận (Matrix Factorizations)	
8. Phân rã Trị riêng (Eigendecomposition)	Với ma trận đối xứng S : $S = Q \Lambda Q^T$ Trong đó Q là ma trận trực giao (các cột là vector riêng), Λ là ma trận đường chéo (trị riêng).
9. Phân rã SVD (Singular Value Decomposition)	$A = U \Sigma V^T = \sum_{i=1}^r \sigma_i u_i v_i^T$ Ứng dụng: PCA, Nén ảnh, Hệ gợi ý. σ_i là các giá trị kỳ dị thể hiện độ quan trọng của thông tin.

Bảng 4: Tổng hợp công thức Đại số tuyến tính cốt lõi cho Khoa học Dữ liệu

5 Tổng Hợp: Mô Hình Xác Suất & Suy Diễn Bayes

Bảng dưới đây hệ thống hóa các định nghĩa, quy tắc cập nhật niềm tin và các phương pháp tối ưu hóa tính toán trong các mô hình xác suất của AI.

Khái niệm & Ý nghĩa	Công thức / Định nghĩa Toán học
1. Tiên đề Xác suất (Probability Axioms)	$0 \leq P(X = x) \leq 1$ $\sum_x P(X = x) = 1$ <i>(Tổng xác suất của mọi khả năng trong miền giá trị phải bằng 1)</i>
2. Phân phối Đồng thời (Joint Distribution)	$P(X_1, \dots, X_n)$ <i>Độ phức tạp: $O(d^n)$ (Bùng nổ số mũ). (Là "nguồn sự thật duy nhất" chứa mọi thông tin của hệ thống)</i>
3. Xác suất Lẻ (Marginalization)	$P(X) = \sum_y P(X, y)$ <i>(Triệt tiêu biến không quan tâm bằng cách cộng tổng - Summing out)</i>
4. Xác suất Có điều kiện (Conditional Probability)	$P(a \mid b) = \frac{P(a, b)}{P(b)}$ <i>(Niềm tin về a thay đổi như thế nào khi đã biết bằng chứng b)</i>
5. Quy tắc Nhân (Product Rule)	$P(a, b) = P(a \mid b)P(b)$ <i>(Dùng để phân rã phân phối đồng thời thành chuỗi xác suất nhỏ hơn)</i>
6. Định luật Bayes (Bayes' Rule)	$P(c \mid e) = \frac{P(e \mid c)P(c)}{P(e)}$ <i>(Chẩn đoán: Từ xác suất nhân quả $P(e c)$, suy ra xác suất nguyên nhân $P(c e)$)</i>
7. Sự Độc lập (Independence)	$P(x, y) = P(x)P(y) \quad \text{hoặc} \quad P(x \mid y) = P(x)$ <i>(Chiến lược "Chia để trị": Giảm độ phức tạp lưu trữ từ d^n xuống $n \times d$)</i>
8. Chuẩn hóa Suy diễn (Inference by Enumeration)	$P(Q \mid e) = \alpha \sum_h P(Q, h, e)$ Trong đó $\alpha = 1/Z$ là hệ số chuẩn hóa để tổng xác suất bằng 1.

Bảng 5: Hệ thống công thức Mô hình Xác suất trong Khoa học Máy tính

6 Tổng Hợp: Công Thức Xác Suất & Ma Trận Thống Kê

Bảng dưới đây hệ thống hóa các tiên đề xác suất, các dạng phân phối đặc trưng và cấu trúc ma trận hiệp phương sai trong mô hình đa biến.

Khái niệm & Ý nghĩa	Công thức / Định nghĩa Toán học
1. Quy tắc Cộng Tổng quát (Inclusion-Exclusion)	$P(A \cup B) = P(A) + P(B) - P(A \cap B)$ <i>Insight: Phải trừ phần giao để tránh tính lặp thông tin.</i>
2. Biến Ngẫu nhiên Liên tục (Continuous RV - PDF)	$P(a \leq X \leq b) = \int_a^b f_X(x)dx$ Điều kiện: $\int_{-\infty}^{\infty} f_X(x)dx = 1$ <i>Lưu ý: Tại 1 điểm cụ thể, $P(X = x) = 0$.</i>
3. Kỳ vọng & Phương sai (Expectation & Variance)	Kỳ vọng (Tuyến tính): $E[aX + b] = aE[X] + b$ Phương sai (Phi tuyến): $Var(aX + b) = a^2Var(X)$ Công thức tính nhanh: $Var(X) = E[X^2] - (E[X])^2$
4. Phân phối Chuẩn (Gaussian) (Univariate Normal)	$f(x) = \frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ Quy tắc 68-95-99.7: Tương ứng với độ phủ dữ liệu trong khoảng $1\sigma, 2\sigma, 3\sigma$.
5. Hiệp phương sai (Covariance)	$Cov(X, Y) = E[XY] - E[X]E[Y]$ Hệ số tương quan: $\rho_{XY} = \frac{Cov(X, Y)}{\sigma_X\sigma_Y} \in [-1, 1]$
6. Ma trận Hiệp phương sai (Covariance Matrix Σ)	$\Sigma = \begin{bmatrix} Var(X_1) & Cov(X_1, X_2) \\ Cov(X_2, X_1) & Var(X_2) \end{bmatrix}$ <i>Đặc tính: Đối xứng, Xác định nửa dương (PSD). Đường chéo chính là phương sai của từng biến.</i>
7. Chuẩn Đa biến (Multivariate Gaussian)	$\mathcal{N}(x \mid \mu, \Sigma) = \frac{1}{\sqrt{(2\pi)^D \Sigma }} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1} (x - \mu)\right)$ <i>Đây là dạng tổng quát trong không gian D-chiều.</i>
8. Ước lượng MLE (Likelihood Maximization)	Hàm hợp lý: $L(\theta) = \prod_{i=1}^n P(x_i; \theta)$ Mục tiêu: Tìm θ để Max hóa $L(\theta)$ (thường dùng log-likelihood).

Bảng 6: Tổng hợp công thức Lý thuyết Xác suất và Ma trận thống kê

7 Tổng Hợp: Ước Lượng Tham Số (MLE/MAP) & Tối Ưu Hóa

Bảng dưới đây hệ thống hóa các phương pháp ước lượng tham số từ cơ bản (MLE) đến nâng cao (MAP/Regularization) và cách giải quyết bài toán hồi quy dưới góc nhìn xác suất.

Khái niệm & Ý nghĩa	Công thức / Định nghĩa Toán học
1. Nguyên lý MLE (Maximum Likelihood Estimation)	Mục tiêu: $\theta_{mle} = \arg \max_{\theta} p(D \theta)$ Hàm NLL (Cần cực tiểu hóa): $NLL(\theta) = - \sum_{i=1}^n \log p(x_i \theta)$
2. MLE cho các Phân phối	Bernoulli: $\hat{p} = \frac{n_1}{n_0 + n_1}$ (Tỷ lệ số lần thành công) Categorical: $\hat{\theta}_k = \frac{n_k}{N}$ (Tần suất xuất hiện nhóm k) Gaussian: $\hat{\mu} = \frac{1}{n} \sum x_i, \quad \hat{\sigma}^2 = \frac{1}{n} \sum (x_i - \hat{\mu})^2$
3. Hồi quy Tuyến tính (MLE) (Linear Regression)	Mô hình: $p(y x; w) = \mathcal{N}(y w^T x, \sigma^2)$ Hàm mất mát (RSS): $J(w) = \ y - Xw\ _2^2 = (y - Xw)^T (y - Xw)$
4. Đạo hàm & Phương trình chuẩn (Normal Equations)	Gradient: $\nabla_w RSS(w) = 2X^T Xw - 2X^T y$ Nghiệm đóng (Closed-form): $w_{mle} = (X^T X)^{-1} X^T y$
5. Nguyên lý MAP (Maximum A Posteriori)	Kết hợp dữ liệu với tri thức tiên nghiệm (Prior): $\theta_{map} = \arg \max_{\theta} [\log p(D \theta) + \log p(\theta)]$ (Giúp chống <i>Overfitting</i> khi dữ liệu ít)
6. MAP cho Bernoulli (Kèm Prior Beta(α, β))	$\hat{p}_{map} = \frac{n_1 + \alpha - 1}{n_1 + n_0 + \alpha + \beta - 2}$ <i>Insight: α, β đóng vai trò là "số mẫu ảo" thêm vào để làm mượt dữ liệu.</i>
7. Ridge Regression (MAP với Prior chuẩn $w \sim \mathcal{N}(0)$)	Hàm mục tiêu (L2 Regularization): $J(w) = \ y - Xw\ ^2 + \lambda \ w\ ^2$ Nghiệm tối ưu: $w_{ridge} = (X^T X + \lambda I)^{-1} X^T y$ (Thêm λI giúp ma trận luôn khả nghịch)

Bảng 7: Tổng hợp công thức Ước lượng Tham số và Tối ưu hóa trong Máy học

8 Tổng Hợp: Phân Tích Độ Chệch - Phương Sai (Bias-Variance Trade-off)

Bảng dưới đây hệ thống hóa quá trình phân rã sai số dự báo thành ba thành phần cơ bản: Độ chệch, Phương sai và Nhiễu, cùng với ý nghĩa chẩn đoán mô hình.

Khái niệm & Ý nghĩa	Công thức / Định nghĩa Toán học
1. Mô hình Dữ liệu Thực (Data Generation Process)	$y = f(x) + \epsilon$ Với $\epsilon \sim \mathcal{N}(0, \sigma^2)$ là nhiễu không thể tránh khỏi (Irreducible Error).
2. Giả thiết Trung bình (Average Hypothesis)	$\bar{h}(x) = E_{\mathcal{D}}[h^{(\mathcal{D})}(x)]$ <i>Insight: Đây là mô hình "trung tâm" nếu ta huấn luyện vô số lần trên các tập dữ liệu khác nhau.</i>
3. Công thức Phân rã Sai số (Error Decomposition)	$E[(y - \hat{y})^2] = \text{Bias}^2 + \text{Variance} + \text{Noise}$ Cụ thể: $= (\bar{h}(x) - f(x))^2 + E_{\mathcal{D}}[(h^{(\mathcal{D})}(x) - \bar{h}(x))^2] + \sigma^2$
4. Thành phần Độ chệch (Bias Term)	$\text{Bias}^2(\hat{f}(x)) = (\bar{h}(x) - f(x))^2$ <i>Ý nghĩa: Sai số hệ thống. Bias cao $\rightarrow$ Mô hình quá đơn giản (Underfitting). Nó "trượt" khỏi mục tiêu ngay cả khi có rất nhiều dữ liệu.</i>
5. Thành phần Phương sai (Variance Term)	$\text{Var}(\hat{f}(x)) = E_{\mathcal{D}}[(h^{(\mathcal{D})}(x) - \bar{h}(x))^2]$ <i>Ý nghĩa: Độ nhạy với dữ liệu huấn luyện. Variance cao $\rightarrow$ Mô hình quá phức tạp, học thuộc lòng cả nhiễu (Overfitting).</i>
6. Mở rộng cho Vector/Ma trận (Multivariate Case)	Với tham số vector θ : $MSE(\hat{\theta}) = \text{Trace}(\text{Var}(\hat{\theta})) + \ \text{Bias}(\hat{\theta})\ ^2$ Trong đó $\text{Var}(\hat{\theta})$ là ma trận hiệp phương sai của bộ ước lượng.
7. Sự Đánh đổi (Trade-off) (Model Complexity Strategy)	Mô hình đơn giản (Linear): Bias cao $\uparrow$, Variance thấp $\downarrow$. Mô hình phức tạp (Deep Neural Net): Bias thấp $\downarrow$, Variance cao $\uparrow$. <i>Mục tiêu: Tìm điểm "ngọt" (Sweet Spot) nơi tổng lỗi là thấp nhất (thường là đáy của hình chữ U).</i>
8. Cách khắc phục (Remedies)	High Bias: Thêm đặc trưng (features), tăng độ phức tạp mô hình. High Variance: Thêm dữ liệu, Giảm số đặc trưng, dùng Regularization (L_1, L_2).

Bảng 8: Phân tích thành phần sai số trong Học máy: Bias, Variance và Noise

9 Tổng Hợp: Hồi Quy Logistic & Tối Ưu Hóa Gradient Descent

Bảng dưới đây hệ thống hóa các công thức cốt lõi của Hồi quy Logistic, từ hàm kích hoạt, hàm mất mát BCE đến quy trình tính toán Gradient ngược (Backpropagation).

Khái niệm & Ý nghĩa	Công thức Toán học
1. Mô hình Hồi quy Logistic (Logistic Model)	Logit (Điểm số tuyến tính): $z = w^T x + b$ Dự đoán (Xác suất): $a = \hat{y} = \sigma(z) = P(y = 1 \mid x)$
2. Hàm kích hoạt Sigmoid (Activation Function)	$\sigma(z) = \frac{1}{1 + e^{-z}}$ Đạo hàm đặc biệt: $\sigma'(z) = a(1 - a)$ (Giúp nén giá trị thực bất kỳ vào khoảng $(0, 1)$)
3. Biên quyết định (Decision Boundary)	Ngưỡng quyết định: $a \geq 0.5 \iff z \geq 0$ Phương trình siêu phẳng: $w^T x + b = 0$ (Là đường thẳng trong 2D phân chia 2 lớp dữ liệu)
4. Hàm mất mát BCE (Binary Cross-Entropy)	Cho 1 mẫu: $L(a, y) = -[y \log(a) + (1 - y) \log(1 - a)]$ Hàm chi phí (Cost): $J(w, b) = \frac{1}{n} \sum_{i=1}^n L(a^{(i)}, y^{(i)})$ (Đảm bảo tính lồi - Convexity để tối ưu hóa hiệu quả)
5. Gradient (Backpropagation) (Chain Rule)	Tính theo chuỗi: $\frac{\partial L}{\partial w} = \frac{\partial L}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial w}$ Kết quả rút gọn: $\frac{\partial L}{\partial w_j} = (a - y)x_j$ (Lưu ý: Kết quả này có dạng giống hệt Hồi quy tuyến tính)
6. Quy tắc cập nhật GD (Gradient Descent Update)	$w := w - \alpha \frac{1}{n} \sum_{i=1}^n (a^{(i)} - y^{(i)})x^{(i)}$ $b := b - \alpha \frac{1}{n} \sum_{i=1}^n (a^{(i)} - y^{(i)})$
7. Vector hóa (Vectorization) (Matrix Form for NumPy)	Input $X \in \mathbb{R}^{n \times d}$, Label $Y \in \mathbb{R}^{n \times 1}$ Forward: $A = \sigma(Xw + b)$ Backward: $\nabla_w J = \frac{1}{n} X^T (A - Y)$ (Tận dụng phép nhân ma trận để tăng tốc tính toán)
8. Đạo hàm Sigmoid (Derivative Formulas)	Hàm số: $\sigma(z) = \frac{1}{1 + e^{-z}}$ Đạo hàm $\sigma'(z)$ có 3 dạng thường gặp: $\sigma(z)(1 - \sigma(z))$ (Dùng cho Backprop) $\sigma(z)\sigma(-z)$ (Dạng đối xứng) $\frac{e^{-z}}{(1+e^{-z})^2}$ (Dạng đại số (mũ âm)) $\frac{e^z}{(1+e^z)^2}$ (Dạng đại số (mũ dương)) Nhược điểm: Vanishing Gradient (Triệt tiêu đạo hàm) Khi $z \gg 0$ hoặc $z \ll 0 \implies \sigma'(z) \approx 0$. → Trọng số không được cập nhật, mạng ngừng học.

Bảng 9: Hệ thống công thức Hồi quy Logistic và Gradient Descent

10 Tổng Hợp: Hồi Quy Softmax (Phân Loại Đa Lớp)

Bảng dưới đây hệ thống hóa mô hình xác suất, biểu diễn ma trận và thuật toán tối ưu hóa cho bài toán phân loại C lớp ($C > 2$).

Khái niệm & Ý nghĩa	Công thức / Định nghĩa Ma trận
1. Logit từng lớp (Linear Score)	Với mỗi lớp $k \in \{1, \dots, C\}$: $z_k = w_k^T x + b_k$ <i>(Mỗi lớp có một vector trọng số w_k riêng)</i>
2. Hàm Softmax (Activation Function)	$a_k = P(y = k x) = \frac{e^{z_k}}{\sum_{j=1}^C e^{z_j}}$ <i>(Chuyển đổi điểm số thành phân phối xác suất: $\sum a_k = 1$)</i>
3. Cấu trúc Ma trận (Matrix Dimensions)	Dữ liệu đầu vào: $X \in \mathbb{R}^{n \times d}$ Trọng số: $W \in \mathbb{R}^{d \times C}$ (Mỗi cột là 1 lớp) Output (Logits): $Z = XW + b \in \mathbb{R}^{n \times C}$ Dự đoán (Probs): $A = \text{softmax}(Z) \in \mathbb{R}^{n \times C}$
4. Categorical Cross-Entropy (Loss Function)	Cho 1 mẫu (với y là one-hot vector): $L(a, y) = - \sum_{k=1}^C y_k \log(a_k)$ Hàm chi phí toàn cục: $J(W, b) = -\frac{1}{n} \sum_{i=1}^n \sum_{k=1}^C y_k^{(i)} \log(a_k^{(i)})$
5. Gradient (Đẹp & Gọn) (Backpropagation)	Đạo hàm theo Logit: $\frac{\partial L}{\partial z} = a - y$ Đạo hàm theo Trọng số W : $\nabla_W J = \frac{1}{n} X^T (A - Y)$ <i>(Lưu ý: Công thức giống hệt Hồi quy Logistic nhưng Y, A là ma trận)</i>
6. Cập nhật tham số (Optimization Update)	$W := W - \alpha \nabla_W J$ $b := b - \alpha \frac{1}{n} \sum_{i=1}^n (a^{(i)} - y^{(i)})$ <i>(Tổng theo cột để cập nhật bias cho từng lớp)</i>
7. One-hot Encoding (Data Preparation)	Chuyển nhãn $y \in \{1, \dots, C\}$ thành vector đơn vị. Ví dụ 3 lớp, nhãn là lớp 2 $\rightarrow y = [0, 1, 0]^T$. <i>Giúp việc tính toán mất mát trở thành phép nhân vô hướng đơn giản.</i>

Bảng 10: Hệ thống công thức Hồi quy Softmax và Ma trận tính toán

11 Tổng Hợp: Mạng Nơ-ron & Lan Truyền Ngược

Bảng dưới đây hệ thống hóa cấu trúc của một nơ-ron nhân tạo, quy trình lan truyền tiến (Forward Propagation) và thuật toán lan truyền ngược (Backpropagation) để huấn luyện mô hình.

Khái niệm & Ý nghĩa	Công thức Toán học
1. Cấu trúc một Nơ-ron (The Perceptron Unit)	Tổng hợp tuyến tính: $z = w^T x + b$ Kích hoạt phi tuyến: $a = \sigma(z) = \frac{1}{1 + e^{-z}}$ (Mỗi nơ-ron hoạt động như một bộ Hồi quy Logistic nhỏ)
2. Lan truyền tiến (Forward Propagation)	Tại tầng l (với đầu vào là $a^{[l-1]}$): $z^{[l]} = W^{[l]} a^{[l-1]} + b^{[l]}$ $a^{[l]} = g^{[l]}(z^{[l]})$ (Dữ liệu chảy từ input $\rightarrow$ hidden $\rightarrow$ output)
3. Hàm mất mát BCE (Binary Cross-Entropy)	Cho 1 mẫu dự đoán a và nhãn y : $L(a, y) = -[y \log(a) + (1 - y) \log(1 - a)]$ Hàm chi phí toàn cục: $J(W, b) = -\frac{1}{n} \sum_{i=1}^n [y^{(i)} \log a^{(i)} + (1 - y^{(i)}) \log(1 - a^{(i)})]$
4. Quy tắc Dây chuyền (Chain Rule Logic)	Để tìm gradient của trọng số w : $\frac{\partial L}{\partial w} = \underbrace{\frac{\partial L}{\partial a} \cdot \frac{\partial a}{\partial z}}_{\delta \text{ (Lỗi cục bộ)}} \cdot \frac{\partial z}{\partial w}$
5. Lan truyền ngược (Backpropagation - Scalar)	Sai số tại đầu ra (Delta): $\delta = \frac{\partial L}{\partial z} = a - y$ Gradient trọng số: $\frac{\partial L}{\partial w_i} = (a - y) x_i$ Gradient bias: $\frac{\partial L}{\partial b} = a - y$
6. Dạng Ma trận (Layer cuối) (Matrix Gradients)	Gradient $\nabla_W J = \frac{1}{n} X^T (A - Y)$ Gradient $\nabla_b J = \frac{1}{n} \sum (A - Y)$ (Tính toán song song cho cả batch dữ liệu)
7. Tối ưu hóa Gradient Descent (Optimization)	$W := W - \alpha \nabla_W J$ $b := b - \alpha \nabla_b J$ (Di chuyển ngược hướng đạo hàm để xuống đáy thung lũng lỗi)

Bảng 11: Hệ thống công thức Mạng Nơ-ron cơ bản và Lan truyền ngược

12 Tổng Hợp: Cơ Sở Toán Học Cho Tối Ưu Hóa (Optimization Basis)

Bảng dưới đây hệ thống hóa các định nghĩa giải tích ma trận, điều kiện tối ưu và các phương pháp cập nhật tham số cơ bản.

Khái niệm & Ý nghĩa	Công thức / Định nghĩa Toán học
1. Bài toán Tối ưu Tổng quát (General Problem)	Tìm θ^* để cực tiểu hóa hàm mất mát: $\theta^* = \arg \min_{\theta \in \Theta} L(\theta)$ (Mục tiêu: Tìm đáy thấp nhất của hàm số)
2. Gradient (Bậc 1) (Direction of Steepest Ascent)	Vector đạo hàm riêng (hàm $f : \mathbb{R}^n \rightarrow \mathbb{R}$): $\nabla f(x) = \begin{bmatrix} \frac{\partial f}{\partial x_1} & \dots & \frac{\partial f}{\partial x_n} \end{bmatrix}^T$ (Gradient luôn chỉ hướng hàm số tăng nhanh nhất)
3. Ma trận Hessian (Bậc 2) (Curvature Matrix)	Ma trận đạo hàm riêng bậc hai (Đối xứng): $H_f = \nabla^2 f(x) \in \mathbb{R}^{n \times n}$ với $(H_f)_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}$ (Quyết định hình dạng bề mặt: lõm, lồi hay yên ngựa)
4. Tính Xác định Dương (Positive Definiteness)	Ma trận A xác định dương ($A \succ 0$) khi: $x^T A x > 0, \quad \forall x \neq 0$ Hệ quả: Tất cả trị riêng $\lambda_i > 0 \implies$ Hàm lồi chặt (có đáy duy nhất).
5. Điều kiện Cần & Đủ (Optimality Conditions)	Để θ^* là cực tiểu địa phương chặt: 1. Cần: $\nabla L(\theta^*) = 0$ (Điểm dừng) 2. Đủ: $\nabla^2 L(\theta^*) \succ 0$ (Hessian xác định dương)
6. Hàm Lồi (Convex) (Convex Function)	$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$ Tính chất vàng: Mọi cực tiểu địa phương là cực tiểu toàn cục.
7. Phương pháp Bậc nhất (First-order Methods)	Quy tắc cập nhật lặp: $\theta_{t+1} = \theta_t + \rho_t d_t$ Hướng dốc nhất (Steepest Descent): $d_t = -\nabla L(\theta_t)$ Điều kiện giảm: $d^T \nabla L < 0$ (Góc tù với Gradient).
8. Tìm kiếm đường thẳng (Exact Line Search - Quadratic)	Với hàm toàn phương $L(\theta) = \frac{1}{2}\theta^T A \theta + b^T \theta$, bước nhảy tối ưu: $\rho = \frac{-\nabla L^T d}{d^T A d}$ (Giải tích chính xác bước nhảy để giảm lỗi nhiều nhất)

Bảng 12: Hệ thống các khái niệm Toán học trong Tối ưu hóa

12.1 Ma trận Hessian và Cực trị

12.1.1 1. Điểm dừng (Critical Point)

Cho hàm số hai biến $z = f(x, y)$. Điểm $M(x_0, y_0)$ được gọi là **điểm dừng** nếu tại đó các đạo hàm riêng cấp một bằng 0:

$$\begin{cases} f_x(x_0, y_0) = 0 \\ f_y(x_0, y_0) = 0 \end{cases} \tag{1}$$

12.1.2 2. Ma trận Hessian

Ma trận Hessian H của hàm f tại điểm M là ma trận các đạo hàm riêng cấp hai:

$$H = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{pmatrix} \quad (2)$$

Lưu ý: Với các hàm sơ cấp thường gặp, ta có định lý Schwarz: $f_{xy} = f_{yx}$.

12.1.3 3. Định thức Hessian (Biệt thức)

Định thức của ma trận Hessian được ký hiệu là D (hoặc Δ):

$$D = \det(H) = f_{xx} \cdot f_{yy} - (f_{xy})^2 \quad (3)$$

12.2 Quy tắc phân loại cực trị (Cực quan trọng)

Để xác định tính chất của điểm dừng $M(x_0, y_0)$, ta tính giá trị D tại điểm đó và xét các trường hợp sau:

- **Trường hợp 1: $D > 0$**
 - Nếu $f_{xx} > 0$: Hàm số đạt **Cực tiểu** tại M .
 - Nếu $f_{xx} < 0$: Hàm số đạt **Cực đại** tại M .
- **Trường hợp 2: $D < 0$**
 - Điểm M không phải là cực trị.
 - M được gọi là **Điểm yên ngựa (Saddle Point)**.
- **Trường hợp 3: $D = 0$**
 - **Không kết luận được** bằng phương pháp Hessian. Cần dùng định nghĩa hoặc phương pháp khác.

12.3 Ví dụ áp dụng (Bài Câu 15)

Đề bài: Xét hàm số $f(x, y) = x^2 - y^2 - 2xy - 2x - 2y + 2$. Kiểm tra tính chất của bề mặt hàm số thông qua ma trận Hessian.

12.3.1 Bước 1: Tính đạo hàm riêng cấp 1

$$\begin{aligned} f_x &= 2x - 2y - 2 \\ f_y &= -2y - 2x - 2 \end{aligned}$$

12.3.2 Bước 2: Tính đạo hàm riêng cấp 2

Ta lấy đạo hàm thêm một lần nữa từ kết quả trên:

$$\begin{aligned} f_{xx} &= \frac{\partial}{\partial x}(2x - 2y - 2) = 2 \\ f_{yy} &= \frac{\partial}{\partial y}(-2y - 2x - 2) = -2 \\ f_{xy} &= \frac{\partial}{\partial y}(2x - 2y - 2) = -2 \end{aligned}$$

12.3.3 Bước 3: Lập ma trận Hessian và tính D

Ma trận Hessian là:

$$H = \begin{pmatrix} 2 & -2 \\ -2 & -2 \end{pmatrix}$$

Định thức Hessian D :

$$D = (2)(-2) - (-2)^2 = -4 - 4 = -8$$

12.3.4 Bước 4: Kết luận

Ta thấy $D = -8 < 0$. Theo lý thuyết ở Mục 2 (Trường hợp 2), vì $D < 0$ nên bề mặt đồ thị tại mọi điểm đều có dạng hình yên ngựa.

Kết quả: Điểm đang xét có tính chất của **Điểm yên ngựa (Saddle Point)**.

13 Tổng Hợp: Các Phương Pháp Tối Ưu Bậc Nhất (First-Order Methods)

Bảng dưới đây hệ thống hóa các thuật toán tối ưu dựa trên Gradient, từ cơ bản (Vanilla GD) đến các biến thể hiện đại (Momentum, Adam) giúp tăng tốc độ hội tụ.

Phương pháp & Ý nghĩa	Công thức Toán học
1. Nguyên lý cơ bản (First-Order Basis)	Xấp xỉ Taylor bậc nhất tại w_0 : $h(w) \approx g(w_0) + \nabla g(w_0)^T (w - w_0)$ Điều kiện tối ưu: $\nabla g(w^*) = 0$
2. Coordinate Descent (Tối ưu từng thành phần)	Thay vì cập nhật toàn bộ vector w , cập nhật từng w_j : $w_j^{\text{new}} = \arg \min_{w_j} g(w_1, \dots, w_j, \dots, w_n)$ Hoặc giải phương trình: $\frac{\partial g}{\partial w_j} = 0$
3. Gradient Descent (GD) (Standard / Vanilla)	Quy tắc cập nhật: $w_k = w_{k-1} - \alpha \nabla g(w_{k-1})$ Chuẩn hóa (Normalized GD): $w_k = w_{k-1} - \alpha \frac{\nabla g(w_{k-1})}{\ \nabla g(w_{k-1})\ _2}$
4. Momentum (Động lượng) (Exponential Moving Average)	Tính đà v (hoặc m): $v_k = \beta v_{k-1} + (1 - \beta)(\nabla_w J)$ Cập nhật tham số (xuống dốc): $w_k = w_{k-1} - \alpha v_k$ (Lưu ý: $\beta \approx 0.9$. Bản chất là GD có nhớ hướng đi cũ)
5. RMSprop (Adaptive Learning Rate)	Tích lũy bình phương gradient (để chuẩn hóa): $h_{k-1} = \gamma h_{k-2} + (1 - \gamma)[\nabla g(w_{k-1})]^2$ Cập nhật (chia cho căn bậc hai của h): $w_k = w_{k-1} - \frac{\alpha}{\sqrt{h_{k-1}} + \epsilon} \odot \nabla g(w_{k-1})$
6. Adam (Momentum + RMSprop)	Moment bậc 1 (Trung bình): $m_k = \beta_1 m_{k-1} + (1 - \beta_1) \nabla g_k$ Moment bậc 2 (Phương sai): $v_k = \beta_2 v_{k-1} + (1 - \beta_2) (\nabla g_k)^2$ Cập nhật tham số: $w_{k+1} = w_k - \alpha \frac{m_k}{\sqrt{v_k} + \epsilon}$

Bảng 13: Hệ thống công thức Gradient Descent và các biến thể tối ưu

14 Công thức Tính Số Lượng Tham Số (Softmax/Linear Layer)

Đối với đầu vào là hình ảnh có kích thước $H \times W$ và C kênh màu, phân loại vào K lớp:

$$N = (H \times W \times C \times K) + K$$

Trong đó:

- H : Chiều cao ảnh (Height)
- W : Chiều rộng ảnh (Width)
- C : Số kênh màu (Channels - thường là 3 cho ảnh màu, 1 cho ảnh xám)
- K : Số lớp cần phân loại (Classes)
- **Cộng** ($H \times W \times C \times K$): Là số lượng trọng số (Weights).
- **Cộng thêm** K : Là số lượng hệ số chệch (Biases - mỗi lớp 1 bias).

15 Công thức Tính Tham Số Mạng Nơ-ron Đa Tầng (MLP)

Giả sử mạng có:

- N_0 : Kích thước đầu vào (Input Features).
- $N_1, N_2, \dots, N_L$: Số nơ-ron tại các lớp ẩn và lớp ra.

Tổng số tham số P được tính bằng tổng tham số của từng cặp lớp liên kề:

$$P = \sum_{i=1}^L (N_{i-1} \times N_i + N_i)$$

Hoặc viết tường minh:

$$P = \underbrace{(N_0 \times N_1 + N_1)}_{\text{Layer 1}} + \underbrace{(N_1 \times N_2 + N_2)}_{\text{Layer 2}} + \dots + \underbrace{(N_{L-1} \times N_L + N_L)}_{\text{Layer L}}$$

16 Confusion Matrix (Ma trận nhầm lẫn)

Đây là nền tảng để tính toán các chỉ số khác.

Cấu trúc Ma trận

		Dự đoán (Predicted)	
		Positive (1)	Negative (0)
Thực tế (Actual)	Positive (1)	TP (True Positive)	FN (False Negative)
	Negative (0)	FP (False Positive)	TN (True Negative)

1. Accuracy (Độ chính xác toàn thể)

Tỷ lệ dự đoán đúng trên tổng số mẫu.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

4. Specificity (Độ đặc hiệu)

Trong các mẫu thực tế là Negative, bao nhiêu mẫu dự đoán đúng?

$$\text{Specificity} = \frac{TN}{TN + FP}$$

2. Precision (Độ chính xác dự báo)

Trong các mẫu dự đoán là Positive, bao nhiêu mẫu đúng?

$$\text{Precision} = \frac{TP}{TP + FP}$$

5. F1 Score

Trung bình điều hòa giữa Precision và Recall (dùng khi dữ liệu mất cân bằng).

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

3. Recall / Sensitivity (Độ nhạy)

Trong các mẫu thực tế là Positive, bao nhiêu mẫu được tìm thấy?

$$\text{Recall} = \frac{TP}{TP + FN}$$

6. Log Loss (Cross-Entropy Loss)

Đánh giá độ tự tin của xác suất dự đoán.

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

7. ROC Curve

Đồ thị biểu diễn mối quan hệ giữa TPR và FPR tại các ngưỡng (threshold) khác nhau.

$$TPR = \text{Recall} = \frac{TP}{TP + FN}$$

$$FPR = 1 - \text{Specificity} = \frac{FP}{FP + TN}$$

8. AUC (Area Under Curve)

- Diện tích dưới đường cong ROC.
- Giá trị từ $0 \rightarrow 1$.
- $AUC = 0.5$: Dự đoán ngẫu nhiên.
- $AUC = 1$: Phân loại hoàn hảo.

9. Matthews Correlation Coefficient (MCC)

Chỉ số tương quan chất lượng phân loại, tốt hơn F1 và Accuracy khi dữ liệu mất cân bằng nặng. Giá trị từ -1 đến $+1$.

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

16.1 Bài tập ví dụ

Question 18 – 22 use the following information. Students need to write out the formula, substitute the numbers, and calculate the final answer in percentage (%) for the questions 18 – 21. Round to the nearest hundredth, for example: 12.34%.

We have a model M that supports diagnosing a type of disease X based on images of damaged skin. We evaluate this model on a dataset of 100 correctly labeled images and obtain the following results:

		Predicted Label	
		Positive	Negative
True Label	Positive	45	5
	Negative	2	48

Hình 1:

1. Xác định các đại lượng từ dữ liệu

Gọi D là sự kiện người đó mắc bệnh (True Positive Class). Gọi $+$ là sự kiện mô hình dự đoán Positive.

Từ bảng nhầm lẫn (Confusion Matrix), ta tính các xác suất có điều kiện của mô hình:

- **Độ nhạy (Sensitivity/Recall) - $P(+|D)$:**

$$P(+|D) = \frac{TP}{TP + FN} = \frac{45}{45 + 5} = \frac{45}{50} = 0.9$$

- **Tỷ lệ dương tính giả (False Positive Rate) - $P(+|\neg D)$:**

$$P(+|\neg D) = \frac{FP}{TN + FP} = \frac{2}{48 + 2} = \frac{2}{50} = 0.04$$

Thông tin từ đề bài về dân số (Prior probability):

- Xác suất mắc bệnh: $P(D) = 0.01\% = 0.0001$
- Xác suất không mắc bệnh: $P(\neg D) = 1 - 0.0001 = 0.9999$

2. Công thức (Định lý Bayes)

Ta cần tìm xác suất hậu nghiệm $P(D|+)$ (xác suất thực sự bị bệnh khi đã test dương tính):

$$P(D|+) = \frac{P(+|D) \cdot P(D)}{P(+)} = \frac{P(+|D) \cdot P(D)}{P(+|D) \cdot P(D) + P(+|\neg D) \cdot P(\neg D)}$$

3. Thay số và Tính toán

Thay các giá trị đã xác định vào công thức:

$$P(D|+) = \frac{0.9 \times 0.0001}{(0.9 \times 0.0001) + (0.04 \times 0.9999)}$$

Tính toán từng phần:

- Tử số (True Positives trong dân số): 0.00009
- Mẫu số hạng 1: 0.00009
- Mẫu số hạng 2 (False Positives trong dân số): 0.039996

$$P(D|+) = \frac{0.00009}{0.00009 + 0.039996} = \frac{0.00009}{0.040086}$$

$$P(D|+) \approx 0.00224517...$$

4. Kết quả cuối cùng

Đổi sang đơn vị phần trăm và làm tròn đến chữ số thập phân thứ hai:

$$0.00224517 \times 100 = 0.224517\% \approx 0.22\%$$

9. Perceptron Logic Gates

(Standard Weights & Biases) & Input $x \in \{0, 1\}$. Output $y = 1$ nếu $\sum w_i x_i + b \geq 0$.

Bảng tra nhanh (Cheat Sheet):

Gate	w_1	w_2	b	Đặc điểm (Mẹo nhớ)
AND	1	1	-1.5	Khắt khe (Cần cả 2 là 1)
OR	1	1	-0.5	Dễ dãi (Cần ít nhất 1)
NAND	-1	-1	1.5	Ngược của AND
NOR	-1	-1	0.5	Ngược của OR
NOT	-1	-	0.5	Đảo ngược input

Quy tắc: $w = 1$ (ủng hộ), $w = -1$ (phản đối). b là ngưỡng phải vượt qua.