

Đại học Quốc gia TP.HCM
Trường Đại học Công nghệ Thông tin



BÁO CÁO ĐỒ ÁN CUỐI KỲ

TOÁN CHO KHOA HỌC MÁY TÍNH

ĐỀ TÀI: DENOISING DIFFUSION PROBABILISTIC MODELS

Lớp: CS115.Q11.KHTN

GVHD: TS. Lương Ngọc Hoàng

Thành viên:

1. Bảo Quý Định Tân - 24520028
2. Hà Xuân Thiện - 24520031
3. Trần Quang Trường - 24521901

Contents

1	Đặt vấn đề	2
2	Tổng quan đề tài	2
3	Denoising Diffusion Probabilistic Model	2
3.1	Forward Process	2
3.2	Reverse Process	3
3.3	Hàm mục tiêu và Huấn luyện mô hình	3
3.3.1	Biến đổi ELBO	4
3.3.2	Phân tích số hạng L_{t-1} và sự lựa chọn phân phối Gaussian	5
3.4	Tiếp tục đơn giản hóa hàm mất mát	6
3.5	Tham số hóa dưới dạng epsilon	7
3.6	Hàm mất mát cuối cùng	7
4	Thực nghiệm và Đánh giá	8
4.1	Chi tiết thực nghiệm	8
4.2	Kết quả thực nghiệm (Results)	8

1 Đặt vấn đề

Trong những năm gần đây, các mô hình sinh sâu (deep generative models) đã đạt được nhiều thành tựu nổi bật, cho phép tạo ra các mẫu dữ liệu chất lượng cao trên nhiều lĩnh vực như hình ảnh, âm thanh và văn bản. Các hướng tiếp cận phổ biến bao gồm Generative Adversarial Networks (GAN) (Goodfellow et al., 2014), Variational Autoencoders (VAE) (Kingma and Welling, 2013), Normalizing Flows (Rezende and Mohamed, 2015) và các mô hình tự hồi quy (Autoregressive models) (Oord et al., 2016).

Tuy nhiên, mỗi phương pháp đều tồn tại những hạn chế nhất định. Mặc dù GAN có khả năng sinh mẫu với độ chi tiết cao, quá trình huấn luyện thường gặp khó khăn do sự mất ổn định, khó hội tụ và hiện tượng sụp đổ mode (mode collapse). Ngược lại, các mô hình dựa trên likelihood (likelihood-based) như VAE hay Autoregressive models tuy có nền tảng xác suất chặt chẽ nhưng thường tạo ra ảnh bị mờ hoặc đòi hỏi chi phí tính toán lớn khi lấy mẫu.

Mô hình khuếch tán (Diffusion Models) lần đầu được Sohl-Dickstein et al. (2015) đề xuất trong bối cảnh học không giám sát. Tuy nhiên, phương pháp này chưa nhận được nhiều sự chú ý vào thời điểm đó do sự thống trị của GAN. Phải đến khi Denoising Diffusion Probabilistic Models (DDPM) được Ho et al. (2020) công bố, tiềm năng của hướng tiếp cận này mới được chứng minh rõ rệt. DDPM không chỉ giải quyết được các vấn đề về sự ổn định trong huấn luyện mà còn đạt được chất lượng mẫu sinh vượt trội, đóng vai trò nền tảng cho sự phát triển mạnh mẽ của các mô hình Generative AI hiện nay (Dhariwal and Nichol, 2021).

2 Tổng quan đề tài

Đề tài này tập trung nghiên cứu sâu về cơ sở lý thuyết của DDPM, bao gồm việc xây dựng quá trình khuếch tán thuận (Forward Process), mô hình hóa quá trình ngược (Reverse Process) và chứng minh tường minh hàm mục tiêu thông qua biến đổi Cận dưới Biến phân (Variational Lower Bound - VLB). Đồng thời, báo cáo cũng trình bày quá trình thực nghiệm, huấn luyện mô hình trên các tập dữ liệu như MNIST và CIFAR-10 để kiểm chứng khả năng hội tụ và chất lượng mẫu sinh của DDPM.

3 Denoising Diffusion Probabilistic Model

Diffusion Models là một mô hình sinh dữ liệu dựa trên ý tưởng mô phỏng quá trình thêm nhiễu dần dần dữ liệu thật theo một phân phối chuẩn cho đến khi ảnh mất hoàn toàn cấu trúc ban đầu (pure noise); Lúc này, mô hình sẽ học cách đảo ngược quá trình đó để sinh dữ liệu mới. Quá trình thêm nhiễu được gọi là quá trình khuếch tán thuận hay quá trình thuận (Forward Process), và quá trình mô hình học cách khử nhiễu là quá trình khuếch tán ngược hay quá trình ngược (Reverse Process).

3.1 Forward Process

Quá trình lan truyền thuận là quá trình thêm nhiễu dần dần dữ liệu theo một phân phối chuẩn. Bắt đầu từ một mẫu dữ liệu ban đầu x_0 được lấy từ phân phối dữ liệu thực $x_0 \sim q(x)$. Ở mỗi thời gian t , x_t được tạo ra bằng cách thêm một lượng nhỏ Gaussian noise vào dữ liệu. Quá trình này được mô tả bằng một phân phối có điều kiện:

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t\mathbf{I}); \quad q(\mathbf{x}_{1:T}|\mathbf{x}_0) = \prod_{t=1}^T q(\mathbf{x}_t|\mathbf{x}_{t-1}) \quad (1)$$

Trong đó, $\beta_t \in (0, 1)$ là hệ số nhiễu tại bước t , được xác định trước.

Mẫu dữ liệu ban đầu x_0 sẽ dần dần mất đi các đặc trưng khi thời gian t tăng dần. Cuối cùng, khi $t \rightarrow \infty$, mục tiêu của ta là mong x_t sẽ tương đương với một phân phối Gaussian đẳng hướng (Isotropic Gaussian distribution). Mục đích của việc đưa $x_t \sim \mathcal{N}(0, \mathbf{I})$ là để thuận tiện cho quá trình huấn luyện và khai triển các công thức.

Đặc điểm của quá trình thuận cho phép ta lấy mẫu x_t tại thời điểm t bất kỳ. Cụ thể, gọi $\alpha_t = 1 - \beta_t$ và $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$, ta có:

$$\begin{aligned} x_t &= \sqrt{1 - \beta_t} x_{t-1} + \sqrt{\beta_t} \cdot \epsilon_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{1 - \alpha_t} \cdot \epsilon_t \\ &= \sqrt{\alpha_t \alpha_{t-1}} x_{t-2} + \sqrt{\alpha_t (1 - \alpha_{t-1})} \cdot \epsilon_{t-1} + \sqrt{1 - \alpha_t} \cdot \epsilon_t = \sqrt{\alpha_t \alpha_{t-1}} x_{t-2} + \sqrt{1 - \alpha_t \alpha_{t-1}} \cdot \bar{\epsilon}_{t-2} \\ &= \dots = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \cdot \epsilon \end{aligned} \quad (2)$$

Trong đó, $\epsilon_1, \epsilon_2, \dots, \epsilon_t \sim \mathcal{N}(0, \mathbf{I})$ độc lập với nhau và $\bar{\epsilon}_i = \epsilon_{i+1} + \epsilon_{i+2} + \dots + \epsilon_t$.

Từ đó, ta có thể lấy mẫu x_t từ x_0 thông qua phân phối có điều kiện sau:

$$q(x_t | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) \mathbf{I}) \quad (3)$$

Lúc này, với $\beta_t \in (0, 1)$, khi t tiến dần tới ∞ thì $\bar{\alpha}_t$ sẽ tiến dần về 0. Từ đó suy ra, $\sqrt{\bar{\alpha}_t} x_0$ sẽ tiến dần về 0 và $(1 - \bar{\alpha}_t) \mathbf{I}$ sẽ tiến dần về $\mathbf{I}$. Nói cách khác, $q(x_t | x_0)$ sẽ tiến dần về $\mathcal{N}(0, \mathbf{I})$ hay x_t lúc này sẽ tương đương một gaussian đẳng hướng.

Từ đây ta có thể tóm gọn lại **quá trình thêm nhiễu** như sau:

$$q(x_1, \dots, x_T | x_0) = q(x_1 | x_0) q(x_2 | x_1, x_0) \dots q(x_T | x_{T-1}, \dots, x_0) \quad (4)$$

Ta nhận ra rằng quá trình thêm nhiễu từ bước 0 để có ảnh ở bước t thực ra chỉ dựa trên bước $t - 1$ thôi là đủ (không cần quan tâm từ $t - 2$ trở về trước), nên ta có thể viết lại như dạng của chuỗi Markov:

$$q(x_1, \dots, x_T | x_0) = q(x_1 | x_0) q(x_2 | x_1) \dots q(x_T | x_{T-1}) \quad (5)$$

Cuối cùng ta có thể ghi gọn lại các ký hiệu:

$$q(x_{1:T} | x_0) = \prod_{t=1}^T q(x_t | x_{t-1}) \quad (6)$$

3.2 Reverse Process

Nếu như quá trình thuận là quá trình phá hủy cấu trúc, thông tin của ảnh ban đầu bằng cách thêm nhiễu, thì mục tiêu của quá trình ngược lại: khôi phục dữ liệu gốc x_0 từ nhiễu thuần túy $x_T \sim \mathcal{N}(0, \mathbf{I})$.

Về lý thuyết, nếu bước thêm nhiễu β_t đủ nhỏ, quá trình đảo ngược cũng sẽ là một phân phối Gaussian $q(x_{t-1} | x_t)$. Tuy nhiên, do ta không biết phân phối thực của dữ liệu $q(x)$, ta không thể tính trực tiếp phân phối này. Thay vào đó, ta sử dụng một mạng nơ-ron để xấp xỉ phân phối ngược này, ký hiệu là p_θ với θ có nghĩa là tham số của mô hình:

$$p_\theta(x_{0:T}) = p(x_T) \prod_{t=1}^T p_\theta(x_{t-1} | x_t) \quad (7)$$

3.3 Hàm mục tiêu và Huấn luyện mô hình

Mục tiêu huấn luyện mà ta nghĩ tới trước tiên là cực tiểu hóa **Negative Log-Likelihood**:

$$L = -\log p_\theta(x_0) \quad (8)$$

Tuy nhiên, việc tính toán trực tiếp $p_\theta(x_0) = \int p_\theta(x_{0:T}) dx_{1:T}$ là **bất khả thi** (intractable) do phải tích phân trên toàn bộ không gian biến tiềm ẩn. Do đó, ta sử dụng cận dưới biến phân (Variational Lower Bound - VLB) hay còn gọi là Evidence Lower Bound (ELBO).

3.3.1 Biến đổi ELBO

Áp dụng **bất đẳng thức Jensen** cho hàm lồi $f(x) = -\log(x)$, ta có chặn trên của NLL như sau:

$$\begin{aligned} -\log p_\theta(x_0) &= -\log \int p_\theta(x_{0:T}) dx_{1:T} = -\log \int q(x_{1:T} | x_0) \frac{p_\theta(x_{0:T})}{q(x_{1:T} | x_0)} dx_{1:T} \\ &= -\log \mathbb{E}_{q(x_{1:T}|x_0)} \left[\frac{p_\theta(x_{0:T})}{q(x_{1:T} | x_0)} \right] \leq \mathbb{E}_{q(x_{1:T}|x_0)} \left[-\log \frac{p_\theta(x_{0:T})}{q(x_{1:T} | x_0)} \right] \end{aligned} \quad (9)$$

Gọi biểu thức bên phải là L_{VLB} . Từ đây ta thấy rằng nếu ta cực tiểu hóa được L_{VLB} , thì Negative Log Likelihood cũng giảm theo. Ta khai triển biểu thức này:

$$\begin{aligned} L_{VLB} &= \mathbb{E}_q \left[\log \frac{q(x_{1:T} | x_0)}{p_\theta(x_{0:T})} \right] = \mathbb{E}_q \left[\log \frac{\prod_{t=1}^T q(x_t | x_{t-1})}{p(x_T) \prod_{t=1}^T p_\theta(x_{t-1} | x_t)} \right] \\ &= \mathbb{E}_q \left[-\log p(x_T) + \sum_{t=1}^T (\log q(x_t | x_{t-1}) - \log p_\theta(x_{t-1} | x_t)) \right] \end{aligned} \quad (10)$$

Sử dụng định lý Bayes cho quá trình thuận:

$$q(x_t | x_{t-1}) = q(x_t | x_{t-1}, x_0) = \frac{q(x_{t-1} | x_t, x_0) q(x_t | x_0)}{q(x_{t-1} | x_0)} \quad (11)$$

Cùng với các bước biến đổi đại số và tách ghép các số hạng, hàm mục tiêu có thể được viết lại dưới dạng:

$$L_{VLB} = \mathbb{E}_q \left[\log \frac{q(\mathbf{x}_T | \mathbf{x}_0)}{p_\theta(\mathbf{x}_T)} + \sum_{t=2}^T \log \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} - \log p_\theta(\mathbf{x}_0 | \mathbf{x}_1) \right] \quad (12)$$

Sau đó ta áp dụng Kullback-Leibler (KL) Divergence, sẽ được:

$$L_{VLB} = \mathbb{E}_q \left[\underbrace{D_{KL}(q(x_T | x_0) \parallel p(x_T))}_{L_T} + \sum_{t=2}^T \underbrace{D_{KL}(q(x_{t-1} | x_t, x_0) \parallel p_\theta(x_{t-1} | x_t))}_{L_{t-1}} - \underbrace{\log p_\theta(x_0 | x_1)}_{L_0} \right] \quad (13)$$

Trong đó:

- L_T : Là hằng số (do $q(x_T|x_0)$ và $p(x_T)$ không có tham số huấn luyện và xấp xỉ $\mathcal{N}(0, I)$), ta có thể **bỏ qua**.
- L_0 : Quá trình khử nhiễu bước cuối cùng vì giá trị này thường sẽ nhỏ do số bước của ta lớn nên sẽ không ảnh hưởng nhiều, ta **bỏ qua**.
- L_{t-1} : Thành phần **quan trọng** nhất, đo lường sự khác biệt giữa phân phối hậu nghiệm thực tế (ground truth) $q(x_{t-1}|x_t, x_0)$ và phân phối dự đoán của mô hình $p_\theta(x_{t-1}|x_t)$.

3.3.2 Phân tích số hạng L_{t-1} và sự lựa chọn phân phối Gaussian

Để đơn giản hóa hàm mất mát, ta dựa vào các tính chất sau:

1. Phân phối hậu nghiệm thực $q(x_{t-1}|x_t, x_0)$ là phân phối Gaussian

Theo định lý Bayes, ta có thể khai triển phân phối hậu nghiệm như sau:

$$q(x_{t-1} | x_t, x_0) = \frac{q(x_t | x_{t-1}, x_0)q(x_{t-1} | x_0)}{q(x_t | x_0)} \quad (14)$$

Do quá trình thuận là một chuỗi Markov, $q(x_t | x_{t-1}, x_0) = q(x_t | x_{t-1})$. Ta nhận thấy cả tử số và mẫu số đều là các phân phối Gaussian. Vì tích của các hàm mật độ xác suất Gaussian cũng là một hàm mật độ xác suất Gaussian, nên cũng giải thích được việc phân phối hậu nghiệm $q(x_{t-1} | x_t, x_0)$ bắt buộc phải có dạng Gaussian:

$$q(x_{t-1} | x_t, x_0) = \mathcal{N}(x_{t-1}; \tilde{\mu}_t(x_t, x_0), \tilde{\beta}_t \mathbf{I}) \quad (15)$$

2. Chọn mô hình $p_\theta(x_{t-1}|x_t)$ là phân phối Gaussian

Mục tiêu của mô hình là đảo ngược quá trình khuếch tán, tức là xấp xỉ phân phối $q(x_{t-1}|x_t)$. Mặc dù $q(x_{t-1}|x_t)$ thực tế (khi không biết x_0) rất phức tạp, nhưng [Feller \(1949\)](#) và [Sohl-Dickstein et al. \(2015\)](#) đã chỉ ra rằng: nếu các bước khuếch tán β_t đủ nhỏ, phân phối nghịch đảo thực tế $q(x_{t-1}|x_t)$ cũng sẽ tiệm cận phân phối Gaussian.

Chính vì lý do đó, để đơn giản hóa việc tính toán và khớp với dạng hàm của phân phối hậu nghiệm $q(x_{t-1} | x_t, x_0)$, [Ho et al. \(2020\)](#) tham số hóa mô hình p_θ dưới dạng một phân phối Gaussian:

$$p_\theta(x_{t-1} | x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t)) \quad (16)$$

Và để đơn giản hơn nữa và cũng thuận tiện cho việc huấn luyện mô hình, tác giả đã cố định phương sai của mô hình p_θ .

3. Đơn giản hóa hàm mất mát

L_{t-1} đo lường sự khác biệt giữa phân phối hậu nghiệm thực tế và phân phối dự đoán của mô hình tại mỗi bước thời gian:

$$L_{t-1} = \mathbb{E}_q \left[\sum_{t=2}^T D_{\text{KL}}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \| p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)) \right] \quad (17)$$

Vì cả q và p_θ đều là phân phối chuẩn, ta xét bài toán tổng quát với $P \sim \mathcal{N}(\mu_1, \sigma_1^2 \mathbf{I})$ và $Q \sim \mathcal{N}(\mu_2, \sigma_2^2 \mathbf{I})$ với $\mu_1, \sigma_1, \sigma_2$ cố định.

Ta thực hiện biến đổi D_{KL} dựa trên định nghĩa:

$$\begin{aligned} D_{\text{KL}}(P \| Q) &= \mathbb{E}_{x \sim P} [\log P(x) - \log Q(x)] \\ &= \mathbb{E}_{x \sim P} \left[\left(\log \frac{1}{\sqrt{2\pi\sigma_1^2}} - \frac{(x - \mu_1)^2}{2\sigma_1^2} \right) - \left(\log \frac{1}{\sqrt{2\pi\sigma_2^2}} - \frac{(x - \mu_2)^2}{2\sigma_2^2} \right) \right] \\ &= C - \frac{1}{2} + \frac{1}{2\sigma_2^2} \mathbb{E}_{x \sim P} [(x - \mu_2)^2] \end{aligned} \quad (18)$$

Để tính kỳ vọng $\mathbb{E}_{x \sim P} [\|x - \mu_2\|^2]$, ta thêm bớt μ_1 và khai triển:

$$\begin{aligned} \mathbb{E}_{x \sim P} [\|(x - \mu_1) + (\mu_1 - \mu_2)\|^2] &= \underbrace{\mathbb{E}[\|x - \mu_1\|^2]}_{\text{Var}(P) = \sigma_1^2} + \underbrace{2(\mu_1 - \mu_2)\mathbb{E}[x - \mu_1]}_0 + \|\mu_1 - \mu_2\|^2 \\ &= \sigma_1^2 + \|\mu_1 - \mu_2\|^2 \end{aligned} \quad (19)$$

Thế ngược lại, ta thu được kết quả cuối cùng cho thấy D_{KL} tỉ lệ thuận với sai số bình phương trung bình (MSE) giữa hai vector kỳ vọng:

$$D_{KL}(P \parallel Q) = \text{Const} + \frac{1}{2\sigma_2^2} \|\mu_1 - \mu_2\|^2 \quad (20)$$

Ở đây khi đổi thứ tự P và Q trong D_{KL} , vì phương sai của hai phân phối chuẩn này bị cố định nên việc đổi thứ tự không còn hiệu ứng mean-seeking (forward D_{KL}) và mode-seeking (backward D_{KL}). Tuy nhiên để thuận tiện hơn trong việc huấn luyện và hợp mới mạch khai triển, ta giữ nguyên thứ tự. Áp dụng vào DDPM với $\mu_1 = \tilde{\mu}_t$ và $\mu_2 = \mu_\theta$, hàm mất mát trở thành:

$$\mathbb{E}_q \left[\sum_{t=2}^T \frac{1}{2\sigma_t^2} \|\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) - \mu_\theta(\mathbf{x}_t, t)\|^2 \right] \quad (21)$$

3.4 Tiếp tục đơn giản hóa hàm mất mát

Từ hậu nghiệm ngược thật (true posterior) của quá trình thêm nhiễu, ta biết rằng:

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1}; \tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0), \tilde{\beta}_t \mathbf{I})$$

Từ đây, ta sẽ bắt đầu suy ra công thức tường minh cho trung bình $\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0)$ và phương sai $\tilde{\beta}_t$. Áp dụng định lý Bayes:

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) = q(\mathbf{x}_t \mid \mathbf{x}_{t-1}) \frac{q(\mathbf{x}_{t-1} \mid \mathbf{x}_0)}{q(\mathbf{x}_t \mid \mathbf{x}_0)} \quad (22)$$

Ta có thể thấy trong đó các phân phối đều là Gaussian:

$$\begin{aligned} q(\mathbf{x}_t \mid \mathbf{x}_{t-1}) &= \mathcal{N}(\mathbf{x}_t; \sqrt{\alpha_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}) \\ q(\mathbf{x}_{t-1} \mid \mathbf{x}_0) &= \mathcal{N}(\mathbf{x}_{t-1}; \sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0, (1 - \bar{\alpha}_{t-1}) \mathbf{I}) \\ q(\mathbf{x}_t \mid \mathbf{x}_0) &= \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}) \end{aligned}$$

Ta thay dạng mật độ xác suất của Gaussian vào các phân phối, rồi bỏ hệ số chuẩn hóa, ta được:

$$q(x_{t-1} \mid x_t, x_0) \propto \exp \left(-\frac{1}{2} \left[\frac{(x_t - \sqrt{\alpha_t} x_{t-1})^2}{\beta_t} + \frac{(x_{t-1} - \sqrt{\bar{\alpha}_{t-1}} x_0)^2}{1 - \bar{\alpha}_{t-1}} - \frac{(x_t - \sqrt{\bar{\alpha}_t} x_0)^2}{1 - \bar{\alpha}_t} \right] \right) \quad (23)$$

Tiếp tục khai triển các bình phương: Ta lần lượt khai triển hai hạng tử đầu:

$$(x_t - \sqrt{\alpha_t} x_{t-1})^2 = \textcolor{teal}{x}_t^2 - 2\sqrt{\alpha_t} x_t \textcolor{blue}{x}_{t-1} + \alpha_t \textcolor{red}{x}_{t-1}^2 \quad (24)$$

$$(x_{t-1} - \sqrt{\bar{\alpha}_{t-1}} x_0)^2 = \textcolor{red}{x}_{t-1}^2 - 2\sqrt{\bar{\alpha}_{t-1}} x_0 \textcolor{blue}{x}_{t-1} + \bar{\alpha}_{t-1} \textcolor{teal}{x}_0^2 \quad (25)$$

Loại bỏ các hạng tử không phụ thuộc x_{t-1} . Các hạng tử chỉ phụ thuộc vào x_t và x_0 (màu xanh lá) sẽ được gom lại thành một hằng số $C(x_t, x_0)$, bao gồm:

$$x_t^2, \quad \bar{\alpha}_{t-1} x_0^2, \quad \frac{(x_t - \sqrt{\bar{\alpha}_t} x_0)^2}{1 - \bar{\alpha}_t}$$

Gom các hạng tử theo x_{t-1} . Giữ lại các hạng tử bậc hai và bậc nhất theo số mũ của x_{t-1} , ta thu được:

$$q(x_{t-1} \mid x_t, x_0) \propto \exp \left(-\frac{1}{2} \left[\left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) \textcolor{red}{x}_{t-1}^2 - \left(\frac{2\sqrt{\alpha_t}}{\beta_t} x_t + \frac{2\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} x_0 \right) \textcolor{blue}{x}_{t-1} + C(x_t, x_0) \right] \right) \quad (26)$$

Bây giờ ta đã đưa về dạng bình phương hoàn chỉnh:

$$\exp \left(-\frac{1}{2} (A \mathbf{x}_{t-1}^2 - 2B \mathbf{x}_{t-1} + C) \right) \quad (27)$$

với $A = \frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}}$ và $B = \frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0$.

So sánh với dạng chuẩn của Gaussian $\mathcal{N}(x; \mu, \sigma^2) \propto \exp \left(-\frac{1}{2\sigma^2} (x^2 - 2\mu x + \mu^2) \right)$, ta suy ra:

$$\tilde{\beta}_t = \frac{1}{A} = \frac{1}{\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}}} = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t \quad (28)$$

$$\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{B}{A} = \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t} \mathbf{x}_0. \quad (29)$$

3.5 Tham số hóa dưới dạng epsilon

Từ parameterization trick của công thức quá trình thêm nhiễu:

$$\mathbf{x}_0 = \frac{1}{\sqrt{\bar{\alpha}_t}} (\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}_t) \quad (30)$$

Ta thay vào $\tilde{\mu}_t$ và rút gọn để có được:

$$\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_t \right) \quad (31)$$

Vì phân phối hậu nghiệm thực tế $q(x_{t-1} | x_t, x_0)$ có dạng Gaussian với trung bình $\tilde{\mu}_t(x_t, x_0)$, ta thay trực tiếp $\boldsymbol{\epsilon}_t$ thành dự đoán của model $\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)$ trong biểu thức của $\tilde{\mu}_t$, để thu được công thức cho giá trị trung bình của mô hình:

$$\boldsymbol{\mu}_\theta(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \right) \quad (32)$$

3.6 Hàm mất mát cuối cùng

Từ việc tham số hóa dưới dạng epsilon, ta tiếp tục đơn giản hóa hàm loss ELBO:

$$\begin{aligned} L_t &= \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}} \left[\frac{1}{2 \|\boldsymbol{\Sigma}_\theta(\mathbf{x}_t, t)\|_2^2} \|\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) - \boldsymbol{\mu}_\theta(\mathbf{x}_t, t)\|^2 \right] \\ &= \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}} \left[\frac{1}{2 \|\boldsymbol{\Sigma}_\theta\|_2^2} \left\| \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_t \right) - \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \right) \right\|^2 \right] \\ &= \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}} \left[\frac{(1 - \alpha_t)^2}{2 \alpha_t (1 - \bar{\alpha}_t) \|\boldsymbol{\Sigma}_\theta\|_2^2} \|\boldsymbol{\epsilon}_t - \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)\|^2 \right] \end{aligned}$$

Nhưng qua thực nghiệm, tác giả bài báo nhận thấy được hàm mất mát khi bỏ đi các hệ số sẽ thu được kết quả tốt hơn:

$$L_t^{\text{simple}} = \mathbb{E}_{t \sim [1, T], \mathbf{x}_0, \boldsymbol{\epsilon}_t} [\|\boldsymbol{\epsilon}_t - \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)\|^2] \quad (33)$$

Objective	IS	FID
$\tilde{\mu}$ prediction (baseline)		
L , learned diagonal Σ	7.28 ± 0.10	23.69
L , fixed isotropic Σ	8.06 ± 0.09	13.22
$\ \tilde{\mu} - \tilde{\mu}_\theta\ ^2$	–	–
ϵ prediction (ours)		
L , learned diagonal Σ	–	–
L , fixed isotropic Σ	7.67 ± 0.13	13.51
$\ \tilde{\epsilon} - \epsilon_\theta\ ^2$ (L_{simple})	9.46 ± 0.11	3.17

Table 1: Thực nghiệm về kết quả của các cách tham số hóa quá trình ngược và hàm mục tiêu khác nhau trên CIFAR10. Các ô trống biểu thị quá trình huấn luyện không ổn định và tạo ra mẫu kém chất lượng [Ho et al. \(2020\)](#).

4 Thực nghiệm và Đánh giá

Algorithm 1 Training

```

1: repeat
2:    $\mathbf{x}_0 \sim q(\mathbf{x}_0)$ 
3:    $t \sim \text{Uniform}(\{1, \dots, T\})$ 
4:    $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
5:   Take gradient descent step on
      $\nabla_\theta \|\epsilon - \epsilon_\theta(\sqrt{\alpha_t}\mathbf{x}_0 + \sqrt{1 - \alpha_t}\epsilon, t)\|^2$ 
6: until converged

```

Algorithm 2 Sampling

```

1:  $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
2: for  $t = T, \dots, 1$  do
3:    $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  if  $t > 1$ , else  $\mathbf{z} = \mathbf{0}$ 
4:    $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{1-\alpha_t}{\sqrt{1-\alpha_t}} \epsilon_\theta(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$ 
5: end for
6: return  $\mathbf{x}_0$ 

```


Figure 1: Tóm tắt thuật toán Training và Sampling của DDPM ([Ho et al., 2020](#)). Quá trình thực nghiệm tuân thủ các bước được mô tả tại đây.

4.1 Chi tiết thực nghiệm

Mô hình được huấn luyện và đánh giá trên tập dữ liệu chữ số viết tay **MNIST** và **CIFAR-10** ([Krizhevsky and Hinton, 2009](#)) là tập dữ liệu phức tạp hơn bao gồm 60.000 ảnh màu (RGB) thuộc 10 lớp đối tượng khác nhau (máy bay, ô tô, chim, mèo,...). Mô hình được cài đặt sử dụng thư viện **Deepinv** (MNIST) và **Diffusers** (CIFAR-10). Các siêu tham số (hyperparameters): Số bước thêm nhiễu (T): 1000, lịch trình nhiễu (Noise Schedule) là tuyến tính (Linear), β_{start} : 10^{-4} , β_{end} : 0.02, learning Rate: 10^{-4} , batch size: 32 (64 với CIFAR-10) và số epoch: 10 (100 với CIFAR-10).

4.2 Kết quả thực nghiệm (Results)


Hình 3 biểu diễn các mẫu dữ liệu được sinh ra bởi mô hình sau 10 epoch huấn luyện. Quá trình lấy mẫu (sampling) bắt đầu từ nhiễu chuẩn $\mathcal{N}(\mathbf{0}, \mathbf{I})$ và thực hiện khử nhiễu qua 1000 bước thời gian ngược.




(a) Epoch 1



(b) Epoch 5



(c) Epoch 35



(d) Epoch 100

Figure 2: Quá trình cải thiện chất lượng ảnh sinh trên **CIFAR-10** qua các epoch: (a) Epoch 1, (b) Epoch 5, (c) Epoch 35, và (d) Epoch 100.

Nhận xét: Tại những epoch đầu tiên (Hình 2a, Hình 2b), mô hình chưa học được phân phối dữ liệu, kết quả chủ yếu là nhiễu ngẫu nhiên. Đến giữa quá trình huấn luyện (Hình 2c), mô hình bắt đầu nắm bắt được cấu trúc toàn cục (global structure) và màu sắc chủ đạo của các lớp (ví dụ: nền xanh của bầu trời hoặc cỏ). Kết thúc 100 epoch (Hình 2d), các mẫu sinh ra đã có độ sắc nét tốt hơn, các đặc trưng cục bộ (local features) được tái tạo rõ ràng.




Figure 3: Các mẫu chữ số được sinh ra ngẫu nhiên tại Epoch 10. Mặc dù thời gian huấn luyện ngắn, mô hình đã nắm bắt được cấu trúc hình học cơ bản của các chữ số viết tay.

References

- Dhariwal, P. and Nichol, A. (2021). Diffusion models beat gans on image synthesis. In *Advances in neural information processing systems*, volume 34, pages 8780–8794.
- Feller, W. (1949). On the theory of stochastic processes. *Proceedings of the Berkeley Symposium on Mathematical Statistics and Probability*, 1:403–432.
- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., and Bengio, Y. (2014). Generative adversarial nets. In *Advances in neural information processing systems*, volume 27.
- Ho, J., Jain, A., and Abbeel, P. (2020). Denoising diffusion probabilistic models. In *Advances in neural information processing systems*, volume 33, pages 6840–6851.
- Kingma, D. P. and Welling, M. (2013). Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*.
- Krizhevsky, A. and Hinton, G. (2009). Learning multiple layers of features from tiny images. Technical report, Citeseer.
- Oord, A. v. d., Kalchbrenner, N., and Kavukcuoglu, K. (2016). Pixel recurrent neural networks. In *International conference on machine learning*, pages 1747–1756. PMLR.
- Rezende, D. and Mohamed, S. (2015). Variational inference with normalizing flows. In *International conference on machine learning*, pages 1530–1538. PMLR.
- Sohl-Dickstein, J., Weiss, E., Maheswaranathan, N., and Ganguli, S. (2015). Deep unsupervised learning using nonequilibrium thermodynamics. In *International conference on machine learning*, pages 2256–2265. PMLR.