

1 Xác định các đại lượng dùng để tính score

Xét hai nhóm hàng A và B . Trong bài toán này, mỗi nhóm hàng có thể là một giá trị của cat_1 hoặc một cặp $(\text{cat_1}, \text{cat_2})$, tùy theo mức phân tích được lựa chọn.

1.1 Định nghĩa basket

Mỗi *basket* được xác định bởi một bộ ba:

$$(\text{customer_id}, \text{date}, \text{location})$$

Nói cách khác, mỗi bộ giá trị cụ thể của $(\text{customer_id}, \text{date}, \text{location})$ được xem là một basket riêng biệt. Tất cả sản phẩm được mua bởi cùng một khách hàng, trong cùng một ngày, tại cùng một địa điểm sẽ được gom vào cùng một basket.

1.2 Co-count

Xét hai nhóm hàng A và B . Sau khi *join* hai bảng theo item_id , mỗi item_id sẽ được gán vào một nhóm hàng tương ứng. Khi đó, một item_id được xem là thuộc A nếu sau khi join, nó có giá trị nhóm hàng bằng A ; tương tự cho B .

Gọi N là tổng số basket riêng biệt trong dữ liệu. Với mỗi basket i , định nghĩa:

$$I_i(A, B) = \begin{cases} 1, & \text{nếu trong basket } i \text{ có ít nhất một } \text{item_id} \text{ thuộc } A \text{ và ít nhất một } \text{item_id} \text{ thuộc } B \\ 0, & \text{ngược lại} \end{cases}$$

Khi đó:

$$\text{co_count}(A, B) = \sum_{i=1}^N I_i(A, B)$$

Tóm lại $\text{co_count}(A, B)$ là số basket riêng biệt có chứa đồng thời nhóm hàng A và nhóm hàng B .

1.3 Số lần xuất hiện của từng nhóm hàng

Với mỗi basket i , định nghĩa:

$$I_i(A) = \begin{cases} 1, & \text{nếu trong basket } i \text{ có ít nhất một } \text{item_id} \text{ thuộc } A \\ 0, & \text{ngược lại} \end{cases}$$

Khi đó:

$$\text{count}(A) = \sum_{i=1}^N I_i(A) \quad \text{count}(B) = \sum_{i=1}^N I_i(B)$$

Trong đó, $\text{count}(A)$ là số basket có chứa nhóm hàng A , và $\text{count}(B)$ được hiểu tương tự.

1.4 Xác suất có điều kiện

Từ các đại lượng trên, xác suất có điều kiện $P(B|A)$ được định nghĩa là:

$$P(B|A) = \frac{\text{co_count}(A, B)}{\text{count}(A)}$$

Tương tự:

$$P(A|B) = \frac{\text{co_count}(A, B)}{\text{count}(B)}$$

Nói cách khác, $P(B|A)$ cho biết trong các basket có chứa A , có bao nhiêu basket đồng thời chứa B ; còn $P(A|B)$ được hiểu tương tự.

1.5 Công thức score

Trong bài toán này, chỉ những cặp nhóm hàng thỏa mãn $\text{co_count}(A, B) > 0$ mới được đưa vào đồ thị. Nếu $\text{co_count}(A, B) = 0$, hai nhóm hàng không đồng xuất hiện trong bất kỳ basket nào nên không tạo cạnh.

Với các cặp có cạnh, score được xác định như sau:

$$\text{score}(A, B) = \log(\text{co_count}(A, B)) \cdot (P(B|A) + P(A|B))$$

Trong đó:

- $\log(\text{co_count}(A, B))$ phản ánh tần suất đồng xuất hiện giữa hai nhóm hàng;
- $P(B|A) + P(A|B)$ phản ánh mức độ liên hệ giữa hai nhóm hàng theo hai phía.

Do bài toán xây dựng đồ thị vô hướng, score trên có tính đối xứng theo A và B :

$$\text{score}(A, B) = \text{score}(B, A)$$

1.6 Đánh giá tính hợp lý của công thức score

Công thức score được sử dụng trong bài toán là:

$$\text{score}(A, B) = \log(\text{co_count}(A, B)) \cdot (P(B|A) + P(A|B))$$

Công thức này có tính hợp lý vì kết hợp được hai khía cạnh quan trọng trong quan hệ giữa hai nhóm hàng. Thành phần $\text{co_count}(A, B)$ phản ánh số lần A và B cùng xuất hiện trong các basket, tức là mức độ đồng mua về mặt tần suất. Thành phần $P(B|A) + P(A|B)$ phản ánh mức độ liên hệ theo cả hai chiều giữa hai nhóm hàng. Việc sử dụng hàm log đối với $\text{co_count}(A, B)$ giúp giảm ảnh hưởng của các cặp có tần suất đồng xuất hiện quá lớn, tránh để một số cạnh lấn át hoàn toàn các cạnh còn lại.

Tuy nhiên, công thức này chưa cho thấy rõ sự đồng xuất hiện giữa A và B có thực sự cao hơn mức kỳ vọng hay không. Trong thực tế, một nhóm hàng xuất hiện rất phổ biến có

thể đồng thời đi kèm với nhiều nhóm khác, làm cho score tăng lên dù mối liên hệ chưa chắc thật sự nổi bật.

Vì vậy, thay vì chỉ dùng xác suất có điều kiện, ta sử dụng thêm độ đo

$$\text{lift}(A, B) = \frac{\text{co_count}(A, B) \cdot N}{\text{count}(A)\text{count}(B)}$$

để so sánh mức đồng xuất hiện thực tế với mức kỳ vọng nếu hai nhóm hàng độc lập. Khi đó, $\text{lift}(A, B) > 1$ cho thấy hai nhóm hàng xuất hiện cùng nhau nhiều hơn kỳ vọng, còn $\text{lift}(A, B) \leq 1$ cho thấy mối liên hệ không đáng kể hoặc yếu hơn kỳ vọng.

Mặt khác, nếu dùng trực tiếp lift thì giá trị này có thể rất lớn khi $\text{count}(A)$ hoặc $\text{count}(B)$ quá nhỏ. Do đó, ta lấy thêm log để làm giảm ảnh hưởng của các giá trị lift quá lớn, đồng thời kết hợp với $\log(\text{co_count}(A, B))$ để vẫn giữ thông tin về tần suất đồng mua.

Từ đó, score được xác định như sau:

$$\text{score}(A, B) = \begin{cases} \log(\text{co_count}(A, B)) \cdot \log(\text{lift}(A, B)), & \text{nếu } \text{lift}(A, B) > 1 \\ 0, & \text{nếu } \text{lift}(A, B) \leq 1 \end{cases}$$

Công thức này hợp lý hơn công thức ban đầu vì kết hợp được cả hai yếu tố: **tần suất đồng mua** và **mức độ liên hệ vượt kỳ vọng**. Đồng thời, việc chỉ giữ các cặp có $\text{lift}(A, B) > 1$ giúp score tập trung vào các mối liên hệ dương thực sự, còn phép log giúp hạn chế việc các cặp hiếm có lift quá lớn chi phối kết quả.