



CS117

DỮ LIỆU ĐÁNH GIÁ

Giảng viên: NGÔ ĐỨC THÀNH



KHÁI NIỆM DỮ LIỆU ĐÁNH GIÁ



Dữ liệu trong đánh giá

Dữ liệu đánh giá là cơ sở dùng để đo lường mức độ thành công của giải pháp theo các tiêu chí đã đặt ra

- Dữ liệu đánh giá là tập hợp thông tin được sử dụng để kiểm chứng hiệu quả và độ tin cậy của giải pháp.
- Có thể bao gồm dữ liệu đầu vào (input), dữ liệu nhãn chuẩn (ground truth), dữ liệu kết quả (output), dữ liệu gián tiếp, dữ liệu phản hồi từ người dùng...
- Mang tính khách quan, giúp quá trình đánh giá có cơ sở rõ ràng.
- Được thiết kế phù hợp với mục tiêu, bối cảnh và phạm vi của bài toán.
- Có thể định lượng (số liệu đo được) hoặc định tính (phản hồi, quan sát).

Dữ liệu trong đánh giá

Dữ liệu là nền tảng để mọi hoạt động đánh giá có ý nghĩa, giúp biến tiêu chí trừu tượng thành kết quả đo lường được

- **Cơ sở để đo lường** → không có dữ liệu, các tiêu chí đánh giá (metrics) chỉ tồn tại trên lý thuyết, không thể kiểm chứng.
- **So sánh giải pháp** → dữ liệu chung làm chuẩn để so sánh nhiều giải pháp hoặc nhiều phiên bản của một giải pháp.
- **Khách quan hóa đánh giá** → dữ liệu giúp tránh đánh giá dựa trên cảm tính, thay bằng con số và bằng chứng.
- **Phát hiện vấn đề tiềm ẩn** → qua phân tích dữ liệu, có thể phát hiện lỗi, bias, hoặc tình huống mà giải pháp chưa xử lý tốt.




Mối quan hệ dữ liệu – tiêu chí – kết quả

Dữ liệu là cơ sở để đo lường theo tiêu chí, và tiêu chí là công cụ để chuyển hóa dữ liệu thành kết quả đánh giá có ý nghĩa

- Người dùng đặt ra mong đợi và được diễn dịch thành tiêu chí (metrics) → Tiêu chí yêu cầu dữ liệu phù hợp để đo lường → Dữ liệu (input, output, ground truth, feedback...) được thu thập → Áp dụng tiêu chí lên dữ liệu và sinh ra kết quả đánh giá.
- Ví dụ:
 - **Mong đợi:** chatbot trả lời chính xác & nhanh.
 - **Tiêu chí:** accuracy, thời gian phản hồi trung bình.
 - **Dữ liệu:** tập câu hỏi chuẩn + đáp án - câu trả lời chuẩn + log hệ thống.
 - **Kết quả:** chatbot đạt 92% accuracy, 1.8 giây/response.

Yêu cầu dữ liệu đánh giá





Yêu cầu dữ liệu đánh giá – Đúng ngữ cảnh

Dữ liệu dùng để đánh giá phải phản ánh đúng bối cảnh mà giải pháp sẽ được áp dụng

- **Phù hợp với mục tiêu** → dữ liệu phải liên quan trực tiếp đến bài toán.

Ví dụ: đánh giá hệ thống điểm danh cần dữ liệu khuôn mặt của sinh viên, không phải dữ liệu ảnh minh họa trên Internet.

- **Phản ánh tình huống thực tế** → dữ liệu phải đại diện cho điều kiện môi trường, thiết bị, và cách sử dụng trong thực tiễn.

Ví dụ: đánh giá chatbot chăm sóc khách hàng phải dùng tập hội thoại thật, thay vì hội thoại giả định quá đơn giản.

- **Ngăn ngừa đánh giá sai lệch** → nếu dữ liệu không đúng ngữ cảnh, kết quả đánh giá có thể cao trong đánh giá nhưng thất bại khi triển khai thực tế.



Yêu cầu dữ liệu đánh giá – Đầy đủ, cân bằng, đại diện

- **Đầy đủ (Completeness)** → bao quát các trường hợp mà hệ thống có thể gặp trong thực tế
 - Ví dụ: hệ thống nhận diện chữ viết tay phải có dữ liệu từ nhiều kiểu chữ khác nhau.
- **Cân bằng (Balance)** → không để một nhóm dữ liệu chiếm ưu thế quá lớn, gây sai lệch kết quả.
 - Ví dụ: đánh giá hệ thống phân loại hình ảnh “mèo/chó” → nếu 90% ảnh là mèo, kết quả sẽ thiếu công bằng.
- **Đại diện (Representativeness)** → phản ánh đúng đặc điểm của môi trường và người dùng thực.
 - Ví dụ: hệ thống điểm danh phải có dữ liệu từ nhiều lớp, nhiều điều kiện ánh sáng, không chỉ ảnh chụp chuẩn trong studio.



Yêu cầu dữ liệu đánh giá – Độ tin cậy và tính cập nhật

Dữ liệu đánh giá phải chính xác và luôn được cập nhật để đảm bảo kết quả đánh giá có giá trị

- **Độ tin cậy (Reliability)** → dữ liệu phải phản ánh đúng thực tế, không chứa lỗi hoặc nhầm sai. Nhãn chuẩn (ground truth) cần được xác nhận bởi chuyên gia hoặc quy trình đáng tin cậy. Ví dụ: hệ thống AI y tế cần dữ liệu chẩn đoán từ bác sĩ.
- **Tính cập nhật (Up-to-date)** → dữ liệu phải theo kịp sự thay đổi trong môi trường và hành vi người dùng. Ví dụ: chatbot chăm sóc khách hàng cần dữ liệu hội thoại cập nhật liên tục, vì sản phẩm và dịch vụ thay đổi theo thời gian.
- Hậu quả nếu thiếu tin cậy/cập nhật → hệ thống bị đánh giá sai, kết quả không phản ánh tình trạng hiện tại → dễ dẫn đến quyết định sai khi triển khai.



DỮ LIỆU CHUẨN


Dữ liệu với đáp án chuẩn (ground-truth)

Ground-truth là “sự thật gốc”, dùng làm chuẩn mực để đối chiếu và đánh giá hiệu quả của giải pháp.

- Ground-truth là tập thông tin “*được xem là*” đúng tuyệt đối (theo chuẩn mực hoặc được xác nhận bởi chuyên gia), dùng làm cơ sở so sánh với kết quả mà hệ thống tạo ra.
 - Càng chính xác thì kết quả đánh giá càng đáng tin cậy.
 - Có thể được xây dựng thủ công (con người gán nhãn), bán tự động (AI hỗ trợ) hoặc từ thiết bị chuẩn (cảm biến, máy đo).
- Không có ground-truth, việc đánh giá chỉ là ước lượng, không thể xác nhận độ đúng sai của giải pháp.

Dữ liệu với đáp án chuẩn (ground-truth)

COCO Dataset (cocodataset.org)



Background image courtesy: Antonio Torralba



Ground-truth và Benchmark

- **Ground-truth** → “sự thật gốc” – thông tin được coi là đúng tuyệt đối, dùng để so sánh với kết quả hệ thống.
 - Mục đích: Kiểm chứng độ chính xác của mô hình hay giải pháp.
 - Phạm vi: Thường ở mức dữ liệu hoặc nhãn (labels).
- **Benchmark** → “bộ chuẩn tham chiếu” – tập dữ liệu, tiêu chí và quy trình chuẩn để so sánh hiệu suất giữa nhiều giải pháp/mô hình.
 - Mục đích: Không chỉ kiểm chứng, mà còn để so sánh công bằng giữa các phương án.
 - Phạm vi: Thường bao gồm cả dữ liệu (đã có ground-truth đi kèm), tiêu chí đánh giá (metrics), và quy trình thực hiện.


Ground-truth là một phần của benchmark, benchmark bao gồm cả dữ liệu, tiêu chí và cách so sánh

Nguồn ground-truth

Dữ liệu dùng để đánh giá phải phản ánh đúng bối cảnh mà giải pháp sẽ được áp dụng

- **Con người/Chuyên gia gán nhãn:**

- Ground-truth được tạo ra bởi người dùng hoặc chuyên gia có kiến thức trong lĩnh vực.
- Độ tin cậy phụ thuộc vào trình độ và quy trình gán nhãn.
- Ví dụ: bác sĩ gán nhãn ảnh X-quang, con người gán nhãn hình ảnh mèo/chó, luật sư gán nhãn tài liệu pháp lý.




- **Thiết bị đo lường chính xác (Sensors/Measurement devices):**

- Sử dụng các thiết bị đạt chuẩn để ghi nhận dữ liệu thật.
- Ví dụ: GPS chuẩn để xác định vị trí, máy đo y tế để ghi lại nhịp tim hoặc huyết áp.



Nguồn ground-truth

- **Crowdsourcing:**
 - Huy động số lượng lớn người tham gia gán nhãn để tạo ground-truth nhanh chóng.
 - Ví dụ: gán nhãn ảnh trên Amazon Mechanical Turk, Zooniverse, reCAPTCHA...
- **Kết hợp nhiều nguồn:**
 - Kết hợp crowdsourcing (nhanh, rẻ) và chuyên gia (chính xác) để tối ưu chi phí và chất lượng.



Chất lượng ground-truth phụ thuộc trực tiếp vào nguồn tạo, quy trình tạo nhãn chuẩn, cần cân bằng giữa độ tin cậy, chi phí và tốc độ

Bias trong dữ liệu đánh giá – Khái niệm và nguyên nhân

Bias trong dữ liệu đánh giá là sự thiên lệch, khiến kết quả đánh giá không phản ánh đúng hiệu quả thật của giải pháp

- Bias xuất hiện khi dữ liệu đánh giá không trung lập, mà nghiêng về một nhóm, một tình huống, hoặc một kiểu mẫu nhất định → giải pháp có thể đạt kết quả tốt trên dữ liệu đánh giá nhưng thất bại trong thực tế.
 - ***Mẫu dữ liệu không cân bằng*** → một nhóm chiếm tỷ lệ quá lớn.
 - ***Sai lệch trong gán nhãn*** → người gán nhãn chủ quan, thiếu nhất quán hoặc sai sót.
 - ***Thu thập dữ liệu không đa dạng*** → dữ liệu chỉ từ một nguồn, một môi trường.
 - ***Thiếu tính cập nhật*** → dữ liệu cũ, không phản ánh tình hình hiện tại.



Ví dụ thực tế về Bias trong dữ liệu

Bias trong dữ liệu đánh giá có thể gây ra nhiều vấn đề nghiêm trọng trong thực tế, đặc biệt với các hệ thống AI

- ***Thị giác máy tính (Computer Vision)***: hệ thống nhận diện khuôn mặt của một số hãng bị phát hiện có độ chính xác cao với người da sáng, nhưng thấp với người da tối do dữ liệu huấn luyện và đánh giá thiên lệch.
- ***Y tế thông minh (AI in Healthcare)***: một mô hình dự đoán nguy cơ bệnh tim sử dụng dữ liệu chủ yếu từ bệnh nhân nam → kết quả đánh giá tốt cho nam giới nhưng kém chính xác với nữ giới.
- ***Ngôn ngữ tự nhiên (NLP)***: chatbot huấn luyện và đánh giá trên tập hội thoại chuẩn mực → khi triển khai thực tế với ngôn ngữ địa phương, slang, hoặc phương ngữ, hệ thống cho kết quả kém.
- ***Ứng dụng gọi xe công nghệ***: hệ thống định giá cước được đánh giá bằng dữ liệu từ thành phố lớn → khi triển khai ở vùng nông thôn, giá cước tính toán không hợp lý vì thiếu dữ liệu bối cảnh.



QUY TRÌNH CHUẨN BỊ DỮ LIỆU ĐÁNH GIÁ



Tổng quan quy trình chuẩn bị dữ liệu đánh giá

*Chuẩn bị dữ liệu đánh giá là một quy trình nhiều bước và **có thể lặp lại**, nhằm đảm bảo dữ liệu đủ chất lượng để phản ánh chính xác hiệu quả giải pháp*

- **Bước 1 – Xác định mục tiêu đánh giá** → hiểu rõ bài toán và các tiêu chí cần đo lường.
- **Bước 2 – Thu thập dữ liệu** → lấy từ nhiều nguồn, đảm bảo tính đại diện, tin cậy, đầy đủ, cân bằng, cập nhật và đúng ngữ cảnh.
- **Bước 3 – Làm sạch và tiền xử lý** → loại bỏ dữ liệu sai, thiếu, trùng lặp, chuẩn hóa định dạng
- **Bước 4 – Gán nhãn chuẩn** → tạo ground-truth theo quy trình đã xây dựng → kiểm tra chéo để đảm bảo độ tin cậy.
- **Bước 5 – Kiểm định và hiệu chỉnh** → đánh giá thử để phát hiện bias, mất cân bằng → điều chỉnh dữ liệu nếu cần.

Làm sạch dữ liệu (Data Cleaning) và Chuẩn hóa



- **Phát hiện và xử lý dữ liệu thiếu (Missing data)** → điền giá trị thay thế (imputation) hoặc loại bỏ các trường hợp không đủ thông tin.
- **Loại bỏ dữ liệu trùng lặp (Duplicate data)** → tránh việc một mẫu xuất hiện nhiều lần, gây sai lệch trong đánh giá.
- **Xử lý dữ liệu nhiễu (Noisy data)** → loại bỏ hoặc điều chỉnh dữ liệu bất thường (outlier).
- **Chuẩn hóa định dạng** → dữ liệu có thể được thu thập dưới nhiều định dạng khác nhau, gây khó khăn cho việc xử lý và phân tích.

Gán nhãn dữ liệu (Annotation)

Gán nhãn dữ liệu là bước tạo ground-truth để hệ thống có “đáp án chuẩn” phục vụ đánh giá

- Gán nhãn (annotation) là quá trình chuẩn bị đáp án chuẩn (đáp án kì vọng) cho dữ liệu đã làm sạch để biến nó thành dữ liệu có thể dùng trong đánh giá.
- **Phương pháp gán nhãn:** thủ công, bán tự động, tự động với thiết bị...
- **Nguyên tắc:**
 - ✓ Nhãn phải rõ ràng, nhất quán, không mơ hồ.
 - ✓ Cần hướng dẫn (guideline) chi tiết để đảm bảo tính đồng nhất của kết quả gán nhãn, đặc biệt với nhãn gán bởi con người.
 - ✓ Thường có cơ chế kiểm tra chéo (cross-check) giữa nhiều người để tăng độ tin cậy.



Guideline cho người gán nhãn (Annotation Guideline)

Guideline là bộ hướng dẫn chi tiết giúp người gán nhãn thực hiện công việc nhất quán và chính xác

- Nội dung cần có trong guideline
 - **Định nghĩa nhãn** → mỗi nhãn phải có giải thích rõ ràng, ví dụ minh họa.
 - **Quy tắc gán nhãn** → khi nào chọn nhãn A, khi nào chọn nhãn B.
 - **Xử lý trường hợp mơ hồ** → hướng dẫn cụ thể nếu dữ liệu không rõ ràng.
 - **Ví dụ chuẩn (positive examples)** → cho người gán nhãn thấy mẫu đúng.
 - **Ví dụ sai (negative examples)** → cho thấy mẫu dễ gây nhầm lẫn.

Thách thức trong lựa chọn người gán nhãn

Chọn đúng người gán nhãn là yếu tố quyết định chất lượng dữ liệu đánh giá

- Thách thức:
 - **Trình độ chuyên môn** → một số bài toán (y tế, pháp luật...) cần tri thức chuyên gia.
 - **Độ tin cậy và tính ổn định** → người gán nhãn có thể làm ẩu (spam), hiệu quả suy giảm theo thời gian → gây ra nhãn sai.
 - **Chi phí và thời gian** → thuê chuyên gia tốn kém, crowdsourcing hay bán tự động nhanh nhưng khó đảm bảo chất lượng.
 - **Các yếu tố chủ quan từ người gán nhãn** như khác biệt văn hóa, ngôn ngữ, giới tính, độ tuổi, sở thích, địa phương... → cần loại bỏ hoặc đa dạng hóa để tránh bias.
 - **Tính bảo mật, an toàn** → dữ liệu nhạy cảm (y tế, tài chính...) không thể công khai

Đảm bảo chất lượng nhãn gán

- **Đào tạo & hướng dẫn người gán nhãn** → tập huấn về guideline trước khi gán nhãn, cung cấp ví dụ minh họa rõ ràng (positive & negative cases).
- **Gán nhãn lặp lại (redundant labeling)** → một mẫu được nhiều người gán → lấy nhãn theo đa số hoặc chuyên gia xác nhận.
- **Đo độ đồng thuận (agreement measures)** → áp dụng chỉ số thống kê như Cohen's Kappa, Fleiss' Kappa để kiểm tra sự nhất quán giữa nhiều người gán nhãn.
- **Sử dụng “Gold Standard”** → thêm các mẫu đã có nhãn chuẩn vào tập dữ liệu, đo xem người gán nhãn có làm đúng với các mẫu này không.
- **Kiểm tra ngẫu nhiên (spot-check)** → chuyên gia rà soát một phần dữ liệu đã gán để phát hiện lỗi.
- **Cơ chế thưởng/phạt** → thưởng cho người gán nhãn chính xác, loại bỏ những người thường xuyên sai hoặc làm qua loa.

Một số công cụ gán nhãn

- **Các nền tảng gán nhãn mã nguồn mở:**
 - Label Studio: hỗ trợ đa dạng loại dữ liệu (ảnh, văn bản, âm thanh).
 - CVAT (Computer Vision Annotation Tool): mạnh trong gán nhãn video và hình ảnh.
- **Công cụ thương mại:**
 - Prodigy: tích hợp AI hỗ trợ gán nhãn bán tự động.
 - SuperAnnotate, Labelbox: quản lý dự án gán nhãn quy mô lớn.
- **Crowdsourcing platform:**
 - Amazon Mechanical Turk, Appen: huy động cộng đồng gán nhãn nhanh chóng.
- **Tính năng quan trọng:** quản lý nhiều người gán nhãn cùng lúc + tích hợp kiểm soát chất lượng (review, consensus) + xuất dữ liệu theo định dạng chuẩn (JSON, CSV, COCO...).



TỔNG KẾT VỀ DỮ LIỆU ĐÁNH GIÁ



Thách thức trong lựa chọn người gán nhãn

Dữ liệu đánh giá là nền tảng của mọi hoạt động đánh giá

- Dữ liệu là cơ sở để đo lường theo tiêu chí, và tiêu chí là công cụ để chuyển hóa dữ liệu thành kết quả đánh giá có ý nghĩa
 - Cơ sở đo lường theo tiêu chí.
 - Giúp khách quan hóa đánh giá, phát hiện vấn đề tiềm ẩn.
 - Cho phép so sánh công bằng nhiều giải pháp.
- **Yêu cầu:** dữ liệu phải đúng ngữ cảnh, đầy đủ, cân bằng, đại diện, tin cậy, cập nhật.
- **Ground-truth:** “sự thật gốc” – nền tảng để so sánh và đánh giá; là một phần trong benchmark.

Thách thức trong lựa chọn người gán nhãn

Chất lượng dữ liệu quyết định chất lượng đánh giá



- **Bias:** dữ liệu thiên lệch → đánh giá sai lệch, gây mất công bằng và giảm niềm tin.
- **Quy trình chuẩn bị dữ liệu:** Xác định mục tiêu → Thu thập → Làm sạch & chuẩn hóa → Gán nhãn chuẩn → Kiểm định & hiệu chỉnh.
- **Gán nhãn:** cần guideline rõ ràng, chọn đúng người gán nhãn, đảm bảo chất lượng nhãn qua kiểm định.
- **Nguyên tắc vàng:** Chính xác – Đại diện – Công bằng – Tin cậy – Cập nhật.



CHÂN THÀNH CẢM ƠN